

分类号: TP391

单位代码: 10335

密 级: 公开

学 号: 12021149

浙江大学

博士学位论文



中文论文题目: 时空记忆构建与计算的
脉冲生成式模型研究

英文论文题目: Research on A Spiking Generative Model of
Spatiotemporal Memory
Construction and Computation

申请人姓名: 马歌华

指导教师: 唐华锦 教授

学科(专业): 人工智能

研究方向: 类脑计算

所在学院: 计算机科学与技术学院

论文递交日期 2024年4月17日

时空记忆构建与计算的
脉冲生成式模型研究



论文作者签名: 马少华
指导教师签名: 唐华光

论文评阅人 1: 隐名
评阅人 2: 隐名
评阅人 3: 隐名
评阅人 4: 隐名
评阅人 5: 隐名

答辩委员会主席: 陈勋, 中国科学技术大学
委员 1: 吴争光, 浙江大学控制科学与工程学院
委员 2: 何宏建, 浙江大学物理学院
委员 3: 顾实, 电子科技大学计算机科学与工程学院
委员 4: 余肇飞, 北京大学人工智能研究院
委员 5: 刘斌, 之江实验室

答辩日期 2024 年 6 月 5 日

**Research on A Spiking Generative Model of
Spatiotemporal Memory
Construction and Computation**



Author's signature: _____

Supervisor's signature: _____

External reviewers: _____

Examining Committee Chairperson:

Xun Chen, Univ. of Sci. and Tech. of China

Examining Committee Members:

Zhengguang Wu, Zhejiang University

Hongjian He, Zhejiang University

Shi Gu, Univ. of Electronic Sci. and Tech. of China

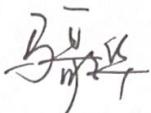
Zhaofei Yu, Peking University

Bin Liu, Zhejiang Lab

Date of oral defence: 2024.06.05

浙江大学研究生学位论文独创性声明

本人声明所呈交的学位论文是本人在导师指导下进行的研究工作及取得的研究成果。除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得 浙江大学 或其他教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示谢意。

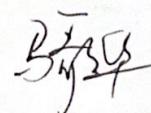
学位论文作者签名: 

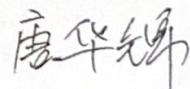
签字日期: 2026 年 6 月 18 日

学位论文版权使用授权书

本学位论文作者完全了解 浙江大学 有权保留并向国家有关部门或机构送交本论文的复印件和磁盘，允许论文被查阅和借阅。本人授权 浙江大学 可以将学位论文的全部或部分内容编入有关数据库进行检索和传播，可以采用影印、缩印或扫描等复制手段保存、汇编学位论文。

(保密的学位论文在解密后适用本授权书)

学位论文作者签名: 

导师签名: 

签字日期: 2026 年 6 月 18 日

签字日期: 2026 年 6 月 18 日

答辩委员会

陈 �勋	教授	中国科学技术大学（主席）
吴争光	教授	浙江大学控制科学与工程学院
何宏建	教授	浙江大学物理学院
顾 实	教授	电子科技大学
余肇飞	研究员	北京大学人工智能研究院
刘 斌	研究员	之江实验室

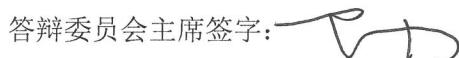
答辩评语

该论文针对类脑时空记忆模型构建与计算问题，开展了脉冲神经网络的生成式模型研究，选题具有重要的理论意义和应用价值。论文的主要创新点如下：

1. 提出了噪声扰动神经元动态下的脉冲神经网络模型理论框架及学习规则，提升了脉冲神经网络模型的抗扰动和容错性能；提出了自然范式下的时间条件计算的脉冲生成式模型，提升了拟合神经响应的准确性及多时间尺度的泛化性；
2. 提出了基于双重记忆构建机制的计算方法，缓解了神经网络在任务增量场景下的灾难性遗忘现象；结合大脑内嗅皮质-海马体神经环路时空信息表征策略，提出了时空感知的嵌入框架，提升了抽取目标时空表征的有效性；
3. 实现了基于脉冲神经元的时空记忆模型构建与计算系统，模拟了记忆构建过程以及多种典型的重要记忆计算功能。

论文结构合理，条理清晰，书写规范，实验对比分析充分。论文工作表明作者在该领域具备坚实的理论基础和系统深入的专业知识，具有独立研究能力。在答辩中，论述思路清晰，回答问题准确。经答辩委员会投票表决，一致同意通过其博士论文答辩，并建议授予工程博士学位。

答辩委员会主席签字：



致谢

风带来故事的种子，时间使之发芽，回首整个攻读生涯，虽有崎岖，却让我砥砺奋进；回想该部论文的写作过程，虽有不易，却使我除却浮躁。在此过程中，我深入思考、自省，也更加深切地体会了计算机科学的精髓和奥义。感谢父母、家人的支持，为我提供了前进的强大动力。

本论文在唐华锦教授、燕锐教授的悉心指导下完成。唐老师和燕老师知识渊博、治学严谨、乐观豁达、平易近人，经常鼓励我不畏艰难，勇于攀登科学的最高峰，两位老师的言传身教将使我终生受益。感谢师兄、师姐和师弟、师妹们，在科研过程中给我以鼓励和帮助。最后，谨在此感谢本论文的评阅者提供高质量的意见和建议，这对提升本文的水准起到了莫大帮助。

马歌华

2024年4月17日

摘要

时空记忆的构建与计算是大脑诸多复杂认知功能的计算基础，而理解大脑是如何实现时空记忆构建与计算的，需要开发这一过程的计算模型。时至今日，认知科学、神经科学已经为我们提供了如何将基于记忆的认知分解为功能性组成部分，并通过互相协同的人工神经元来构成其计算实现的理论依据。另一方面，神经形态计算技术的发展则使得我们能够通过丰富的脉冲神经元模型来进行生物可信度更高的计算模拟。借助上述这些领域的进展和创新，本文聚焦于研究、发展时空记忆构建与计算的脉冲生成式模型。时空记忆的构建与计算通常被认为是涉及多个大脑区域的复杂过程，其研究面临几个主要的难点：如何模拟神经计算机制；如何实现时空记忆表示方式和组织方法；如何构建生物真实的计算模型。针对这三个研究难点，论文在第二到第五章有针对性地开展了四种关键技术的研究，并提出一套基于四种关键技术研究成果的时空记忆构建与计算的脉冲生成式模型系统。本文以复杂三维场景时空流下的时空记忆构建与计算作为应用范式，实现从理论方法到系统论证的技术转化。本文的主要贡献点包括：

- 本文通过考虑噪声扰动的神经元动态，提出了一种非确定性的脉冲神经网络模型，并通过概率图模型建立了称为噪声脉冲神经网络的通用框架。基于该理论框架，本文提出了一种称为噪声驱动学习的三因子学习规则用于噪声脉冲神经模型的突触优化。该学习规则直接地为广为使用的替代梯度操作提供了随机噪声视角下的理论依据。评估结果表明噪声脉冲神经网络框架可以导致极具竞争力的脉冲神经网络模型，并展现出显著增强的抗扰动和容错性能。此外，噪声脉冲神经网络在作为生物神经网络编码过程的计算替代物时，再现了重要的神经活动变异性特征，从而展现出其作为神经计算建模工具的巨大潜力。
- 本文提出了一种自然范式下运行的时间条件计算的脉冲生成式模型。该模型通过时间条件操作，将隐变量模型的推理与生成过程显式条件化，使之能够自适应的处理时空数据流中长时程的时序依赖信息。在视觉神经编码基准下的评估表明，该方法在生成统计数据和原始神经响应任务中取得了显著的性能提升，并表现出优秀的在不同时间尺度下的泛化性能。
- 本文提出了一种高效的记忆构建机制的计算实现。该实现主要基于长短期记忆双

重记忆系统以及系统巩固理论。本文提出使用基于诧异度的增量式更新方法实现短期记忆组织与构建，并通过功能模块的信息转移来模拟记忆巩固的过程。任务增量设定下的连续学习测试基准上的评估表明，该计算实现能够有效地应对复杂的长任务序列的特异性和一般性信息，实现高效的记忆构建过程并显著减轻神经网络在任务序列上的灾难性遗忘。

- 提出了基于内嗅皮质-海马体神经环路时空信息表示策略的时空感知嵌入框架，包括了具体可行的时空图构建与时空联合表征策略。受大脑高效的图表征策略启发，本文提出使用基于规则构建的时空上下文图结构来挖掘时空数据的相似性关系。借鉴海马体位置细胞的信息融合表征机制，本文提出时空联合建模的时空表征策略，避免了既有解决方案中时空维度分离导致的次优嵌入问题。本文基于时空感知嵌入框架，在大规模现实世界数据上通过兴趣点推荐、交通流量预测的时空任务进行了有效性评估，证明本文方法在刻画时空特性，抽取目标时空特征方面的优越性。
- 在前述研究基础上，本文提出了一个基于脉冲神经元的时空记忆构建与计算的模型系统。该系统将时空记忆的构建与计算过程动态地整合在一起，成功地模拟了记忆构建过程以及多种典型的重要记忆计算功能。该系统展示了脉冲生成式模型如何将从经验中学习到的关联性和概念信息分布式地储存在神经网络内部的连接中，并通过其时空活动模式形成时空记忆的内部表示和预测依据，进而为我们理解神经网络处理和理解复杂信息的能力提供了更深的洞见。

关键词：类脑计算；神经形态计算；脉冲神经网络

Abstract

The construction and computation of spatiotemporal memory serve as the computational basis for numerous complex cognitive functions in the human brain. Understanding how the brain realizes the construction and computation of spatiotemporal memory requires developing computational tools. Cognitive and neuroscience have provided us with theoretical foundations for decomposing memory-based cognition into functional components and establishing their computational implementations through various types of synergistic artificial neurons. On the other hand, the advancement of neuromorphic computing technology enables us to conduct more biologically plausible computational simulations with a swathe of spiking neuron models.

Building upon the progress and innovations in these domains, this dissertation focuses on studying and developing spiking generative models for the construction and computation of spatiotemporal memory. The construction and computation of spatiotemporal memory are commonly considered a complex process that involves multiple brain regions. The study faces several main difficulties: how to simulate neurocomputational mechanisms; how to implement the representation modalities and organization methods of spatio-temporal memory; and how to construct biologically realistic computation models. To address these three research difficulties, this dissertation describes four key technologies. It introduces a spiking generative model system for the construction and computation of spatiotemporal memory based on the research results of these key technologies. Finally, this dissertation takes the construction and computation of spatiotemporal memory under complex three-dimensional scene spatiotemporal flow as an application paradigm and exemplifies the technical transformation from theoretical methods to system demonstration.

The main contributions of this dissertation include:

- This thesis introduces a stochastic spiking neural network model by considering noise-disturbed neuronal dynamics and establishes a general framework called the Noise Spiking Neural Network (NSNN) through the formulation of probabilistic graph models. Based on this theoretical framework, this thesis proposes a three-factor learning rule, termed noise-driven learning, for the synaptic optimization of the NSNN model. This learning

rule provides a theoretical basis for the widely used ad-hoc surrogate gradient tricks from the perspective of stochastic noise. Evaluations demonstrate that the NSNN framework can lead to highly competitive spiking neural network models and exhibit significantly enhanced disturbances and fault tolerance performance. In addition, as a computational substitute for biological neural network coding processes, the NSNN captures important characteristics of neural activity variability, demonstrating its immense potential as a neural computation modeling tool.

- This thesis presents a spiking generative model for temporal conditioning computation under a natural paradigm. Through temporal conditioning operations, the model explicitly conditions the inference and generation processes of the hidden variable model, enabling it to adaptively process mid to long-term temporal dependencies in spatiotemporal data flows. Evaluations under the visual neural coding benchmark indicate that this method has achieved significant performance improvements in generating statistical data and original neural response tasks, and demonstrates excellent generalization performance across different time scales.
- This thesis introduces a computational implementation of the memory construction mechanism. This implementation is primarily based on the dual-memory model which consists of long short-term memories and the system consolidation theory. This implementation utilizes an incremental updating method based on Bayesian surprise for organizing and building short-term memories and simulates the process of memory consolidation through information transfer between functional modules. Extensive evaluations on a continuous learning benchmark indicate that the proposed computational implementation can effectively handle the specificity and generality of complex long-task sequences, achieve efficient memory construction processes, and significantly alleviate catastrophic forgetting in neural networks on task sequences.
- This thesis introduces a spatiotemporal aware embedding framework based on the spatiotemporal information representation strategy of the entorhinal-hippocampal neural circuit, which includes concrete graph construction and conjunctive information mining

strategy. Inspired by the brain's efficient graph representation strategy, this thesis proposes using a spatiotemporal context graph structure built on rules to exploit the similarity relationships within spatiotemporal data. Borrowing the information fusion representation mechanism of hippocampal place cells, this thesis proposes a spatiotemporal representation strategy with joint modeling of time and space, avoiding the suboptimal embedding problem caused by the separation of time and space dimensions in existing solutions. Based on the spatiotemporal perception embedding framework, this thesis conducts efficacy evaluations on large-scale real-world data through spatiotemporal tasks including points of interest recommendation and traffic flow prediction, demonstrating the superiority of the proposed methods in characterizing spatiotemporal characteristics and extracting target spatiotemporal features.

- Building upon prior research, this dissertation constructs a model system for spatiotemporal memory construction and computation based on spiking neurons. This system dynamically integrates the processes of spatiotemporal memory construction and computation, successfully simulating the process of memory construction as well as several essential memory computation functions. It demonstrates how the spiking generative model can store association and conceptual information learned from experience in a distributed manner within the neural network's synaptic connections, forming a latent representation and predictive basis for spatiotemporal memory through its activity patterns. This provides deeper insights into our understanding of the capabilities of neural networks to process and learn complex information.

Keywords: Neuromorphic Computing; Spiking Neural Models; Brain-inspired Computing;

缩略词表

英文缩写	英文全称	中文全称
MLP	Multi-Layer Perceptron	多层感知机
ANN	Artificial Neural Network	人工神经网络
RNN	Recurrent Neural Network	循环（递归）神经网络
CNN	Convolutional Neural Network	卷积神经网络
SNN	Spiking Neural Network	脉冲神经网络
GRU	Gated Recurrent Unit	门控递归单元
LSTM	Long Short-term Memory Unit	长短期记忆单元
ReLU	Rectified Linear Unit	修正线性单元
VAE	Variational Autoencoder	变分自编码器
LVM	Latent Variable Model	隐变量模型
GP	Gaussian Process	高斯过程
ODE	Ordinary Differential Equation	常微分方程
SDE	Stochastic Differential Equation	随机微分方程
POI	Point-Of-Interest	兴趣点

目录

致谢	I
摘要	III
Abstract	V
缩略词表	IX
目录	XI
图目录	XV
表目录	XVII
第 1 章 绪论	1
1.1 研究背景与现状	1
1.1.1 时空记忆与记忆模型	3
1.1.2 脉冲神经网络	4
1.2 研究内容与主要贡献	8
1.3 本文组织结构	12
第 2 章 非确定性脉冲神经网络中内部噪声诱导的计算与学习理论	15
2.1 本章引言	15
2.2 研究方法	17
2.2.1 噪声脉冲神经模型	18
2.2.2 噪声驱动的学习规则	21
2.2.3 噪声脉冲神经网络稳定性理论分析	23
2.3 实验结果	28
2.3.1 无外部扰动目标识别实验	28
2.3.2 外部扰动下的模型性能评估	30
2.4 本章小结	34
第 3 章 自然范式下时间条件计算的生成式脉冲神经网络研究	37
3.1 本章引言	37
3.2 研究方法	41
3.3 实验结果	48

3.3.1 实验数据	48
3.3.2 评估指标与脉冲特征	49
3.4 本章小结	56
第 4 章 用于时空记忆构建的时空表征方法	59
4.1 本章引言	59
4.2 时空感知嵌入框架	62
4.2.1 时空感知嵌入框架中的序列模型	63
4.2.2 时空感知嵌入框架中的时空模型	63
4.3 实验结果	67
4.3.1 连续兴趣点推荐任务	68
4.3.2 交通流量预测任务	72
4.4 本章小结	76
第 5 章 记忆构建与计算机制研究	79
5.1 本章引言	79
5.2 双重记忆系统启发的记忆构建与计算方法	80
5.2.1 本章相关工作	80
5.2.2 本章基础设定	83
5.2.3 记忆构建与计算方法	84
5.2.4 基于记忆构建与计算方法的连续学习	87
5.3 实验结果	92
5.4 本章小结	100
第 6 章 一种时空记忆构建与计算的脉冲生成式模型	103
6.1 本章引言	103
6.2 时空记忆构建与计算的脉冲生成式模型系统	104
6.3 实验结果	109
6.4 本章小结	114
第 7 章 总结与展望	115
7.1 本文工作总结	115
7.2 未来展望	117

参考文献	119
攻读期间的代表性科研成果	137

图目录

图 1-1 几种时空记忆计算模型框架图	3
图 1-2 神经元的典型结构	5
图 1-3 脉冲神经元模型在计算代价和生物合理性角度的比较	6
图 1-4 脉冲时间依赖性可塑性的关键窗口	7
图 1-5 本文主要研究内容与创新点	9
图 1-6 本文内容的组织结构	13
图 2-1 神经元信息传递过程存在多源随机性	16
图 2-2 NSNN 和 NDL 方法示意图	17
图 2-3 噪声脉冲神经网络概率模型与功能模型图示	20
图 2-4 系统稳定性分析示意图	23
图 2-5 CIFAR-10 和 CIFAR-100 数据集的扰动识别实验结果	32
图 2-6 噪声脉冲神经网络内部噪声强度对模型性能的影响	33
图 3-1 自然时间序列处理范式图示	38
图 3-2 自然视觉刺激下视网膜神经响应的计算建模过程简图	39
图 3-3 自然视觉刺激下视网膜神经响应的 TeCoS-LVM 模型的图形说明	40
图 3-4 本章方法的计算操作图示	42
图 3-5 影片 1、影片 2 的示例帧	49
图 3-6 脉冲发放率预测结果可视化	51
图 3-7 脉冲发放率预测结果定量对比	52
图 3-8 脉冲发放自相关性	53
图 3-9 脉冲活动栅格图	54
图 3-10 真实记录及模拟的脉冲活动变异性	54
图 3-11 脉冲序列预测结果定量对比	55
图 3-12 长测试序列的泛化性能实验结果	56
图 3-13 隐藏状态和隐变量空间动态的可视化	57
图 4-1 内嗅皮质-海马体神经环路的表征机制和时空嵌入模型的框架	60
图 4-2 时间维度下的相似性在不同层次上的定义	65

图 4-3 连续兴趣点推荐任务下的超参数敏感性分析	72
图 4-4 时空感知嵌入框架下的交通流量预测任务示意图	74
图 4-5 基于时空感知嵌入框架的交通流量预测结果可视化	76
图 5-1 Dual-MEM 与大脑记忆-感知系统映射关系图示	81
图 5-2 本章使用的单次遍历连续学习设定图示	83
图 5-3 基于本章介绍的记忆构建、计算过程的连续学习过程示意	87
图 5-4 八种测试基准的 Acc, Bwt 和 Fwt 评估结果	94
图 5-5 连续学习过程中的 Acc 指标变化	95
图 5-6 不同记忆容量下的性能表现	96
图 5-7 特征空间中记忆样本点的 t-SNE 可视化	98
图 5-8 超参数敏感性分析实验结果	100
图 5-9 多次接触设定下的性能表现	101
图 6-1 本章节的计算模型构建过程简图	104
图 6-2 时空记忆构建与计算的脉冲生成式模型系统图示	105
图 6-3 时空记忆构建与计算的脉冲生成式模型系统包含的神经计算过程	108
图 6-4 空间场景样本图例	110
图 6-5 短期空间记忆场景再现过程中的记忆扭曲	111
图 6-6 基于时空记忆的完全线索下的回忆计算过程	112
图 6-7 基于时空记忆的想象类计算过程	113

表目录

表 2-1 DSNN 和 NSNN 推理和学习过程的异同与联系	27
表 2-2 本章实验用到的超参数设定一览	28
表 2-3 DVS-CIFAR 基准上 EventDrop 扰动下的评估结果	33
表 2-4 DVS-CIFAR 基准上的脉冲发放状态扰动下的评估结果	34
表 2-5 无外部干扰识别实验结果	36
表 3-1 SPIKE, Victor-Purpura 和 van Rossum 脉冲序列距离下的评估结果	55
表 3-2 本章实验涉及之神经网络架构(功能模型)列表	58
表 4-1 本章节中的主要记号与标识	62
表 4-2 时空感知嵌入框架用于下游连续兴趣点推荐任务的性能对比结果	68
表 4-3 兴趣点数据集统计信息	71
表 4-4 用于连续兴趣点推荐任务的时空感知嵌入框架的模块有效性实验	73
表 4-5 基于时空感知嵌入框架的交通流量预测方法的对比实验结果	77
表 5-1 本章节测试基准一览	92
表 5-2 本章介绍的记忆构建(更新)策略的有效性验证实验结果	99
表 5-3 基于双重记忆的方法性能比较	102

第1章 绪论

1.1 研究背景与现状

我们生活在一个由时空描述的世界里，而基于时空的记忆构造和计算是人类高级认知行为的基础。时空记忆的构建与计算被认为是涉及多个大脑区域的复杂过程，因此如何模仿神经计算机制，特别是记忆的内部表示方式和组织方法来设计其计算模型，仍然存在挑战。除了对神经科学的研究的意义之外，记忆构建与基于记忆的计算也是神经形态人工智能领域悬而未解的难题。即便是在海量文本库上训练的高级机器学习模型，仍然缺少有效的方式来纳入灵活高效的记忆机制，以使得生成的内容具备更强的上下文一致性和逻辑性。在这一背景下，探索如何在现有的神经科学研究、机器学习研究基础上，更新、迭代时空记忆构建与计算的范式，从而设计出一般性更强且兼顾生物真实性的计算模型，成为了神经形态人工智能-计算神经科学交叉领域的一个富有挑战性的前沿问题。

以人工神经网络为代表的现代机器学习方法有着极强的数据拟合能力，因而一个极富前景的方向是通过机器学习模型来作为承载部分神经处理过程的计算替代物，通过将认知神经科学、感官神经科学问题定义为典型的机器学习问题^[1]来实现计算层面的理解。这种技术路线主要基于一个经典的认识，即对认知功能的定义假设的测试或许无法导致真正计算理解^[2]。也就是说，这些假设需要通过构建具体执行任务的计算模型来进行补充。换言之，如果理论假设确实对神经信息处理机制有着较为准确的理解和刻画，那么这些理论应该是能被用于进行工程设计并实现的（例如，大脑视觉回路中的视觉注意力机制、多尺度机制均已被广泛的实现并推广^[3]），正如著名的物理学家 Richard Feynman 所说：“*What I cannot create, I do not understand*”。

一种广受认可的观点认为解释认知功能如何从具有神经科学、生物学可信度的计算组件或模型中产生，将会是下一阶段认知计算神经科学的核心^[4]。不过，现阶段的计算机硬件技术和机器学习的理论仍然不足以模拟大脑认知过程的全部的复杂性。尽管如此，具有神经科学可信度的、脑启发的人工智能模型，特别是基于生成式模型的研究在近年来不断取得可喜的进展，并在一定程度上解决了认知科学、神经科学研究界的一些研究问题^[5-8]。因而，研究时空记忆构建与计算的脉冲神经模型，并尝试在计算层面提

供一个有效的工具，对神经科学研究有着实质性的益处。这种工具可以进一步被应用在诸如神经元类型研究^[9-10]，神经系统辨识^[6,11]，和构建更复杂的神经系统的计算替代^[7]等任务中。

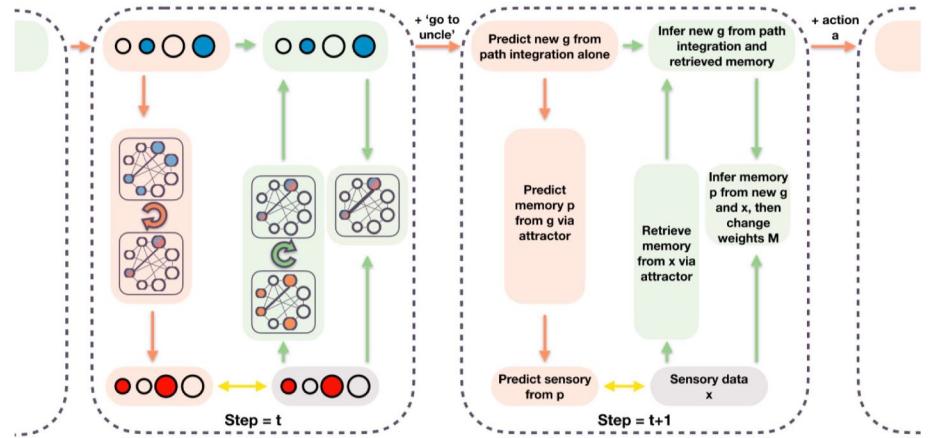
近年来，神经形态计算领域研究呈现迅猛的发展势头^[12-17]，而其主要的研究对象是基于脉冲神经元实现的人工神经网络，即脉冲神经网络。与常规的人工神经网络相比，脉冲神经网络模拟了大脑中神经元间利用脉冲（即动作电位）进行信息传输的机制，被认为是构建神经计算模型的理想候选。然而，传统的确定性脉冲神经模型仍然存在着一些问题，如不能解释神经脉冲列中的变异性^[18]。而近期的神经科学研究^[19]将静息状态皮质噪声视为可能限制识别能力的神经生理性状，这意味着我们的大脑是非确定性的。为了进一步提升计算模型的生物真实性，我们理应将非确定性的脉冲神经模型纳入考虑。在此基础上，本文的研究将通过挖掘脉冲神经网络模型在时空刺激下的计算与认知架构，为更普适的、基于脉冲神经元的神经形态计算认知模型的构建提供宝贵的理论基础与技术参考，从而对神经形态人工智能领域研究起到推动作用。

总体而言，本文主要从具备生物可信度的机器学习模型角度入手，结合现有的神经科学研究基础以及脉冲神经网络模型与手段，探索如何构建一个时空记忆构建与计算的脉冲生成式模型，并由此引出本文的研究内容以及研究方法。我们认为理想的模型应当具备以下几个方面的性质^[1]。首先是刺激可计算性，即模型应当能够接受较为一般形式的任意刺激并进行相应的神经计算。再有是可映射性，表现为不同层次上的生物真实性与可信性，即计算模型的组成部分应当与神经系统的实验可定义的组成部分相对应。最后是预测性及生成性，即计算模型应当能够对刺激做出相应的反应，并在此基础上生成、创造出新的响应模式。

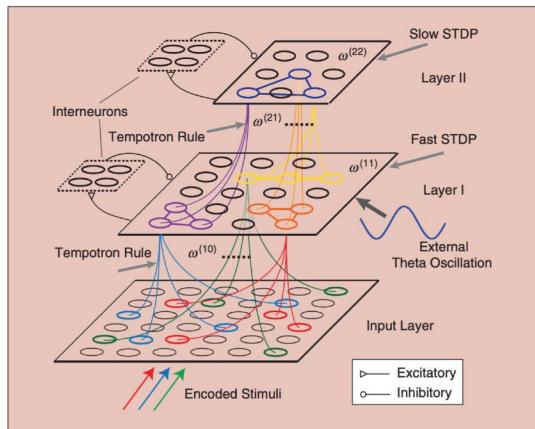
这些标准在一定程度上可能导致模型性能的下降，因为在某些特别精细的粒度上实施的可映射的真实性约束可能损害在复杂真实世界刺激下的性能表现^[8]。因此，在何种程度的简化的生物合理性、真实性背景下寻求神经回路的计算模型形式就显得至关重要。理想的计算实现需要既能够准确预测对真实世界刺激的神经反应，又满足一定层面上的生物真实性与合理性。重新回到本文的研究内容上，本文的研究对象主要涉及时空记忆与记忆模型、脉冲神经网络模型及生成式模型几个部分。因而，本文的研究大致会在上述几个方向展开。接下来本章将对上述几个研究方向的研究现状进行简要介绍，而在后续章节中，会有更针对性的相关工作的叙述。

1.1.1 时空记忆与记忆模型

A. Tolman–Eichenbaum Machine model



B. Spatio-Temporal Memory model



C. Long-term Memory organization model

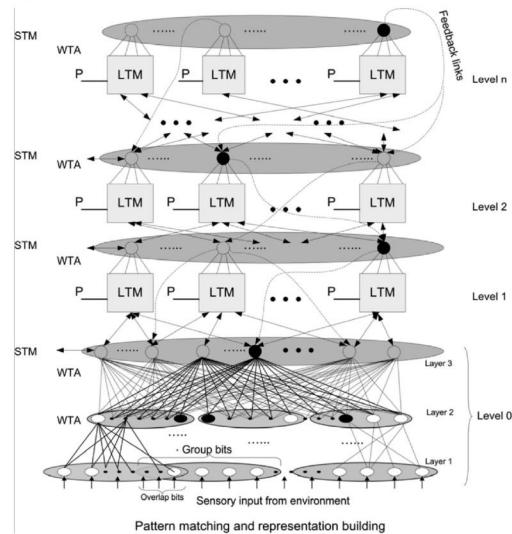


图 1-1 几种时空记忆计算模型的框架图, 图源: 文献[20-22]。

早期的研究者基于时空记忆的形成理论与假说, 提出了各异的计算实现。更早期的研究主要在理论层面上考虑用于学习时空模式的神经网络模型及其数学框架^[23]。通常而言, 对记忆的建模的研究内容从探索生物神经回路如何持久地保存神经元活动的模式^[24], 再到试图明确地解决某种基于记忆的计算任务^[25-26]。此外, 文献^[20]提出了一种生物启发的记忆架构, 使之可以用作神经元级别的构建模块, 并通过设计相互输入增强和阻隔机制讨论了其学习、预测的运行方式。Graves 等提出了一种通过注意力过程与外部

记忆资源交互的扩展的神经网络系统神经图灵机 (Neural Turing Machine, NTM)，其能够直接以端到端的方式通过梯度下降法进行高效学习，并能够再现复制、排序等简单的认知功能。在神经图灵机的基础上，研究者提出了被称作可微分神经计算机 (Differentiable Neural Computer, DNC) 的机器学习模型^[28]，通过外部记忆矩阵扩展神经网络在长时间储存信息方面的能力，并在符号序列的任务上展示了其有效性。上述的研究与本文研究有着紧密的关系，然而与它们有所不同的是，本文的研究主要探索通过生成式网络对记忆的构建与计算过程进行统一的刻画，并主要通过生成式网络分布式地组成记忆本身。

在文献^[29]中，研究者探索了从离散的皮质神经元衍生的网络模型，并表明其具有处理相对简单的时空信息和识别时间模式的能力。文献^[21]提出一种具有层次结构的脉冲神经网络计算实现，用于研究神经元集群及组织的原理。在这一模型中，感知信息沿着层次化的脉冲神经网络流动，并通过将感知信息映射成神经元群体的活动来形成记忆。Gemici 等提出了一种具有记忆功能的通用的生成式模型架构，并在变分推理框架内建模具有长时间依赖性的一般问题，他们的方法在某些任务场景下由于具有隐藏状态的递归神经网络模型。文献^[22]基于海马体-内嗅皮质系统的一些机械性理解，提出了该神经环路背后的统一计算原则，即结构化知识表述与感觉表征的连结。在此基础上，Whittington 等提出了称为 Tolman-Eichenbaum Machine 的计算模型，在几种预设的模式任务上展现出了从时空线索中学习经验性表示的能力。

从方法论的角度而言，上述的研究都采用了偏向假设驱动的设计方法，即基于一些已知的神经活动机制或信息处理机制的描述来定义脑区或模块间的相互作用^[31]。后期的许多研究工作都延续了该研究思路，即关注描述在大脑区域整体神经活动水平上的交互，并通过这些神经活动的情况来假设不同区域间的信息交互。接下来，这些假设可以被自然而然地映射到机器学习的模型实现上，因为后者通常也是由许多功能模块或基本单元组成的。在后续的章 5 和章 4 中，我们将分别针对时空表征和记忆机制本身的研究进展和相关工作进行更为具体的介绍与讨论。

1.1.2 脉冲神经网络

虽然人工神经网络在形式上被认为是受到大脑计算方式的启发，然而其计算实现方式上仍然与生物神经网络有着显著地不同。具体而言，在生物神经网络中，神经元间主

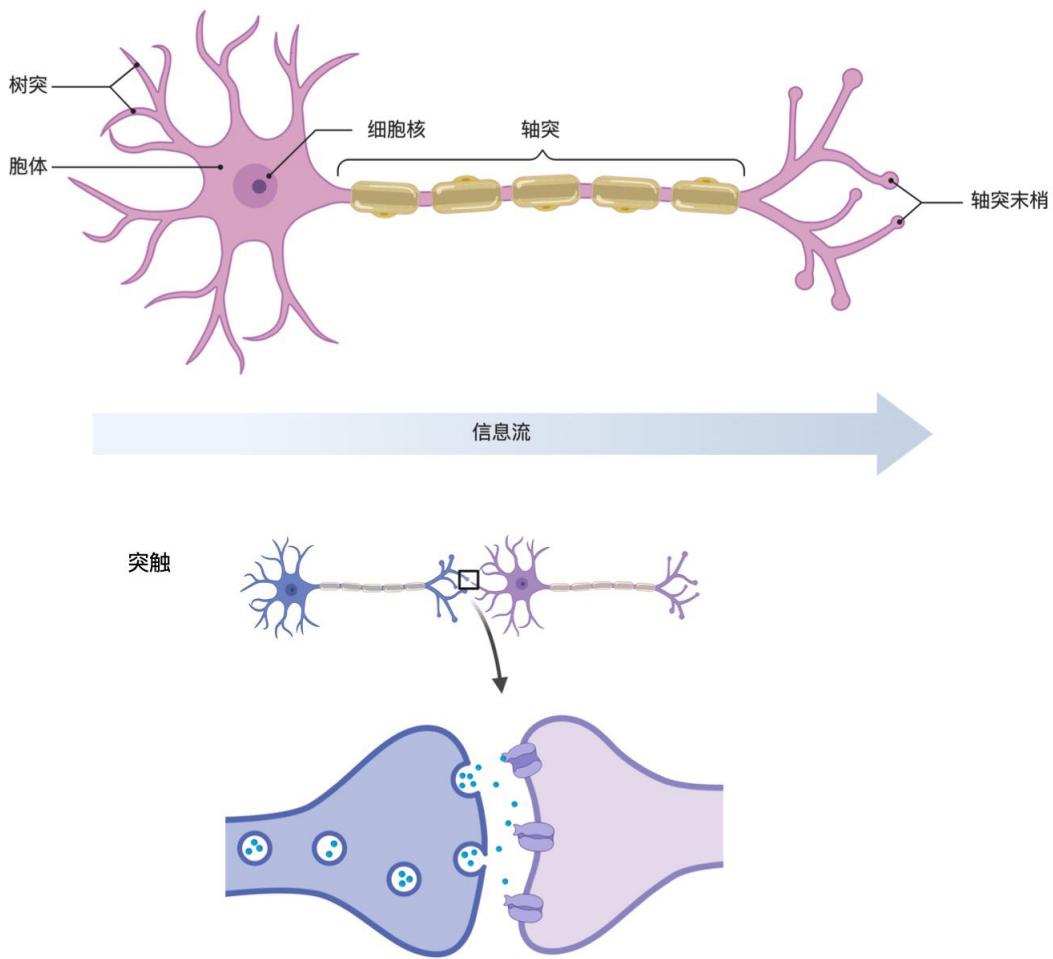


图 1-2 神经元的典型结构。

要是通过脉冲（动作电位）的形式来进行信息传输与计算。脉冲神经网络由于其基于脉冲的计算机制，被认为能够更好地利用生物神经系统中的稀疏性，并且在神经元层面上运行在连续的时间上，从而天然地兼容于一般性的涉及时间维度的认知任务。

在生物神经网络中，神经元是最基本的功能单元，这些单元将电化学信号转换为动作电位的形式进行传播，进而处理信息。动作电位的形成涉及细胞内外的复杂电、化学过程，但是主要是由其内部的离子活动导致的。这些离子（主要包括 Na^+ , K^+ 和 Cl^- 离子）通过细胞膜不断地进出细胞，从而引发电势、电流的活动。图 1-2 展示了神经元的典型结构，其主要组成部分为树突、胞体、轴突和突触。树突将从突触前神经元释放的神经递质所携带的化学信号转化为电信号。而胞体是信息流自突触输入后传播整合的所在，发生在该位置的运算决定了突触后细胞是否发放脉冲，并将之传输到轴突。轴突

将动作电位通过突触传播到其他的神经细胞。根据突触的作用不同，我们可以进一步将之划分为兴奋性突触和抑制性突触。前者将促使突触后神经元进行脉冲发放，而后者则会抑制突触后神经元的脉冲发放。而在常用的、简化的数学模型中，我们可以使用一个数值来表示某个突触的效用，并使用其符号来区分兴奋性与抑制性。

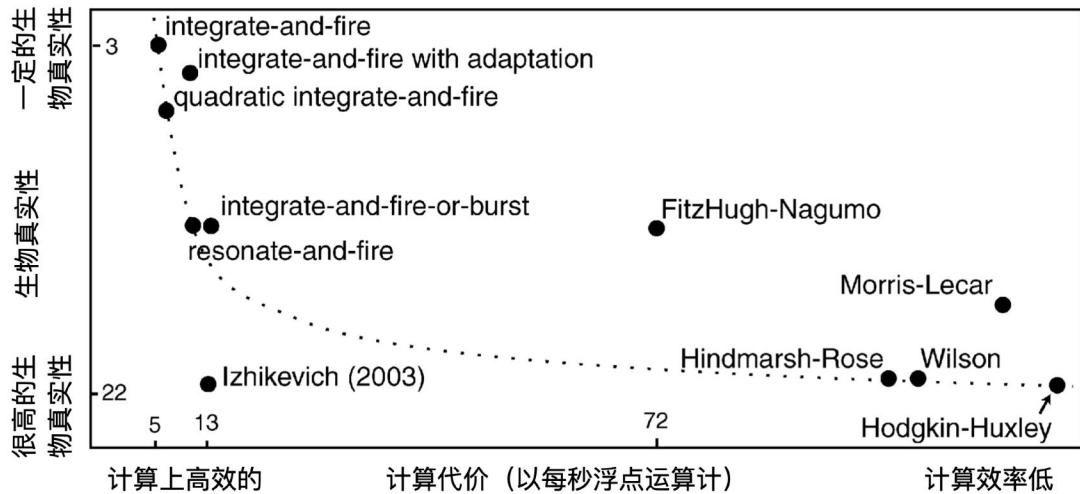


图 1-3 脉冲神经元模型在计算代价和生物合理性角度的比较，图源：文献^[32]。

脉冲神经元模型 根据上述的生物神经元的计算过程，研究者提出了多种脉冲神经元模型，这些模型在生物真实性（准确性）与计算代价之间进行了不同的取舍（见图 1-3）。就目前而言，仍然很难在兼得很高的生物真实性与计算高效性，因此在不同的研究场景中，研究者会根据研究目标的侧重来选择脉冲神经元模型作为计算的基本单元。这里本章将主要介绍几种比较有代表性的神经元模型。Hodgkin-Huxley 模型^[33] (H-H) 是一种准确性很高的脉冲神经元模型，该模型中分别建模了不同离子通道对脉冲产生的作用，从而非常精细地刻画了神经元的内部活动。尽管如此，H-H 模型需要求解多个复杂方程，因而难以在神经元数量较大的模拟中进行使用。

事实上，研究者们发现在实际任务似乎不需要这么复杂的模型，尝试略微降低神经元模型的复杂程度也能够满足一些场景下的建模需求。Izhikevich 通过一个由常微分方程描述的二维动力系统来刻画神经元动态，这种模型的复杂度相较于 H-H 模型大幅降低（图 1-3），不过仍然能够在适当的参数选择下还原出大量已知的大脑皮层神经元的活

动模式。

如果我们追求更高的计算效率，更简洁的模型也能够满足一定程度上的神经动态建模需求。积分-发放模型^[35-36] (Integrate-and-Fire, IF) 就是一种广为使用的高度抽象的脉冲神经元模型。其仅使用一个有一阶常微分方程描述的一维的动力系统来刻画生物神经元积累线索-发放脉冲的计算过程。在 IF 模型基础上，研究者提出了漏电-积分-发放模型 (Leaky Integrate-and-Fire, LIF)，即在 IF 的基础上额外考虑了漏电导致的膜电压衰减过程。由于 LIF 模型具有简洁的表示并能够高效地计算实现，因而受到越来越多计算神经科学、神经形态人工智能研究者的青睐。在后续的章 2 中，我们将对该种脉冲神经元的相关工作与研究进展展开更深入的叙述和探讨。

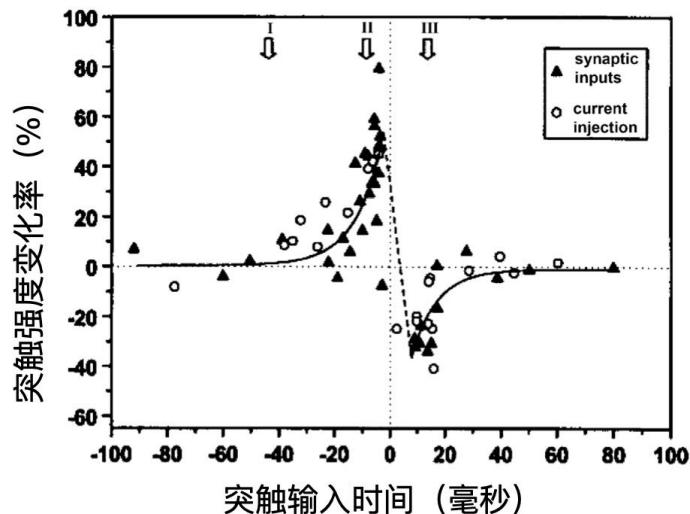


图 1-4 脉冲时间依赖性可塑性的关键窗口，图源：文献^[37]。

脉冲神经网络学习规则 在神经网络范畴下，学习主要指通过修改神经元连接性，或称为突触权重的值来实现。然而脉冲神经元激活过程的非连续性使其不能像人工神经网络一样直接使用反向传播与梯度下降法的组合来进行优化。脉冲神经网络的现有的学习规则主要为两类，其一是基于赫布理论^[38] (Hebbian Theory) 的突触可塑性基本原理的学习规则。该理论主要表述了反射活动的持续及重复导致神经元突触传递效能的提升，该种理论被后来的研究精确表述为时序依赖可塑性^[37] (图 1-4)。尽管突触可塑性类的局部学习规则有着很好的生物真实性和合理性，然而其学习性能通常低于全局的、监督的学习方式。另一类常用的脉冲神经网络学习规则沿用了人工神经网络使用的反向传播

以及梯度下降技术路线。SpikeProp 算法^[39]提出了基于脉冲发放时间的反向传播学习实现，在非线性分类的测试基准下取得了与频率编码脉冲神经网络相当的性能。在此基础上，SuperSpike 算法^[40]提出了基于电压的监督学习规则，从而网络能够从无脉冲发放的静息状态开始学习。文献^[41]提出了用于多层脉冲神经网络的监督学习方法，以线性方式反向传播误差信号。然而上述的大多数研究不得不面临如何处理脉冲发放函数的导数的问题。一种最常用的解决方式是所谓的替代梯度^[42-44] (Surrogate Gradient, SG, 即伪导数^[45])，即通过使用平滑的函数的导数来替代脉冲发放函数的导数，以兼容反向传播的工作流程。即上述的工作有所不同，本文中的脉冲神经网络学习方法允许在一般性的概率框架下对脉冲神经网络的梯度下降的学习方式进行一致性的定义（章 2）。与本文的研究紧密相关的是，在文献^[46]中，研究者提出了一种基于软阈值的发放方式，从而使得标准的反向传播梯度下降方式得以适用。在后续相应章节中（章 2），我们将对脉冲神经网络的学习方法进行更深入的、更有针对性的探讨。

1.2 研究内容与主要贡献

尽管已有的时空记忆计算模型研究已经在一些精心设计的模式任务上取得了一定的进展，但受所采用的设计方法论和当时的技术限制，仍然存在一些缺陷。尤其，已有的时空记忆计算模型工作在生物真实性，或者说生物物理学合理性方面仍然存在一定的局限性。神经科学的研究可以为我们提供关于计算模型的模块化和层次化架构的理论指导，这些架构可以适应给予神经形态人工智能系统以灵活的记忆与计算能力。对特定神经回路活动如何参与到记忆的构建与计算过程的深入理解，也可能启发对更先进的时空记忆模型的架构设计，从而使其在更直观的模式任务上展现出记忆构建与计算的认知功能。

基于这样的模型，我们将能够开发支持更灵活、多样任务的神经形态人工智能系统。例如，尽管现代的深度神经网络模型可以轻易地学习并在像目标识别这样的任务中取得超越人类的表现。然而，这些系统与生物神经系统相比显得更为脆弱，且对细微的扰动非常敏感：仅需要改变几个像素的值，就可能导致模型的性能出现大幅下降。要在多变复杂的现实世界中正常运转，我们所研究的时空记忆计算模型需要能够通过从一般性知识中学习生成式的概率分布，以期掌握不断出现的新情况。这个过程既包含了快速

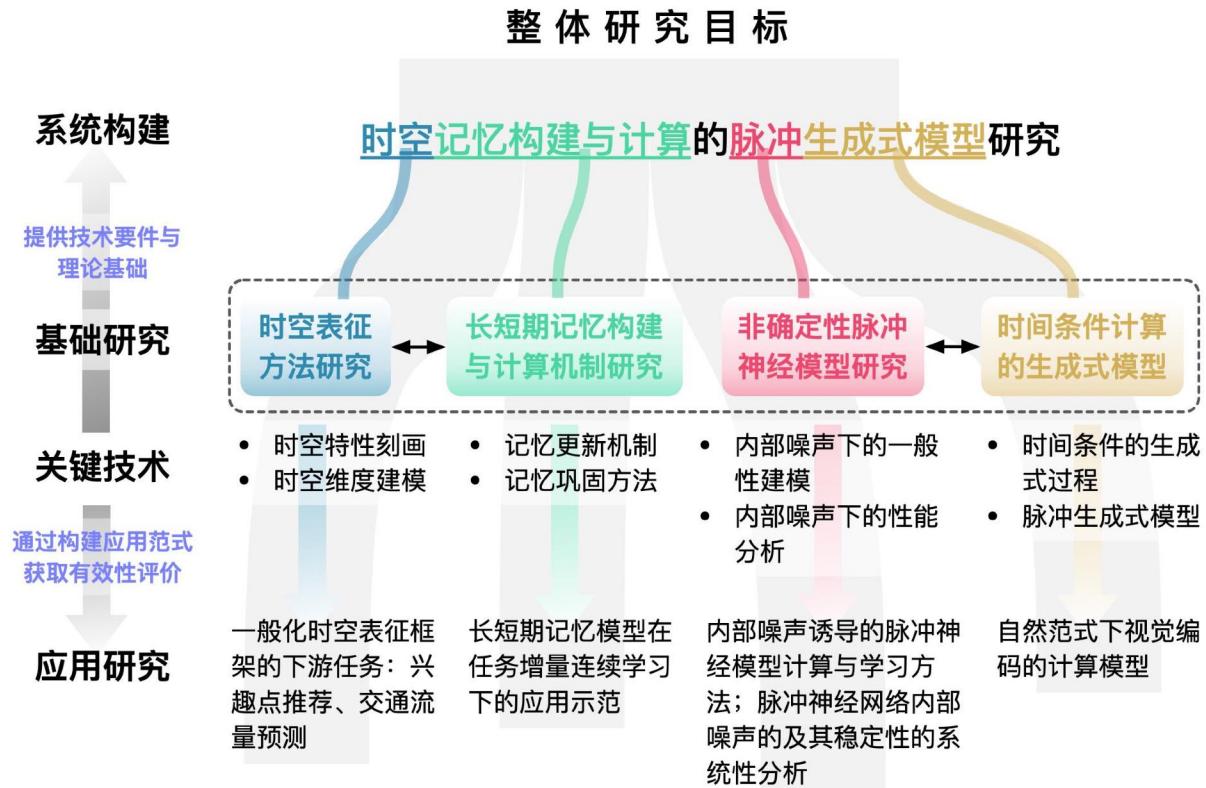


图 1-5 本文主要研究内容与创新点总览。本文将主要研究内容细化为四部分关键技术的研究，本文分章节地对非确定性脉冲神经网络模型，脉冲生成式模型，时空表征方法与记忆构建与计算机制进行深入研究，并在每部分中通过构建应用示范来（分部分地）获取其有效性评价。上述四部分研究内容共同组成了本文核心研究内容，即时空记忆构建与计算的脉冲生成式模型的全部技术要件，并为实现本文最终的研究目标提供了理论基础。

地从有限的经验中获取、总结经验，亦包含了如何进一步抽象、稳定化这些经验，作为长期的认知与决策的基础。如何使用神经形态计算模型来对时空记忆构建与计算的过程进行模拟，是本文所关注的科学问题。解决这一科学问题面临诸多技术上的、理论上的问题与挑战，在本文中，我们主要关注以下几个关键技术及理论问题：

- 随机性脉冲神经网络的系统性理论研究。作为当前神经形态人工智能的模型基础，虽然现有的工作已经对脉冲神经网络开展了广泛的研究，但大部分研究都着眼于确定性的脉冲神经网络模型，而忽视了神经计算的内在非确定性和噪声特性。尽管采用理想化的确定性模型仍然能够部分实现基于脉冲的计算过程，然而这种模型本身的随机性缺失极大地限制了其作为计算工具的表达能力。近年来大量的研

究^[47-49]指出内在噪声对于神经网络的计算价值。因此，如何通过引入带有噪声的神经元动力学，系统性地研究一般性的噪声脉冲神经网络模型及其学习规则是一个重要的研究问题。

- 自然范式下时间条件计算的脉冲生成式模型研究。生成式模型是用于建模大脑时空记忆构建与计算过程的理想方式^[50-52]，因其参数化现实世界的数据生成过程概率分布的方式和生物体学习和理解外部世界的方式是原理上一致的^[53-55]。此外，通过学习的生成式模型能够进一步地基于连续的抽象概念空间中的表征，实现基于记忆的计算认知功能。尽管目前的生成式模型研究在一些典型应用任务上展现出了超凡的能力，然其仍存在一些关键性的问题。其一是如何以有限参数的模型刻画中、长时程的时序依赖关系。记忆的形成并非是一蹴而就的^[56]，其背后是一个横跨时间尺度的学习过程，尽管递归神经网络单元及其变体在一定程度上赋予神经元以时空信息处理能力，然而这种时间条件下的计算如何在更高层次的功能部分与基础模块间进行交互、运作仍然缺乏一个较好的解决方案。其二是如何以自然的运行范式进行连续的生成。当前的大部分处理时空信息的生成式模型依赖时空滤波器或是纯离线的非自然时序计算范式，与生物神经系统快速的、在线的时空信息接收-处理能力存在明显差异，进而损害了其作为计算模型的生物真实性。因此，自然范式下时间条件计算的脉冲生成式模型研究是一个颇具挑战性的重要研究问题。
- 类脑时空表征方式与表征策略研究。时空表征方法是计算模型在处理时空信息过程中不可避免的技术问题。如何进行有效的时空信息表征将会影响后端基于特征表示的记忆构建过程，进而影响下游模式任务的表现。尽管现有的时空分离的时空表征方法与策略在诸多应用任务上获得了成功，然而其时空分离的时空处理方式却不可避免地导致了时空维度下的次优表征效果。因此如何基于大脑的高效时空表征机制，建立其与时空表征方法、表征策略的对应关系，进而实现用于时空记忆构建与计算的时空表征方法是本文的另一重要研究问题。
- 记忆的构建与计算是本文整体研究目标的核心之一。虽然在近年来迅猛发展的技术手段加持下，神经科学、认知科学领域的关于记忆构建与计算机制的研究成果呈现井喷态势，然而以何种方式，从何种层面，在何种程度上将这些记忆理论与

假设进行计算化的实现，并验证其有效性仍然是一个开放的难题，也是本文的一个重要研究问题。

因此，本文从随机性脉冲神经网络模型，自然范式下的生成式时间条件计算模型，面向时空记忆构建的时空表征方法与策略，以及记忆构建，特别是长-短期记忆构建的计算机制几个方面分部分地开展系统性的研究。并最终整合、系统化上述关键研究问题的研究成果，从而形成基于脉冲生成式模型的时空记忆构建与计算原型系统。本文的主要贡献点包括：

- 针对系统性的非确定性脉冲神经模型理论研究的缺失问题，本文介绍了噪声脉冲神经模型和噪声驱动学习方法，利用神经元噪声作为脉冲神经元网络中的计算和学习资源。本文通过在确定性脉冲神经元模型中引入了一个膜噪声项，构建了这些噪声脉冲神经元的网络，并推导出被称作噪声驱动学习的方法来进行突触优化。在多个测试基准上的详细评估结果表明，本章提出的上述方法及模型取得了良好的学习性能与泛化能力。进一步的扰动测试表明，其对各种扰动，包括具有挑战性的对抗性攻击，都表现出显著改善的鲁棒性，进而为内部噪声模型稳定性理论分析结果提供了实证支持。本文研究中介绍的噪声脉冲神经网络方法能够被推广到需要随机性存在的广泛领域，从而为神经环路计算建模研究提供了一个有效易用的计算工具。
- 针对自然范式下时间计算的生成式工具的缺失问题，本文研究了运行在自然范式下的时间条件脉冲生成式模型。受到了生物神经网络高效编码理论的启发，本文的相关方法在隐变量模型的信息瓶颈理论框架内进行了形式化，从而使其具备了理论上的切实性。该方法提出的模型能够在自然时序处理范式下直接生成时空数据，而非重复多次进行单步生成。在自然场景刺激下的视网膜神经响应任务的评估基准上，该模型展现出其在生物真实性、生成物准确性方面的显著优势。
- 针对用于时空记忆构建的时空表征方式与策略的研究问题，本文探索了一种用于时空表征的一般方式——时空感知嵌入框架。该框架将海马-内嗅皮层的多种时、空表征机制转化为时空嵌入的计算方法与维度融合策略，克服了常用的时空分离表征策略所导致的次优嵌入问题。该方法在两个大规模真实时空数据基准的预测任务上展现出了高效的性能。

- 针对缺少记忆构建的计算方法研究，本文主要考虑了一个经典的理论记忆模型，即双存储记忆模型^[57]作为理论基础。本文研究强调了记忆构建策略在记忆形成过程中的关键性，并通过神经科学的研究启发的基于新颖性（诧异度）的方式来监督记忆的构建过程。此外，本文研究表明短期记忆-长期记忆的转化过程可以通过功能区域的转移来进行计算实现。以任务增量连续学习设定下的多种测试基准证明了本文的记忆构建计算机制的有效性。
- 在前述四个关键研究问题的成果基础上，本文展示了一个时空记忆构建与计算的模型系统，将基于脉冲神经元的时空记忆构建与计算过程进行了动态整合。该系统成功地模拟了记忆构建过程与多种典型的重要记忆计算功能，展示了脉冲生成式模型如何将从经验中学习到的关联与概念分布式地存储在神经网络的内部连接中，从而以其时空活动模式构成时空记忆的内部表征与预测依据。

1.3 本文组织结构

本文围绕时空记忆构建与计算的脉冲生成式模型的主题分部分地开展了研究，论文的总体组织结构如下：

- 第一章为本文的绪论。该章对于本文研究内容的背景进行了概述，并介绍了该研究问题的科学意义。该章随后对本文研究问题的相关研究分三部分进行了概括性的介绍，主要包括时空记忆、记忆模型，脉冲神经网络，以及生成式模型。该部分的介绍进行在一个较一般的层面上，而在后续的章节中我们会对相应章节对应的细分研究问题进行更有针对性的研究现状叙述。本章的最后梳理了本文研究面临的一些研究难点，进而引出了本文的研究内容，并对行文的组织结构进行了介绍。
- 本文的第二章研究了非确定性（随机性）脉冲神经网络的一种理论分析框架，脉冲神经元及其网络模型是本文研究的一个基础构件。本章的研究通过引入一种噪声扰动的神经元动力学，构建了噪声脉冲神经网络模型框架并提出了噪声驱动学习规则，以利用噪声神经处理的计算优势。本章介绍的噪声脉冲神经网络提供了一个理论上充分的脉冲神经模型概率框架，从而能够以极强的可扩展性和灵活性产生可靠的概率计算模型。实验分析表明，噪声脉冲神经网络理论框架能够促成

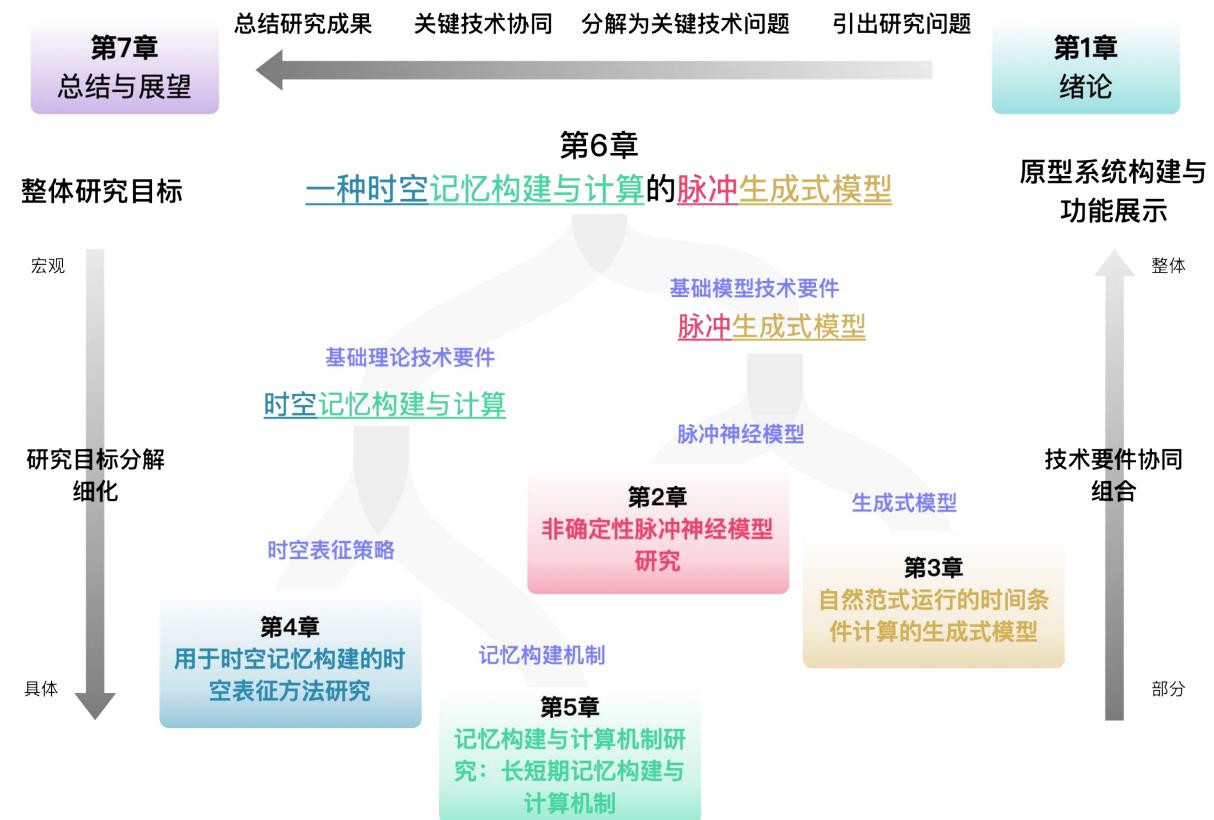


图 1-6 本文组织结构及内容安排。

具有高性能的脉冲神经模型，并且相比于确定性脉冲神经网络具备更优的抵抗外部扰动性能。此外还能够更好地再现神经系统中的概率计算过程，从而进一步增强模型的生物可信度。

- 本文的第三章研究了运行在自然范式下的时间条件计算的脉冲生成式模型，开发此种生成式计算模型对于实现本文的研究目标具有重要意义。目前最先进的基于神经网络的方法常使用时间滤波器来处理时间依赖性，从而导致了一种生物上不可信的处理范式。本章提出了一种时间调节的脉冲隐变量模型来模拟初级视觉神经系统对自然刺激的响应。该方法使用基于脉冲神经元的网络模型以直接输出与真实记录的神经活动相匹配的脉冲序列。这种方法除了有助于避免丢失原始脉冲序列中嵌入的信息，亦能够充分地发挥脉冲表征的稀疏性优势。本章的方法从模型的参数空间中排除了时间维度，并引入了时间调节操作，将时间感受野转移到

模型内部表征空间，从而使得模型能够在自然范式下自适应地探索和利用刺激序列中的时间依赖性。总体而言，本章介绍的方法无论是在生物可解释性、可信度上，还是在时序泛化性能和生成性能方面，均较已有的替代方法有着明显的优势。

- 本文的第四章研究了用于构建时空记忆的时空表征方法。具体而言，现有时空表征方法通常分别在空间和时间维度上进行时空表征，这种策略武断地隔离了目标的空间和时间特性，从而导致了次优的时空嵌入。本章基于哺乳动物大脑的内嗅-海马系统的图表征方式，内嗅皮质网格细胞的简洁空间表征机制，以及海马体位置细胞的结合信息表征机制，提出了时空感知嵌入框架，并在两个典型的时空表征下游任务上证明了其时空表征的高效性，从而为本文时空记忆构建提供了时空表征策略的技术基础。
- 本文的第五章研究了记忆构建与计算机制，特别是记忆的巩固和更新方式。本文中的研究重点是时空记忆构建与计算的脉冲生成式模型。在为实现这一目标所构建的研究框架中，用于实现记忆的构建、巩固过程的算法是另一大重要的基础技术，对时空记忆构建与计算的实现起到关键支撑作用。本章的最后在连续学习的任务场景下，围绕大脑记忆机制以及其计算过程建模问题进行研究，进而直接对本章介绍的记忆机制及计算过程的算法有效性进行直观的评估，并证明了其有效性。
- 本文的第六章介绍了基于二至五章研究基础的一种时空记忆的构建与计算的脉冲生成式模型系统，并在一个典型的时空刺激记忆模式任务上展现了其应用方式。本章首先对系统与前述章节的联系、整体设计思路以及功能模块进行了说明；随后使用该系统进行了在空间场景序列记忆任务下的构建过程与计算过程的模拟，还原了记忆再现过程中的记忆扭曲等认知现象，验证了本章介绍的模型的可行性和有效性。
- 第七章对本文的工作进行了整体的总结与展望。

第2章 非确定性脉冲神经网络中内部噪声诱导的计算与学习理论

本文研究内容为时空记忆构建与计算的生成式脉冲神经网络研究，作为其中的重要组成部分，脉冲神经网络支撑着大脑的非凡信息处理能力，并已成为神经形态人工智能的支柱模型。尽管对脉冲神经网络（Spiking Neural Network, SNN）进行了广泛的研究，但大多数研究都建立在确定性模型上，忽视了神经计算的固有非确定性、噪声性质。

本章的研究通过引入噪声神经元动力学，介绍了噪声脉冲神经网络模型和噪声驱动学习规则，以利用噪声神经处理的计算优势。噪声脉冲神经网络提供了一个理论充分的脉冲神经模型框架，支持以极强的可扩展性和灵活性产生可靠的概率计算。本章研究通过实验表明，噪声脉冲神经网络理论框架能够促成具有高性能的脉冲神经模型，相比于确定性 SNN 具备更优的抵抗外部扰动性能，并更好地再现神经系统中的概率计算过程。除了构成本文的基础技术要素之外，本章研究也为机器学习、神经形态智能实践者和计算神经科学研究提供了一个强大且易于使用的工具。

2.1 本章引言

脉冲神经网络（SNN）被广泛地用作神经科学研究中的计算模型^[9,58]。受益于深度学习的最近进展^[59-61]，SNN 也在各种下游应用中取得了显著的优势，如计算机视觉和机器人技术^[62-70]。总的来说，大多数脉冲神经模型是基于确定性 SNN（Deterministic SNN, DSNN）模型建立的，这些模型在形式化中忽略了真实神经元的固有随机性。具有噪声扰动的神经元动态的脉冲神经元被认为更具生物真实性，因为离子通道的波动和突触传输的随机性都会导致膜电位的亚阈值动态受到噪声干扰^[71-78]。此外，脉冲神经模型的内部噪声能够通过促进构建更具容错性的表征空间^[49,79-80] 并防止过拟合^[81]，从而带来潜在的泛化性能优势。然而，目前仍没有一个通用和灵活的方法来使用和分析噪声脉冲神经模型，对于噪声在脉冲神经网络中的作用也缺乏深入、系统的理解。

先前的一些研究^[82-83] 通过在描述膜电压动态的微分方程中引入噪声项，研究了具有随机神经活动模型的脉冲神经元模型。在这些工作中，噪声通常被建模为在随机微分

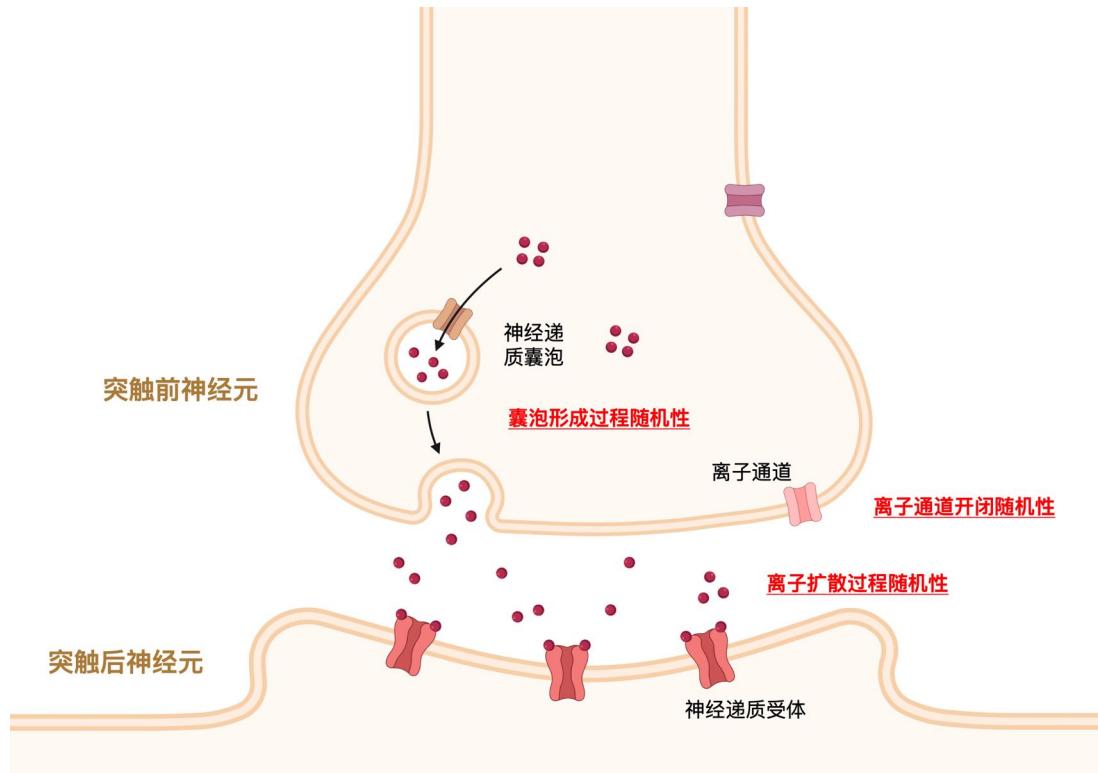


图 2-1 神经元信息传递过程存在多源随机性。

方程中由扩散过程导出的白噪声或彩色噪声^[84-85]项。上述工作虽然引入了具有噪声膜电压动力学的详细脉冲模型；然而，它们并没有能够在网络层面上构建一种通用方法。另一些研究^[86-89]提出了可以进行概率推理的噪声脉冲神经元的小型网络。然而，由于缺乏有效的学习方法，这些方法很难融入当下流行的网络架构和深度学习方法。最近的一项研究^[90]引入了确定性脉冲响应模型的广义线性模型变体，但他们的方法也无法扩展到本章所关注的深度脉冲神经网络。

在深度脉冲神经网络中，一种被称为替代梯度学习^[42-44] (Surrogate Gradient Learning, SGL, 伪导数^[45]) 的特定性的解决方案已经成为解决 SNN 反向传播^[91] 时的不连续性问题的广泛使用的方法。虽然替代梯度方法已经被证明相当有效^[92]，但它们缺乏一个扎实的理论基础和合理的生物物理学解释^[93]。相比之下，像 STDP^[37,94-95] 这样的基于神经科学的研究得出的学习方法尽管在理论上有着确切的依据，且被认为具备进一步深入研究的潜力，但在大型网络和复杂任务中的性能仍然不足以替代现有的替代梯度方式。

因此，本章希望能够开发一种如 SGL 一般有效且可扩展的学习方法，同时保留 STDP 中对生物神经系统学习机制的见解。简而言之，现有的工作普遍缺少了对噪声脉

冲神经模型的一般计算和学习规则的统一设计，这客观上阻碍了它们应用和发展。同时，这也使得研究者们无法充分利用噪声脉冲神经网络作为机器学习模型的优势，同时也无法重复发挥其作为神经科学计算工具的潜力。因此，本章研究旨在提供深度脉冲神经网络和噪声脉冲神经模型的通用、灵活的集成方法。这将使得本章方法能够获取生物要素上更加真实的脉冲神经模型，并能够直接从日新月异的深度学习领域的工程进步中受益，并获得附加的模型性能提升。更为关键地，从理论研究价值的角度来看，本章的研究将阐释噪声如何可能作为脉冲神经元网络的计算和学习资源^[96]，而非单纯的干扰。

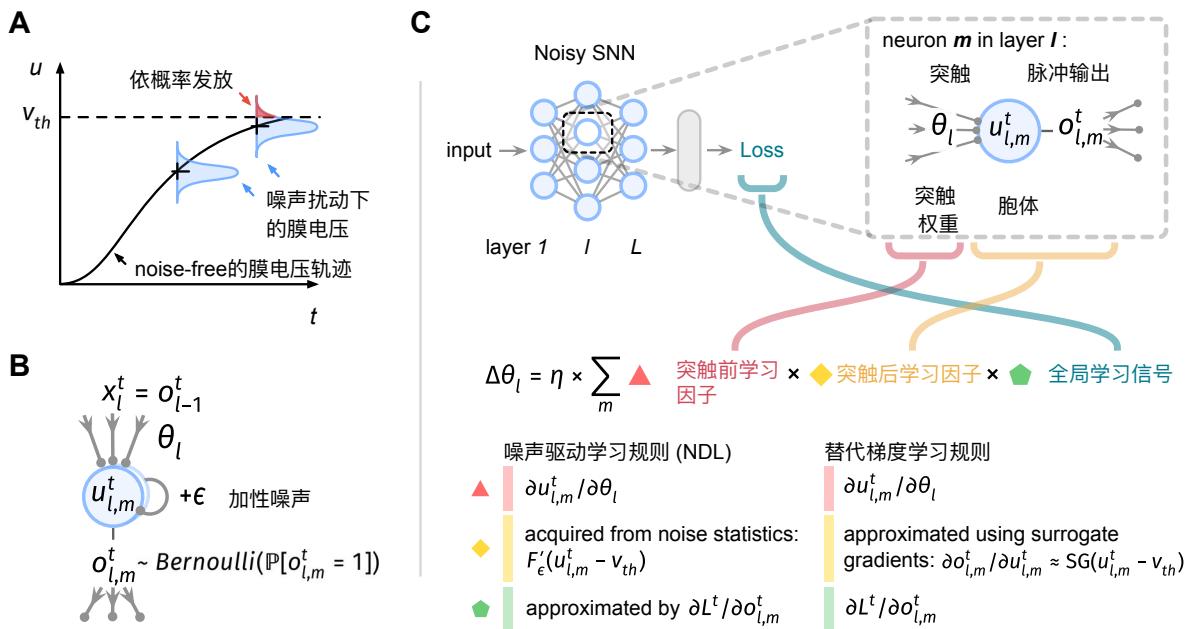


图 2-2 NSNN 和 NDL 方法示意图。A. 引入噪声的神经元动力学诱导出了一种随机脉冲发放机制，其中发放概率由膜噪声累积分布函数给出，如噪声扰动的膜电压分布下的阴影红色部分所示。这里 u 表示膜电压， v_{th} 表示发放阈值。B. 带有膜电压 $u_{l,m}^t$ 、输入 \mathbf{o}_{l-1}^t 和输出 $\mathbf{o}_{l,m}^t$ 的 Noisy LIF 神经元 l, m 的计算流程。C. 使用 NDL 和 SGL 更新第 l 层的突触权重 θ_l 的计算示意。 F_ϵ 表示噪声 ϵ 的累积分布函数， η 表示学习率。

2.2 研究方法

本章主要记号与定义 本章使用 x, u, o 来表示输入、膜电位和脉冲输出。此外， $x_{l,m}^t, u_{l,m}^t, o_{l,m}^t$ 表示在时间 t 的第 l 层的神经元 m 的变量（其维度为 $\text{dim}(l) = \text{dim}(\mathbf{x}_l)$ ），其中 $l \in [1, L]$ 且 $t \in [1, T]$ 。本章使用粗体来表示变量的集合或是矩阵。例如，第 l 层在时间步 t 的变

量标记为 $\mathbf{x}_l^t, \mathbf{u}_l^t, \mathbf{o}_l^t$ 。脉冲状态空间标记为 \mathbb{S} 。符号 $\mathbb{E}[\cdot], \mathbb{P}[\cdot], p(\cdot)$ 和 $F(\cdot)$ 分别表示期望、概率、概率分布和累积分布函数。

2.2.1 噪声脉冲神经模型

LIF 神经元模型 本章的研究考虑了常用的漏电积分和发放 (Leaky Integrate-and-Fire, LIF) 神经元模型^[35-36], 该模型描述的阈值下膜电位动态如下

$$\tau_m \frac{du}{dt} = -(u - u_{\text{reset}}) + RI(t), u < v_{\text{th}}, \quad (2-1)$$

其中 R, τ_m 是膜电阻系数和时间衰减常数, I 表示输入电流, $v_{\text{th}}, u_{\text{reset}}$ 分别是脉冲发放阈值, 静息电位。在实际模拟中, 上述动态导致了如下描述的离散时间计算形式^[63,97]:

$$\text{阈下动态: } u^t = \tau u^{t-1} + \phi_\theta(x^t),$$

$$\text{脉冲发放: } o^t = \text{spike}(u^t, v_{\text{th}}) \triangleq \text{Heaviside}(u^t - v_{\text{th}}),$$

$$\text{膜电位重置: } u^t = u_{\text{reset}} \text{ if } o^t = 1,$$

其中 x^t 是时间 t 的输入, τ 是膜电位衰减时间常数, $\phi_\theta : \mathbb{S}^{\dim(x^t)} \rightarrow \mathbb{R}$ 表示参数化的输入转换映射。本文统一假设 $v_{\text{th}} = 1$, $\tau = 0.5$ 和 $u_{\text{reset}} = 0$ 。

噪声 LIF 神经元模型 本章介绍的噪声 LIF (Noisy LIF) 模型基于之前使用扩散近似的相关工作^[84-85,98], 其中, 阈下的膜电位动态过程由 Ornstein-Uhlenbeck 模型描述^[99-100]:

$$\begin{aligned} \tau_m \frac{du}{dt} &= -(u - u_{\text{reset}}) + RI(t) + \xi(t), \text{ e.q.} \\ du &= -(u - u_{\text{reset}}) \frac{dt}{\tau_m} + RI(t) \frac{dt}{\tau_m} + \sigma dW^t, \end{aligned} \quad (2-2)$$

其中, 白噪声 ξ 是一个随机过程, σ 是噪声的幅度, dW^t 是 Wiener 过程在 dt 中的增量^[85]。由于 σdW^t 是从零均值高斯分布中抽取的随机变量, 这种形式可以直接应用于离散时间模拟。具体来说, 使用 Euler-Maruyama 方法, 本章方法将在式 2-2 的右侧得到一个额外的高斯噪声项。

不失一般地, 本方法将离散形式中的附加噪声项扩展到一般的连续噪声上^[101], 通

过式2-2，噪声LIF模型的阈下动态可以描述为：

$$\text{Noisy LIF 阈下动态: } u^t = \tau u^{t-1} + \phi_\theta(x^t) + \epsilon, \quad (2-3)$$

其中，噪声 ϵ 是从满足 $\mathbb{E}[\epsilon] = 0$ 和 $p(\epsilon) = p(-\epsilon)$ 的已知分布中独立抽取的。式2-3也可以通过离散化LIF神经元的Itô随机微分方程变体得到^[78,102]。在本文的研究中，默认情况下本文考虑的Noisy LIF神经元的均使用高斯噪声。

由于随机噪声的注入，神经元膜电位和脉冲输出转变为随机变量。换言之，以噪声作为媒介，本章自然地得到了基于阈值发放机制的噪声LIF的脉冲发放概率分布：

$$\begin{aligned} \mathbb{P}[\text{在时间 } t \text{ 发放脉冲}] &= \mathbb{P}\underbrace{[u^t + \epsilon > v_{\text{th}}]}_{\text{阈值发放}} \\ &= \mathbb{P}\underbrace{[\epsilon < u^t - v_{\text{th}}]}_{\text{CDF 定义}} \triangleq F_\epsilon(u^t - v_{\text{th}}) \end{aligned} \quad (2-4)$$

因此有

$$o^t = \begin{cases} 1, \text{ 依概率 } F_\epsilon(u^t - v_{\text{th}}), \\ 0, \text{ 依概率 } (1 - F_\epsilon(u^t - v_{\text{th}})). \end{cases} \quad (2-5)$$

上述表达式显示了噪声如何作为计算的资源^[96]。进一步地，本章方法可以将噪声LIF的脉冲发放过程表述为

$$\text{Noisy LIF 依概率发放机制: } o^t \sim \text{Bernoulli}(F_\epsilon(u^t - v_{\text{th}})) \quad (2-6)$$

具体来说，该形式与先前关于逃逸噪声（Escape Noise）模型的文献密切相关^[84,103-104]，其中的差值 $u - v_{\text{th}}$ 决定了神经元的发放概率^[76,85]。此外，噪声LIF采用与LIF模型相同的膜电位重置机制。

噪声脉冲神经网络 本节以概率识别模型为例，进行噪声脉冲神经网络（NSNN）模型的形式化（参见图2-3A）。设 x_1^t 表示时间 t 的输入，基于式2-3-式2-6中的Noisy LIF

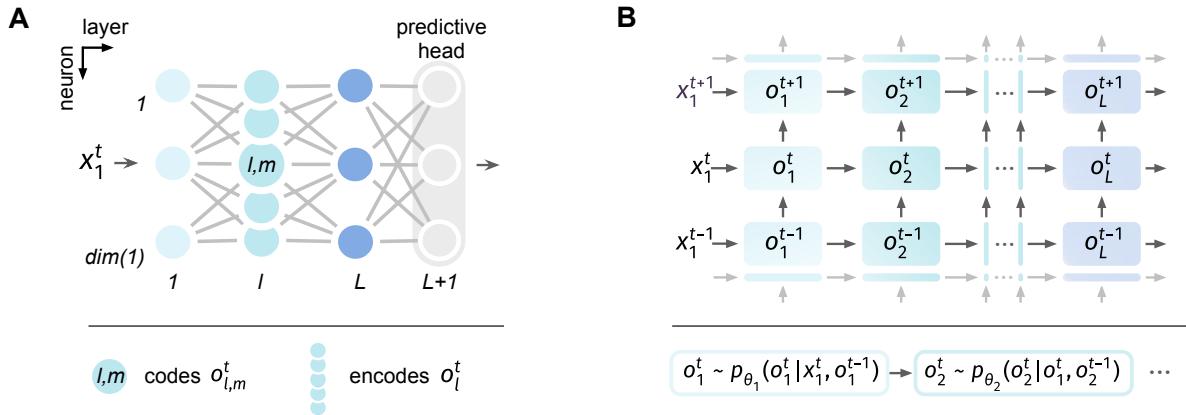


图 2-3 噪声脉冲神经网络概率模型与功能模型图示。A. NSNN 功能模型图示，其中 x_1 表示网络的初始输入。B. 贝叶斯网络概率图框架视角下的 NSNN 脉冲状态的依赖关系。以时间 t 为例，联合分布由 $p_\theta(o_1^t \dots o_L^t | x_1^t, o_1^{t-1}) = p_{\theta_1}(o_1^t | x_1^t, o_1^{t-1}) \prod_{l=2}^L p_{\theta_l}(o_l^t | o_{l-1}^t, o_l^{t-1})$ 给出，其中 θ 表示可学习的突触参数。

动态描述，由 $L + 1$ 层组成的 NSNN 可以表示为

$$\begin{aligned} \text{输入层: } & \mathbf{x}_1^t = x_1^t, \\ & \mathbf{u}_1^t = \tau \mathbf{u}_1^{t-1} + \Phi_{\theta_1}(\mathbf{x}_1^t) + \boldsymbol{\epsilon}_1, \quad (2-7) \\ & \mathbf{o}_1^t = \{o_{1,m}^t : o_{1,m}^t \sim \text{Bernoulli}(\mathbb{P}[o_{1,m}^t = 1])\}_{m=1}^{\dim(1)}, \end{aligned}$$

$$\begin{aligned} \text{隐藏层: } & \mathbf{x}_l^t = \mathbf{o}_{l-1}^t, \\ & \mathbf{u}_l^t = \tau \mathbf{u}_l^{t-1} + \Phi_{\theta_l}(\mathbf{x}_l^t) + \boldsymbol{\epsilon}_l, \\ & \mathbf{o}_l^t = \{o_{l,m}^t : o_{l,m}^t \sim \text{Bernoulli}(\mathbb{P}[o_{l,m}^t = 1])\}_{m=1}^{\dim(l)}, \end{aligned}$$

$$\text{任务头: } \mathcal{L} = f_{\theta_{L+1}}(\mathbf{o}_L^t) = f(\Phi_{\theta_{L+1}}(\mathbf{o}_L^t))$$

其中，层 l 的输出 \mathbf{o}_l^t 为脉冲空间 $\mathbb{S}^{\dim(l)}$ 中的向量，膜电位 $\mathbf{u}_l^t \in \mathbb{R}^{\dim(l)}$ ，映射 $\Phi_{\theta_l} : \mathbb{S}^{\dim(l-1)} \rightarrow \mathbb{R}^{\dim(l)}$ 。噪声向量 $\boldsymbol{\epsilon}_l \in \mathbb{R}^{\dim(l)}$ 由已知分布（本文中为高斯）的独立随机噪声组成。任务头（预测头） $f_{\theta_{L+1}}(\mathbf{o}_L^t)$ 包括参数化的映射 $\phi_{\theta_{L+1}}(\mathbf{o}_L^t)$ 和损失函数 f ，表示从脉冲神经表示 \mathbf{o}_L^t 解码、预测并计算损失值的部分。 ϕ_{θ_l} 表示如全连接或卷积的映射，因此它关于参数 θ_l 是可微的。如上所述的按层划分突触参数，不会使这一形式失去一般性，因为它们可以被定义为任何可微映射。

例如,为了解决目标识别问题,该方法应考虑预测概率模型 $p_{\theta_{L+1}}(y|\mathbf{o}_L^t) = \text{softmax}(\phi_{\theta_{L+1}}(\mathbf{o}_L^t))$, 其中映射 $\phi_{\theta_{L+1}}$ 使用脉冲神经表示 \mathbf{o}_L^t 来计算预测分数。函数 f 可以是预测分布 $p_{\theta_{L+1}}(y|\mathbf{o}_L^t)$ 和目标分布 $p_{\text{target}}(y|x_1^t)$ 的交叉熵。注意,这里的 $f_{\theta_{L+1}}(\mathbf{o}_L^t)$ 计算的是瞬时损失,与 $\frac{1}{T} \sum_t f^t$ 不同,后者是在整个时间窗口上计算的,忽略了潜在的在线学习^[97]。

由于每个神经元编码一个随机变量 $o_{l,m}^t$,本章方法可以用贝叶斯网络模型(参见图 2-3B)作为概率图模型来描述 NSNN,并将给定输入 x_1^t 下的 NSNN 所有脉冲状态的联合分布描述为

$$p_{\theta}(\mathbf{o}_{1\dots L}^t | x_1^t, \mathbf{o}_{1\dots L}^{t-1}) = p_{\theta_1}(\mathbf{o}_1^t | x_1^t, \mathbf{o}_1^{t-1}) \prod_{l=2}^L p_{\theta_l}(\mathbf{o}_l^t | \mathbf{o}_{l-1}^t, \mathbf{o}_l^{t-1}), \quad (2-8)$$

其中每层的表示为 $p_{\theta_l}(\mathbf{o}_l^t | \mathbf{o}_{l-1}^t, \mathbf{o}_l^{t-1}) = \prod_{m=1}^{\text{dim}(l)} p_{\theta_l}(o_{l,m}^t | \mathbf{o}_{l-1}^t, o_{l,m}^{t-1})$ 。

2.2.2 噪声驱动的学习规则

本章节中,NSNN 突触优化的中心问题是估计期望损失 $\mathbb{E}_{\mathbf{o}_{1\dots L}^t} [\mathcal{L}]$ 的梯度。根据式 2-7,式 2-8,可以直接给出 g_l :

$$g_l = \nabla_{\theta_l} \mathbb{E}_{\mathbf{o}_{1\dots L}^t} [\mathcal{L}] = \nabla_{\theta_l} \sum_{\mathbf{o}_{1\dots L}^t} p_{\theta}(\mathbf{o}_{1\dots L}^t | x_1^t, \mathbf{o}_{1\dots L}^{t-1}) f_{\theta_{L+1}}(\mathbf{o}_L^t) \quad (2-9)$$

由于式 2-9 难以确切地计算,本章希望能得到它的一个估计,以便可以直接通过基于梯度的深度学习工具来实现 NSNN 突触优化。由于脉冲状态空间的维度很小(要么脉冲发放,要么静息),利用这一特质可以通过条件化(局部边际化)导出一个梯度估计器,该估计器通过对单个随机变量进行精确求和来减少估计器的方差^[105-106]。首先将联合分布 $p_{\theta}(\mathbf{o}_{1\dots L}^t | x_1^t, \mathbf{o}_{1\dots L}^{t-1})$ 因式分解为 $\prod_{i \neq l} p_{\theta_i}(\mathbf{o}_i^t | \mathbf{o}_{i-1}^t, \mathbf{o}_i^{t-1})$, $\prod_{k \neq m} p_{\theta_l}(o_{l,k}^t | \mathbf{o}_{l-1}^t, o_{l,k}^{t-1})$ 和 $p_{\theta_l}(o_{l,m}^t | \mathbf{o}_{l-1}^t, o_{l,m}^{t-1})$ 项的乘积。然后,代入式 2-9 可得

$$\begin{aligned} g_l &= \\ &\sum_{\mathbf{o}_{1\dots L}^t} \sum_m \left(\prod_{i \neq l} p_{\theta_i}(\mathbf{o}_i^t | \mathbf{o}_{i-1}^t, \mathbf{o}_i^{t-1}) \prod_{k \neq m} p_{\theta_l}(o_{l,k}^t | \mathbf{o}_{l-1}^t, o_{l,k}^{t-1}) \right) \nabla_{\theta_l} p_{\theta_l}(o_{l,m}^t | \mathbf{o}_{l-1}^t, o_{l,m}^{t-1}) f_{\theta_{L+1}}(\mathbf{o}_L^t) \end{aligned} \quad (2-10)$$

基于等式 $\mathbb{P}[o_{l,m}^t = 0] = 1 - \mathbb{P}[o_{l,m}^t = 1]$, 可得

$$\sum_{o_{l,m}^t} \nabla_{\theta_l} p_{\theta_l}(o_{l,m}^t | \mathbf{o}_{l-1}^t, o_{l,m}^{t-1}) f_{\theta_{L+1}}(\mathbf{o}_L^t) = \nabla_{\theta_l} p_{\theta_l}(o_{l,m}^t | \mathbf{o}_{l-1}^t, o_{l,m}^{t-1}) \Delta \mathcal{L}, \quad (2-11)$$

其中损失的差异项 $\Delta \mathcal{L} = f_{\theta_{L+1}}(\mathbf{o}_L^t) - f_{\theta_{L+1}}(\mathbf{o}_{l,m}^t)$, 这里使用 $\mathbf{o}_{l,m}^t$ 来表示如果 $o_{l,m}^t$ 改变后的新脉冲发放状态 \mathbf{o}_L^t 。给定 $\sum_{o_{l,m}^t} p_{\theta_l}(o_{l,m}^t) = 1$ 并考虑式 2-10, 式 2-11, 可得到

$$g_l = \sum_{\mathbf{o}_{1 \dots L}^t} \left(\prod_{i=1}^L p_{\theta_i}(\mathbf{o}_i^t | \mathbf{o}_{i-1}^t, \mathbf{o}_i^{t-1}) \right) \hat{g}_l = \mathbb{E}_{\mathbf{o}_{1 \dots L}^t} [\hat{g}_l], \quad (2-12)$$

其中

$$\hat{g}_l = \sum_m \nabla_{\theta_l} p_{\theta_l}(o_{l,m}^t | \mathbf{o}_{l-1}^t, o_{l,m}^{t-1}) \Delta \mathcal{L} \quad (2-13)$$

直观地说, 这个局部梯度被定义为层 l 中所有神经元贡献的总和。为了得到 g_l 的估计, 本章方法从 $p_{\theta}(\mathbf{o}_{1 \dots L}^t | \mathbf{x}^t)$ 采样, 并使用式 2-13 进行计算。然而, 计算 $\Delta \mathcal{L}$ 仍然存在现实问题, 因为它需要重复评估损失值, 因此可能难以扩展到规模更大的网络模型^[107]。受之前的研究启发^[107-109], 本章将损失值的变化归因于变量 $o_{l,m}^t$ 的状态变化。进而, 可以使用一个一阶近似来估计当 $o_{l,m}^t$ 的状态改变导致的损失差值 $\Delta \mathcal{L}$:

$$\Delta \mathcal{L} \approx (o_{l,m}^t - (1 - o_{l,m}^t)) \frac{\partial f_{\theta_{L+1}}}{\partial o_{l,m}^t} = (2o_{l,m}^t - 1) \nabla_{o_{l,m}^t} f_{\theta_{L+1}} \quad (2-14)$$

这种近似处理给梯度估计器引入了偏差, 除非该映射 f 是多线性的^[107,109]。由式 2-13, 式 2-14, 可得

$$\hat{g}_l = \sum_m \nabla_{\theta_l} p_{\theta_l}(o_{l,m}^t | \mathbf{o}_{l-1}^t, o_{l,m}^{t-1}) (2o_{l,m}^t - 1) \nabla_{o_{l,m}^t} f_{\theta_{L+1}} \quad (2-15)$$

由式 2-5, 有 $\nabla_{\theta_l} p_{\theta_l}(o_{l,m}^t | \mathbf{o}_{l-1}^t, o_{l,m}^{t-1}) = (2o_{l,m}^t - 1) F'_\epsilon(u_{l,m}^t - v_{\text{th}}) \nabla_{\theta_l} u_{l,m}^t$ 。联合式 2-15, 可将噪声驱动的学习规则 (Noise Driven Learning, NDL) 表述为^[110-111]

$$\text{NDL: } \hat{g}_l = \sum_m \underbrace{\nabla_{\theta_l} u_{l,m}^t}_{\text{突触前学习因子}} \overbrace{\underbrace{F'_\epsilon(u_{l,m}^t - v_{\text{th}})}^{\text{突触后学习因子}} \underbrace{\nabla_{o_{l,m}^t} f_{\theta_{L+1}}}_{\text{全局学习信号}}}^{\text{突触后学习因子}}. \quad (2-16)$$

使用式 2-16 计算突触权重更新不需要在前向传播中计算额外的梯度生成器，因为 \hat{g}_l 可以在单次反向传播中逐层计算得到。具体而言，该规则下的梯度估计仍是通过反向传播进行的，其中精确链式求导法则中的 $\nabla_{u_{l,m}^t} o_{l,m}^t$ 项被替换为使用噪声概率密度函数 F'_ϵ 计算的项。因此，NDL 易于实现，并且可以与广为使用的自动微分框架（Torch, TensorFlow 等）相融。并且，由于 NDL 形式上直接与反向传播契合，本章可以轻松地使用它来优化任何架构的 NSNN 模型。有趣的是，一些先前的工作^[112] 也通过在脉冲神经元中经验性地添加无穷小的高斯扰动来构造了一个替代梯度函数（伪导数来替代 $\nabla_{u_{l,m}^t} o_{l,m}^t$ 项）。他们通过单神经元分析得到的替代梯度函数与 NDL 中的后突触项与本节介绍的方法有着类似的见解，然而，本节中结果是从网络级别的推导中得到的。

2.2.3 噪声脉冲神经网络稳定性理论分析

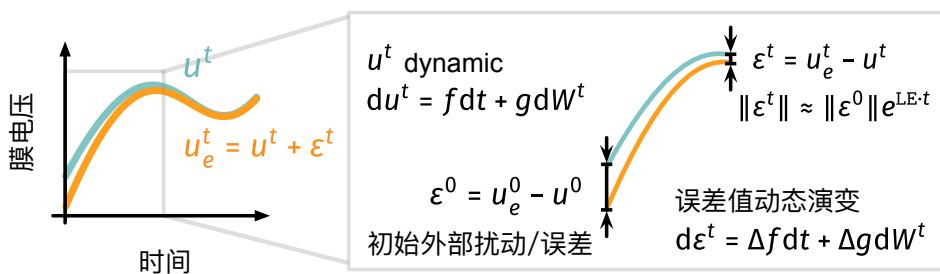


图 2-4 系统稳定性分析示意图。本章通过分析误差动态（式 2-19）的稳定性，研究了给定小的初始扰动 ε^0 下的连续 NSNN 固下动态（式 2-17）的稳定性。

本节将分析连续 NSNN 固下动态的稳定性（参见图 2-4）。本节的理论结果表明，NSNN 中的内部噪声可以通过允许更快的状态自我修正来提高对外部扰动的稳定性。这也将为突出 NSNN 的性能提升和鲁棒性增益提供另一个视角^[113]。在正式进入理论分析之前，本章将 NSNN 层建模为一个包含一个漂移项 f （用于模拟其动态的确定性部分）和一个扩散项 g （用于模拟随机部分）的随机动力系统的特例，形式上可以表述为

$$d\mathbf{u}^t = \mathbf{f}(\mathbf{u}^t, \mathbf{I}^t)dt + \mathbf{g}(\mathbf{u}^t, \mathbf{I}^t)d\mathbf{W}^t, \quad (2-17)$$

其中 $\mathbf{u}^t, \mathbf{I}^t \in \mathbb{R}^{\dim(\mathbf{u}^t)}$, \mathbf{W}^t 是一个 $\dim(\mathbf{u}^t)$ -维的 Wiener 过程。并且系数 \mathbf{f}, \mathbf{g} 满足以下

假设。

假设 1 存在一个常数 $K > 0$ 使得 $\|\mathbf{f}(\mathbf{u}_1^t, t) - \mathbf{f}(\mathbf{u}_2^t, t)\| + \|\mathbf{g}(\mathbf{u}_1^t, t) - \mathbf{g}(\mathbf{u}_2^t, t)\| \leq K\|\mathbf{u}_1^t - \mathbf{u}_2^t\|$ 对所有的 $\mathbf{u}_1^t, \mathbf{u}_2^t \in \mathbb{R}^{\text{dim}(\mathbf{u}^t)}$, $t \in \mathbb{R}^+$ 都成立。

特别地, 本章关注 \mathbf{f} 和 \mathbf{g} 的选择:

$$\begin{aligned}\mathbf{f}(\mathbf{u}^t, \mathbf{I}^t) &= a_1 \mathbf{u}^t + \mathbf{B}_1 \mathbf{I}^t, \\ \mathbf{g}(\mathbf{u}^t, \mathbf{I}^t) &= a_2 \text{diag}(1) + b_2 \mathbf{f}(\mathbf{u}^t, \mathbf{I}^t),\end{aligned}\tag{2-18}$$

其中 $a_1 \in \mathbb{R}$, $a_2, b_2 \in [0, \infty)$ 是常数, $\mathbf{B}_1 \in \mathbb{R}^{\text{dim}(\mathbf{u}^t) \times \text{dim}(\mathbf{u}^t)}$ 。通过让 $a_1 = -1/\tau_m$, $a_2 = \sigma$ 并取 $b_2 = 0$, 可以得到本章关注的 Noisy LIF 神经元组成的 NSNN 层的形式。

接下来, 本节进一步考虑式 2-17 和式 2-18 表示的系统, 用两个略有差异的初始状态 \mathbf{u}^0 和 $\mathbf{u}_e^0 \triangleq \mathbf{u}^0 + \boldsymbol{\varepsilon}^0$ 进行初始化, 其中 $\boldsymbol{\varepsilon}^0 \in \mathbb{R}^{\text{dim}(\mathbf{u})}$ 是膜电位的初始外部扰动 (误差)。自然地, 误差 $\boldsymbol{\varepsilon}^t = \mathbf{u}_e^t - \mathbf{u}^t$ 的演变满足随机微分方程 (SDE)

$$d\boldsymbol{\varepsilon}^t = \Delta\mathbf{f}(\boldsymbol{\varepsilon}^t)dt + \Delta\mathbf{g}(\boldsymbol{\varepsilon}^t)dt,\tag{2-19}$$

其中

$$\begin{aligned}\Delta\mathbf{f}(\boldsymbol{\varepsilon}^t) &\triangleq (\mathbf{f}(\mathbf{u}^t + \boldsymbol{\varepsilon}^t, \mathbf{I}^t) - \mathbf{f}(\mathbf{u}^t, \mathbf{I}^t)), \\ \Delta\mathbf{g}(\boldsymbol{\varepsilon}^t) &\triangleq (\mathbf{g}(\mathbf{u}^t + \boldsymbol{\varepsilon}^t, \mathbf{I}^t) - \mathbf{g}(\mathbf{u}^t, \mathbf{I}^t)).\end{aligned}\tag{2-20}$$

这里本章假设两个随机过程 $\mathbf{u}^t, \mathbf{u}_e^t = \mathbf{u}^t + \boldsymbol{\varepsilon}^t$ 是由相同的 Wiener 过程驱动的, 以使上述的减法操作有效。由于 $\Delta\mathbf{f}(0) = 0$ 和 $\Delta\mathbf{g}(0) = 0$, $\boldsymbol{\varepsilon}^t = 0$ 对于式 2-19 提供了一个平凡解, 且其唯一性由 1 保证^[114]。进一步地, 本章着眼于分析平凡解 $\boldsymbol{\varepsilon}^t = 0$ 的稳定性; 如果它是稳定的, 那么小的初始外部扰动 $\boldsymbol{\varepsilon}^0 \neq 0$ 将随着系统的演变而不断减小。这意味着由式 2-17 描述的噪声神经网络系统具有自我纠偏的能力, 也即, 能够在面对小的外部扰动或误差时可靠地工作。具体来说, 本章关注以下定义的几乎确定的指数稳定性 (即具备指数稳定性概率为 1)。

几乎必然的指数稳定性^[114] 如果样本李雅普诺夫指数 (Sample Lyapunov Exponent) $\text{LE} \triangleq \limsup_{t \rightarrow \infty} \frac{1}{t} \log \|\boldsymbol{\varepsilon}^t\|$ 对于所有的 $\boldsymbol{\varepsilon}^0 \in \mathbb{R}^{\text{dim}(\mathbf{u}^t)}$ 都几乎必然为负, 那么平凡解 $\boldsymbol{\varepsilon}^t = 0$ 就是几乎必然指数稳定的。

对于上述平凡解的样本李雅普诺夫指数 LE，存在一个正常数 C 和一个随机变量 $\tau \in [0, \infty)$ 使得对于所有的 $t > \tau$, $\|\varepsilon^t\| \leq C \exp(t \cdot \text{LE})$ 的概率为 1。因此，几乎必然的指数稳定性意味着几乎所有从非零初始值开始的样本路径，将以指数速度收敛到平衡点 $\varepsilon^t = 0$ ，即，NSNN 系统可以快速自我纠正小的扰动。进一步，本章有关于该平凡解的样本李雅普诺夫指数数学边界的一个重要结果。

定理 1 (平凡解 $\varepsilon^t = 0$ 的样本李雅普诺夫指数的上下界) 假设对于所有的非零 $\varepsilon^t \in \mathbb{R}^{\dim(\mathbf{u}^t)}$, $t \in \mathbb{R}^+$, 都有 $0 \leq a_2 \|\varepsilon^t\| \leq \|\Delta \mathbf{g}(\varepsilon^t)\|_F \leq (a_2 + b_2) \|\varepsilon^t\|$ 成立。那么，几乎必然地，

$$a_1 - \frac{1}{2}a_2^2 - b_2^2 - 2a_2b_2 \leq \text{LE} \leq a_1 - \frac{1}{2}a_2^2 + \frac{1}{2}b_2^2 + a_2b_2$$

对于所有的 $\varepsilon^0 \in \mathbb{R}^{\dim(\mathbf{u}^t)}$ 成立。

为了证明上述定理，首先引入微分算子 L 。为了简化符号，此处暂时省略上标 t ，亦即，这里使用 \mathbf{u}, ε 而不是 $\mathbf{u}^t, \varepsilon^t$ 。与式 2-19 相关的微分算子定义为

$$L = \frac{\partial}{\partial t} + \sum_{i=1}^{\dim(\mathbf{u})} \Delta f_i(\varepsilon, t) \frac{\partial}{\partial \varepsilon_i} + \frac{1}{2} \sum_{i,j=1}^{\dim(\mathbf{u})} [\Delta \mathbf{g}^T(\varepsilon, t) \Delta \mathbf{g}(\varepsilon, t)]_{ij} \frac{\partial^2}{\partial \varepsilon_i \partial \varepsilon_j}, \quad (2-21)$$

其中下标表示张量的类目。此外，本章引入了如下引理：

引理 1 (随机李雅普诺夫定理) 假设存在一个在 $\mathbb{R}^{\dim(\mathbf{u})} \times \mathbb{R}^+$ 上定义的非负实值函数 $V(\varepsilon, t)$ ，记作 $V \in C^{2,1}(\dim(\mathbf{u}) \times \mathbb{R}^+; \mathbb{R}^+)$ 。此外，函数 V 有连续的偏导数，记作

$$V_\varepsilon = \frac{\partial V}{\partial \varepsilon}, V_t = \frac{\partial V}{\partial t}, V_{\varepsilon, \varepsilon} = \frac{\partial^2 V}{\partial \varepsilon \partial \varepsilon^T},$$

和常数 $c_1, C_1 > 0$, $c_2, C_2 \in \mathbb{R}$, $c_3, C_3 \geq 0$ ，使得对于所有非零的 ε 和 $t \in \mathbb{R}^+$ ，满足以下三个条件

1. $c_1 \|\varepsilon\|^2 \leq V(\varepsilon, t) \leq C_1 \|\varepsilon\|^2$,
2. $c_2 V(\varepsilon, t) \leq L V(\varepsilon, t) \leq C_2 V(\varepsilon, t)$,
3. $c_3 V(\varepsilon, t)^2 \leq \|V_\varepsilon(\varepsilon, t) \Delta \mathbf{g}(\varepsilon)\|_F^2 \leq C_3 V(\varepsilon, t)^2$ 。

则样本李雅普诺夫指数满足式

$$\frac{c_2}{2} - \frac{C_3}{4} \leq \limsup_{t \rightarrow \infty} \frac{1}{t} \log \|\boldsymbol{\varepsilon}\| \leq \frac{C_2}{2} - \frac{c_3}{4} \quad a.s.$$

上述引理可以通过将早期文献^[114]的定理3.3和3.5相结合得到^[80]。接下来继续证明定理1。

证明1 设 $V(\boldsymbol{\varepsilon}, t) = \|\boldsymbol{\varepsilon}\|^2$ 。如果取 $c_1 = C_1 = 1$, 则引理1的条件1得到满足。由式2-21, 有

$$LV(\boldsymbol{\varepsilon}, t) = V_\varepsilon^T \Delta \mathbf{f}(\boldsymbol{\varepsilon}, t) + \frac{1}{2} \text{trace} (\Delta \mathbf{g}^T(\boldsymbol{\varepsilon}, t) V_{\varepsilon, \varepsilon} \Delta \mathbf{g}(\boldsymbol{\varepsilon}, t)),$$

由式2-18, 式2-19, 可以容易地证明对于所有非零的 $\boldsymbol{\varepsilon} \in \mathbb{R}^{\dim(u)}$, $t \in \mathbb{R}^+$,

$$(2a_1 + a_2^2) \|\boldsymbol{\varepsilon}\|^2 \leq LV(\boldsymbol{\varepsilon}, t) \leq (2a_1 + (a_2 + b_2)^2) \|\boldsymbol{\varepsilon}\|^2$$

成立。因此满足了引理1的条件2。

为了满足引理1的条件3, 基于先前对 $\Delta \mathbf{g}$ 的假设, 有

$$4a_2^2 V^2 \leq \|V_\varepsilon \Delta \mathbf{g}\|_F^2 \leq 4(a_2 + b_2)^2 V^2$$

综上, 取 $c_1 = 1, C_1 = 1, c_2 = 2a_1 + a_2^2, C_2 = 2a_1 + (a_2 + b_2)^2, c_3 = 4a_2^2, C_3 = 4(a_2 + b_2)^2$, 通过引理1可以得到样本李雅普诺夫指数的上下界, 即

$$a_1 - \frac{1}{2}a_2^2 - b_2^2 - 2a_2b_2 \leq LE \leq a_1 - \frac{1}{2}a_2^2 + \frac{1}{2}b_2^2 + a_2b_2$$

□

根据定理1, 平凡解 $\boldsymbol{\varepsilon}^t = 0$ 的样本李雅普诺夫指数的下界 LB 和上界 UB 为

$$LB = a_1 - \frac{1}{2}a_2^2 - b_2^2 - 2a_2b_2, UB = a_1 - \frac{1}{2}a_2^2 + \frac{1}{2}b_2^2 + a_2b_2$$

通常情况下, 根据几乎确定指数稳定性的定义, 如果 $UB < 0$, 则平凡解是几乎确定指

数稳定的。即使 $a_1 > 0$, 通过引入内部噪声项也可以保证系统稳定, 以确保上界为负。对于 LIF 建模的脉冲神经网络, 由于 $a_1 = -\frac{1}{\tau_m} < 0$, 如果 $\frac{1}{\tau_m} > -\frac{1}{2}a_2^2 + \frac{1}{2}b_2^2 + a_2 b_2$, 则阈下动态的动力系统是能够自我纠正的, 即 $\epsilon^t \xrightarrow{\text{a.s.}} 0$ 。随后本章转而考虑加性噪声的情况 ($a_2 > 0, b_2 \rightarrow 0$), 本章介绍的 NSNN 即属此类。

在加性噪声情况下, 系统中的乘性噪声组件趋于零 $b_2 \rightarrow 0$, 样本李雅普诺夫指数的上界变为 $UB_{\text{additive}} = a_1 - \frac{1}{2}a_2^2$ 。另一方面, 在无噪声情况下, 两个噪声项都趋于零, $a_2 \rightarrow 0, b_2 \rightarrow 0$, 此时下界为 $LB_{\text{noise free}} = a_1$ 。因而有 $UB_{\text{additive}} < LB_{\text{noise free}} = a_1 < 0$ 成立。同时, 在较小的时间间隔内, 对于时间 t 的误差, 有 $\|\epsilon^t\| = \|\epsilon^0\| \exp(\text{LE} \cdot t)$ 成立。因此, 引入加性噪声确保了比无噪声情况下更负的样本李雅普诺夫指数, 从而实现了更迅速的自我纠正。这将允许快速检测和纠正可能导致不稳定的系统因素, 从而提高 NSNN 系统的稳定性。

表 2-1 DSNN 和 NSNN 推理和学习过程的异同与联系。下表列出了一些典型的替代梯度函数及其相应的膜电位噪声分布。按下离子布朗运动的生物学事实不表 (对应高斯噪声的情况), 可以将表中的结果扩展到其他具有零均值和对称 PDF 的连续随机分布噪声。

模型种类	确定性脉冲神经网络	噪声脉冲神经网络
推理 脉冲发放机制	确定性的 (本质为对随机推理的近似) $o_{l,m}^t = \mathbf{1}_{u_{l,m}^t > v_{th}}$	随机性的 $o_{l,m}^t \sim \text{Ber}(\mathbb{P}[o_{l,m}^t = 1])$
	替代梯度近似	来自噪声信息 $F'_\epsilon = p_\epsilon$
	ERF	 $\mathcal{N}(0, \sigma^2)$
学习 突触后学习因子 $\frac{\partial o}{\partial u}$	Sigmoid	 $\text{Logistic}(0, s)$
	Rectangular	 $\mathcal{U}(-a, a)$
	Triangular	 $\text{Triangular}(-a, 0, a)$
	Arctangent	 $\text{Atan}(0, \phi)$

表2-2 本章实验用到的超参数设定一览。

数据集	算法	结构	T	初始 LR	批大小	SG	Noise
DSNN	CIFAR-10	STBP TET, $\lambda = 0.05$	ResNet-18	2/4	0.01	256/256	ERF SG /
				2/4	0.01	256/256	ERF SG /
	CIFAR-100	STBP	CIFARNet	2/4	0.004	256/256	ERF SG /
		STBP TET, $\lambda = 0.05$	ResNet-18	2/4	0.005	256/256	ERF SG /
				2/4	0.005	256/256	ERF SG /
		STBP	CIFARNet	2/4	0.001	256/256	ERF SG /
NSNN	DVS-CIFAR	STBP TET, $\lambda = 0.001$ tdBN	ResNet-19 VGGSN	10	0.0005	32	ERF SG /
				10	0.0002	64	ERF SG /
				10	0.0002	64	ERF SG /
	CIFAR-10	STBP TET, $\lambda = 0.05$	ResNet-18	2/4	0.002	256/256	/ \mathcal{N}
				2/4	0.002	256/256	/ \mathcal{N}
		STBP	CIFARNet	2/4	0.003	256/128	/ \mathcal{N}
NSNN	CIFAR-100	STBP TET, $\lambda = 0.05$	ResNet-18	2/4	0.001	256/256	/ \mathcal{N}
				2/4	0.001	256/256	/ \mathcal{N}
		STBP	CIFARNet	2/4	0.002	256/256	/ \mathcal{N}
	DVS-CIFAR	STBP TET, $\lambda = 0.001$ tdBN	ResNet-19 VGGSN	10	0.0005	20	/ \mathcal{N}
				10	0.0003	32	/ \mathcal{N}
				10	0.0003	32	/ \mathcal{N}

2.3 实验结果

2.3.1 无外部扰动目标识别实验

为了验证本章介绍的 NSNN 的有效性和兼容性，本章使用多种 SNN 架构和算法的组合，在多个识别基准数据集上进行了实验。本章考虑的识别数据集包括静态图像数据集，包括 CIFAR-10 和 CIFAR-100^[115]，以及使用 DVS 相机（硅视网膜）收集的事件流数据集，包括 DVS-CIFAR^[116] 和 DVS-Gesture^[117]。

测试基准和实验设定 CIFAR 数据集^[115] 包括 50k 个 32×32 的训练图像和 10k 个评估图像。本章实验中对训练样本采用随机裁剪、随机水平翻转和 AutoAugment^[118]。在训练和评估阶段，使用 z-score 缩放方式对其进行归一化。DVS-CIFAR 数据集^[116] 是一个具有挑战性的神经形态基准，使用来自 CIFAR-10 的图像通过 DVS 相机记录。沿用已有的研究工作^[119] 的预处理流程，即将原始集划分为一个 9k 样本的训练集和 1k 样本的评估集，所有的事件流文件都被空间下采样到 48×48 。本章同样沿用之前的研究^[65] 的方式对训练样本进行数据增强。DVS-Gesture 数据集^[117] 使用 DVS128 事件相机记录。它包含了在三种照明条件下 29 个主题的 11 种手势的记录。

本节实验中使用数据集的样本-标签对优化了 SNN 模型，并在不重叠的测试数据上计算了性能指标。预测准确率被用作这些任务的性能指标。对于每个网络架构和 SNN 算法组合，本章通过网格搜索为 DSNN 和 NSNN 设置了不同架构和算法组合下的最优超参数，以确保公平的比较。本章在结果中指出了相应的模拟时间步，这是离散 SNN 实现的模拟持续时间。对于静态图像数据，静态图像被反复输入，因此更长的模拟时间步通常会导致更准确的识别。对于事件流数据集，固定长度的连续事件流被离散化为模拟时间步时间窗口。嵌入在这些事件流中的信息将在许多时间步中传播。因此，更大的模拟时间步通常会导致更精细的计算和更准确的识别。本章在 CIFAR-10、CIFAR-100 和 DVS-Gesture 实验中将神经元膜电压的噪声的标准差（强度）设置为 0.3，在 DVS-CIFAR 实验中设置为 0.2。这些设定在绝对性能和抗扰动性能之间提供了一个折衷。对于 DSNN 使用的 SGL，本章采用 ERF 替代梯度 $SG_{ERF}(x) = \frac{1}{\sqrt{\pi}} \exp(-x^2)$ 。本章的所有实验中，Adam 求解器^[120] 与余弦退火学习率衰减策略^[121] 一起被用于训练所有网络。在表 2-2 中列出了识别实验中采用的超参数设定，其中的初始学习率是通过网格搜索获得的。

本文中使用的 ResNet-19^[122]、VGG-SNN^[65]、CIFARNet^[64] 和 7B-Net^[68] SNN 架构遵循前面工作中的原始实现。ResNet-18 架构由 64C3-2(64C3-4C3)-2(128C3-128C3)-2(256C3-256C3)-2(512C3-512C3)-AP-FC 给出。其中，AP 表示平均池化，FC 表示全连接层，C 表示卷积层。这里使用的 SNN 算法 STCA^[123]、STBP^[63]、STBP-tdBN^[122] (tdBN) 和 TET^[65] 遵循这些工作中提出的原始实现。比较中报告的一些结果来自原始论文，主要包括 LIAF-Net^[124]、STCA^[123]、STBP-tdBN^[122] 与 ResNet-19 和 ResNet-17、TET^[65] 与 ResNet-19、Wide-7B-Net^[68] 和 7B-Net^[68]。

本章分析了在这些测试基准上模型的识别准确率表现，并主要关注与确定性的常规 SNN 的比较。如表 2-5 所示，CIFAR-10 和 CIFAR-100 的结果证明了 NSNN 在静态图像识别任务上的有效性。例如，在 CIFAR-10 上，NSNN 模型（使用 STBP, CIFARNet）在两个模拟时间步上达到了 0.9390 的准确率，而其确定性对照物为 0.9188。本章的结果表明，NSNN 与各种 SNN 架构和算法配合得很好，显示出极大的兼容性。因此，NSNN 可以从更高效的 SNN 算法或架构中受益。例如，当使用 ResNet-18 架构时，使用更高效的 TET 算法的 NSNN 模型的性能明显优于使用 STBP 的 NSNN 模型（表 2-5, CIFAR-10, CIFAR-100）。NSNN 也在事件流数据识别任务（表 2-5, DVS-CIFAR, DVS-Gesture）上显示出有效性和兼容性，并超过了他们的 DSNN 对应模型。特别是，在 DVS-CIFAR 数据上，使用 STBP 和 ResNet-19 的 NSNN 模型明显优于其对应的 DSNN 模型，其他组合的性能改进也很明显。由于样本数量有限，DSNN 在处理 DVS-CIFAR 和 DVS-Gesture 数据时经常会出现严重的过拟合。然而，在 NSNN 中，内部噪声提高了模型的泛化能力，从而使其最终性能表现优于对应的确定性模型，这种由 NSNN 中的内部噪声带来的泛化提升的现象与 ANN 领域的早先研究中的结论与观察是一致的^[79-81]。

2.3.2 外部扰动下的模型性能评估

对于脉冲神经模型的信息处理过程而言，鲁棒性是至关重要的，其有助于防止无处不在且无孔不入的外部干扰和内部误差。而从应用的角度来看，模型的鲁棒性能够确保在面对有损的输入（可能由数据收集和处理中的错误引起）和扰动的内部信息流（可能由不同单元之间的通信异常引起）时，能够提供可靠的性能表现。而在构建生物真实的计算神经电路方面来说，鲁棒的脉冲神经模型更符合生物电路的嘈杂而又稳定的生物物理特性^[47,75,113]。本节将通过实验来体现使用 NSNN 所取得的鲁棒性改善。为此，本章在 CIFAR-10、CIFAR-100 和 DVS-CIFAR 数据上进行了外部扰动下的识别实验。本章通过评估 DSNN 和 NSNN 在各种类型和强度的外部扰动下的识别准确率和损失值，衡量了它们的抗扰性能。上述的这些模型是按照前一节中描述的程序进行训练的。

在本章节的实验首先考虑了几种极具挑战性的输入级扰动。对于静态图像数据 CIFAR-10 和 CIFAR-100，本章使用极具挑战性的对抗攻击来构造对抗输入样本。本节主要考虑了两种对抗攻击：快速梯度符号方法 (Fast Gradient Sign Method, FGSM) 和直接优化方法 (Direct Optimisation, DO)。而对于事件流数据 DVS-CIFAR，本章使用了

EventDrop^[125] 扰动，其基本思想是以 ρ 的概率随机丢弃一部分事件。除了在输入层面上施加外部扰动之外，本章还考虑直接扰动 SNN 中的所有脉冲状态（脉冲神经元的发放状态），以直接模拟生物神经电路中的脉冲序列的变异性。

外部扰动的实现方法 此处将待评估的神经网络模型记为 NN。DO 对抗攻击方法通过直接解决约束优化问题^[126]来构造对抗样本

$$\Delta x = \arg \max_{\|\Delta x\|_2=\gamma} \text{loss}(f(x + \Delta x), y), \quad (2-22)$$

其中， Δx 为对抗扰动， $x + \Delta x$ 为对抗样本。L-2 范数有界的加性扰动张量被初始化为零，并通过一个学习率为 0.002 的 Adam 求解器进行 30 次迭代优化。之后，加性扰动被用来产生对抗样本，并输入到目标模型（本章节中的 DSNN 或 NSNN）。FGSM 方法的实现遵循原始实现^[127]，其中对抗样本的构造为

$$\tilde{x}^{adv} = x + \gamma_{FGSM} \times \text{sign}[\nabla_x \text{loss}(\text{NN}(x), y)]. \quad (2-23)$$

对于动态输入（事件流），输入层面的扰动是通过在原始输入脉冲序列中随机丢弃脉冲来实现的^[125]，其事件丢弃概率由参数 ρ 给定。本章考虑的事件丢弃策略是 Random Drop^[125]，它结合了空间和时间的事件丢弃策略。在评估过程中，首先对测试集中的每个样本单独进行 EventDrop，然后将扰动的输入送入测试对象。脉冲状态的外部扰动包括两种具体的扰动类型：发放状态从 1 到 0（脉冲到静默）和发射状态从 0 到 1（静默到脉冲）。为了简化设置，本章使用一个参数 β ，来控制这两种扰动施加的概率。让变量 o_{old} 表示原始的脉冲状态，如果 $o_{\text{old}} = 1$ ，有 $\mathbb{P}[o_{\text{new}} = 0] = \beta$ ，否则，如果 $o_{\text{old}} = 0$ ， $\mathbb{P}[o_{\text{new}} = 1] = \beta$ 。

图 2-5 显示，使用 NSNN 显著提高了静态数据识别任务（CIFAR-10, CIFAR-100）的鲁棒性。当面对具有挑战性的对抗攻击和脉冲发放状态扰动时，NSNN 模型始终优于 DSNN。例如，在 CIFAR-100 FGSM 对抗攻击实验中（图 2-5B），NSNN 表现出良好的韧性，而 DSNN 的可靠性随着扰动强度的增加而急剧下降。同样，当面对神经元脉冲状态的直接干扰（图 2-5C）时，NSNN 表现出优于其确定性对照模型的鲁棒性。DVS-CIFAR 数据的扰动实验也显示，NSNN 模型比 DSNN 具有更好的鲁棒性（表 2-3, 表 2-4）。当面

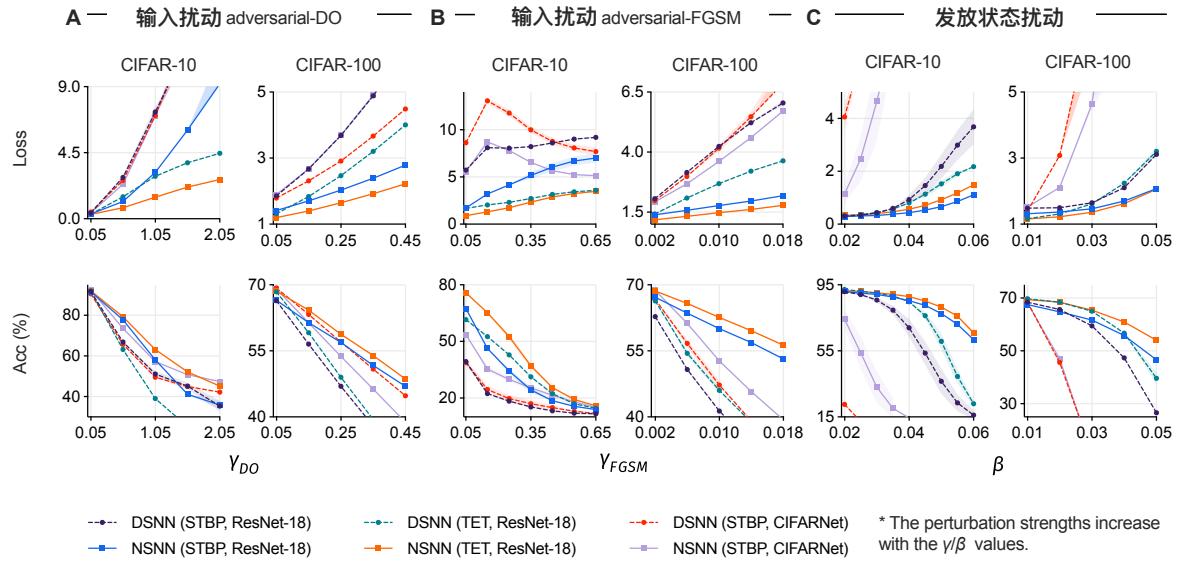


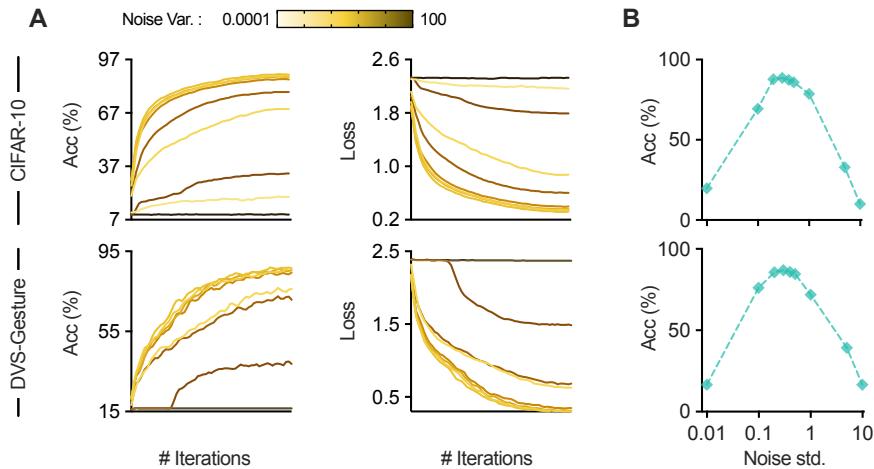
图 2-5 CIFAR-10 和 CIFAR-100 数据集的扰动识别实验结果。A, B. 输入层面对抗性攻击 (DO 方法, FGSM 方法) 下的损失和识别精度。C. 在脉冲发放状态层面施加外部扰动下的损失和识别精度。

对输入级 EventDrop 扰动时, NSNN 在大多数情况下比其确定性对应物实现了更低的损失和更高的准确率 (表 2-3)。同样, 如表 2-4 所示, 当面对脉冲发放状态扰动时, NSNN 表现出良好的鲁棒性能, 且当扰动 (脉冲状态) 强度级别增加时, 它们的优越性变得明显。例如, 在扰动级别为 $\beta = 0.01$ (使用 STBP 和 ResNet-19) 时, NSNN 的准确率表现比 DSNN 高出 4.5%。当扰动级别增加到 0.04 时, NSNN 比 DSNN 的准确率领先幅度扩大到 46.3%。

内部噪声强度的选择 尽管之前已经介绍了基于噪声的计算和学习方法, 但仍有一个问题尚未解决: 应当如何为噪声脉冲神经网络选择适当的内部噪声强度参数。内部噪声水平会影响学习的效率, 因为在 NDL 中突触后学习因子 $F'_\epsilon(u - v_{\text{th}})$ 是使用膜噪声 ϵ 的概率密度函数计算的。当方差很小时, 噪声分布收敛到具有极有限信息 (以信息熵衡量) 的 Dirac 分布, 这将阻碍 NDL 获取足够的信息以有效地进行学习。而在推理时, NSNN 内部噪声水平会直接影响脉冲发放过程的随机性; 较小的噪声导致神经元动力学的扰动较少, 而较大的噪声 (具有高方差) 会过度受扰的膜电压动态, 从而破坏网络中确定性关键信息的流动, 进而导致性能恶化。本章的前文中经提供了关于内部噪声、网络稳定性和性能的理论解释, 而在本节通过实验证来表明适度的模型内部噪声对脉冲神经网

表 2-3 DVS-CIFAR 基准上 EventDrop 扰动下的评估结果， ρ 数值越大，扰动越强。

算法 & 结构	类型	ρ	损失值				准确率 (%)			
			0.05	0.25	0.45	0.65	0.05	0.25	0.45	0.65
STBP & DSNN	NSNN	2.27 _{±0.16}	6.89 _{±2.05}	8.60 _{±1.55}	9.06 _{±1.08}	60.09 _{±2.46}	17.68 _{±5.72}	13.21 _{±1.31}	12.42 _{±0.29}	
ResNet-19	NSNN	1.80 _{±0.09}	5.84 _{±0.76}	7.65 _{±1.21}	8.55 _{±1.40}	65.66 _{±1.80}	25.31 _{±5.72}	16.36 _{±3.23}	13.32 _{±0.61}	
tdBN & DSNN	NSNN	2.24 _{±0.14}	6.31 _{±0.74}	8.25 _{±1.49}	9.49 _{±1.61}	64.98 _{±1.63}	26.64 _{±3.32}	18.41 _{±2.43}	13.74 _{±1.00}	
VGGSN	NSNN	1.90 _{±0.06}	6.91 _{±0.16}	8.19 _{±0.82}	8.66 _{±1.35}	70.28 _{±1.36}	30.14 _{±0.99}	22.55 _{±2.07}	18.78 _{±1.97}	
TET & DSNN	NSNN	1.21 _{±0.01}	2.88 _{±0.31}	3.44 _{±0.31}	4.13 _{±0.57}	67.86 _{±0.43}	29.26 _{±4.34}	20.76 _{±2.45}	15.70 _{±2.80}	
VGGSN	NSNN	1.03 _{±0.05}	2.55 _{±0.25}	4.02 _{±0.29}	4.15 _{±0.18}	71.67 _{±1.20}	29.14 _{±1.16}	21.34 _{±0.73}	14.73 _{±0.29}	

**图 2-6** 噪声脉冲神经网络内部噪声强度对模型性能的影响。A. 不同内部噪声强度下的学习曲线。B. 模型性能和内部噪声强度的关系曲线。

络性能有益。在早期的理论研究^[113] 中，基于对神经元动力学的分析，研究者指出，在某些条件下噪声可以对性能产生积极影响。更近期的文献^[128] 研究了在 STDP 学习规则下，具有神经元白噪声的小规模脉冲神经模型的学习性能。研究发现，适当的神经元噪声水平可以提高模型的学习能力，这与本节中从定量分析中得到的实验结果一致。

本节的实验使用 CIFAR-10 和 DVS-Gesture 数据集进行了实验，并训练了具有不同内部噪声水平设置的相同的网络模型。结果通过学习曲线和模型性能（以识别精度计）- 内部噪声强度（以标准差计）曲线在图 2-6A 中呈现。实验结果表明，当内部噪声的方差从 0 增加时，模型的性能最初会有所增益，然后会转而恶化。值得注意的是，NSNN

表 2-4 DVS-CIFAR 基准上的脉冲发放状态扰动下的评估结果，使用参数 β 控制扰动的强度。

β 类型	损失值				准确率 (%)			
	0.01	0.02	0.03	0.04	0.01	0.02	0.03	0.04
STBP & DSNN	1.43 ± 0.04	1.72 ± 0.06	2.44 ± 0.03	3.43 ± 0.25	69.73 ± 0.88	63.91 ± 1.37	53.60 ± 1.39	40.32 ± 1.91
ResNet-19 NSNN	1.23 ± 0.04	1.30 ± 0.03	1.41 ± 0.13	1.74 ± 0.32	72.88 ± 0.69	70.44 ± 0.42	67.27 ± 2.66	58.99 ± 6.80
tdBN & DSNN	1.29 ± 0.05	1.30 ± 0.08	1.49 ± 0.18	1.88 ± 0.29	74.09 ± 0.66	70.61 ± 1.37	63.19 ± 2.89	50.74 ± 3.32
VGGSNN NSNN	1.25 ± 0.01	1.19 ± 0.02	1.22 ± 0.06	1.50 ± 0.13	76.16 ± 0.13	73.38 ± 0.55	68.77 ± 0.78	55.64 ± 1.87
TET & DSNN	0.82 ± 0.03	0.91 ± 0.06	1.08 ± 0.08	1.37 ± 0.06	76.41 ± 0.92	72.60 ± 1.11	66.46 ± 1.93	56.06 ± 1.05
VGGSNN NSNN	0.75 ± 0.01	0.80 ± 0.01	0.94 ± 0.06	1.25 ± 0.14	78.28 ± 0.27	76.32 ± 1.01	71.54 ± 1.07	62.48 ± 0.52

在适度的内部强度值附近（参见图 2-6B）实现了高性能，这也确认了本章先前的理论分析结论，即适度的噪声对于高性能是有益处的。此外，根据本节的实验结果，在适度内部噪声范围内（从 0.2 到 0.5）改变 $\text{std}[\epsilon]$ 对最终性能不产生显著影响。这为在实践中使用 NSNN 时提供了可选的内部噪声水平参考。

2.4 本章小结

本章介绍了噪声脉冲神经模型和噪声驱动学习方法，利用神经元噪声作为脉冲神经元网络中的计算和学习资源。本章在确定性脉冲神经元模型^[82,85,136]中引入了一个膜噪声项，构建了这些噪声脉冲神经元的网络，并推导出 NDL 学习方法来进行突触优化。本章中多个数据集上的结果表明，NSNN 表现出竞争性的性能和改善的泛化能力。进一步的扰动测试显示，NSNN 对各种扰动，包括具有挑战性的对抗性攻击，都显示出改善的鲁棒性，从而为内部噪声模型稳定性分析提供了实证支持。此外，NSNN 可以轻松地与各种 SNN 算法和网络架构集成，使本章的方法能够被平凡地推广到需要随机性存在的广泛领域，从而为神经编码研究提供了一个颇有前景的计算工具。此外，由于本研究中提出的一般框架包含了传统的确定性脉冲模型，本章的方法有望在具有固有不可靠性的神经形态硬件上实现更灵活和鲁棒的计算过程。

生物神经网络中的噪声来源多样，包括电压或配体门控离子通道、突触囊泡的融合

以及信号分子向受体的扩散^[75]。通道噪声也可以影响膜电位、脉冲的产生以及在小轴突和细胞体中的脉冲传播^[137]。此外，突触在囊泡中释放的递质分子数量以及分子的扩散过程中也表现出随机性^[75]。早期的神经科学家认识到，大脑活动中的内在噪声可能通过随机化神经动力学带来好处，从而在创造力、概率决策、不可预测性以及划分为离散类别等方面具有优势^[138]。现代脑信号采集和成像技术，如 EEG、iEEG 和 fMRI，使研究人员能够通过精确定位不同认知过程的位置，探索噪声作为大脑网络中计算元素的作用。例如，最近的一项研究^[19] 使用 iEEG 测量证明，静息状态的皮层噪声可能影响视觉识别能力。这表明，噪声不仅仅是神经处理的伴随现象^[138]，而且在大脑网络中可以发挥独特和重要的作用。通过利用 NSNN 框架结合大脑成像和电生理信号采集技术，研究者可以建立神经活动变异性与概率行为之间的可处理的计算链接。这可能进一步提高对神经处理中噪声作用的理解，并有助于理解大脑中记忆和决策的机制。

最后，脉冲神经模型在神经科学的研究中受欢迎，因为它们具有生物真实的基于脉冲的计算范式。然而，传统的确定性脉冲神经模型不能解释神经脉冲序列的变异性^[18]。最近的神经科学的研究^[19] 提出静息状态的皮层噪声可能是限制识别能力的神经生理特征，这一定程度上表明大脑是非确定性的。为了理解和模拟如记忆、识别、注意力和决策等非确定性的神经系统的认知功能，必须要面对大规模的、复杂的计算系统。而目前看来，模拟这些系统需要由大量神经元组成的复杂神经网络。因此，对可扩展的噪声脉冲神经模型的研究，旨在提供一个在计算层面有用的工具，对计算神经科学有实际的好处。NSNN 有望被用于神经元类型^[9-10]，神经系统识别^[6,11]，以及构建神经电路的预测对应物^[5,7]。NSNN 提供了一种有前景的工具，用于构建各种感觉神经电路的计算账户，并将使大脑中复杂神经计算的更丰富的模型成为可能，在本文的后续章节中将继续以本章研究为基础，进一步拓展其作为基础计算模块的应用场景。

表 2-5 无外部干扰识别实验结果, 结果为准确率 (%), • 表示 NSNN 结果。

NSNN	算法名称	网络结构	准确率 Avg ± SD(T)
Cifar-10	○ STCA ^[123]	CIFARNet	91.23(12)
	○ Rathi 等	VGG-16	92.02(200)
	○ Hu 等	ResNet-44	92.37(350)
	○ Zhang 等	CIFARNet	91.41(5)
	○ Wu 等	CIFARNet	90.53(12)
	○ STBP-tdBN (Zheng 等)	ResNet-19	92.34(2) 92.92(4) 93.16(6)
	○ STBP [†] (Wu 等)	ResNet-18*	93.18±0.07(2) 93.93±0.11(4)
	● STBP [†]	ResNet-18*	92.87±0.04(2) 93.77±0.12(4)
	○ STBP [†]	CIFARNet	91.88±0.09(2) 92.79±0.14(4)
	● STBP	CIFARNet	93.90±0.12(2) 94.30±0.08(4)
Cifar-100	○ TET (Deng 等)	ResNet-19	94.16±0.03(2) 94.44±0.08(4) 94.50±0.07(6)
	○ TET [†] (Deng 等)	ResNet-18*	93.62±0.02(2) 94.09±0.20(4)
	● TET	ResNet-18*	93.12±0.07(2) 94.14±0.05(4)
	○ Rathi 等	ResNet-20	64.07(5)
	○ STBP-tdBN	ResNet-19	69.41±0.08(2) 70.86±0.22(4) 71.12±0.57(6)
	○ STBP [†]	ResNet-18*	70.15±0.14(2) 70.88±0.19(4)
	○ STBP-tdBN (Zheng 等)	ResNet-19	72.22±0.03(2) 73.41(4)
	● STBP	ResNet-18*	69.57±0.09(2) 71.16±0.40(4)
	○ STBP [†]	CIFARNet	72.25±0.08(2) 72.94±0.21(4)
	● STBP	CIFARNet	73.36±0.14(2) 74.17±0.28(4)
DVS-CIFAR	○ TET	ResNet-19	72.87±0.10(2) 74.47±0.15(4) 74.72±0.28(6)
	○ TET [†]	ResNet-18*	71.72±0.13(2) 74.01±0.43(4)
	● TET	ResNet-18*	71.34±0.09(2) 73.33±0.03(4)
	○ Sironi 等	N/A	52.40
	○ Ramesh 等	N/A	65.78
	○ Kugele 等	3B-DenseNet	66.75
	○ Liu 等	1-layer SNN	32.20
	○ Wu 等	LIAFNet	71.70
	○ Wu 等	6-layer SNN	60.50
	○ Fang 等	Wide-7B-Net	74.4(16)
DVS-Gesture	○ STBP [†]	ResNet-19	71.74±0.92(10)
	● STBP	ResNet-19	74.30±0.61(10)
	○ STBP-tdBN [†]	VGGSNN	75.51±0.49(10)
	● STBP-tdBN	VGGSNN	76.97±0.10(10)
	○ TET [†]	VGGSNN	78.26±0.17(10)
	● TET	VGGSNN	79.52±0.38(10)
			($T = 16$)
DVS-Gesture	○ Fang 等	7B-Net(Fang 等)	97.92
	○ Zheng 等	ResNet-17	96.87($T = 40$)
	○ STBP	7B-Net	95.84±0.27
	● STBP	7B-Net	96.88±0.28

*: 在原结构^[61]基础上修改。

†: 复现结果。

第3章 自然范式下时间条件计算的生成式脉冲神经网络研究

开发神经响应的计算模型对于理解感官处理和神经计算至关重要。目前最先进的基于神经网络的方法常使用时间滤波器来处理时间依赖性，导致了一种不切实际和不灵活的处理范式。同时，现有的研究通常只针对通过试验平均计算的脉冲发放率统计信息，因而无法捕获脉冲序列中的重要特征。本章介绍了时间调节的脉冲隐变量模型来模拟初级视觉神经系统对自然刺激的响应。该方法使用基于脉冲神经元的网络模型以直接输出与真实记录的神经活动相匹配的脉冲序列。这种方法有助于避免丢失原始脉冲序列中嵌入的信息。本章方法从模型参数空间中完全排除了时间维度，并引入了一种时间调节操作，将时间感受野转移到模型内部表征空间，使模型能够在自然范式下自适应地探索和利用刺激序列中的时间依赖性。

本章通过实验展示了上述模型可以产生更真实的脉冲活动，并比强大的替代方案更准确地拟合脉冲统计数据。此外，短序列上学习到的模型可以很好地推广到更长的时间尺度。总的来说，在保持计算可行性的同时，本章介绍的模型更为有效地捕获了神经编码系统的关键特征，从而为构建各种感知电路的准确预测的计算替代物提供了一个有用的工具。

3.1 本章引言

构建精确的自然视觉刺激的神经反应计算模型是感官神经科学中的一个基本科学问题。这些计算模型可以提供对神经环路计算过程的深入理解，揭示新的计算机制，或是验证理论预测^[139-144]。然而，由于神经编码涉及到诸多复杂的非线性过程，例如非线性的突触传输函数和多变的膜电压动力学，构建这样的模型十分具有挑战性。具体到针对于视网膜对自然刺激反应的计算建模，早期工作中使用的使用线性-非线性（Linear-Nonlinear, LN）模型和广义线性模型（Generalized Linear Model, GLM）的尝试在处理如白噪声这样的简单输入时取得了一定的效果^[140,145]，但在处理更复杂的刺激，例如自然的视觉刺激时却效果不佳^[146-147]。

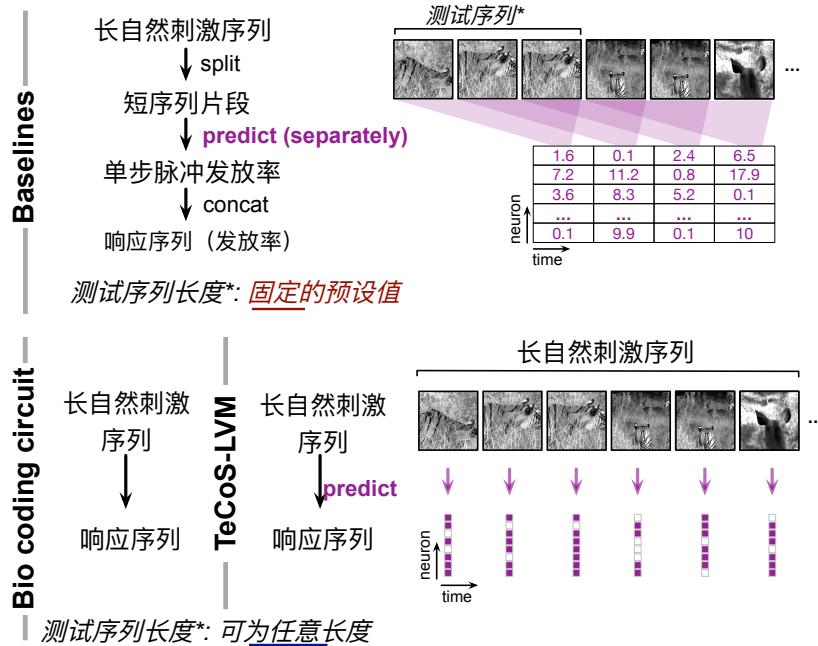


图 3-1 自然时间序列处理范式图示。

ANN 作为强大的函数逼近器，在一定程度上有着类似于生物神经元和神经环路架构的计算结构^[148-149]，因而已有大量工作通过涉及基于 ANN 的方法建模视觉刺激编码过程，并取得了不错的效果^[147,150-153]。最近的理论研究表明，复杂、高维的神经活动可以在低维空间中得到很好的表示^[154-155]。这引发了人们对细分类型 ANN——隐变量模型（LVM）的兴趣。LVM 在模型预测准确性和内部表征（隐变量）空间的简洁性之间取得了微妙的平衡，使得模型不但能够准确地建模神经编码过程，同时还能在低维表征空间中解耦、分析神经活动^[156-162]。总而言之，尽管已有的先进的视觉神经编码 ANN 模型已经取得了不错的成绩，并提供了一些令人兴奋的见解，然而它们存在两个共性的问题。

首先，大部分的研究都聚焦于如何模拟真实神经元的发放率指标。当考虑常规的人工神经网络模型时，这不失为一个合理的选择（遵循经典的泊松 LN/GLM 模型）。然而，作为一种试验平均的脉冲统计量，发放率只能描述原始脉冲序列的部分信息^[85]，即某一时间分辨率/尺度下的平滑后的脉冲活动情况。因此，直接使用发放率作为目标会丢失原始脉冲序列中的信息^[163-164]。其二是，现有的模型大多采用固定长度的时间滤波器来部分地处理输入序列的时序依赖。举例来说，CNN 方法^[147]就是将固定长度时间内的刺激序列作为模型输入并使用相应的时间滤波器来进行处理。在这种模式下，现有方法

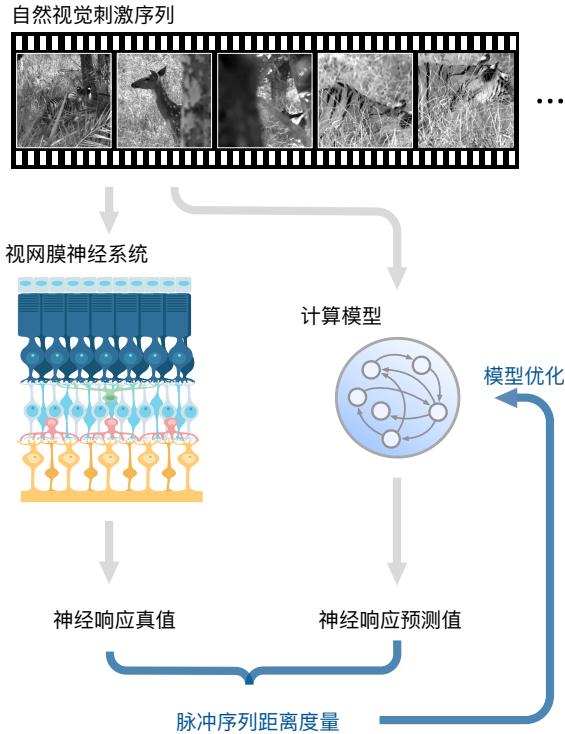


图 3-2 自然视觉刺激下视网膜神经响应的计算建模过程简图。

似乎难以像真实的神经环路一样直接处理长刺激序列（单纯通过迭代来遍历时间维度）。相反，它们必须将长序列划分成固定长度的较短片段再进行分别处理，从而失去了一定的生物现实性（参见图 3-1）。其次，在计算模拟中，在训练数据上学习的模型只能接受与训练阶段相同长度的切分输入，从而限制了它们的灵活性，也使得这一处理过程的多时间尺度性质变得难以分析。

尽管上述两点对于生物合理的计算模型而言是重要的属性，但就目前而言，仍然缺乏一种能够解决上述问题的方法。本章介绍了时间调节脉冲隐变量模型（Temporal Conditioning Spiking LVM, TeCoS-LVM），用于模拟神经对自然视觉刺激的反应。该方法中主要采用脉冲神经元，以使得模型能够直接以产生真实的脉冲序列为目，从而避免在目标脉冲统计过程中发生的脉冲信息损失。其次，本章介绍的方法完全排除了计算模型参数空间中的时间维度，并引入了一个时间调节操作来处理长序列的时序依赖性。此外，受到生物编码系统中的信息压缩机制的启发，本章的研究在隐变量模型的信息瓶颈框架内进行形式化，并推导了本章模型的通用学习方法。在真实的神经记录数据上的系统性的评估表明，本章介绍的 TeCoS-LVM 模型能够准确地拟合脉冲统计并产生真实的脉冲活动。而进一步的实验分析表明，在短序列上的学习的本章模型可以很好地推广到

更长的时间尺度 (Train Short, Test Long)，并展示出与生物认知电路中的机制类似的记忆特性。

本章的研究建立在早期对视觉场景的神经反应建模研究的基础之上。正如前文中已提到的，早期的尝试包括线性-非线性 (LN)^[165-166] 和广义线性模型 (GLM)^[140,145]。然而，这些简单模型的拟合能力有限，在面对更复杂的刺激时会失败^[146-147]。一个颇有前景的方向是借助于强大的人工神经网络，这种技术路线的一个显著的优点是，它或许能够完全避免基于知识的强先验的必要性，从而降低对未知神经环路的建模难度。McIntosh 等^[147] 提出了一种基于 CNN 的方法，该方法在很大程度上优于 LN 和 GLM 基线。亦有研究人员也考虑了带有循环层的 CNN 变体^[147,153]。Batty 等^[150] 提出了一种混合模型，该模型结合了 GLM 和循环神经网络，以便分离并实现神经编码中的空间和时间处理组件。本章介绍的方法也包含处理时间维度的指定结构，但在本章方法中，时间和空间处理是紧密集成的（后续章节中会对此种做法的优点进行深入研究）。生成对抗网络 (GAN) 也被用来合成真实的神经响应活动^[152]，然而这种方法却不能直接用于预测给定刺激下的神经响应。Mahuas 等^[167] 引入了一种新的两步策略来改进基本的 GLM 方法并取得了一定的收益。Bellec 等^[168] 引入了一个带有脉冲反应模型 (SRM) 神经元的模型，并在传统的泊松似然目标外提出了一个度量项用以帮助模型优化。最近，Rahmani 等^[159] 将高斯过程先验和变分信息瓶颈理论引入到 LVM 中，用于建模视网膜反应。

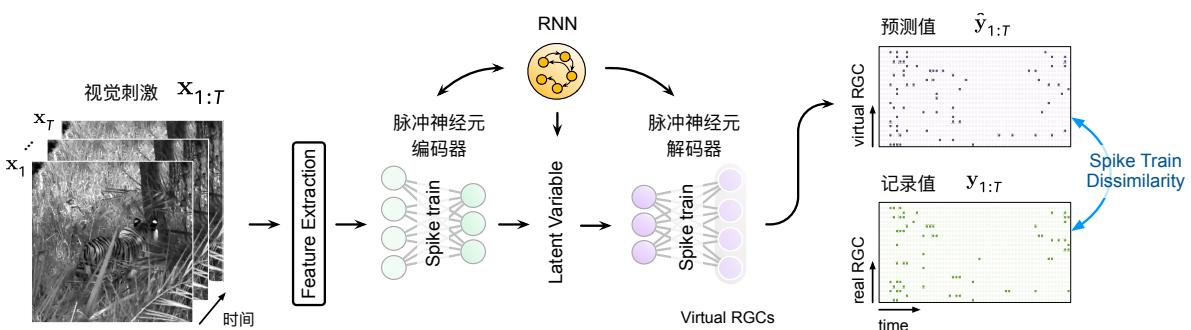


图 3-3 自然视觉刺激下视网膜神经响应的 TeCoS-LVM 模型的图形说明。

3.2 研究方法

本章研究沿用了上一章中对脉冲神经模型研究的基础设定，并采用了 LIF 神经元模型，该模型描述的亚阈值膜电位动态在本章中如下表示：

$$\tau_m \frac{du}{dt} = -(u - u_{\text{reset}}) + RI(t), \quad (3-1)$$

与上一章相同地，其中 u_t 表示膜电位， R, τ_m 是膜电阻，时间常数， I 是输入电流。 $v_{\text{th}}, u_{\text{reset}}$ 分别表示发放阈值，静息电位。在实践中，它导致以下离散时间计算形式^[42,45,63] $u_t = \tau u_{t-1} + I_t; o_t = \text{Heaviside}(u_t - v_{\text{th}}); u_t = u_{\text{reset}}$ 当 $o_t = 1$ ，其中， o_t 是脉冲输出， I_t 是输入电流，通常由参数化映射转换， τ 是膜时间常数。在这种离散形式中，膜常数 τ_m 与时间步长 dt 合并以简化，因为在本章所有的实验中，模拟时间步长 dt 是固定的。本章延续上一章的假设，亦即 $v_{\text{th}} = 1, \tau = 0.5$ 是固定常数。对于本章研究中的所有神经元， $u_{\text{reset}} = 0$ 。

隐变量模型 隐变量模型是研究和建模神经反应的常用工具^[156-157,169]，尤其近几年该方向的涌现了诸多高质量的成果。使用该类模型背后的逻辑是，根据早期的神经科学的研究，低维隐变量足以有效地表示高维神经活动^[154-155]。而在最近的工作中，隐变量模型在揭示运动区复杂神经活动的低维结构方面展示了喜人的结果^[158,160-161]。除此之外，隐变量模型在视觉神经编码建模方面也显示出前景^[156-157,159]。

条件化操作 条件化是一种有效的可以整合多源信息并实现自适应的门控的技术手段。通常意义上的条件化主要依赖于外部信息源，如标签^[170] 或是其他模型的输出^[171-173]。而一些研究已经证明，直接对先前的状态进行条件化也可以显著提高性能，特别是在序列处理模式中^[174-176]；这些方法通常被称为自条件化或时间条件化。值得注意的是，本章中介绍的时间条件设计灵感来源于 Tolman-Eichenbaum Machine^[174]，其中的时间条件操作确保了模型能够从序列学习的范式中获得收益。

变分信息瓶颈理论框架 信息瓶颈^[177] 提供了一个与 LVM 天然契合的理论框架。简而言之，在此理论的假设下，一个理想的 LVM 应该具有关于其目标的最大的表达性，同

时对其输入有着最大压缩度的隐变量表征。具体而言，本章考虑一个具有输入 \mathbf{x} ，目标 \mathbf{y} ，和由参数编码器 $q(\mathbf{z}|\mathbf{x}; \boldsymbol{\theta})$ 定义的隐变量 \mathbf{z} 的 LVM 模型 $\boldsymbol{\theta}$ 。让 $I(\mathbf{z}, \mathbf{y}; \boldsymbol{\theta})$ 是 \mathbf{z} 和 \mathbf{y} 之间的互信息， $I(\mathbf{z}, \mathbf{x}; \boldsymbol{\theta})$ 是 \mathbf{z} 和 \mathbf{x} 之间的互信息，IB 定义了上述模型的目标

$$\max_{\boldsymbol{\theta}} I(\mathbf{z}, \mathbf{y}; \boldsymbol{\theta}) \text{ s.t. } I(\mathbf{z}, \mathbf{x}; \boldsymbol{\theta}) < I_c, \quad (3-2)$$

其中 I_c 是信息约束项。进一步地，引入拉格朗日乘数 β （广义拉格朗日乘子法^[177]），上述的 IB 目标即等价于

$$\max_{\boldsymbol{\theta}} [I(\mathbf{z}, \mathbf{y}; \boldsymbol{\theta}) - \beta I(\mathbf{z}, \mathbf{x}; \boldsymbol{\theta})]. \quad (3-3)$$

变分 IB^[178-179]则是利用变分推断（Variational Inference, VI）技术来构造实现式 3-3 中 IB 目标的下界。首先假设因子化 $p(\mathbf{x}, \mathbf{y}, \mathbf{z}) = p(\mathbf{z}|\mathbf{x})p(\mathbf{y}|\mathbf{z})p(\mathbf{x})$ 成立，则能够得到包含一个预测项和一个压缩项的等价目标（具体过程见本章后文）如下：

$$\min_{\boldsymbol{\theta}} \underbrace{\mathbb{E}_{q(\mathbf{z}|\mathbf{x}; \boldsymbol{\theta})}[-\log p(\mathbf{y}|\mathbf{z}; \boldsymbol{\theta})]}_{\mathcal{L}^{\text{pred}}: \text{鼓励预测能力}} + \beta \cdot \underbrace{\text{KL}[q(\mathbf{z}|\mathbf{x}; \boldsymbol{\theta})||p(\mathbf{z})]}_{\mathcal{L}^{\text{comp}}: \text{鼓励压缩性}}, \quad (3-4)$$

其中 $\text{KL}[Q||P]$ 是两个概率分布之间的 Kullback-Leibler 散度， $p(\mathbf{y}|\mathbf{z}; \boldsymbol{\theta})$ 是一个参数化的解码器。通常，先验 $p(\mathbf{z})$ 是一个高斯分布 $\mathcal{N}(\boldsymbol{\mu}, \text{diag}(\boldsymbol{\sigma}^2))$ ^[180-181]。上述的变分编码器 $q(\mathbf{z}|\mathbf{x}; \boldsymbol{\theta})$ 和解码器 $p(\mathbf{y}|\mathbf{z}; \boldsymbol{\theta})$ 通过最小化式 3-4 来共同优化参数。

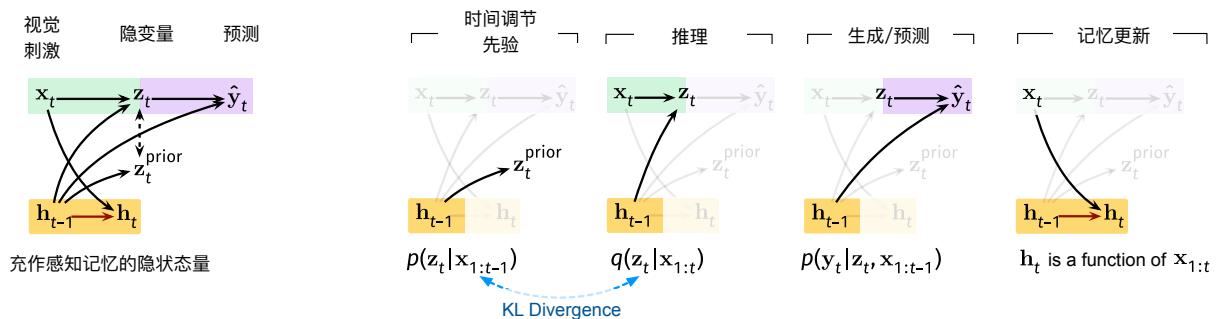


图 3-4 本章方法的计算操作图示。

本章研究基本设定 本章的研究中，将一系列连续的视觉刺激记为 $\mathbf{x} = (\mathbf{x}_t)_{t=1 \dots T}$ ，其中 $\mathbf{x}_t \in \mathbb{R}^{\dim[\mathbf{x}_t]}$ ， $\dim[\mathbf{x}_t]$ 表示 \mathbf{x}_t 的维度。同样，将神经元群体的反应（亦即本章研究的

预测目标) 记为 $\mathbf{y} = (\mathbf{y}_t) \in \{0, 1\}^{T \times \dim[\mathbf{y}_t]}$, 其中 $\dim[\mathbf{y}_t]$ 表示视网膜神经节细胞 (Retinal Ganglion Cells, RGCs) 的数量。在每个时刻 t , 接收到一个高维度的视觉刺激 \mathbf{x}_t , 本章希望预测神经元群体的反应 \mathbf{y}_t 。这是通过一个隐变量模型 (LVM) 实现的, 它首先将视觉刺激压缩成一个低维度的潜在表示 $\mathbf{z}_t \in \mathbb{R}^{\dim[\mathbf{z}_t]}$, 然后从中解码神经元群体的反应。受到神经编码过程中的信息压缩机制 (高效编码理论) 的启发^[182-185]。进一步地, 本章希望这个 LVM 构建一个潜在表征空间, 其中 \mathbf{z} 对 \mathbf{y} 有最大的预测力, 同时对 \mathbf{x} 有最大的压缩性。因此, 本章模拟视觉刺激的神经编码的目标变成了在信息瓶颈 (Information Bottleneck, IB) 框架内的一个优化问题。事实上其他模态的刺激完全可以以类似的方式来处理, 但在本章的研究中主要以视觉系统的案例为实例。

然而, 由于刺激-神经反应建模中存在复杂的时间依赖性, 假设隐变量在时间维度上的独立性变得不切实际^[186-188]。为了解决这个问题, 本章介绍的方法在常规隐变量模型的先验、编码器和解码器中引入了一个额外的隐状态。这个隐状态自适应地、选择性地保留了早期的刺激信息^[189-190], 使得整个推理-生成过程能够基于整个刺激序列 $\mathbf{x}_{1:t}$, 而不仅仅是 \mathbf{x}_t 或时间窗口内的几个时刻。本章中, 为了能够适应性地利用和积累刺激序列中的时间依赖性, 本章采用了一个递归神经网络来更新该隐状态^[191-194]。具体而言, 这一过程可以如下描述

$$\mathbf{h}_t = f_{\text{RNN}}(\mathbf{x}_t, \mathbf{h}_{t-1}). \quad (3-5)$$

这里的隐状态充当了感官记忆^[195], 即采用了类似于 Tolman-Eichenbaum Machine^[174]的方式, 这一工作采用了一个吸引子网络模型来实现存储和检索记忆。需要指出, 由于本章的研究主要关注的是高维的视觉刺激, 因此本章使用了一个脉冲卷积特征提取器来降低刺激的维度。这一特征提取部分在隐状态更新和时间条件编码器推理过程中是共享的。为了使本章的记号更简单易读, 本章在形式化中并没有明确标示特征提取器 (即实际使用特征计算, 但仍标记为原始刺激输入 \mathbf{x})。类似地, 编码器不仅是 \mathbf{x}_t 的函数, 也是 \mathbf{h}_{t-1} 的函数。根据式 3-5, 隐状态 \mathbf{h}_{t-1} 是 $\mathbf{x}_{1:t-1}$ 的函数。因此, 时间条件编码器定义了分布 $q(\mathbf{z}_t | \mathbf{x}_{1:t})$, 即

$$q(\mathbf{z}_t | \mathbf{x}_{1:t}) = \mathcal{N}\left(\mathbf{z}_t; \psi^{\text{enc}}(\mathbf{x}_t, \mathbf{h}_{t-1}), \text{diag}(\psi^{\text{enc}}(\mathbf{x}_t, \mathbf{h}_{t-1}))\right), \quad (3-6)$$

其中, ψ^{enc} 是用于计算变分后验分布的参数模型, 也是一个脉冲神经元 MLP。解码器仅

使用隐表示 \mathbf{z}_t 和隐状态 \mathbf{h}_{t-1} 作为输入来生成神经群响应 \mathbf{y}_t 。由于隐状态是先前刺激序列的函数，该解码器事实上定义了分布

$$p(\mathbf{y}_t | \mathbf{z}_t, \mathbf{x}_{1:t-1}; \psi^{\text{dec}}),$$

其中 ψ^{dec} 代表解码器的可学习参数。由于本章方法使用脉冲神经元，解码器将直接输出模拟记录的神经群体响应的脉冲序列。

TeCoS-LVM 模型被优化以最小化损失函数（式 3-4），其形式为：

$$\mathcal{L} = \mathcal{L}^{\text{pred}} + \beta \mathcal{L}^{\text{comp}}, \quad (3-7)$$

所有突触权重在学习过程中共同优化。接下来介绍这一目标的推导过程。

基于先前的 IB 研究^[177-179]，假设联合分布的分解如下，

$$\begin{aligned} p(\mathbf{x}, \mathbf{y}, \mathbf{z}) &= p(\mathbf{z} | \mathbf{x}, \mathbf{y}) p(\mathbf{y} | \mathbf{x}) p(\mathbf{x}) \\ &= p(\mathbf{z} | \mathbf{x}) p(\mathbf{y} | \mathbf{x}) p(\mathbf{x}), \end{aligned} \quad (3-8)$$

亦即，假设一个马尔可夫链 $\mathbf{y} \leftrightarrow \mathbf{x} \leftrightarrow \mathbf{z}$ 成立。这意味着 $p(\mathbf{z} | \mathbf{x}, \mathbf{y}) = p(\mathbf{z} | \mathbf{x})$ ，表明隐变量 \mathbf{z} 不直接依赖于预测目标（神经响应） \mathbf{y} 。根据 IB 原则^[177]，本章方法的优化目标具有以下形式

$$\max \underbrace{[I(\mathbf{z}, \mathbf{y})]}_{\text{预测项}} - \underbrace{\beta I(\mathbf{z}, \mathbf{x})}_{\text{压缩项}}. \quad (3-9)$$

预测项鼓励预测能力，而压缩项强制信息压缩。并且它等价于最小化损失函数 $-I(\mathbf{z}, \mathbf{y}) + \beta I(\mathbf{z}, \mathbf{x})$ 。

首先考虑预测项 $I(\mathbf{z}, \mathbf{y})$ 。 \mathbf{z} 和 \mathbf{y} 之间的互信息为

$$\begin{aligned} I(\mathbf{z}, \mathbf{y}) &= \int d\mathbf{y} d\mathbf{z} p(\mathbf{y}, \mathbf{z}) \log \frac{p(\mathbf{y}, \mathbf{z})}{p(\mathbf{y})p(\mathbf{z})} \\ &= \int d\mathbf{y} d\mathbf{z} p(\mathbf{y}, \mathbf{z}) \log \frac{p(\mathbf{y} | \mathbf{z})}{p(\mathbf{y})} \end{aligned} \quad (3-10)$$

根据先前假设的马尔可夫链关系(式3-8),似然函数 $p(\mathbf{y}|\mathbf{z})$ 为

$$\begin{aligned} p(\mathbf{y}|\mathbf{z}) &= \int d\mathbf{x} p(\mathbf{x}, \mathbf{y}|\mathbf{z}) \\ &= \int d\mathbf{x} p(\mathbf{y}|\mathbf{x}) p(\mathbf{x}|\mathbf{z}) \\ &= \int d\mathbf{x} p(\mathbf{y}|\mathbf{x}) \frac{p(\mathbf{z}|\mathbf{x}) p(\mathbf{x})}{p(\mathbf{z})}, \end{aligned} \quad (3-11)$$

并且在本章研究的范畴内,由一个参数化的变分解码器 $p(\mathbf{y}|\mathbf{z}; \psi^{\text{dec}})$ 近似。鉴于

$$\text{KL}[p(\mathbf{y}|\mathbf{z}) \| p(\mathbf{y}|\mathbf{z}; \psi^{\text{dec}})] \geq 0$$

可知

$$\begin{aligned} \int d\mathbf{y} p(\mathbf{y}|\mathbf{z}) \log \frac{p(\mathbf{y}|\mathbf{z})}{p(\mathbf{y}|\mathbf{z}, \psi^{\text{dec}})} &\geq 0 \\ \Rightarrow \int d\mathbf{y} p(\mathbf{y}|\mathbf{z}) \log p(\mathbf{y}|\mathbf{z}) &\geq \int d\mathbf{y} p(\mathbf{y}|\mathbf{z}) \log p(\mathbf{y}|\mathbf{z}; \psi^{\text{dec}}) \end{aligned} \quad (3-12)$$

因此有

$$\begin{aligned} I(\mathbf{z}, \mathbf{y}) &\geq \int d\mathbf{y} d\mathbf{z} p(\mathbf{y}, \mathbf{z}) \log \frac{p(\mathbf{y}|\mathbf{z}; \psi^{\text{dec}})}{p(\mathbf{y})} \\ &= \int d\mathbf{y} d\mathbf{z} p(\mathbf{y}, \mathbf{z}) \log p(\mathbf{y}|\mathbf{z}; \psi^{\text{dec}}) + H(\mathbf{y}) \end{aligned} \quad (3-13)$$

由于目标信息熵 $H(\mathbf{y})$ 与参数模型的参数优化过程无关,因此可以暂时予以忽略。因此,

$$\max I(\mathbf{z}, \mathbf{y}) = \max \int d\mathbf{y} d\mathbf{z} p(\mathbf{y}, \mathbf{z}) \log p(\mathbf{y}|\mathbf{z}; \psi^{\text{dec}})$$

由式3-8,

$$p(\mathbf{y}, \mathbf{z}) = \int d\mathbf{x} p(\mathbf{x}) p(\mathbf{y}|\mathbf{x}) p(\mathbf{z}|\mathbf{x}),$$

因此,

$$\max I(\mathbf{z}, \mathbf{y}) = \max \int d\mathbf{x} d\mathbf{y} d\mathbf{z} p(\mathbf{x}) p(\mathbf{y}|\mathbf{x}) p(\mathbf{z}|\mathbf{x}) \log p(\mathbf{y}|\mathbf{z}; \psi^{\text{dec}}). \quad (3-14)$$

现在继续考虑目标(式3-9)中的压缩项 $\beta I(\mathbf{z}, \mathbf{x})$, 并且暂时搁置常数因子 β 。输入刺激和隐变量之间的互信息由下式给出

$$\begin{aligned} I(\mathbf{z}, \mathbf{x}) &= \int d\mathbf{x}d\mathbf{z} p(\mathbf{x}, \mathbf{z}) \log \frac{p(\mathbf{z}|\mathbf{x})}{p(\mathbf{z})} \\ &= \int d\mathbf{x}d\mathbf{z} p(\mathbf{x}, \mathbf{z}) \log p(\mathbf{z}|\mathbf{x}) - \int d\mathbf{z} p(\mathbf{z}) \log p(\mathbf{z}) \end{aligned} \quad (3-15)$$

记 $p(\mathbf{z}; \phi^{\text{prior}})$ 为边缘分布 $p(\mathbf{z})$ 的变分近似, 由于 $\text{KL}[p(\mathbf{z}) \| p(\mathbf{z}; \phi^{\text{prior}})] \geq 0$, 有

$$\int d\mathbf{z} p(\mathbf{z}) \log p(\mathbf{z}) \geq \int d\mathbf{z} p(\mathbf{z}) \log p(\mathbf{z}; \phi^{\text{prior}}) \quad (3-16)$$

借助式3-15并使用参数化的编码器 $q(\mathbf{z}|\mathbf{x}; \psi^{\text{enc}})$, 可以推知以下上界:

$$I(\mathbf{z}, \mathbf{x}) \leq \int d\mathbf{x}d\mathbf{z} p(\mathbf{x}) q(\mathbf{z}|\mathbf{x}; \psi^{\text{enc}}) \log \frac{q(\mathbf{z}|\mathbf{x}; \psi^{\text{enc}})}{p(\mathbf{z}; \phi^{\text{prior}})} \quad (3-17)$$

根据式3-14和式3-17, 可以得到信息瓶颈框架下模型优化目标的下界,

$$\begin{aligned} I(\mathbf{z}, \mathbf{y}) - \beta I(\mathbf{z}, \mathbf{x}) &\geq \int d\mathbf{x}d\mathbf{y}d\mathbf{z} p(\mathbf{x}) p(\mathbf{y}|\mathbf{x}) q(\mathbf{z}|\mathbf{x}; \psi^{\text{enc}}) \log p(\mathbf{y}|\mathbf{z}; \psi^{\text{dec}}) \\ &\quad - \beta \int d\mathbf{x}d\mathbf{z} p(\mathbf{x}) q(\mathbf{z}|\mathbf{x}; \psi^{\text{enc}}) \log \frac{q(\mathbf{z}|\mathbf{x}; \psi^{\text{enc}})}{p(\mathbf{z}; \phi^{\text{prior}})} \end{aligned} \quad (3-18)$$

这里使用 $\boldsymbol{\theta}$ 来表示模型的所有参数($\phi^{\text{prior}}, \psi^{\text{enc}}, \psi^{\text{dec}}$ 以及其他可学习参数, 比如特征提取器的参数), 有

$$\max_{\boldsymbol{\theta}} [I(\mathbf{z}, \mathbf{y}; \boldsymbol{\theta}) - \beta I(\mathbf{z}, \mathbf{x}; \boldsymbol{\theta})] = \min_{\boldsymbol{\theta}} \mathcal{L}, \quad (3-19)$$

其中

$$\begin{aligned} \mathcal{L} &= - \underbrace{\int d\mathbf{x}d\mathbf{y}d\mathbf{z} p(\mathbf{x}) p(\mathbf{y}|\mathbf{x}) q(\mathbf{z}|\mathbf{x}; \psi^{\text{enc}}) \log p(\mathbf{y}|\mathbf{z}; \psi^{\text{dec}})}_{\mathcal{L}^{\text{pred}}: \text{鼓励预测能力}} \\ &\quad + \beta \underbrace{\int d\mathbf{x}d\mathbf{z} p(\mathbf{x}) q(\mathbf{z}|\mathbf{x}; \psi^{\text{enc}}) \log \frac{q(\mathbf{z}|\mathbf{x}; \psi^{\text{enc}})}{p(\mathbf{z}; \phi^{\text{prior}})}}_{\mathcal{L}^{\text{comp}}: \text{鼓励信息压缩}} \end{aligned} \quad (3-20)$$

至此已经得到了本章研究中式 3-4 表示的优化目标。

接下来推导 TeCoS-LVM 模型在神经编码任务下的损失函数。根据之前的文献^[178]，可以使用经验数据分布 $\frac{1}{T} \sum_{t=1}^T \delta(\mathbf{x} - \mathbf{x}_{1:t})\delta(\mathbf{y} - \mathbf{y}_t)$ 来近似数据分布 $p(\mathbf{x}, \mathbf{y})$ ，其中 δ 是狄拉克 delta 函数。因此有

$$\begin{aligned} \mathcal{L} &\approx \frac{1}{T} \sum_{t=1}^T \left[\underbrace{\mathbb{E}_{q(\mathbf{z}_t | \mathbf{x}_{1:t}; \psi^{\text{enc}})}[-\log p(\mathbf{y}_t | \mathbf{z}_t; \psi^{\text{dec}})]}_{\mathcal{L}_t^{\text{pred}}} + \beta \underbrace{\text{KL}[q(\mathbf{z}_t | \mathbf{x}_{1:t}; \psi^{\text{enc}}) \| p(\mathbf{z}_t; \phi^{\text{prior}})]}_{\mathcal{L}_t^{\text{comp}}} \right] \\ &= \underbrace{\frac{1}{T} \sum_t \mathcal{L}_t^{\text{pred}}}_{\text{预测项 (总体): } \mathcal{L}^{\text{pred}}} + \beta \underbrace{\frac{1}{T} \sum_t \mathcal{L}_t^{\text{comp}}}_{\text{压缩项 (总体): } \mathcal{L}^{\text{comp}}} \end{aligned} \quad (3-21)$$

由于本章的时间条件先验和编码器中采用了高斯分布，可以解析地计算由 Kullback-Leibler 散度组成的压缩损失项 $\mathcal{L}^{\text{comp}}$ 。

进一步地，考虑目标函数（式 3-9）中的预测项。由于在视觉刺激编码任务中本章模型直接产生模拟的脉冲序列，本章通过计算预测序列 $\hat{\mathbf{y}}_{1:t}$ 和真实记录序列 $\mathbf{y}_{1:t}$ 之间的脉冲序列差异，来直接评估模型的预测能力。这种差异也被用作每个时间步的预测损失项。特别地，这里采用最大平均差异（Maximum Mean Discrepancy, MMD）来衡量脉冲序列之间的距离。这种方法已经在之前的文献中被证明尤其适用于脉冲序列^[163, 196]。

沿用早先研究^[196]的做法，本章使用突触后电位（Post-Synaptic Potential, PSP）核进行 MMD 计算。这里使用一阶模型作为 PSP 函数，以有效地捕获脉冲序列数据中的时间依赖性^[40]。本章中使用的 PSP 核函数可以写作

$$\kappa_{\text{PSP}}(\hat{\mathbf{y}}_{1:t}, \mathbf{y}_{1:t}) = \sum_{\tau=1}^t \text{PSP}(\hat{\mathbf{y}}_{1:\tau}) \text{PSP}(\mathbf{y}_{1:\tau}), \quad (3-22)$$

其中，

$$\text{PSP}(\mathbf{y}_{1:\tau}) = \left(1 - \frac{1}{\tau_s}\right) \text{PSP}(\mathbf{y}_{1:\tau-1}) + \frac{1}{\tau_s} \mathbf{y}_\tau, \quad (3-23)$$

这里 τ_s 是突触时间常数，默认设置为 2。进一步地，可以得到经验数据分布 (p) 和模

型预测分布 ($p_{\psi^{\text{dec}}}$) 之间的 (平方) PSP 核 MMD 距离为

$$\begin{aligned} & \text{MMD}\left[p_{\psi^{\text{dec}}}(\hat{\mathbf{y}}_{1:t}), p(\mathbf{y}_{1:t})\right]^2 \\ &= \sum_{\tau=1}^t \left\| \mathbb{E}_{\hat{\mathbf{y}}_{1:\tau} \sim p_{\psi^{\text{dec}}}} [\text{PSP}(\hat{\mathbf{y}}_{1:\tau})] - \mathbb{E}_{\mathbf{y}_{1:\tau} \sim p} [\text{PSP}(\mathbf{y}_{1:\tau})] \right\|^2 \end{aligned} \quad (3-24)$$

在实践中, 使用 $\sum_{\tau} \|\text{PSP}(\hat{\mathbf{y}}_{1:\tau}) - \text{PSP}(\mathbf{y}_{1:\tau})\|^2$ 来近似计算脉冲序列的差异^[196], 其由式 3-24 中的平方 PSP 核 MMD 来衡量。因此, 本章的自然视觉刺激编码任务中, 模型的预测损失项由

$$\mathcal{L}_t^{\text{pred}} = \sum_{\tau=1}^t \|\text{PSP}(\hat{\mathbf{y}}_{1:\tau}) - \text{PSP}(\mathbf{y}_{1:\tau})\|^2 \quad (3-25)$$

给出。与压缩项 $\mathcal{L}_t^{\text{comp}} = \text{KL}[q_{\psi^{\text{enc}}}(\mathbf{z}_t) \| p_{\phi^{\text{prior}}}(\mathbf{z}_t)]$ 一起, 通过式 3-21, 可以计算出总体的损失函数并优化本章介绍的 TeCoS-LVM 模型。为了允许直接通过随机模型的单次采样进行反向传播, 本章沿用了文献^[180]中介绍的重参数化技巧。

本章的后续实验将主要考虑两种类型的 TeCoS-LVM 的具体模型, 即 TeCoS-LVM 和 TeCoS-LVM Noisy, 这两种模型的情况如下。在 TeCoS-LVM 中, 所有的脉冲神经元都是 LIF 神经元。在 TeCoS-LVM Noisy 中, 所有的脉冲神经元都是 Noisy LIF 脉冲神经元^[197] (参见上一章内容)。脉冲神经元与内部噪声的研究在先前的文献中已经得到了广泛的研究^[85], 而最近的研究将它们扩展到更大的网络, 并从理论和实证上展示了它们的计算优势^[197]。使用 Noisy LIF 神经元使 TeCoS-LVM 具备了神经元级的决策随机性, 这被认为是生物神经计算的一个关键组成部分^[72,74-75]。特别地, Noisy LIF 神经元在膜电位水平上包含一个高斯噪声项 ϵ 。它的亚阈值动态由 $u_t = \tau u_{t-1} + I_t + \epsilon$ 给出, 而产生的发放机制由 $o_t \sim \text{Bernoulli}(F_{\epsilon}(u_t - v_{\text{th}}))$ 描述, 其中 F_{ϵ} 表示内部噪声的 CDF。

3.3 实验结果

3.3.1 实验数据

本章使用蝶螈视网膜上的真实神经记录数据进行本章方法的评估和性能分析。该数据集^[198]包含两个视网膜对两部电影的脉冲反应。对于视网膜 1, 有 75 次影片 1 的重复

实验和 107 次影片 2 的重复实验。对于视网膜 2，分别有 30 次和 42 次影片 1 和影片 2 的重复实验。影片 1 包含水缸中的蝾螈的自然场景，影片 2 包含森林中老虎捕猎的更为复杂的自然场景。两部影片的长度都约为 60 s，并被离散化为 33 ms 的区间。所有帧都被转换为灰度，其分辨率为 360×360 像素，则每像素对应 $7.5 \mu\text{m} \times 7.5 \mu\text{m}$ ，也就是覆盖视网膜上的 $2700 \mu\text{m} \times 2700 \mu\text{m}$ 区域。

本章将所有神经活动记录划分为 1 秒（30 个时间区间）的自然场景-神经响应样本对，并将所有帧降采样到 90×90 像素。这产生了四个本章中用于评估的数据集，每个数据集都被划分为不重复的训练/测试（50%/50%）部分。本章的后续内容将这四个数据集简记为以下名称。**影片 1 视网膜 1 (Mov1 Ret1)**：包含 38 个神经元对影片 1 (“Salamander Movie”) 的神经活动记录，包含 75 次重复实验。**影片 1 视网膜 2 (Mov1 Ret2)**：包含 49 个神经元对影片 1 的神经活动记录，包含 30 次重复实验。**影片 2 视网膜 1 (Mov2 Ret1)**：包含 38 个神经元对影片 2 (“Wildlife Movie”) 的神经活动记录，包含 107 次重复实验。**影片 2 视网膜 2 (Mov2 Ret2)**：包含 49 个神经元对影片 2 的神经活动记录，包含 42 次重复实验。



图 3-5 影片 1、影片 2 的示例帧。

3.3.2 评估指标与脉冲特征

皮尔逊相关系数 (Pearson CC, CC) 该指标通过计算记录的发放率和预测的发放率之间的皮尔逊相关系数来评估模型的性能^[147,152-153]。其值越高，则预测准确性越好。对于直接给出脉冲输出的 TeCoS-LVM 模型，其脉冲发放率是使用 20 次重复试验平均计算的。

脉冲序列差异度 (Spike Train Dissim.) 该指标通过计算记录的脉冲序列和预测的脉冲序列之间的不相似度来评估模型的性能，其值越低，代表模型性能越好。本章使用 MMD 和一阶 PSP 核^[40,131] 来测量脉冲序列的不相似度^[164,196,199]。一阶 PSP 函数由 $\text{PSP}(\mathbf{y}_{1:t}) = (1 - \frac{1}{\tau_s})\text{PSP}(\mathbf{y}_{1:t-1}) + \frac{1}{\tau_s}\mathbf{y}_t$ 给出，其中 τ_s 是突触常数，设为 2。给定一个记录的脉冲序列 $\mathbf{y}_{1:T}$ 和一个预测的脉冲序列 $\hat{\mathbf{y}}_{1:T}$ ，这个指标由 $\sum_{t=1}^T \|\text{PSP}(\mathbf{y}_{1:t}) - \text{PSP}(\hat{\mathbf{y}}_{1:t})\|^2$ 计算。由于神经活动的随机性，在评估中本章随机选择了十个（试验）记录的脉冲序列，并使用了它们的平均值。

van Rossum 距离 (van Rossum Dist.) 此种脉冲序列距离在参考文献^[200] 中被提出，其中离散的脉冲序列被一个指数核 $\text{Heaviside}(t) \exp(-t/\tau_R)$ 卷积，这里使用 $\tau_R = 10$ 。最终的分数是通过平均使用十个记录的脉冲序列计算的结果得到的。

Victor-Purpura 距离 (V.-P. Dist.) 这个脉冲序列距离^[201] 通过求和计算将一个脉冲序列转换为另一个脉冲序列的最小“成本”来衡量两个脉冲序列间的不相似度。其定义的转换操作包括插入、删除和移位几种。本章的实验中，采用十次试验的平均结果作为最终的指标。

SPIKE 距离 (SPIKE Dist.) SPIKE 距离^[202] 是一个相对于时间尺度独立的脉冲序列距离。其值在区间 $[0, 1]$ 内，只有对完全相同的序列才能得到零。与大多数其他脉冲序列距离（如 Victor-Purpura 距离）不同，该指标是时间解析的，并能够跟踪瞬时聚类的变化，即，两个或更多脉冲序列之间的时间局部化的不相似性模式。SPIKE 距离也可以被表述为一种因果测量，它被定义为瞬时不相似度的值只依赖于过去的信息，以便可以实时估计时间解析的脉冲序列同步性。

脉冲自相关性图 (Spike Autocorrelogram) 脉冲自相关性图是通过计算在预定义时间窗口内每个脉冲周围发生的脉冲数量来计算的^[147,152]。然后，所得的轨迹被归一化到其最大值（被构造为在时间轴的原点处出现）。在本章中，最大值被设为零，以便更好地进行可视化和比较。

对于 TeCoS-LVM 模型，所有数据集上的所有超参数都固定为相同。本章默认将隐变量维度设置为 32，隐藏状态维度设置为 64。本章中使用 Adam 优化器 ($\beta_1 = 0.9, \beta_2 =$

0.999)，其学习率遵循余弦衰减策略且初始值 0.0003，批大小为 64。所有上述模型的训练进行了 64 个周期。这里使用相同的网络结构来实现所有的 TeCoS-LVM 模型（表 3-2）。对于 LIF 神经元 TeCoS-LVM 模型（记为 TeCoS-LVM），本章使用了 ERF 替代梯度的替代梯度学习 (SGL) $\text{SG}_{\text{ERF}}(x) = \frac{1}{\sqrt{\pi}} \exp(-x^2)$ 。对于 Noisy LIF 神经元 TeCoS-LVM 模型（记为 TeCoS-LVM Noisy），本章使用了高斯噪声 $\mathcal{N}(\epsilon; 0, 0.2^2)$ 和相应的噪声驱动学习，这在前一章中有详细的介绍，此处不再赘述。由于本章的模型涉及到随机潜在变量，这里同样采用了重参数化技巧以进行高效训练。本章考虑的高性能的 CNN, IB 基线方法均遵循了其（CNN^[147,153] 和 IB-Disjoint^[159]）原始实现中的设置。这些基线方法的部分设置利用了脉冲发放率的先验统计结构信息，从而事实上有利于这些模型的性能指标^[147]。特别地，CNN 模型在训练中对神经网络注入了高斯噪声，且对模型参数进行了 L-2 范数正则化 (0.001)，此外还对预测的激活进行了 L1 范数正则化 (0.001)^[147,153]。而 IB-Disjoint 模型使用了 $\beta = 0.01$ 进行优化，该设定被证明可以提高预测能力^[159]。本章也为 IB-Disjoint 模型使用了重参数化技巧进行高效训练。本章为基线模型使用了常数学习率 0.001，批大小 64，和默认的 Adam 优化器。遵循他们的原始实现，本章在实验过程中使用了提前停止 (Early Stop) 技术。

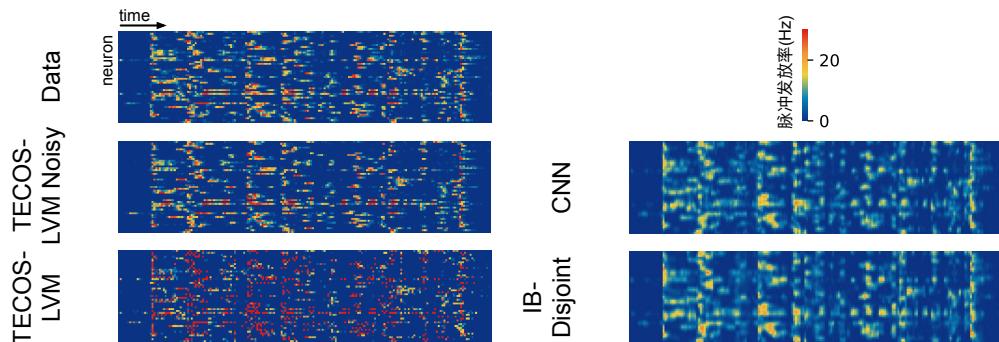


图 3-6 脉冲发放率预测结果可视化。

如图 3-6 和图 3-7 所示，TeCoS-LVM 模型可以有效地拟合记录的神经元真实脉冲发放率。特别地，TeCoS-LVM Noisy 比基线模型更准确地预测了真实的发放率。此外，该部分实验证了使用试验平均统计数据作为优化目标可能导致的潜在信息损失。虽然发放率目标可能允许模型学习粗粒度特征，但并不一定能最优地捕获如脉冲自相关等细粒度的神经活动特征。如图 3-8 的脉冲发放自相关性拟合结果所示，两种基线模型均未能准确捕获脉冲自相关特征。相比之下，TeCoS-LVM 模型更精确地再现了真实神经活

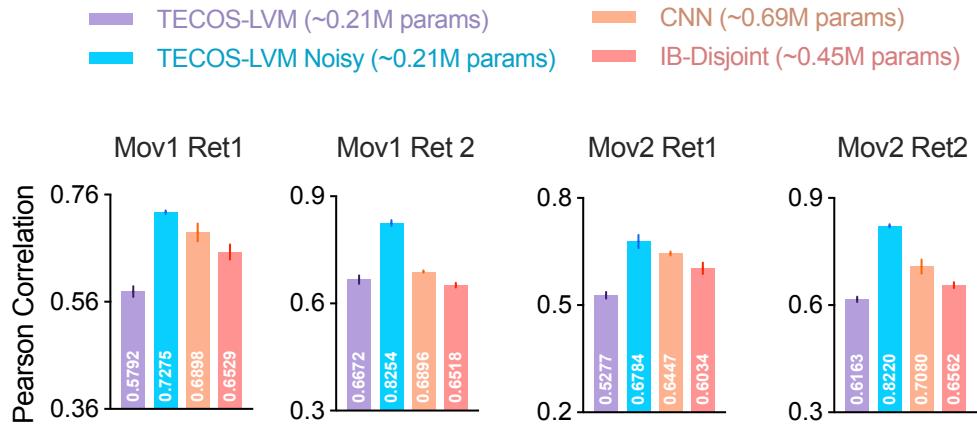


图 3-7 脉冲发放率预测结果定量对比。

动数据的脉冲自相关性。此外，TeCoS-LVM 模型在合成更真实的脉冲活动方面也显著地优于其他模型（见图 3-9）。本章的结果表明，TeCoS-LVM 模型可以准确地拟合真实的脉冲活动和统计数据。特别是，TeCoS-LVM Noisy 模型在所有指标上都显著优于基线模型。

本章还注意到，包括神经元噪声对于建模神经活动是十分重要的。由于神经元级别的随机性的缺失，TeCoS-LVM 模型无法再现真实神经活动的试验间变异性（见图 3-10）。因此，如图 3-7 所示，TeCoS-LVM 的发放率预测（通过对多次运行进行平均得到）相较于其他模型的预测平滑度更低，这对发放率相关性指标造成了负面影响。这也解释了 TeCoS-LVM 在某些数据上（图 3-11 中的 Movie 1 Retina 2, Movie 2 Retina 2）获得了较低的脉冲序列差异，但在发放率指标（图 3-8）方面仍然落后于其他方法的原因。

特别地，由于 TeCoS-LVM 模型通过优化以最小化 PSP 核空间中的预测序列与真实序列差异，使得它们在进行基于 PSP-MMD 的脉冲序列差异度评估时具有天然的优势。为了确保更公平地评估不同方法的脉冲序列预测性能，本章另外考虑了几种不同的脉冲序列距离。具体来说，本章计算了预测的脉冲序列与记录的脉冲序列之间的 van Rossum、Victor-Purpura 和 SPIKE 距离。这里观察到 TeCoS-LVM 模型在两个最先进的基线上有一致的和显著的改进，如表 3-1 中的结果所示。本章还注意到，当考虑这些脉冲序列距离时，受噪声扰动的神经动力学影响，TeCoS-LVM Noisy 的脉冲序列预测准确性指标有所下降，这与图 3-11 中的结果一致。然而，TeCoS-LVM Noisy 的整体性能大大超过了基线，并且更为重要的是，同时有效地再现了神经处理中的变异性特征。

由于 TeCoS-LVM 模型完全排除了参数空间中的时间维度，即单纯通过在时间维度

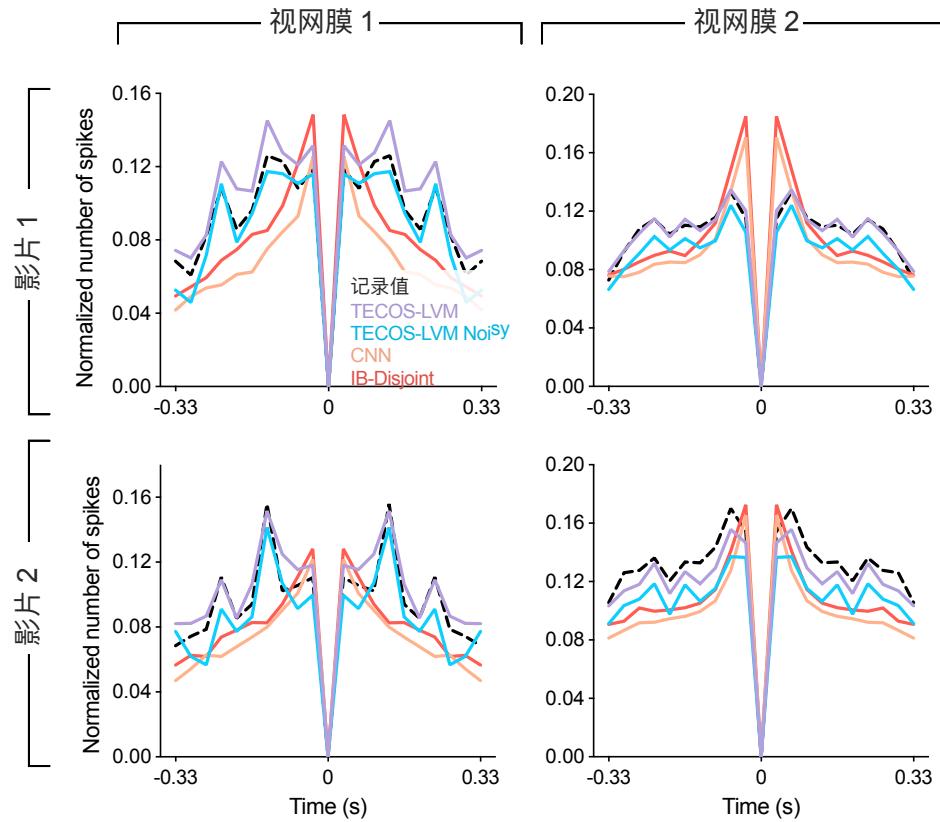


图 3-8 脉冲发放自相关性。

上迭代来处理时序，因此可以直接接受任意持续时长的输入刺激序列，而不受训练数据长度（本章中为 1 秒）的限制。本章通过在更长的测试数据序列上运行 TeCoS-LVM 模型来评估其时间尺度上的泛化性和可扩展性，并计算脉冲发放率相关系数和脉冲序列差异度来衡量其在此过程中的性能变化。本章实验表明 TeCoS-LVM 模型在不同的时间尺度上能够稳定输出准确的编码结果。图 3-12 中的结果表明，增加测试序列的长度只会导致轻微的性能下降。具体表现为发放率相关系数的略有下降以及脉冲序列差异度的些许增加。这表明本章介绍的 TeCoS-LVM 模型能够从短序列训练中学习了一般的（多时间尺度的）时间依赖性。

有趣的是，TeCoS-LVM 模型在初始化后的短时间内内的预测准确性较低，这可能是因为模型的感觉记忆需要时间来积累。本章观察到，隐藏状态的 L2 范数达到长序列上连续运行的平均值最多需要 0.5 秒（见图 3-13A）。因此，本章为所有的测试设置了 0.5 秒的预热期。本章进一步研究了 TeCoS-LVM 模型中的潜在的记忆机制，该机制主要通过隐藏状态更新的方式实现。为此，本章通过计算相邻自然刺激 (x_t 和 x_{t-1}) 的结构

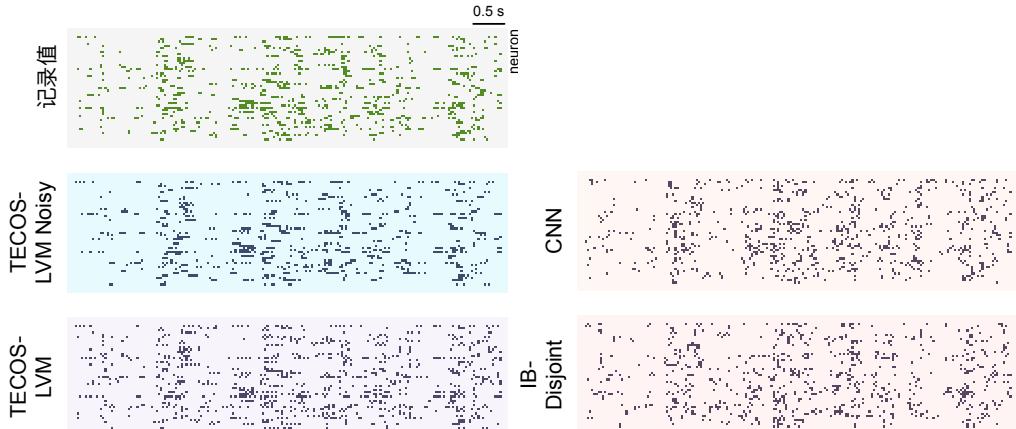


图 3-9 真实记录及模型预测的脉冲活动栅格图。

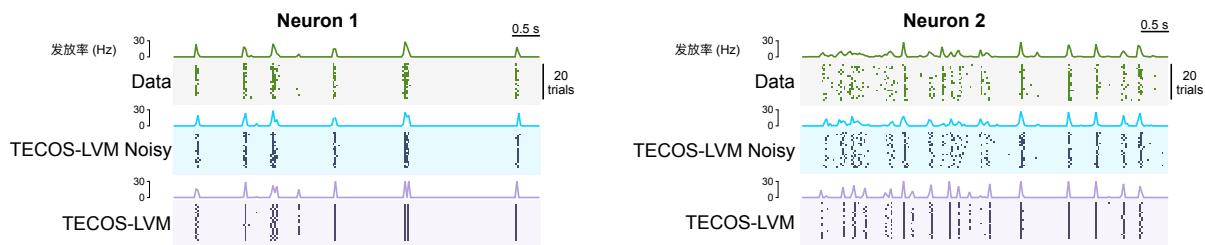


图 3-10 真实记录及模拟的脉冲活动变异性。

相似性 (Structural Similarity Index Measure, SSIM) 来量化自然刺激的变化程度。如果某一时刻自然场景的变化十分剧烈，那么这一时刻自然刺激与前一时刻自然刺激的 SSIM 就很低。对于感官神经系统来说，此种情况下其接收到的刺激是相当新颖或惊讶的^[203]。此外，本章还通过计算相邻隐藏状态向量 (\mathbf{h}_t 和 \mathbf{h}_{t-1}) 的余弦距离 (1—余弦相似度) 来衡量记忆向量更新的程度，即相似度更高表明更新幅度小，反之表示更新幅度更大。如图 3-13B, C 所示，这两者有着强烈的负相关。这表明，当面对高度动态的自然场景刺激 (SSIM 值更低) 时，TeCoS-LVM 模型会进行更显著的记忆更新 (由更大的余弦距离表示)；而当场景相对稳定时，只进行微小的更新。这与早期的感官神经科学实验的发现相吻合，即感官神经环路倾向于更关注不可预测或令人惊讶的事件。而当反复暴露于变化较小的外部刺激时，相关的神经处理过程则变得不那么活跃^[203-206]。

接下来，本章探索了在不同的权重因子 β 设置下的隐变量动态，适中的 β 值设定可以导致更丰富的隐变量空间动态，进而对于通过后续的相关性分析来解析它们与行为等因素的关系更友好。压缩损失项迫使隐变量趋向于最小充分统计量，以保留预测神经反

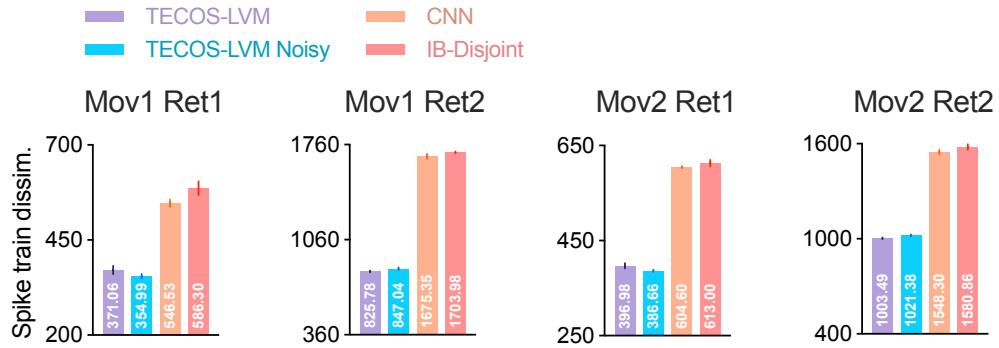


图 3-11 脉冲序列预测结果定量对比。

表 3-1 使用 SPIKE, Victor-Purpura 和 van Rossum 脉冲序列距离的评估结果。

度量类型	SPIKE	Victor-Purpura	van Rossum	SPIKE	V.-P.	van Rossum
模型 \ 数据	Movie1 Retina1			Movie1 Retina2		
TeCoS-LVM Noisy (This work)	0.155	14.024	238.614	0.116	21.599	425.871
TeCoS-LVM (This work)	0.124	12.835	127.346	0.111	18.182	150.445
McIntosh NeurIPS-16	0.207	19.601	376.822	0.220	39.168	2672.211
Rahmani NeurIPS-22	0.224	21.916	394.020	0.219	39.075	2276.706
模型 \ 数据	Movie2 Retina1			Movie2 Retina2		
TeCoS-LVM Noisy (This work)	0.162	14.412	553.510	0.153	28.441	1135.805
TeCoS-LVM (This work)	0.128	12.693	308.784	0.123	22.666	574.298
McIntosh NeurIPS-16	0.212	22.713	1650.823	0.221	39.261	2638.964
Rahmani NeurIPS-22	0.204	22.271	1615.934	0.221	38.378	2244.981

应的最紧致的特征空间结构。因此，极小的 β 取值对应于由压缩项提供的正则化效果很弱。在此种情况下，隐变量确定性更强（图 3-13E-左）。然而这也阻止了模型从压缩损失项带来的正则化中受益，导致其最终性能比适中取值的 β 的情况略逊（见图 3-13D）。而当使用较大的 β 取值时，隐变量时间依赖信息损失急剧增加，表现为近似于不变的隐变量空间动态（图 3-13E-右）。并且如果 β 取值进一步增加，模型特征空间将无法保留足够的自然刺激信息用于预测神经响应，从而导致预测性能急剧下降（图 3-13D）。另一方面，当 β 取值较大大时，模型更倾向于信息压缩而不是预测能力，即发生过度正则化。在这种情况下，隐变量随机性更强，方差值更大。

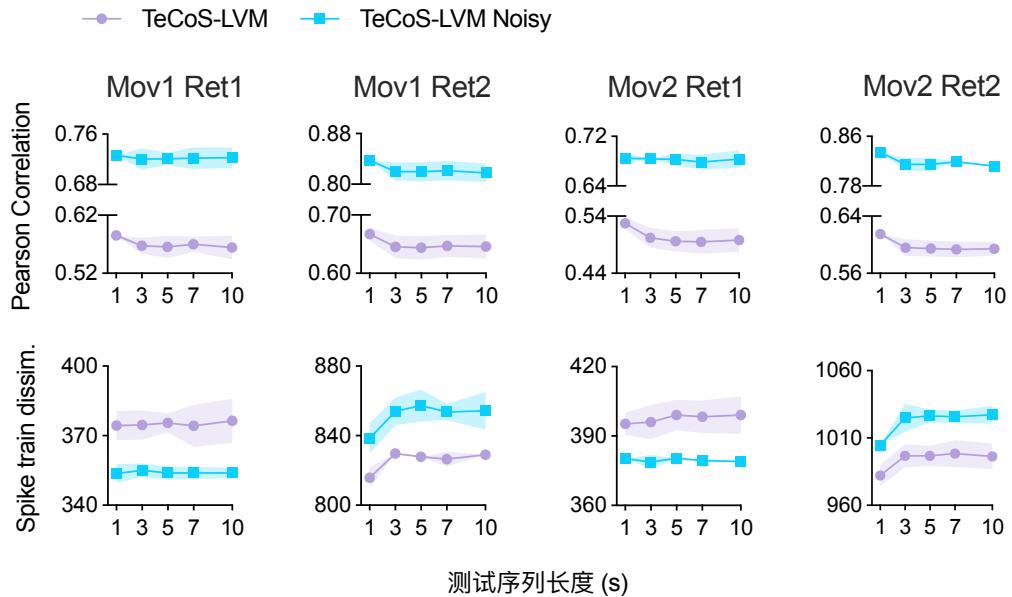


图 3-12 长测试序列的泛化性能实验结果

3.4 本章小结

本章的研究介绍了 TeCoS-LVM 模型。受到了高效编码理论的启发^[182,207]，本章将该方法在隐变量模型的信息瓶颈框架内进行了形式化。TeCoS-LVM 模型能够在自然时序处理范式下直接产生脉冲神经响应序列，而非多次产生单步预测，从而更真实地模拟了生物神经环路的编码过程。以自然场景刺激下的视网膜神经响应为例，本章展示了 TeCoS-LVM 模型在拟合脉冲统计量、脉冲特征和真实脉冲响应序列方面的优越性。尤其是结合了 Noisy LIF 神经元的 TeCoS-LVM 模型显著优于高性能基线方法。此外，短序列学习获得的 TeCoS-LVM 模型在更长的测试序列上表现出良好的泛化能力。这表明本章介绍的方法能够从较小的时间尺度的训练中学习到一般的时间特征。在后续的章节中，本文将在本章研究的基础之上进行拓展和延伸。尤其是本章的条件化计算范式、基于压缩-生成隐变量模型的建模方式都将在本文时空记忆的构建与计算脉冲生成式模型的研究中发挥重要作用。

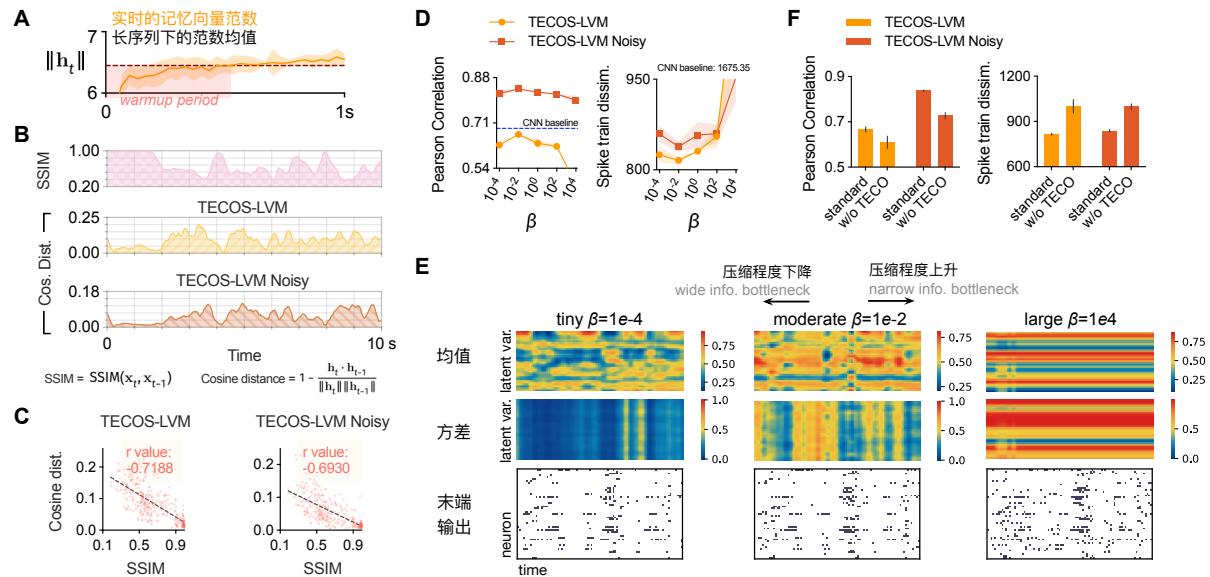


图 3-13 隐藏状态和隐变量空间动态的可视化。A. 模型初始化后，随时间推移 $\|\mathbf{h}_t\|$ 的演变。B. 相邻时刻自然刺激的 SSIM 变化和相邻时刻记忆向量的余弦距离曲线。C. 隐藏状态余弦距离和自然刺激 SSIM 值间的皮尔逊相关系数散点图。D. 不同的权重因子 β 下的模型性能。E. 使用不同 β 参数的 TeCoS-LVM Noisy 模型中的 \mathbf{z}_t 动态过程。F. 时间条件操作的有效性检验。增加了去除时间条件操作的模型的参数数量，使其大致与标准模型相当。

表 3-2 本章实验涉及之神经网络架构(功能模型)列表。其中 conv 表示卷积层, fc 表示全连接层, GRU 表示门控循环单元层。

Model Name	Description
TeCoS-LVM/TeCoS-LVM Noisy (LIF/Noisy LIF spiking neurons, input channel=1); TeCoS-LVM Rate (LIF-Rate neurons input channel=1); TeCoS-LVM Noisy Rate (Noisy LIF-Rate neurons, input channel=1).	(feature extractor) 16conv25-32conv11-fc64 (real-valued RNN) GRU64 (encoder) fc64-fc64 (encoder mean) fc32 (encoder std) fc32 (prior) fc64-fc64 (prior mean) fc32 (prior std) fc32 (decoder) fc64-fc#RGCS
CNN (ReLU neurons, input channel=T)	32conv25-BatchNorm 16conv11-BatchNorm fc#RGCS-BatchNorm ParametricSoftPlus
IB-Disjoint (ReLU neurons, input channel=T)	16conv25-BatchNorm-32conv11-BatchNorm fc64-BatchNorm (encoder) fc64-BatchNorm-fc32-BatchNorm (encoder mean) fc32-BatchNorm (encoder std) fc32-BatchNorm (decoder) fc64-BatchNorm-fc#RGCS-BatchNorm ParametricSoftPlus

通道数 conv 滤波器尺寸; fc 通道数; GRU 隐藏状态维度.

第4章 用于时空记忆构建的时空表征方法

本文的研究核心是时空记忆构建与计算的脉冲生成式模型。在为实现这一目标所构建的研究框架中，时空表征是一个重要的基础技术，对时空记忆构建过程起到关键支撑作用。本章节将围绕时空表征方法进行研究，针对现有时空表征方法的一些共性缺陷，提出高效的时空表征方法。与一般的表征学习研究工作类似^[208]，本章节将进一步通过下游任务上的性能表现来评价表征方法的有效性。具体地，本章节考虑了两种不同的下游任务（兴趣点推荐与交通流量预测），并主要以连续兴趣点推荐任务为主，来对所提出的时空表征方法进行阐释及评价。兴趣点（POI）是较为典型的一种地理实体，具有明晰的时空属性与大量的可用数据。因此，将之作为将抽象的时空表征方法具象化的应用范例是十分合适的。这将使得在本章节中，以 POI 为例阐释的方法能够以极小的额外改动迁移到其他目标（包括记忆）的时空表征问题上。

4.1 本章引言

现有时空表征方法通常分别在空间和时间维度上进行时空表征，这种策略人为地隔离了目标的空间和时间特性，导致了次优的嵌入效果。神经科学的研究已经表明，哺乳动物大脑的内嗅-海马系统为一般知识提供了有效的基于图（Graph）的表征。此外，内嗅网格细胞提供了简洁的空间表征机制，而海马位置细胞有效地表征了感知的结合信息。因此，内嗅-海马系统为时空表征提供了一个新的角度，这启发本章提出了时空感知嵌入框架（Spatiotemporal-aware Embedding, STE）并将其应用于兴趣点（STE of POIs, STEP）。具体而言，STEP 方法考虑了两种兴趣点特定的表征：序列表征和时空结合表征，这些表征是基于本章提出的图构建策略使用稀疏的未标记数据学习的。值得注意的是，STEP 通过构建时空上下文图，使用观察和来自集成的时空维度的上下文信息，共同表征了兴趣点的时空特性。随着 Instagram 和 Yelp 等基于位置的网络服务的快速发展，人们与周围环境的互动方式发生了翻天覆地的变化。通过利用 POI 及其上下文，连续的 POI 推荐可以极大地惠及用户和商家。作为 POI 信息利用的核心，将 POI 编码到向量表征空间对于高级 POI 分析和下游应用具有重要意义。现有的研究试图从不同的角度来表征 POI，并与用户偏好建模合作以实现推荐。由于连续的签到通常高度相关。因

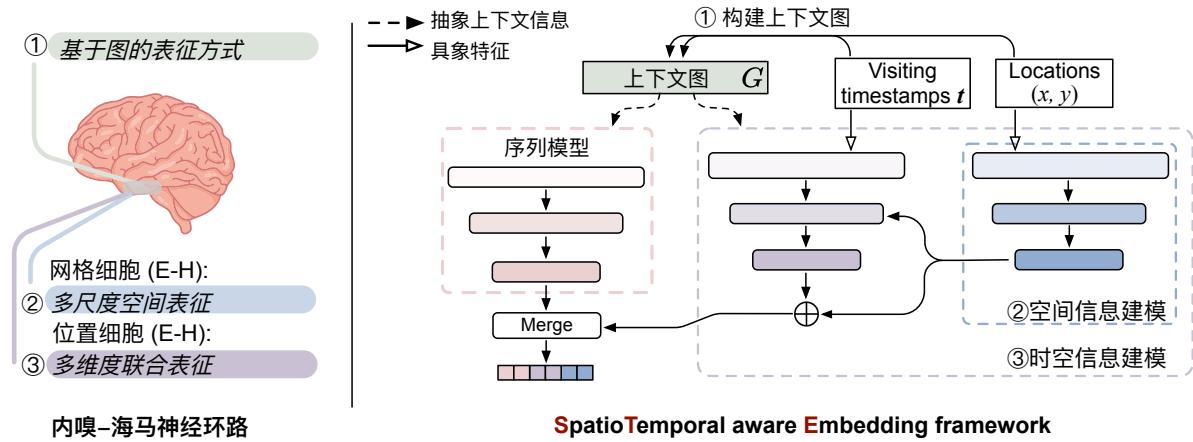


图 4-1 内嗅皮质-海马体神经环路系统（简称 E-H 系统）的表征机制和时空嵌入模型的框架。本章提出的 STE 框架包括构建上下文图的策略来构建简化的亲和图；一个时空模型来提取丰富的项目特定的时空特性；以及一个序列模型来提取序列特性嵌入。这里使用时空信息的独特性在于，本章从时空角度（而不是孤立地）使用观察和上下文联合地表征对象，即时空信息从两个相对独立的分别表征再合并的过程，变为在表征过程中直接增加了时空维度信息交互。

此，十分自然地，像马尔可夫链模型这样的序列建模方法被用来捕捉 POI 的签到序列特性^[209-212]。采用张量分解技术，文献^[213-214]通过交互特性分别对目标用户和 POI 进行建模以进行 POI 推荐。最近，受到神经网络成功的启发，循环神经网络被改造为隐式地表征 POI 和用户偏好^[215-217]。考虑到 POI 的地理属性，研究人员已经使用了幂律分布、高斯分布或者层次划分方法来描述地理影响对 POI 分布特性的影响^[209,218-221]。然而，上述的地理建模方法只提供了单一尺度或者粗粒度的手动设计的 POI 地理影响的表征，这在捕获 POI 特定的空间特性上是不足的。此外，强模型先验的建模方法甚至可能导致过度参数化。时间维度为 POI 建模，以及一般目标的时空表征提供了重要的辅助信息，为了利用签到序列中的 POI 时间信息，一些工作使用时间间隔、时间状态变量或时间转换向量来提升 POI 的表征^[216,222-226]。然而，这些方法主要关注在所有 POIs 中利用一般的时间模式，并未能充分利用 POI 特定的访问时间模式。同时，POI 特定的时空特性也未能得到充分的挖掘和利用。

海马-内嗅皮质系统 (Entorhinal-hippocampal system) 在哺乳动物认知架构中起着核心作用。曾获得诺贝尔生理学与医学奖项的神经科学研究^[227]证明，内嗅网格细胞提供

了一种有效的多空间尺度的，周期性的空间表征^[228-230]。此外，海马-内嗅皮质系统对于依赖于理解各种视角感知之间关联的非空间推理也至关重要^[22,231-232]。一些有前景的研究将空间和非空间问题视为连接的图，并指出海马-内嗅皮质结构内的细胞为这些图提供了有效的联合表征^[232-233]（Conjunctive Representation）。随着海马-内嗅皮质系统中的表征机制被广泛研究，学界普遍接受一个观点，即来自不同维度的信息表征的联合形成了海马对关系记忆的表征^[22,231,234-236]。因此，对于一般目标的时空表征过程，即时空嵌入，其涉及到的各种时空上下文可以构建成亲和图以进行表征学习。此外，像内嗅皮质-海马结构中的联合表征这样的策略可以被转化、抽象为具体的计算过程，以期进一步提高表征的质量（见图 4-1 左部分）。

本章节提出的时空表征方法，及在对一般目标时空表征问题的深入研究过程中所获的经验与洞悉，将一并对本部论文最终的核心研究目标，也即时空记忆构建与计算的脉冲生成式模型起到关键支撑。正如在本文开篇序言中所提及的，本文的模型汇集了机器学习、计算神经科学领域的一些现有思想，对时空记忆构建、计算过程的诸多关键特征提出了计算性的解释。特别地，本章节中提出的方法涉及到这其中与时空表征紧密相关的特质。在本章节中的研究借鉴了内嗅皮质-海马系统的启示，提出了一种时空感知嵌入框架，即 STE，并将其应用于 POI 进行连续的 POI 推荐。模型架构如图 4-1 所示。首先，该方法构建上下文图以实现稀疏签到的无监督嵌入学习。其次，该方法采用一个序列模型从签到序列的角度表征 POIs。此外，该方法引入了一个由网格细胞空间编码器和访问时间编码器组成的时空模型，以捕获 POI 特定的时空特性。时空模型学习使用时空上下文图获取 POI 时空潜在表征。最后，该章节基于 STEP 实现了连续的 POI 推荐系统，以验证前端时空表征学习机制的有效性。实验表明，本章节提出的时空表征方法，配合简单的循环神经网络作为推荐器，即可在兴趣点推荐、交通流量预测等下游任务上达到较高性能。

本章节中的主要贡献可总结如下：受到海马-内嗅皮质系统中结构知识的图表征策略的启发，本章节通过特定的上下文图构建策略，特别是时空上下文图，以基于图的无监督学习方式解决时空嵌入学习问题，充分利用丰富的未标记数据。受到海马-内嗅皮质环路中的联合表征机制的启发，本章节提出了一个具有网格细胞空间编码器和时间模式编码器的时空模型，以利用时空信息。基于独特的时空上下文图的联合表征方法解决了以前的时空建模方法中空间和时间信息被孤立和分别表征的问题。为了验证所提出之

表 4-1 本章节中主要记号与标识一览。

记号/标识	定义
$p_i = (x_i, y_i)$	序号为 i , 地理坐标 x_i, y_i 的 POI
x_i, y_i	p_i 的投影地理坐标
\mathcal{P}	POI 集合
G	上下文图
E	上下文图的边
V	上下文图的节点
\mathcal{S}	序列
t_j^i	p_i 的 j -th 相关时间戳
\mathbf{t}^i	p_i 的时间特征矩阵
e_{spa}^i	p_i 的多尺度空间表征向量
e_{seq}^i	p_i 的序列特征向量
e_{st}^i	p_i 的时空表征向量
\oplus	张量拼接操作

时空表征方法的有效性, 本章节进一步考虑了一系列具体的下游任务。具体而言, 本章提出了一个连续的 POI 推荐系统, 通过结合 STEP 和简单的序列预测器来展示基于所提出的 STE 框架实现特定应用的可行性。本章在现实世界获得的大型数据集上进行评估实验, 以证明 STEP 的有效性, 实验结果表明本文的方法优于基线。一些额外的益处是, 与经典的推荐系统相比, 本章节的解决方案是单纯以 POI 为中心的, 从而可以避免潜在的人工智能的道德风险, 如个人数据泄露, 因为它不需要访问用户偏好等个人信息。此外, 本文的框架可以作为一种通用的时空建模方法应用于更有价值的下游任务, 如气候预测和城市交通调度, 同时为本论文的时空记忆构建与计算的脉冲生成式模型研究提供时空表征方法的算法基础。

4.2 时空感知嵌入框架

本节以 POI 为例, 说明本文提出的时空表征方法, 也就是时空感知嵌入框架的各组成部分, 并描述基于此表征方法的用于下游连续 POI 推荐任务的方法。在本章节中提出的时空表征方法采用一种简单的(无参数)边缘加权策略来构建所有上下文图。举例来

说，如果在上下文图中节点 i 和 j 存在相似性关系，则邻接矩阵元素 $A_{i,j} = 1$ ；这种简化避免了选择上下文图中边加权参数，因而通用与一般目标的时空表征（包括了本章研究中用于举例的 POI）。

4.2.1 时空感知嵌入框架中的序列模型

在本章节提出的时空感知嵌入框架中，序列模型使用上下文图 G_{seq} 来表征 POIs。举例来说，给定一个 POI 和它在访问序列中的上下文（对一般目标而言，则可以为类似的有向或无向序列），如果 p_i, p_j 在同一个序列上下文窗口内，那么 G_{seq} 的邻接矩阵中的元素 $A_{i,j}$ 为 1。这是一种常见的挖掘文本中词、字等符号^[208]或地点^[237]等元素的序列相关性的方法。本章的序列模型旨在挖掘元素在顺序上下文中的相关性，这些元素在序列上下文图中表征为 G_{seq} 中的节点。直观地说，最小化所有目标-邻居对上的目标函数可以保证共享相似序列上下文的目标在嵌入空间（序列特征空间）中的距离更近^[238]。为了避免对整个上下文空间进行难以处理的求和，本章采用噪声对比（Noise Contrastive Estimation, NCE）采样方法^[208,239]来得到一个近似的替代损失。

$$\begin{aligned} \mathcal{L}_{seq}(\theta_{seq}) = & - \sum_{p_i, p_j \in \mathcal{P}} [\mathbb{I}(\gamma = 1) \log \sigma(\mathbf{e}_{seq}^i \cdot \mathbf{e}_{seq}^j) \\ & + \mathbb{I}(\gamma = -1) \log \sigma(-\mathbf{e}_{seq}^i \cdot \mathbf{e}_{seq}^j)], \end{aligned} \quad (4-1)$$

其中，如果 (p_i, p_j) 是一个序列相邻的目标对，则 $\gamma = 1$ ，否则 $\gamma = -1$ 。当参数条件为真时，指示器函数 \mathbb{I} 输出 1，否则输出 0。这个无监督损失也可以被看作是关于分布 $\mathbb{P}(p_i, p_j, \gamma)$ 在 \mathcal{P} 上的期望，该分布是在 POI 序列上下文图 G_{seq} 的条件下的。

4.2.2 时空感知嵌入框架中的时空模型

该小节将对本章节的时空表征方法——时空感知嵌入框架的时空模型进行介绍，其所用到的大脑表征机制的启发可以在图 4-1 中找到直观的展示。本小节所提出的时空模型由两部分组成：多尺度空间特征编码器和时间特征编码器。

多尺度空间特征编码器接收目标位置观测值 (x_i, y_i) 和空间上下文图 G_{spa} 来产生空间表征，此处仍以 POI 为例进行说明。受到哺乳动物中网格细胞的多尺度周期性表征的启发，本章构建了多尺度空间特征编码器，使用不同尺度（Scale）的正弦和余弦函数来

投影目标的地理空间中的原始位置，这部分借鉴了之前的一些研究工作^[230,240]。以 POI 为例，给定一个 POI $p_i = (x_i, y_i) \in \mathbb{R}^2$ ，基于网格细胞模型的多尺度空间特质编码器将二维欧式空间中的坐标编码为 $\mathbb{R}^{d_{spa}}$ 中的空间潜在表征。本章将 POI p_i 的基于网格细胞编码器的空间嵌入表征为

$$\mathbf{e}_{spa}^i = \phi(\psi(x_i, y_i); \theta_{spa}), \quad (4-2)$$

其中，

$$\psi(x_i, y_i) = \psi^1(x_i, y_i) \cdots \oplus \psi^s(x_i, y_i) \cdots \oplus \psi^S(x_i, y_i) \quad (4-3)$$

是 $6S$ 维度的多尺度空间表征组成的组合，此处 S 表征网格尺度的数量， ϕ 代表使用全连接层实现的非线性映射。此处考虑三个单位向量 $\mathbf{a}_1=[1, 0]^T$, $\mathbf{a}_2=[-1/2, \sqrt{3}/2]^T$, $\mathbf{a}_3=[-1/2, -\sqrt{3}/2]^T \in \mathbb{R}^2$ ，在每个尺度下，位置码

$$\psi^s(x_i, y_i) = \psi_1^s \oplus \psi_2^s \oplus \psi_3^s \quad (4-4)$$

是通过如下规则计算得到的

$$\psi_k^s(x_i, y_i) = \left[\cos\left(\frac{[x_i, y_i] \cdot \mathbf{a}_k}{\rho \lambda_{\min}}\right), \sin\left(\frac{[x_i, y_i] \cdot \mathbf{a}_k}{\rho \lambda_{\min}}\right) \right], k \in \{1, 2, 3\} \quad (4-5)$$

空间上下文邻接性定义 本章将地理坐标系统 WGS84 中的坐标投影到投影坐标系统 NAD27，以获取 POI 在 \mathbb{R}^2 中的位置。对于空间上下文图 G_{spa} 的邻接矩阵中的元素 $A_{i,j}$ ，本章使用地理距离赋值给 $A_{i,j}$ 。具体来说，本章计算了 POI 之间的地理距离，并构建了一个带有均质边的无向空间上下文图 G_{spa} ，这些边连接了最近的十个 POI（最近邻策略）。由于网格细胞启发的表征方法可以处理不同尺度的空间分布^[230]，本章没有使用特定的半径 (ϵ -邻域策略) 来过滤邻近的元素，以充分利用其多尺度空间表征能力。这里采用的空间上下文图的构建过程与先前的研究^[237]相关，在该研究中，边的权重根据平均距离进行计算，以便后续进行图注意力计算。本章节发现，以此构建的空间上下文图对本章的研究而言是简单但足够的。同时，本章保留了探索、使用相对更复杂的异质图，并进一步细化基于上下文图的表征能力的可能性。本章继续以 POI 为例，给定目标 POI p_i ，从 G_{spa} 中采样的邻近上下文 POI 集合 \mathcal{P}_{spa}^+ 和负样本集合 \mathcal{P}_{spa}^- ，以此进行的无监督表征学习可以简单地最大化观察到真实空间上下文邻居的对数似然。

同样地，本章可以通过一个通用的损失函数，其目标通过上述的负采样机制来构建：

$$\begin{aligned}\mathcal{O}(ctx) = & - \sum_{p_i \in \mathcal{P}} \sum_{p_j \in \mathcal{P}_{ctx}^+} [\log \sigma(\mathbf{e}_{ctx}^j \cdot \mathbf{e}_{ctx}^i)] \\ & + \frac{1}{K} \sum_{p_k \in \mathcal{P}_{ctx}^-} \log \sigma(-\mathbf{e}_{ctx}^k \cdot \mathbf{e}_{ctx}^i)],\end{aligned}\quad (4-6)$$

此处使用 ctx 表征上下文图类型。在本章节的研究中 $ctx \in \{seq, spa, st\}$ ， σ 是 sigmoid 函数， K 表征负样本集 \mathcal{P}_{ctx}^- 中的样本数量。根据式 4-6，多尺度空间特征编码器的损失函数是：

$$\mathcal{L}_{spa}(\theta_{spa}) = \mathcal{O}(spa). \quad (4-7)$$

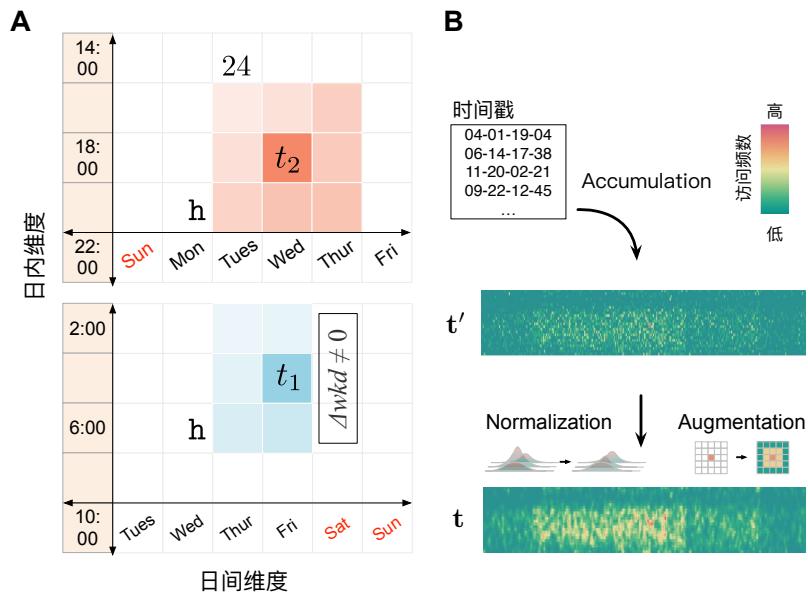


图 4-2 以 POI 为例，对时间维度下的相似性在不同层次上的定义。A. $h = 2$ 下的日内、日间时间邻接性定义。 $\Delta wkd \neq 0$ 为基于先验知识的时间相似性条件（如节假日/工作日）。B. 时间特征的统计与归一化方法。

时空上下文邻接性的定义 为了构建时空上下文图 G_{st} ，本章希望挖掘目标之间的时空关联，这种时空关联应当同时具备时、空维度下的相似性质。因此，以 POI 为例，对于 G_{st} 的邻接矩阵中的元素 $A_{i,j}$ ，本章方法分层次地，按照邻近时间戳 → 时间邻近 → 时空邻近的层次结构赋予 $A_{i,j} = 1$ ：

1. 邻近时间戳。给定任意时间戳对 (t_1, t_2) , 时间间隔 $\Delta t \triangleq |t_1 - t_2|$ 和 $\Delta wkd \triangleq |wkd(t_1) - wkd(t_2)|$, 其中 $wkd(t) = 1$ 如果 t 是周末, 否则为 0。对于一个时间 t , 其时间邻近的时间戳是那些在邻域窗口内并满足 $\Delta wkd = 0$ 的时间戳, 如图 4-2.A 所示。 h 是一个超参数, 表征时间上下文窗口宽度, $h \in (0, 24)$ 小时。
2. 时间维度相似性。POI p_i 和 p_j 具有相应的访问时间戳集 $\mathcal{T}_i = \{t_1^i, t_2^i, \dots\}$ 和 $\mathcal{T}_j = \{t_1^j, t_2^j, \dots\}$ 。邻近时间戳对 (t^i, t^j) 的数量 $> m$, 其中 $t^i \in \mathcal{T}_i$, $t^j \in \mathcal{T}_j$, m 是一个阈值。
3. 时空维度的相似性。如果 p_i , p_j 是空间和时间邻近的, 则它们就是时空邻近的。

在这种策略下, 时间被视为基本空间维度信息的有力补充。在时空表征过程中, 强制时间维度与空间维度信息交互的手段有多种。后续小节的实验结果也证明, 这种交互对于提升时空表征的有效性是非常关键的。本章节的时空上下文图构建过程提供了一种有效的方式来结合目标的时间和地理信息, 本章节没有探索基于跨连、自适应门控等手段的时空维度交互手段, 并将之留待后续章节中实现及探讨。

针对 POI 目标, 本章节开发了一种访问时间模式编码方法, 将时间观察(访问记录在时间戳 t)张量化, 为时空模型提供观察输入。与以前的工作^[215-217,222]不同, 本章研究关注的是特定于 POI 的时间模式, 而不是所有时间戳中的一般时间特性。与以前使用的基于时间间隔或硬编码的方法相比, 本章介绍的编码方案可以更精确地张量化特定于项目的时间信息, 并能为时空建模提供可靠的决策依据。就 POI 而言由于访问时间模式在年度尺度上相对稳定, 但在小时和日期尺度上变化无常, 因此在本章介绍的编码方案中, 通过访问时间戳将访问计入原始矩阵 $\mathbf{t}' \in \mathbb{R}^{24 \times 366}$ 。然后, 对原始矩阵 \mathbf{t}' 进行归一化, 并应用高斯核进行平滑; 这个过程也合理地增加了 POI 访问时间数据。访问时间编码过程如图 4-2 所示。最终的矩阵表征 $\mathbf{t} = \text{smooth}(\text{norm}(\mathbf{t}'))$ 保留了细粒度的访问时间模式以及粗略的特定于项目的访问时间特性。对于一般性的时空表征, 本章也可以采取类似的时间或时序特征构造方式。

时空感知嵌入框架的表征学习方法 延续上文中的定义，本章将时空感知嵌入框架中时空模型所获得的表征标识为：

$$\mathbf{e}_{st}^i = \phi_{\theta_{st}}(\phi_{\theta_{time}}(\mathbf{t}^i), \mathbf{e}_{spa}^i) \oplus \mathbf{e}_{spa}^i, \quad (4-8)$$

其中 ϕ 表征全连接层，根据式 4-6 的定义，本章通过最小化如下的损失来实现时空模型的表征学习：

$$\mathcal{L}(\theta_{time}, \theta_{st}) = \mathcal{O}(st). \quad (4-9)$$

仍以 POI 为例，本章从 G_{st} 中采样 \mathcal{P}_{st}^+ 和 \mathcal{P}_{st}^- ，其中 \mathcal{P}_{st}^+ 是空间时间邻近的 POI 集合，而 \mathcal{P}_{st}^- 是非相邻的 POI 的集合。 K 是 \mathcal{P}_{st}^- 中的样本数量， σ 是 sigmoid 函数。在该优化过程中，多尺度空间特征编码器、时间特征编码器作为时空模型的组成部分被联合优化，优化时空模型的损失函数如下式描述，

$$\mathcal{L}_{st} = \mathcal{L}(\theta_{time}, \theta_{st}) + \lambda_{spa} \mathcal{L}_{spa}(\theta_{spa}), \quad (4-10)$$

其中 λ_{spa} 是一个权重因子，用于在时空建模过程中平衡具象的空间上下文及抽象的时空上下文信息。在优化该模型的过程中，本章首先采样一批空间上下文样本 G_{spa} 来优化空间上下文损失 \mathcal{L}_{spa} 。接下来，本章采样一批时空上下文 G_{st} 来优化时空损失 \mathcal{L}_{st} 以达到保留时空上下文的目的。上述过程会分别重复 I_0 和 $I_1 = I_0 / \lambda_{spa}$ 次，从而使得其迭代次数的比例近似平衡因子 λ_{spa} 。在这一过程中，该算法会更新表征模型的所有可学习参数 $\{\theta_{spa}, \theta_{time}, \theta_{st}\}$ ，直到总体损失 \mathcal{L}_{st} 收敛。

4.3 实验结果

为了更直观地评价使用本章节前述时空表征方法获得的特征向量，参考表征学习的通常做法，本小节通过增加任务头，通过将所获表征运用到不同的下游任务上来实现其量化评价。

表 4-2 时空感知嵌入框架用于下游连续兴趣点推荐任务的性能对比结果。在两个数据集上与基准方法的比较结果，本章用粗体标记最佳值，用下划线标记次优值。基于 CAPE 的方法在 Gowalla 上不适用（因为数据集中没有提供相应文本语料），此外该表格没有报告一些方法在 Instagram Check-in 上的结果，因为它们无法被准确地复现。 \dagger : 需要收集用户偏好信息， \ddagger : 需要额外的文本信息辅助。

数据集	Instagram Check-in				Gowalla			
	HIT@1	HIT@5	HIT@10	MRR	HIT@1	HIT@5	HIT@10	MRR
Random+GRU	0.1197	0.2207	0.2726	0.1792	0.0715	0.0725	0.0732	0.0727
Random+LSTM	0.1207	0.2225	0.2751	0.1805	0.0722	0.0736	0.0749	0.0737
Skip-Gram+GRU	0.1356	0.2419	0.3040	0.1919	0.1090	0.2111	0.2617	0.1612
Skip-Gram+LSTM	0.1318	0.2344	0.2984	0.1875	0.1085	0.2101	0.2585	0.1594
CAPE+GRU \ddagger	0.1390	0.2433	0.3079	0.1953	N/A	N/A	N/A	N/A
CAPE+LSTM \ddagger	0.1381	0.2412	0.3054	0.1939	N/A	N/A	N/A	N/A
Geo+GRU	0.1619	0.2616	0.3248	0.2093	0.1267	0.2309	0.2834	0.1684
Geo+LSTM	0.1622	0.2594	0.3128	0.1875	0.1233	0.2296	0.2811	0.1701
ST-RNN \dagger	0.1054	0.2019	0.2426	0.1681	0.0519	0.0953	0.1304	0.2187
STGN \dagger	—	—	—	—	0.0256	0.0784	0.1144	0.0590
STGCN \dagger	—	—	—	—	0.0424	0.1134	0.1625	0.0842
LSTPM \dagger	0.1261	0.2134	0.3121	0.1957	0.1468	0.2506	0.2983	0.1998
STP-DGAT \dagger	—	—	—	—	0.1344	0.2414	0.2653	0.1856
STP-UDGAT \dagger	—	—	—	—	0.1475	0.2911	0.3285	0.2130
STEP+RNN	<u>0.2458</u>	<u>0.3170</u>	<u>0.3502</u>	<u>0.2822</u>	<u>0.1495</u>	0.2878	0.3634	0.2222
STEP+GRU	0.2467	0.3057	0.3336	0.2781	0.1490	<u>0.2912</u>	<u>0.3636</u>	<u>0.2233</u>
STEP+LSTM	0.2454	0.3204	0.3556	0.2835	0.1539	0.2968	0.3728	0.2282

4.3.1 连续兴趣点推荐任务

本小节介绍基于 STE 的用于连续 POI 推荐的方法（下称 STEP）的实验结果。该方法整体上将时空数据作为输入，构建了上下文图 G ，并将具象的时空观测值信息输入时空特征编码器进行嵌入学习。这一过程中时空感知表征向量根据相应的上下文图进行平滑，以保留上下文信息。然后，将所获得的 POI 表征向量 e_{seq}, e_{st} 合并输入到任务头中生成预测的表征 \hat{e} 。这里采用两层循环网络作为推荐任务的任务头。具体来说本章使用

如下形式：

$$\mathbf{e}_{step}^i = \mathbf{e}_{seq}^i \oplus \mathbf{e}_{st}^i \quad (4-11)$$

将序列和时空表征进行合并。这种合并策略可以保留来自不同维度的信息，无需额外的参数，也不要求嵌入在相同的维度（例如 $d_{st} = d_{seq}$ ），从而提供更多的灵活性。在连续兴趣点推荐任务下，表征模型的参数根据相应的损失函数进行优化 $\mathcal{L}(\theta_*) = \mathcal{L}_* + \alpha \|\theta_*\|_2$ ，其中 $\mathcal{L}_* \in \{\mathcal{L}_{seq}, \mathcal{L}_{st}\}$, $\theta_* \in \{\theta_{seq}, \Theta_{st}\}$, $\Theta_{st} = \{\theta_{spa}, \theta_{time}, \theta_{st}\}$. α 是 2-范数正则化的权重因子。然后，作为任务头的 RNN 预测器在推荐任务上进行优化。在任务头训练阶段，给定一个长度为 n 的 POI 序列 \mathcal{S}_j ，可以得到对应的 POI 的 STEP 嵌入系列 $\{\mathbf{e}_{step}^{(1)}, \dots, \mathbf{e}_{step}^{(gt)}\}$ ，最后一个 POI 被视为推荐目标。推荐器的目标是预测表征 $\hat{\mathbf{e}}_{step}$ 与真实连续 POI 所对应的表征向量 $\mathbf{e}_{step}^{(gt)}$ 相似，这一过程的正式表述如下：

$$\arg \max_{\theta_{pred}} \sum_{\mathcal{S}_j \in \mathcal{S}} \text{sim} \left(\hat{\mathbf{e}}_{step}, \mathbf{e}_{step}^{(gt)} \right) \quad (4-12)$$

用于任务头的目标函数则可以表述为

$$\begin{aligned} \mathcal{L}_{pred}(\theta_{pred}) = & - \sum_{\mathcal{S}_j \in \mathcal{S}} \left[\log \sigma' \left(\text{sim}(\mathbf{e}_{step}^{(gt)}, \hat{\mathbf{e}}_{step}) \right) \right. \\ & \left. - \log \left(\sum_{p_i \in \mathcal{P}} \sigma'(\text{sim}(\mathbf{e}_{step}^i, \hat{\mathbf{e}}_{step})) \right) \right], \end{aligned} \quad (4-13)$$

其中 $\sigma' = \exp(\text{LeakyReLU}(\cdot))$ 和 $\text{sim}(\cdot, \cdot) = \frac{\mathbf{a} \cdot \mathbf{b}}{\|\mathbf{a}\| \cdot \|\mathbf{b}\|}$ 。在测试阶段，本章计算余弦相似度分数来对候选 POI 进行排名，以生成推荐列表。连续兴趣点推荐实验中，超参数设置为以下默认值。本章在序列模型中设置上下文窗口大小为 2，并采用 $h = 2$, $m = 11$ 来构建 G_{st} 。本章节使用 Adam 优化器，批处理大小为 512, $\beta_1 = 0.9$, $\beta_2 = 0.999$ ，并将初始学习率设置为 0.001，然后采用 Reduce-on-Plateau 衰减策略，在训练期间，衰减因子为 0.1。权重因子 α, λ_{spa} 被设置为 $1 \times 10^{-4}, 0.2$ ，表征维度 $\{d_{seq}, d_{spa}, d_{st}\}$ 被设置为 $\{32, 64, 96\}$ 。

实验数据及预处理 给定一组具有对应坐标的兴趣点 $\mathcal{P} = \{p_i\}$, $p_i = (x_i, y_i)$ ，一个签到序列是一天内一个用户连续签到的一组集合，表示为 $\mathcal{S}_j = \{(p_1, t_1^1), \dots, (p_n, t_m^n)\}$ 。本节使用了 Instagram 数据集^[241]，该数据中的包含时空信息的签到记录是从纽约市的 Instagram 社交网络用户中收集的，数据的预处理方式与以前的工作相同^[222-223]。Instagram 数据集

在公开时已经进行了预处理，它包括 2216631 条签到记录，涉及 13187 个兴趣点的 78233 个用户。POI 访问序列按时间戳排序；前 70% 用作训练集，剩余的 30% 用于验证和测试。本节还使用了 Gowalla 数据集，该数据集是一个在全球范围内收集的大规模社交媒体数据集合^[242]。在预处理中，本章剔除了访问次数少于十次的用户的相关条目，以及被少于十个用户访问的兴趣点的相关条目。然后按照时间戳对签到记录进行排序，前 70% 的记录用于训练，剩余的新记录用于测试。

评估指标 在测试阶段，本节介绍的以时空感知嵌入方法为核心的推荐系统，根据每个测试序列的候选 POI 的估计分数给出一个按照相似度分数排序的 POI 推荐列表。本章选用广泛使用的指标 HIT@K（如果真实值在列表的前 k 个中，得分为 1，否则为 0）， $k = 1, 5, 10$ ，以及 MRR（平均倒数排名）进行性能评估。这些指标反映了推荐列表的不同方面，HIT@K 衡量了所有试验中有效推荐的比率，而 MRR 评分了整个推荐列表的质量。本章将本小节提出的推荐方法与下列具有代表性的高性能基线方法进行了比较：

- **两阶段方法。**本章构造了由三种表征方法和两种 RNN 推荐器组成的六种方法。本章使用以下几种表征方法。(1) Random, (2) Skip-Gram^[243], (3) CAPE^[241] 和 (4) Geo^[230]。对于 RNN 推荐器，本章使用基于(1) GRU 单元^[244] 和 (2) LSTM 单元^[245] 的两层网络。
- **一阶段方法。**本章选择了具有代表性的一阶段方法作为基准。(1) ST-RNN^[215], (2) STGN^[216]，一种考虑时间和距离因素的 LSTM 变体，用于建模访问偏好，以及改进的变体 STGCN, (3) LSTPM^[246] 是一种基于 LSTM 的方法, (4) STP-DGAT 和 STP-UDGAT^[237] 是空间-时间-偏好用户维度图注意力网络。

根据表 4-2 中的结果，基于本章节表征方法的连续兴趣点推荐系统在两个数据集上都显著优于基线方法，而且在具有丰富时间信息的 Instagram 数据集上提高了推荐的准确性（根据表 4-3，Gowalla 中的 POI 访问时间戳记录更稀疏）。基于循环神经网络的一阶段方法，如 ST-RNN, LSTPM，通过更充分地利用用户偏好的时空特性，超过了部分基础的基线方法。然而，这些方法仍然不如基于 STEP 的方法，尽管 STEP 没有考虑用户偏好。因此，STEP 方法相对于竞争者的优势表现可以归因于它对项目特定的时空性质的有效利用。本章实验发现基于 STEP 的方法在 MRR 方面有显著的性能提升，表明

基于 STEP 的方法在两个数据集上提供了更好的候选列表，并受益于所提出的时空嵌入模型的效率。此外，在推荐器（任务头）中使用 LSTM 单元稍微提高了性能，与基本的 RNN 单元相比，因为它们在循环连接的门函数方面有优势。此外，搭配本章节时空表征方法的基础的 RNN 任务头也可以超越一阶段的先进基线，这也证明了本章节的脑启发式时空嵌入框架作为时空表征方法的有效性。

表 4-3 兴趣点数据集统计信息。

数据集	Instagram	Gowalla
兴趣点平均记录条数	168.1	34.2
兴趣点平均序列邻居数	66.2	35.5
兴趣点平均空间邻居数	10.0	10.0
兴趣点平均时空邻居数	0.997	0.596

本小节进一步研究了新引入的超参数 h , m , λ_{spa} 的影响，并用 HIT@1 和 MRR 在图 4-3 中报告了结果。参数 h 和 m 控制了时空上下文图的稀疏性， λ_{spa} 调节了时空模型目标函数中空间上下文平滑项的重要性。本章通过改变 h 来构建不同稀疏度的时空上下文图，较大的 h 对应于粗糙的时间邻近条件。在一定范围内增加 h 可以提高性能，但对于精确的 top-1 推荐有不利影响。最佳性能（以 MRR 指标衡量）在 $h = 2$ 时达到的。事实上， h 的选择与任务性质相关；根据两个数据集上的结果， $h = 2$ 可以是 POI 推荐的一个好的初始值。这个值可以根据不同的应用场景或数据集进一步调整，以构建具有期望稀疏度的时空上下文图。本章将 m 设置为从 3 到 15 的区间内取值，较大的 m 导致更稀疏的时空上下文图。本章观察到在增加阈值 m 后，性能稍有变化，当 $m = 11$ 时，获得了最佳性能。本章还研究了平衡因子 λ_{spa} 对时空模型训练的影响，当 $\lambda_{spa} = 0.2$ 时，推荐系统达到了最佳性能，进一步增加只带来微小的改进。因此本章在该部分研究中选择 0.2 作为默认值，这也有助于减少模型训练过程中不必要的迭代。

进一步地，本小节通过使用 LSTM 推荐器进行连续的 POI 推荐任务来研究 STEP 中不同模块的有效性，使用标准 STEP 嵌入模型的方法称为完整。在移除 (1) 时间维度输入后，时空模型退化为一个空间模型。根据表 4-4，在两个数据集上，没有 (1) 的方法表现得更差。根据表 4-3，Gowalla 中的 POI 具有更稀疏的时间观测信息 t 和来自 G_{st} 的上下文信息。这导致在 Instagram 集上的性能提升比在 Gowalla 上更显著。本章用 $\mathbb{R}^{24 \times 366}$

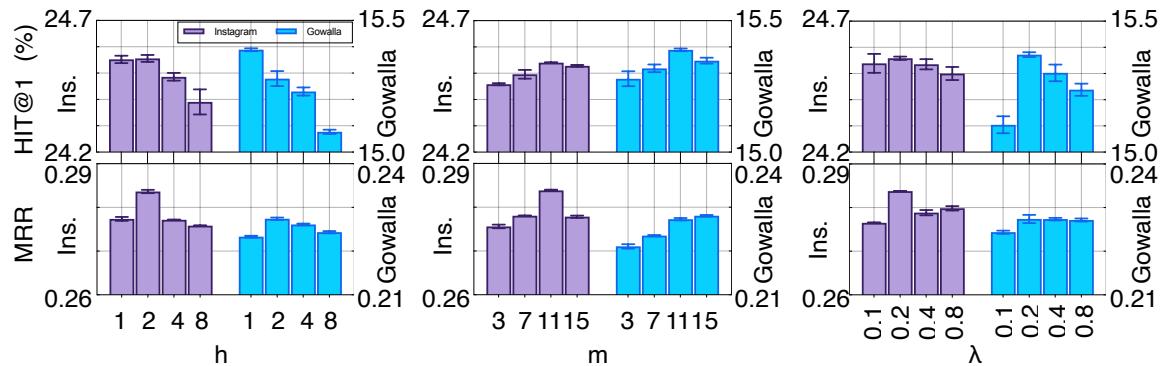


图 4-3 连续兴趣点推荐任务下的超参数敏感性分析。

中的随机初始化矩阵替换 POI 访问时间模式矩阵 t 。本章注意到，使用 (2) 时间特征编码器可以提高两个数据集上的推荐性能，而且提高的程度与数据集的时间信息丰富度正相关。这里使用一个单层神经网络位置编码器 $\psi'(x, y)$ 来替换 STEP 中的 (3) 网格细胞编码器，以评估该模块的有效性。表 4-4 中的结果表明，网格细胞编码器提高了 STEP 表征的质量，并在两个数据集上都提高了连续兴趣点推荐的性能。此处观察到，在去除 (4) 空间表征跨连后，系统的推荐性能明显下降，因为时空结合表征在整合空间和时间属性的同时，也损失了空间信息（由于维度降低）。使用 (4) 空间表征跨连可以在一定程度上缓解这个问题。一个简单的 LSTM 推荐器可以在不考虑序列信息的情况下，达到有竞争力的推荐性能（表 4-4），这证明了本章节时空表征方法对时空维度整合方式的有效性。由于访问序列信息提供了相对粗粒度的 POI 描述，去除序列模型甚至在 Instagram 数据集上提高了 HIT@1。另外，Gowalla 上的指标下降 (-18.6%, -27.8%, -32.4%, -26.2%) 比 Instagram 集上的指标下降 (+3.1%, -11.4%, -15.0%, -6.0%) 更明显，这与它们的时间信息丰富程度（由每个兴趣点的平均记录数量反映）正好相反。

4.3.2 交通流量预测任务

本小节介绍基于 STE 的用于交通流量预测任务的方法（下称 STE of Traffic Grid, STETG）。该方法整体沿用了与兴趣点任务类似的思路，即将时空数据作为输入，构建了上下文图 G （抽象信息），并将时空观测值（具象信息）输入时空特征编码器进行表征学习。这一过程中时空感知表征向量根据相应的上下文图进行平滑，以保留上下文信息。然后，将所获得的交通区块表征向量输入到任务头中生成预测的流量值。

表 4-4 用于连续兴趣点推荐任务的时空感知嵌入框架的模块有效性实验。

性能指标		HIT@1	HIT@5	HIT@10	MRR
Instagram	完整	0.2454	0.3204	0.3556	0.2835
	去除 (1)	0.2433	0.2544	0.2607	0.2504
	去除 (2)	0.2452	<u>0.3151</u>	<u>0.3442</u>	<u>0.2798</u>
	去除 (3)	0.2399	0.3037	0.3305	0.2727
	去除 (4)	0.2298	0.2531	0.2674	0.2451
	保留 (5)	0.2466	0.2840	0.3021	0.2664
Gowalla	完整	0.1539	0.2968	0.3728	0.2282
	去除 (1)	0.1461	0.2825	0.3540	0.2174
	去除 (2)	<u>0.1509</u>	<u>0.2921</u>	<u>0.3664</u>	<u>0.2248</u>
	去除 (3)	0.1006	0.2169	0.2922	0.1657
	去除 (4)	0.0973	0.2117	0.2866	0.1610
	保留 (5)	0.1252	0.2142	0.2519	0.1683

参照先前的相关工作^[247-248]，本章根据经度和纬度将一个城市划分为一个 $M \times N$ 的交通网格地图，其中一个交通网格表征一个地理区域。对于位于第 m 行和第 n 列的网格 (m, n) ，本章考虑了 k^{th} 时刻的两种类型的交通流，即流入和流出，分别定义为

$$x_k^{in,m,n} = \sum_{Tr_k \in \mathbb{P}} |\{i > 1 \mid g_{i-1} \notin (m, n) \wedge g_i \in (m, n)\}| \quad (4-14)$$

$$x_k^{out,m,n} = \sum_{Tr_k \in \mathbb{P}} |\{i \geq 1 \mid g_i \in (m, n) \wedge g_{i+1} \notin (m, n)\}| \quad (4-15)$$

其中 Tr_k 表征第 k^{th} 个时间步的轨迹， g_i 表征地理坐标， $g_i \in (m, n)$ 表征点 g_i 位于网格 (m, n) 内， $|\cdot|$ 表征集合的基数。在时间 k 时，网格 (m, n) 的交通流量表征为 $X_k^{m,n} = (x_k^{in,m,n}, x_k^{out,m,n})$ 。交通流量预测的目标是：给定 $X_k, k \in \{0, 1, \dots, t-1\}$ ，预测 X_t 。

沿用本章节中时空感知嵌入框架应用到连续兴趣点推荐任务的模式，本节介绍的方法 STETG 的输入由观测值（坐标和访问时间模式）和上下文（上下文图）组成。与 STEP 不同的是，在交通区块间的序列信息是不重要的，因为它们仅会发生在地理空间相邻的交通区块之间，即实际上退化为空间信息。除了这部分存在区别外，本小节沿用

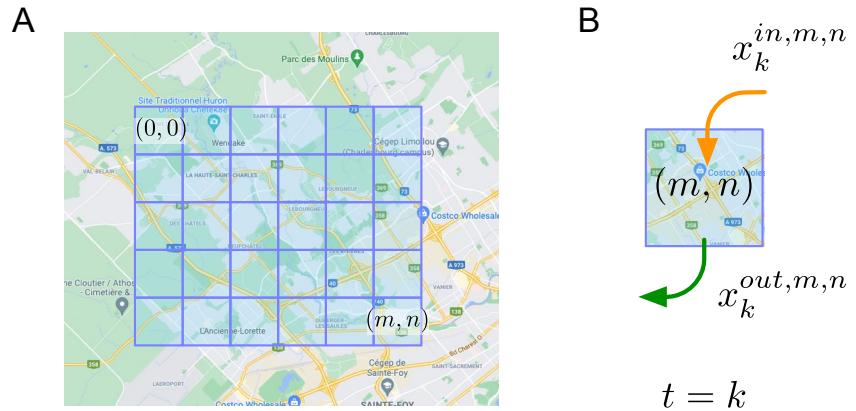


图 4-4 时空感知嵌入框架下的交通流量预测任务示意图。A. 交通区块 (Traffic Grid) 划分示意图；B. 区块流量示意图。

与前文相同的方式使用空间观测值并构建空间上下文图。具体来说，在网格细胞编码器中采用相同的超参数设置 $S, \lambda_{min/max}$ ，并使用 top-10 最近邻策略来构建 G_{spa} 。此外，空间子模型的嵌入目标仍然如本章节前文所述。与 POI 不同，交通网格流数据的时间截是使用标准时间间隔收集的。因此，访问时间模式的编码和时空上下文图的构建都可以简化。值得注意的是，本章用与 POI 相同的方式生成访问时间模式矩阵，作为时空模型的时空观测输入，并且由于时间截是标准的，本章跳过进行兴趣点任务时采用的滤波和正则化步骤。为了构建 G_{st} ，本章使用指定的距离函数 $d(\cdot, \cdot)$ 来定义网格的时间邻接性，该函数是由两个交通网格的归一化交通流差值计算的，可以表述为

$$d((m, n), (m', n')) \triangleq \frac{1}{t} \sum_{k=1}^t \left[\text{abs} \left(x_k^{in,m,n} - x_k^{in,m',n'} \right) + \text{abs} \left(x_k^{out,m,n} - x_k^{out,m',n'} \right) \right] \quad (4-16)$$

本章使用 top-10 最近邻策略来获取距离较近的区块的时间相似性关系。结合空间上下文信息 G_{spa} ， G_{st} 被构建来帮助嵌入模型保留交通网格之间的时空联系。用于优化时空模型的目标函数与正文中的相同。

交通区块的流量与其周围区块的性质有显著的关系，因为一个区域的流出可能导致相邻区域的流入。在本工作中，交通区块的时空性质和区块之间的相关性被编码在时空表征向量 e_{stetg} 中。因此，给定一个查询值 $X_{t-1}^{m,n}$ ，四个地理空间中邻近的交通区块和该

区块 (m, n) 本身的时空表征也会被输入到预测器 f_θ 中，以产生流量的估计值

$$\begin{aligned}\hat{X}_t^{m,n} &= (\hat{x}_t^{in,m,n}, \hat{x}_t^{out,m,n}) \\ &= f_\theta(X_{t-1}^{m,n}, \mathbf{e}^{m,n})\end{aligned}\tag{4-17}$$

其中 $\mathbf{e}^{m,n} = (e_{stetg}^{m,n}, e_{stetg}^{neigh})$ ， e_{stetg}^{neigh} 表征网格 (m, n) 的四个空间邻居的嵌入。本章使用一个简单的三层 $\text{MLP } f_\theta$ ，其激活函数为 ReLU。隐状态的维度为 256，任务头模型的损失函数是流量预测值与真实值间的均方误差 $\|\hat{X} - X\|_2^2$ 。

本小节在几个基准数据集上进行实验：TaxiBJ15^[248] 包含了基于 2015 年北京市出租车 GPS 数据计算的流入/流出量。TaxiBJ^[249] 是一个扩展版本，包含了 2013 年到 2016 年的数据。对于 TaxiBJ15，本章使用最后一周的数据作为测试数据。对于 TaxiBJ，本章选择最后四周的数据作为测试数据。本小节选取了以下几种有代表性的基线方法用于对比。

- HA: 一种基于历史平均值的预测器。
- ARIMA: 自回归整合移动平均方法。
- SARIMA: 考虑季节性因素的 ARIMA 方法变体。
- VAR: 向量自回归方法。
- ST-ANN: 该方法首先提取空间（附近 8 个区域的值）和时间（前 8 个时间间隔）特征，然后输入到一个人工神经网络（ANN）中。
- DeepST^[248]: 一种基于深度神经网络（DNN）的时空数据预测模型，它在人群流量预测方面显示出最先进的结果，本章只考虑最强大的变体，即 DeepST-CPTM。
- ST-ResNet^[249] ST-ResNet 将不同时间的城市交通流量建模为 2D 图像，进行预测。
- LinUOTD^[250]: 一种带有时空正则化的线性回归方法。
- ConvLSTM^[251]: 一种带有卷积模块的 LSTM 变体。

对比实验的结果展示在表 4-5 中。在 STETG 中，只使用网格地图和历史交通流来进行流量预测，而现有的工作通常会考虑天气等元数据。然而，从结果中能发现简单构建的交

通流量预测方法 STETG 达到了有竞争力的性能，这进一步证明了本章节的时空感知嵌入框架作为一般性的时空表征方法的有效性。

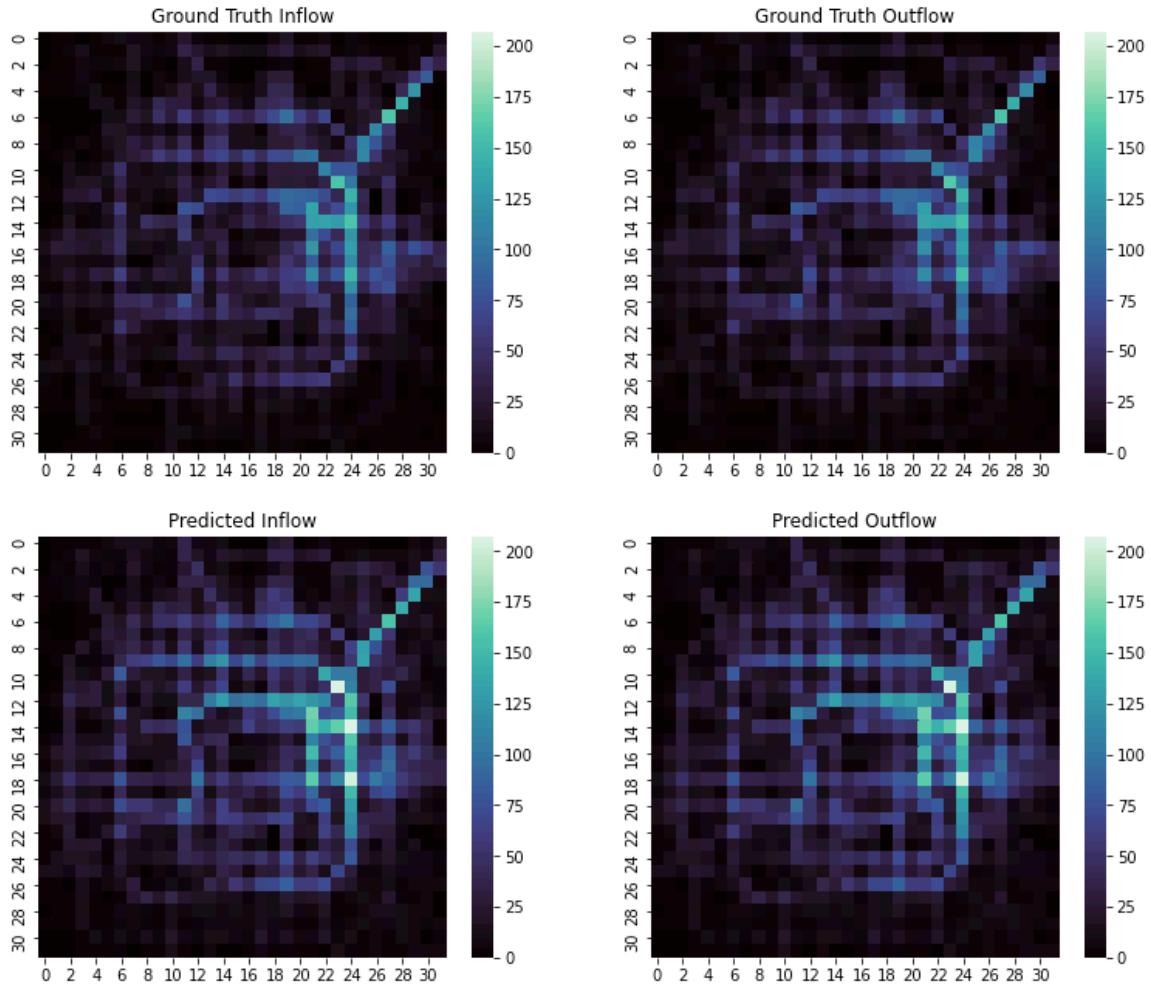


图 4-5 基于时空感知嵌入框架的交通流量预测结果可视化。第一行是交通流量的真实值的热力图可视化，第二行为预测值的可视化。

4.4 本章小结

本章节介绍了用于时空表征的一般方式——时空感知嵌入框架，并介绍了基于该方法的两个下游应用：连续兴趣点推荐以及交通流量预测。具体来说，本章提出了时空感知嵌入框架 STE，并将其应用于 POI。这是第一个将海马-内嗅皮层表征机制转化为时空嵌入的工作。受大脑海马-内嗅皮层系统中的图表征策略的启发，STEP 通过上下文图构建和基于图的嵌入学习，从无标签稀疏数据中捕获顺序和时空表征。此外，STEP 提

表 4-5 基于时空感知嵌入框架的交通流量预测方法在 TaxiBJ15 (左), TaxiBJ (右) 数据上的实验结果。

方法	均方根误差	方法	均方根误差
ARIMA	25.58	HA	57.69
SARIMA	29.11	ARIMA	22.78
VAR	25.59	SARIMA	26.88
CNN	26.08	LinUOTD	21.23
DeepST-CPTM	22.59	ConvLSTM	19.54
STETG (本节方法)	22.05	DeepST-CPTM	18.18
		STETG (本节方法)	18.01

提供了一种高效的时空模型，其受网格细胞的多尺度空间表征和位置细胞的共同表征的启发，克服了常用的分别表征策略所导致的次优嵌入问题。基于 STEP 的连续 POI 推荐方法在两个真实数据集上优于基线和极具竞争力的对比方法。类似地，本章将 STE 框架运用在交通流量数据的预测任务上，实现了极具竞争性的预测性能。

总体而言，与现有的时空表征方法，以及时空相关任务（兴趣点建模、交通分析、气候分析等）中采用的时空信息处理策略相区别的是，**本章节介绍的方法强调时空维度的统一性，并在表征学习过程中强制时空维度进行交互**，而非采取分别表征后融合的既有策略。换言之，其背后的思想和数据挖掘领域“更早、更彻底地进行不同源的特征交叉会带来性能收益^[252]”。具体到本文的研究，本章主要探索了基于规则进行时空维度整合、交互的基于规则的方式，这是一种轻量的、直观的时空特征交叉实现方式。由于本章节中涉及的两个下游任务数据本身有一定的稀疏性，本章采用的基于规则的方式避免了使用参数化手段进行时空维度交互、整合可能面临的正则化难题，同时在表征学习过程中提供了全局的视角。后续的章节将在本章节的研究基础上，总结该章节的研究经验，尝试将类似策略的时空表征方法推广到非典型的具有时空特性的对象。

第5章 记忆构建与计算机制研究

本文中的研究重点是时空记忆构建与计算的脉冲生成式模型。在为实现这一目标所构建的研究框架中，用于实现记忆的构建、巩固过程的算法是另一大重要的基础技术，对时空记忆构建与计算的实现起到关键支撑作用。本章节将在连续学习的任务场景下，围绕大脑记忆机制以及其计算过程建模问题进行研究，这将使得本章除能够直接对记忆机制及计算过程的算法有效性进行直观的评估，从而具象化这一部分的研究，同时又不会使之孤立于本文的研究内容，即时空记忆构建与计算的脉冲生成式模型。

5.1 本章引言

记忆构建与计算机制研究，被认为有助于能够广泛使用于连续学习范式下减少神经网络知识遗忘，因为自然界中的智能体能够长时间稳定地获取并积累解决不同任务的知识与技巧。而人工神经网络模型在进行新任务学习时，会逐渐遗忘以前学到的大部分知识^[253-256]，即发生灾难性遗忘。因此，每当有新任务出现时，整个神经网络都必须再次经历离线训练过程，这无论从经济性还是实用性的角度而言都是难以接受的。记忆回放方法，即维持一个随机更新的存储前期任务样本的缓存，是一种广泛使用的在连续学习范式下缓解灾难性遗忘现象的技术手段。然而，现有的记忆回放方法只考虑了简单的记忆缓存和回放过程。为了实现对记忆构建、计算机制更充分理解，并进一步释放记忆回放连续学习方法的潜力，构建更精细、更复杂的计算模型是相当必要的。神经科学对记忆构建、计算机制的研究为完善其计算过程建模提供了一些思路。在大脑中，短期记忆(Short-term Memory, STM) 和长期记忆(Long-term Memory, LTM) 具有不同的功能，并有不同的系统、机制，这种理论也是学界的一个普遍认同^[257]。根据经典的记忆巩固理论框架，长期记忆最初由海马体(Hippocampus, HC) 中的支持快速学习的系统机制维护，随后在长期存储中将这些记忆痕迹稳定化^[258](即巩固过程)。此外，基于实验和理论研究，神经科学家认为，大脑可能通过增加新皮质-海马回路之间的通信交互，并通过一系列复杂的、微观的神经活动来促进记忆的巩固^[259-262]。另一方面，对STM机制的研究表明，大脑通过激活前额叶(Prefrontal Cortex, PFC) 神经元来主动保持STM中的信息^[263]。因此，PFC-HC回路组成记忆系统(图5-1)实现了一个分层记忆范式，其

中 STM，一个存储任务相关信息的记忆缓存，通过记忆巩固和记忆提取过程与 LTM 相连。现有的研究揭示了 STM 的更新和记忆巩固之间存在微妙的双向交互。然而，这些过程是如何进行的，以及这些记忆是如何参与认知和学习的，仍然不甚清楚。

在深入研究记忆构建和计算机制的基础上，本章节介绍了一种高效的基于记忆重放的任务增量终身学习方法，称为 Dual-MEM (Dual-Memory Model, 双重记忆模型)，受 PFC-HC 记忆系统的启发。具体来说，本章提出了一个具体的计算实现，实现了模仿 PFC-HC 系统的双重记忆系统的学习过程。本章为这一过程的不同子过程提供了具体的计算实现方式，包括 STM 的在线更新、记忆巩固，以及使用 STM 和 LTM 系统的视觉识别任务连续学习。所提出的 Dual-MEM 模型（图 5-1）采用了一个增量更新的固定容量的 STM，以帮助当前任务的学习，并将 STM 巩固为长期的记忆，以在后续的学习序列过程中进行回放，以减轻灾难性遗忘。本章节提出了两种用于 Dual-MEM 模型优化的学习方法。本章节在多种基准数据集合基础上进行了细致、广泛、彻底的实验，实验结果表明，与现有方法相比，Dual-MEM 模型能够实现更高效的任务增量连续学习，同时保持较低的计算资源消耗。

5.2 双重记忆系统启发的记忆构建与计算方法

5.2.1 本章相关工作

连续学习也称为终生学习，指的是在一系列任务上连续进行学习。在终身学习中，学习者（这里特指是参数化的神经网络模型）不仅要不断积累通用知识，还要保留过去任务的特定信息^[264-265]。这个定义导致了这一学习范式在强化学习领域^[266-270] 和监督学习领域^[51,271-272] 中略有不同的实现。一般来说，常用的连续学习设定是任务增量的场景，即向模型提供任务描述符和样本观测^[273]（如视觉刺激、听觉刺激等）。特别地，这章的研究关注一个更加现实、更有挑战性的设定下，进行连续识别任务的学习。具体而言，在本章的设定下，观测样本都只遍历一次，且用于实现记忆的缓存容量有限。

先前的一些研究，如文献^[274-276]，提出了通过减少中间特征空间或最终输出空间中激活的变化来缓解遗忘的方法。然而，这些方法或是需要存储先前的模型的参数，又或者需要不断地为新任务添加新的模型参数。Synaptic Intelligence^[277](SI) 和 Memory Aware Synapses^[278](MAS) 通过算法估计模型参数的重要性来进行额外约束，而 Elastic Weight

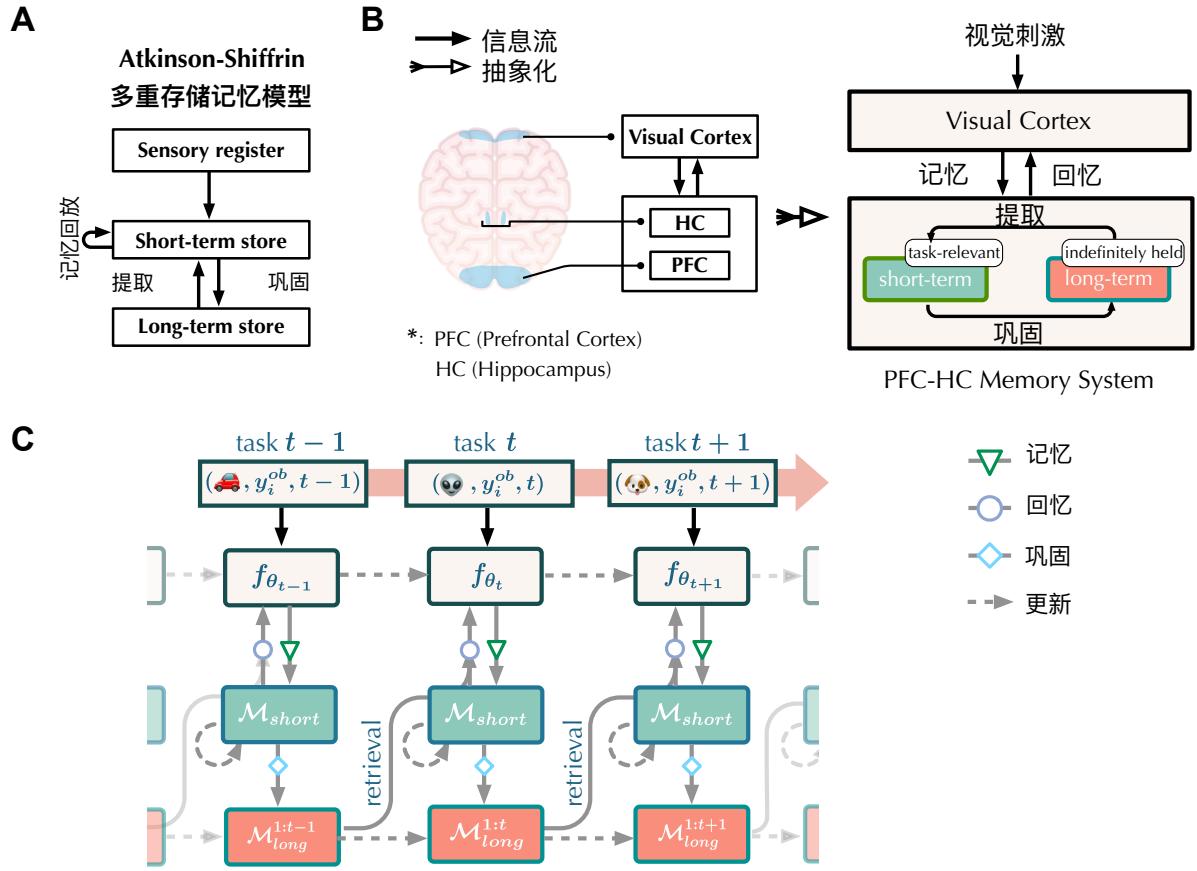


图 5-1 A. Atkinson-Shiffrin 多重存储记忆模型的图形说明^[57]。**B.** 大脑视觉认知系统的简化结构，将视觉识别前额叶皮层-海马体（PFC-HC）回路视为一个由短期（与当前任务相关）和长期记忆组成的系统。这种抽象也可以被认为是 Atkinson-Shiffrin 多重存储模型的一个在视觉任务上的实现。**C.** 在任务序列上提出的 Dual-MEM 模型的终身学习过程的简要说明。Dual-MEM 模型通过一个混合目标函数进行优化，其由主要目标和基于 LTM 的暗知识正则化器组成。

Consolidation^[279](EWC) 和 Gradient Episodic Memory^[271,280](GEM) 方法则在梯度更新过程中增加基于梯度向量角度的约束来进行正则。在另一些研究^[281]中，研究者引入了正交先验来进行神经网络正则化，并设计了一个类似于大脑的依赖于上下文的模块来提高模型的灵活性。由于分层概率模型可以表达大脑中的学习和推理^[282]，一些工作引入了变分推理来避免灾难性遗忘^[283-285]。然而，这些方法不可避免地给神经网络训练过程带来了不小的额外计算负担。

另一类连续学习方法，即参数分置方法（Parameter Isolation）为每个任务应用模型不同的参数子集，以减轻模型的灾难性遗忘。这通常是通过激活与任务相关的参数掩

码、单元掩码或门^[286-289]来实现的。然而，这些基于参数分置的方法不可避免地增加了优化的难度，并且阻碍了跨任务的通用知识积累。

大脑中表征旧任务记忆的神经活动模式的再激活被认为是保持解决已形成经验的先前任务能力的必要条件^[290-293]。受此启发，研究人员设计了基于记忆回放的连续学习方法，也即周期性地重复早期经验的知识，以达到减轻灾难性遗忘的目的。伪回放方法^[50-51,294-295]使用从前一个任务中获取的统计信息的生成模型来生成合成的样本，并在旧任务的合成样本和新任务样本上重新训练。然而，这些方法引入了额外的模型参数，并不可避免地增加了训练的复杂性。真实记忆回放方法^[272,296-297]在一个缓存来存储先前任务的原始样本，并在学习新任务时直接在来自缓存的旧任务样本和新接收到的当前任务样本上训练模型。然而，这类真实记忆回放方法的局限性有两方面。首先，它们的缓存（即记忆）分配策略通常假设一个任务中的所有类别是相等的，并为所有类别分配相同的记忆容量。其次，它们普遍使用诸如特征空间移动平均之类策略来实现记忆更新，这会在训练过程中带来较重的额外计算开销。

连续学习算法的神经科学启发 一些研究致力于从神经科学的理论和机制中汲取灵感，设计连续学习算法。互补学习系统（Complementary Learning Systems, CLS）是常用的启发来源。Shin 等研究者^[50]提出了一种受 CLS 启发的连续学习方法，该方法依次训练学者模型和生成模型。Pham 等研究者^[298]介绍了一种混合方法，该方法包括一个通过无监督学习优化的慢学习器和一个通过监督学习训练的快学习器，受 CLS 中的长期和短期学习机制的启发。他们的方法中，中间特征层的适应性连接了快速和慢速学习器。文献^[299]开发了一种方法，该方法通过存储之前的模型权重以及基本的示例记忆回放来保留语义记忆。与这些工作不同，本工作重点关注记忆模块，并通过在记忆模块内部进行更细粒度的处理来提高记忆回放的效率。尤其值得一提的是，本章介绍的方法与之前采用双重记忆设计的终身学习方法密切相关。文献^[300]提出了一个受神经科学启发的模型，该模型由一组作为短期记忆（STM）的生成模型组成，通过深度生成回放（Generative Replay）与长期记忆（LTM）交互，以减少遗忘，另一项研究^[301]也采用了类似的策略。在 IL2M^[302]方法中，LTM 被定义为任务统计量，这些统计量用于通过测试时对模型预测分数的微调来减轻遗忘。文献^[303]将上一训练阶段的模型参数视为 LTM，并通过移动平均将这些参数集成到新模型中，以减少遗忘。可以看出，上述工作中考虑的双重记忆

设计与本工作不同。所提出的双重记忆方法是单一记忆经验回放方法的一种受大脑记忆机制启发的细化与拓展，且无需在学习过程中额外训练一个单独的生成式模型或存储之前的模型权重。这是通过明确地将记忆缓冲区划分为与当前任务相关的 STM 和与过去任务相关的 LTM 来实现的。

5.2.2 本章基础设定

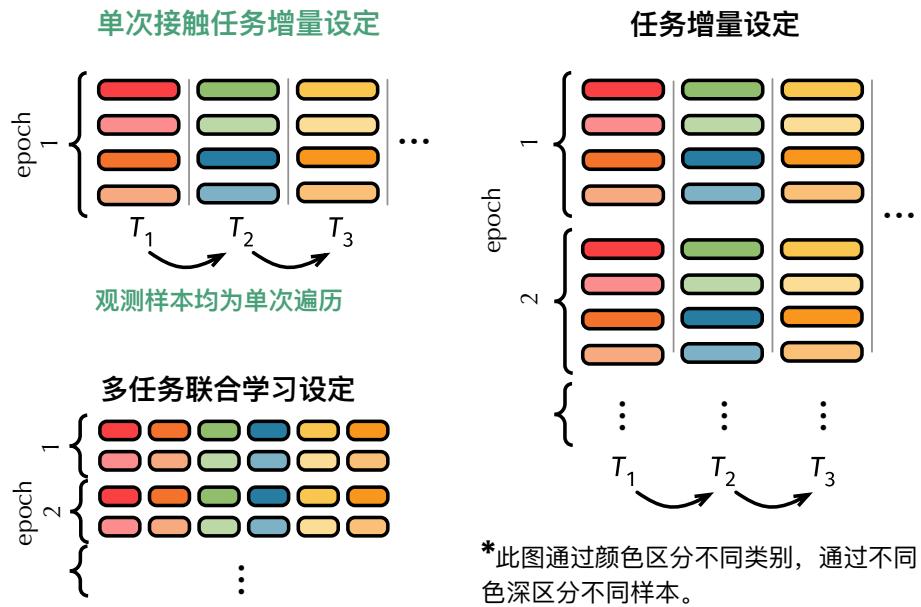


图 5-2 本章使用的单次遍历连续学习设定期示（图左上）。与已有的常用任务增量设置（Task-incremental Lifelong Learning Setting，图右）、多任务设置（Multi-task Joint Setting，图左下）不同，本章采用的设置中所有样本只接触一次，因而更加现实，也更具有挑战性，同时对记忆机制的高效性有着更高的要求。

本章主要记号与定义 本章的研究中采用了固定容量的 $\mathcal{M}_{short} = \{(x_i^s, y_i^s, z_i^s)\}$ 来存储当前任务的样本，和 $\mathcal{M}_{long} = \{(x_i^l, y_i^l, z_i^l, t)\}$ 来存储过去任务的样本。本章将从输入数据流（观察序列），STM 和 LTM 中采样的批分别表示为 \mathcal{B}_{ob} , \mathcal{B}_{short} 和 \mathcal{B}_{long} 。使用 ℓ 来表示交叉熵函数， $|\cdot|$ 来表示集合的势，例如 $|\mathcal{M}|$ 表示代表记忆容量的缓存大小。

单次接触的任务增量学习设定 生物在学习过程中遇到的不同任务有复杂的关系，这些关系可能包括相互联系或是存在某种意义上的交集和重复的。因此，为评估记忆构建与

计算实现而创建一个完全真实的评估设定是颇有挑战性的。这里考虑了一个被广泛使用的简化设置^[281,295]，它具有明确的任务边界^[304-305]。具体来说，这里考虑一个单次接触（Experience-once, Single Exposure）的任务增量设置（图 5-2），沿用先前文献中的研究思路^[52,271,306]。在该设定中，任务序列由数据 (x_i^{ob}, y_i^{ob}, t) 组成，其中包括观察 x_i^{ob} ，目标 y_i^{ob} 和任务指示器 $t \in \mathcal{T} = \{1, \dots, T\}$ 。这对于许多识别和强化学习问题来说是一个自然的场景^[279,307]。对于任务 t ，每个数据对 (x_i^{ob}, y_i^{ob}) 是从该任务的数据生成过程分布 P_t 中抽取的相同且独立分布的示例。训练集包含 T 个子集 $\mathcal{D}_t \stackrel{i.i.d.}{\sim} P_t$ 。所有数据对于给定任务的单次（一次迭代）离线训练都是可用的，而其他任务的数据则无法访问。这里关注分类问题，因为分类是机器学习最成熟的任务之一，可以使用相对标准、简单的神经网络主干进行实现。在这种设置下，学习者的目标是通过最小化所有训练数据的目标来估计参数化预测器 $f(x, t; \theta) : \mathcal{X} \times \mathcal{T} \rightarrow \mathcal{Y}$ ，

$$\arg \min_{\theta} \frac{1}{T} \sum_{t=1}^T \mathbb{E}_{\mathcal{D}_t} [\mathcal{O}(\hat{y}_i^{ob}, y_i^{ob})], \quad (5-1)$$

其中涉及模型预测 $\hat{y}_i^{ob} = \text{softmax}(z_i)$ ，模型响应 $z_i = f_{\theta}(x_i^{ob}, t)$ 和目标函数 $\mathcal{O} : \mathcal{Y} \times \mathcal{Y} \rightarrow \mathbb{R}$ 。

5.2.3 记忆构建与计算方法

这一小节将分部分地阐述本章节之方法。首先本小节会对长短期记忆构建、管理与计算规则的实现方式进行展开，这部分内容的经验性结论将会对本文核心的模型构建产生技术上的支撑。随后，本小节将介绍与之配合的用于单次接触任务增量连续学习场景的神经网络学习策略，这部分使得本章除能够直接对所提出的方法进行有效性的评估。

基于诧异度的增量式记忆更新 在记忆的初始构建过程中，如何选择要保存在记忆缓存中的信息是计算实现该过程中的关键难题。本节提出了一种受生物记忆机制启发的解决方案，用于更新 Dual-MEM 中的短期记忆，本章称之为诧异度最大化更新（Surprise Maximization Updating, SMU）。神经科学的研究发现，对于生物体来说，对其内部认知分布 \hat{P} 的先验预测的冲突会增强对新颖的、惊奇内容的记忆^[55,308]。这种自然选择过程中产生的记忆策略与现有的机器学习解决方案中常用的在线困难样例挖掘（Hard Example

Mining) 策略有着相同的核心逻辑^[309-310]。为了模拟这一过程，首先使用 P_θ 来近似模型内部认知分布 \hat{P} ，这里的 P_θ 是一个由 θ 参数化的人工神经网络，其确定性映射由记号 f_θ 表示。本节采用贝叶斯诧异度^[54] (Bayesian Surprise, 下简称诧异度) 来定量地衡量生物体(由人工模型代替)先验预测和实际观察之间的差异。其具体表现为实际观察分布 $P_{\mathcal{D}_t}$ 和内部认知分布 \hat{P} (由 P_θ 近似) 间的 Kullback-Leibler (KL) 散度。对于给定的某一任务， $\arg \max \text{KL}(P_{\mathcal{D}_t} || P_\theta) = \arg \max H(P_{\mathcal{D}_t}, P_\theta)$ ，因为 $\text{KL}(P_{\mathcal{D}_t} || P_\theta) = H(P_{\mathcal{D}_t}, P_\theta) - H(P_{\mathcal{D}_t})$ ，并且在任务 t 存续期间， $H(P_{\mathcal{D}_t})$ 为一常数。即最大化 KL 散度 (即相对熵) 的过程可等效为最大化交叉熵的过程。因此，可以重新表述 SMU 过程的目标，并通过以下数学形式对其进行描述：

$$\begin{aligned} & \arg \max_{\mathcal{M}_{short}} \sum_{i=1}^{|\mathcal{M}_{short}|} \ell(\hat{y}_i^s, y_i^s), \\ & \text{s.t.}, (x_i^s, y_i^s, z_i^s) \in \mathcal{M}_{short} \end{aligned} \quad (5-2)$$

其中， $\hat{y}_i^s = \text{softmax}(f_\theta(x_i^s, t))$ ，而 ℓ 为交叉熵函数。然而，直接应用式 5-2 中描述的 SMU 会面临两个现实问题。其一，直接实现该目标需要访问整个数据分布 $P_{\mathcal{D}_t}$ ，这在本章采用的连续学习设定下是难以实现的。其二，该目标的实现需要在整个 \mathcal{M}_{short} 上估计期望，该过程的时间复杂度较大，特别是当 STM 的大小 $|\mathcal{M}_{short}|$ 不是很小的情况下。为了解决上述问题，本章提出了一种 SMU 的变体，称为增量式诧异度最大化更新 (Incremental Surprise Maximization Updating, ISMU)，用于近似式 5-2 所描述的目标。对于每次迭代，ISMU 的更新可以如下描述

$$\begin{aligned} \mathcal{M}_{short} & \leftarrow \mathcal{M}_{short} \setminus \mathcal{B}_{short} \cup \mathcal{A} \\ \mathcal{A} & \subsetneq (\mathcal{B}_{short} \cup \mathcal{B}_{ob}) \wedge |\mathcal{A}| = |\mathcal{B}_{short}| \wedge \mathcal{A} = \arg \max_{\mathcal{A}} \ell(\mathcal{A}), \end{aligned} \quad (5-3)$$

其中， \wedge 为逻辑与， \setminus 和 \cup 分别表示集合的减法和加法。特别地，本章从 \mathcal{M}_{short} 中随机抽样 \mathcal{B}_{short} ，从 \mathcal{D} 中抽样 \mathcal{B}_{ob} ，并计算 $\mathcal{B}_{ob} \cup \mathcal{B}_{short}$ 中所有样本的诧异度，即交叉熵。而在此过程中， \mathcal{B}_{short} 中诧异度较低的样本将被 \mathcal{B}_{ob} 中诧异度较高的样本替换。而当 \mathcal{B}_{short} 更新时， \mathcal{M}_{short} 也会同步更新。随着模型 f_θ 遍历的样本数量的增加， \mathcal{M}_{short} 将接近理想的 \mathcal{M}_{short}^* 。本章在算法 5.1 中总结了这一过程。

算法 5.1 诧异度最大化的增量记忆更新过程。

- 1: 输入: t, \mathcal{M}_{short}
- 2: 输入: ℓ_{ob}, ℓ_{short}
- 3: 输入: $\mathcal{B}_{ob} = \{(x_i^{ob}, y_i^{ob})\}_{i=1}^B$
- 4: 输入: $\mathcal{B}_{short} = \{(x_j^s, y_j^s, z_j^s)\}_{j=1}^B$
- 5: **while** $\min_j \ell(\hat{y}_j^s, y_j^s) < \max_i \ell(\hat{y}_i^{ob}, y_i^{ob})$ **do**
- 6: $m \leftarrow \arg \min_j \ell(\hat{y}_j^s, y_j^s)$
- 7: $n \leftarrow \arg \max_i \ell(\hat{y}_i^{ob}, y_i^{ob})$
- 8: $\mathcal{B}_{short}[m] \leftarrow (x_n^{ob}, y_n^{ob}, f_\theta(x_n^{ob}, t))$
- 9: **end while**
- 10: update \mathcal{B}_{short} to \mathcal{M}_{short}
- 11: **return** \mathcal{M}_{short}

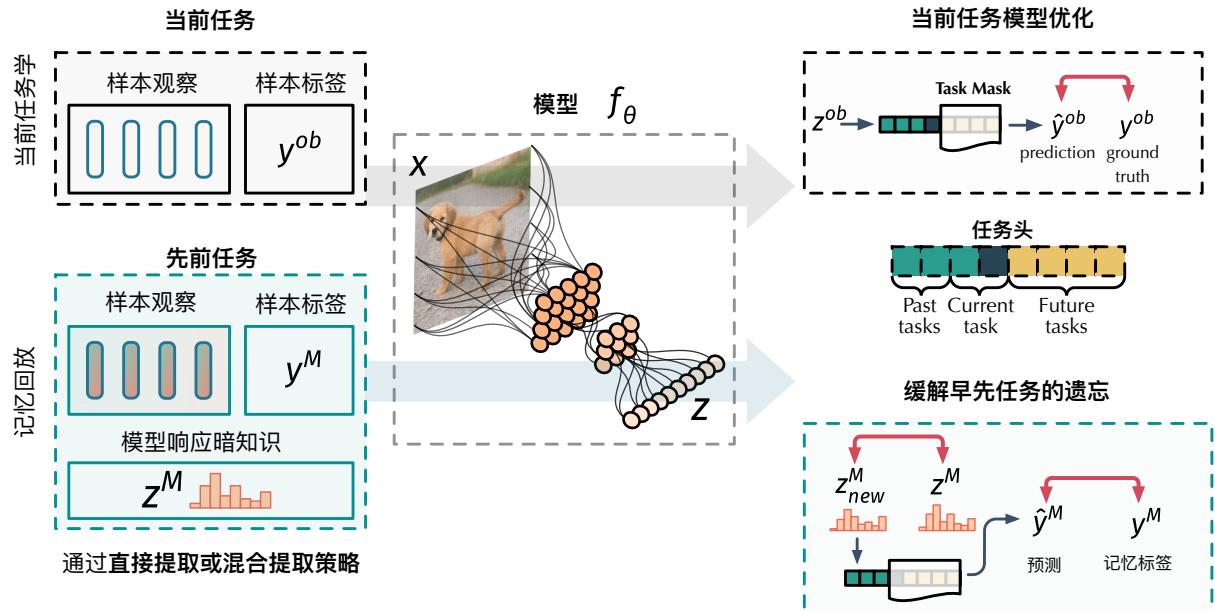
记忆巩固过程 巩固是一种基本的记忆构建与计算过程，它将短期记忆 (STM) 与长期记忆 (LTM) 切实地关联起来^[56,311-312]。现有的神经科学对记忆巩固的研究成果，为本章通过计算来实现记忆巩固提供了理论基础与灵感来源。有研究表明，在记忆巩固过程中，海马体的激活水平逐渐下降，与此同时前额叶区域的激活则逐渐增强^[313]。这一观察暗示了记忆巩固过程中的存在功能区域的转移，也启发了本章应当如何使用简化的计算实现来模拟巩固过程。具体而言，本章介绍的方法，将记忆巩固概括为从短期记忆到长期记忆的记忆内容的数据传输，也就是知识转移的过程。在经历了当前任务的所有样本后， \mathcal{M}_{short} 中的所有记忆内容都将被转移到 \mathcal{M}_{long} 。此外，受到短期记忆中的信息在记忆巩固过程中会逐渐被清除以腾出容量来存储更新的记忆^[314]的启发，本章在计算实现中模拟了上述的记忆清除过程。具体而言，可以将记忆巩固表述为

$$\begin{aligned} \mathcal{M}_{long}^{1:t} &\leftarrow \mathcal{M}_{long}^{1:t-1} \cup \mathcal{M}_{short} \\ \mathcal{M}_{short} &\leftarrow \emptyset, \end{aligned} \tag{5-4}$$

其中 $\mathcal{M}_{long}^{1:t}$ 表示在任务 t 结束时累积的长期记忆。并且 \mathcal{M}_{long} 的容量与 \mathcal{M}_{short} 的容量成比例，也即

$$|\mathcal{M}_{long}^{1:T}| = T \times |\mathcal{M}_{short}|, \tag{5-5}$$

其中 T 是当前经历的任务数量，这是一种直观的整合策略，且不会引入额外的计算，一旦本章验证了这一策略的有效性，它可以容易地被细化、复杂化为更精确的实现形式。



* ob 上标为观测样本, M 为来自记忆之样本.

图 5-3 基于本章介绍的记忆构建、计算过程的连续学习过程示意。其完整的流程主要包括针对当前任务的参数优化和通过使用从记忆缓存中提取记忆和模型响应信息进行回放来减轻遗忘的步骤。

5.2.4 基于记忆构建与计算方法的连续学习

本节中介绍的学习规则描述了在本章的连续学习任务场景下，神经网络如何与记忆进行交互以更新突触权重，特别是如何提取和回放缓存中的记忆（见图 5-3）。记忆提取过程描述了如何处理来自 STM 和 LTM 的记忆，并将其作为整体（或部分）参与到后续模型参数更新，也就是学习的过程中。本节中，主要介绍了两种类型的学习方式：直接提取（Direct Retrieval, DR）学习和混合提取（Mixup Retrieval, MR）学习。这两种学习方法，部分参考了清醒时记忆回放^[315-316]的已有研究，也就是同时进行新的观察接收和记忆重放过程。为了减少对相同观测样本的模型响应的不稳定性，本节额外考虑了模型

响应暗知识^[317]作为记忆的重要组成部分。在此基础上，在本节的最后引入了一个模型响应暗知识损失项以实现进一步的模型正则化。

直接记忆提取学习 本节介绍了一种直观可行的学习方法，即直接从长期记忆中提取、检索信息，并在长期和短期记忆的并集上进行模型训练，这是一种实用的从记忆中学习方式；本章将这种策略称为直接记忆提取学习（Direct Retrieval Learning, DRL）。DRL 是一种简单而有效的与本章介绍的双重记忆模块配合的学习方法。除了形式上简洁之外，其所涉及到的记忆提取和合并过程也并不需要额外的计算成本。在 DRL 中，神经网络 f_θ 使用来自当前任务 t 的观察流的样本，STM 的样本，以及 LTM 中前 $t-1$ 个任务的样本进行优化。在每次迭代中抽取小批量（批量大小为 B ）作为 $\mathcal{B}_{ob} \sim \mathcal{D}_t$, $\mathcal{B}_{long} \sim \mathcal{M}_{long}$ 和 $\mathcal{B}_{short} \sim \mathcal{M}_{short}$ 进行模型参数优化。使用 $\mathcal{B}_{short}, \mathcal{B}_{ob}$ 计算的交叉熵也用于 ISMU 更新，这进一步减少了额外的计算开销。这里的 STM 会议过程相当于自助法^[318]（Bootstrapping），它从 \mathcal{D}_t 中重新抽样。在本章考虑的单次接触任务增量连续学习设置下，短期记忆（当前任务记忆）回放可以帮助进一步高效学习当前任务并最终提高整体性能。使用权重因子 λ_{short} 以平衡在模型优化过程的 STM 回忆强度。同时，该学习过程也会回放保存在 \mathcal{M}_{long} 中的先前任务的样本，以在任务序列上持续缓解灾难性遗忘。本章将 DRL 过程的目标函数形式化如下

$$\begin{aligned}\mathcal{L}_{DR} &= \mathcal{L}_{ce}(\mathcal{B}_{ob} \cup \mathcal{B}_{long}) + \lambda_{short} \cdot \mathcal{L}_{ce}(\mathcal{B}_{short}) \\ &= \mathbb{E}_{\mathcal{B}_{ob} \cup \mathcal{B}_{long}} \ell(\hat{y}, y) + \lambda_{short} \cdot \mathbb{E}_{\mathcal{B}_{short}} \ell(\hat{y}, y)\end{aligned}\tag{5-6}$$

此处将使用 \mathcal{B}_{ob} 、 \mathcal{B}_{short} 和 \mathcal{B}_{long} 计算得到的梯度分别记为 g_{ob} 、 g_{short} 和 g_{long} 。在一些早期工作，如 GEM^[271]中，研究者采用了一个修正后的梯度 \tilde{g}_{ob} 来更新模型参数 θ ，该梯度与在采样集 \mathcal{B}_{long} 上计算的梯度 g_{long} 正交。而在 DRL 中，使用 g_{ob} 、 g_{short} 和 g_{long} 的加权平均来计算参数空间中的更新步骤。相比于平均后的梯度，梯度 g_{short} 更激进地鼓励更新步指向模型参数空间中当前任务的损失更小的位置，而 g_{long} 项则有助于防止模型 θ 过度远离在之前任务的学习过程中找到的使先前任务损失局部最小的位置。

混合记忆提取学习 作为直接记忆提取策略的替代方案，本小节探索了另一种可以用于 Dual-MEM 模型学习的方法。具体来说，本节提出了一种受 Mixup 算法^[319]启发的

记忆提取策略和相应的学习规则。本章将这种学习策略称为混合记忆提取学习（Mixup Retrieval Learning, MRL）。原始的 Mixup 算法提供了一种无需先验知识的数据增强方式，即通过线性插值进行扩增^[320-321]

$$\tilde{x} = \gamma x_i + (1 - \gamma)x_j, \quad \tilde{y} = \gamma y_i + (1 - \gamma)y_j \quad (5-7)$$

其中， $\gamma \sim \text{Beta}(\alpha, \alpha)$ ， $\alpha \in (0, \infty)$ 。而参数 α 控制了样本-标签对之间插值的强度。参考 Mixup 中的线性插值操作，本节通过相同的方式来自混合提取短期和长期记忆。具体而言，对于来自 STM 和 LTM 的样本-标签对 $(x_j^s, y_j^s) \sim \mathcal{M}_{short}$ ， $(x_i^l, y_i^l) \sim \mathcal{M}_{long}$ ，混合记忆提取的实现可以被描述为下式

$$\tilde{x} = \gamma x_i^l + (1 - \gamma)x_j^s, \quad \tilde{y} = \gamma y_i^l + (1 - \gamma)y_j^s \quad (5-8)$$

这里的短期和长期记忆样本之间的线性插值可以被解读为一种联合训练的表现形式。与上文中介绍的 DRL 不同，MRL 并没有明确指定单独的损失项权重因子 λ 。具体来说，当 $\alpha \rightarrow 0$ 时，从概率密度函数 $p_\gamma = \frac{\Gamma(2\alpha)}{\Gamma(\alpha)^2} x^{\alpha-1} (1-x)^{\alpha-1}$ (Γ 表示 Gamma 分布) 的 Beta 分布中采样的插值因子 γ 很可能是 1 或 0。此时，混合提取策略将会退化为

$$\begin{cases} \tilde{x} = x_j^s, \quad \tilde{y} = y_j^s, & \text{if } \gamma = 0 \\ \tilde{x} = x_i^l, \quad \tilde{y} = y_i^l, & \text{if } \gamma = 1 \end{cases} \quad (5-9)$$

这等效于单纯进行 STM 回放 ($\gamma = 0$) 或是 LTM 回放 ($\gamma = 1$)。直观来说，较小的 α 大致对应于短期和长期记忆交替回放的学习策略。一般来说，从 Beta 分布中采样的系数 α 决定了记忆提取过程的具体实现方式，从而间接地影响了回放的效果。因此，MRL 是选择性地以随机方式重组和回放记忆，而不是像在 DRL 中那样回放所有记忆。在 MRL 中，使用观察数据和混合提取得到的记忆来优化模型 f_θ 。在每次迭代中抽取小批量（批大小为 B ）作为 $\mathcal{B}_{ob} \sim \mathcal{D}_t$ ， $\mathcal{B}_{long} \sim \mathcal{M}_{long}$ 和 $\mathcal{B}_{short} \sim \mathcal{M}_{short}$ 。从 LTM 批中的每个样本 (x_i^l, y_i^l) 与从 STM 中随机选择的样本 (x_j^s, y_j^s) 使用式 5-8 的形式进行混合，这里将混合样

本的批记作 $\tilde{\mathcal{B}}_{mem}$ 。整个 MRL 过程的目标函数可以通过下式表述

$$\begin{aligned}\mathcal{L}_{MR} &= \mathcal{L}_{ce}(\mathcal{B}_{ob} \cup \tilde{\mathcal{B}}_{mem}) \\ &= \mathbb{E}_{\mathcal{B}_{ob} \cup \tilde{\mathcal{B}}_{mem}} \ell(\hat{y}, y)\end{aligned}\quad (5-10)$$

基于神经响应暗知识的正则化 对于 DRL 和 MRL，本章介绍的方法不仅保持预测标签在整个学习过程中的一致性，还鼓励模型保持神经响应的稳定性。本小节引入了一个基于响应暗知识^[317] 的正则化项 \mathcal{L}_{dkr} ，该正则项以 LTM 为介质来模仿更细粒度的记忆回放机制。该机制力求保持模型对于同一样本的神经响应状态的稳定性^[295]。换言之，增加的正则化项鼓励模型在任务 t 的学习过程中，匹配旧模型 $\{f_{\theta_k}\}_{k=1}^{t-1}$ 的模型响应暗知识 z ，以增加模型的稳定性并进一步减轻遗忘。特别地，本章将暗知识正则化项定义为从 LTM \mathcal{M}_{long} 提取的模型响应 z^l 与当前响应值 $f_{\theta_t}(x, t)$ 之间的 KL 散度

$$\mathcal{L}_{dkr} \triangleq \mathbb{E}_{\mathcal{B}_{long}} \text{KL}(z_i^l || f_{\theta_t}(x_i^l, t)), \quad (5-11)$$

这里， $\mathcal{B}_{long} \stackrel{B}{\sim} \mathcal{M}_{long}$ ，其中 B 表示批的大小。这种方式也与机器学习技术软目标^[322] (Soft Target) 相关，也即硬标签 (Hard Target) 被训练模型生成的软目标替换。该方式形式上也与自蒸馏^[323] (Self Disillation) 相联系。在常规的蒸馏过程中，一组相同的神经网络通过模型间的互监督实现知识的蒸馏转移。然而，与软目标方法不同，本节的正则化方法中，先前的响应值 z_i^l 并不是用来替代独热编码的目标向量 y_i ，而是提供额外的正则化。此外，尽管形式上与自蒸馏相似，本节使用从 f_{θ} 的过去的自身中提取的模型响应 z_i^l 来计算给定当前模型 f_{θ} 的 \mathcal{L}_{dkr} 值，而不是通过额外的教师模型来获取。完整的优化带有暗知识正则化器 \mathcal{L}_{dkr} 的 Dual-MEM 模型的总体目标是最小化双重记忆学习 $\mathcal{L}_{dual} \in \{\mathcal{L}_{DRL}, \mathcal{L}_{MRL}\}$ 和 \mathcal{L}_{dkr} 的加权和：

$$\theta^* \leftarrow \arg \min_{\theta} \mathcal{L}_{dual} + \lambda_{dkr} \cdot \mathcal{L}_{dkr} \quad (5-12)$$

这里的 λ_{dkr} 是一个用于平衡主要目标和暗知识正则化器的超参数。本节在算法 5.2 中总结了上述的优化过程。相应地，这里除了真实目标向量 $y \in \mathcal{Y}$ ，还需要保存模型神经响

应向量 $z \in \mathbb{R}^{1 \times |\mathcal{Y}|}$:

$$\begin{aligned}\mathcal{M}_{short} &= \{(x_i^s, y_i^s, z_i^s)\}, \\ \mathcal{M}_{long} &= \{(x_j^l, y_j^l, z_j^l, t)\}.\end{aligned}\tag{5-13}$$

这增加了一些内存开销，也即 $|\mathcal{Y}| \times |\mathcal{M}_{long}|$ 个浮点数。然而，与来自高维观察空间的样本 x 的缓存相比，这是微不足道的。此外，计算这个正则项并不会产生显著的额外计算和存储开销，因为模型响应已经在 \mathcal{B}_{long} 的回放过程中保存或计算，并且也不需要存储包含数十、上百万参数的先前模型快照 $\{f_{\theta_k}\}_{k=1}^{t-1}$ 。

算法 5.2 长短期双重记忆参与下的神经网络连续学习。

```

1: 输入:  $\theta, \mathcal{D}_t, \mathcal{M}_{short}, \mathcal{M}_{long}$ 
2: 输入:  $B, K$ 
3: 输入:  $\eta$ 
4: 输入:  $\lambda_{short}, \lambda_{dkr}$ 
5: for  $t = 1$  to  $T$  do
6:   for  $k = 1$  to  $K$  do
7:      $\mathcal{B}_{ob} \xrightarrow{B} \mathcal{D}_t, \mathcal{B}_{short} \xrightarrow{B} \mathcal{M}_{short}, \mathcal{B}_{long} \xrightarrow{B} \mathcal{M}_{long}$ 
8:      $\ell_{ob} \leftarrow \ell(\mathcal{B}_{ob})$ 
9:      $\ell_{short} \leftarrow \ell(\mathcal{B}_{short})$ 
10:     $\mathcal{M}_{short} \leftarrow \text{ISMU}(\mathcal{M}_{short})$ 
11:    if using DRL then
12:       $\ell_{long} \leftarrow \ell(\mathcal{B}_{long})$ 
13:       $\mathcal{L}_{dual} \leftarrow \ell_{ob} + \ell_{long} + \lambda_{short} \cdot \ell_{short}$ 
14:    else
15:       $\tilde{\mathcal{B}}_{mem} \leftarrow \text{mixup}(\mathcal{B}_{short}, \mathcal{B}_{long})$ 
16:       $\mathcal{L}_{dual} \leftarrow \ell_{ob} + \ell(\tilde{\mathcal{B}}_{mem})$ 
17:    end if
18:     $\theta \leftarrow \theta - \eta \nabla_{\theta} (\mathcal{L}_{dual} + \lambda_{dkr} \cdot \mathcal{L}_{dkr})$ 
19:  end for
20:  Consolidate  $\mathcal{M}_{short}$  to  $\mathcal{M}_{long}$ 
21:  Re-initialize  $\mathcal{M}_{short}$ 
22: end for
23: return  $\theta$ 
```

表 5-1 本章节实验使用的测试基准一览。

测试基准	数据源	样本维度	任务量	任务规模	样本量	
					训练集	测试集
CIFAR-100	CIFAR-100	$3 \times 32 \times 32$	20	5 类	5×10^4	1×10^4
CIFAR-100 T10	CIFAR-100	$3 \times 32 \times 32$	10	10 类	5×10^4	1×10^4
CIFAR-100 T5	CIFAR-100	$3 \times 32 \times 32$	5	20 类	5×10^4	1×10^4
Mini ImageNet-100	Mini ImageNet	$3 \times 84 \times 84$	20	5 类	5×10^4	1×10^4
Tiny ImageNet-100	Tiny ImageNet	$3 \times 64 \times 64$	20	5 类	5×10^4	5×10^3
Tiny ImageNet-200	Tiny ImageNet	$3 \times 64 \times 64$	20	10 类	1×10^5	1×10^4
Tiny ImageNet-200 T10	Tiny ImageNet	$3 \times 64 \times 64$	10	20 类	1×10^5	1×10^4
Tiny ImageNet-200 T5	Tiny ImageNet	$3 \times 64 \times 64$	5	40 类	1×10^5	1×10^4

5.3 实验结果

本节的实验中，所有待评估的方法均采用了相同的简化的 ResNet-18 网络架构^[271]。在未有特殊说明的情况下，所有方法都在单次接触任务增量终身学习设置下从随机初始化开始通过误差反向传播^[91]进行优化（使用训练集进行训练），并在相应的测试集上进行评估。本章通过网格搜索为所有方法找到其最优的超参数，并在结果中它们的最佳性能。本章将带有直接记忆提取学习、混合记忆提取学习的 Dual-MEM 分别记作 Dual-MEM-DR、Dual-MEM-MR。对于 Dual-MEM-DR 和 Dual-MEM-MR 方法涉及到的实验，在 Tiny-ImageNet 和 Mini-ImageNet 测试基准上本章使用的批大小为 10。对于 CIFAR-100 系列测试基准上的实验，则将批大小减少到 5，以确保学习过程中有足够的更新迭代次数（因为所有样本只接触一次）。这里为 Dual-MEM 实验采用固定的学习率。具体地，对于 CIFAR-100、Tiny ImageNet-100 和 Tiny ImageNet-200 的基准上进行的实验，学习率 $\eta = 0.01$ ，而对于 Mini ImageNet-100，学习率 $\eta = 0.005$ 。本节实验的 Dual-MEM-DR 方法均采用 $\lambda_{short} = 5 \times 10^{-4}$ ，而在 CIFAR-100 和 Tiny ImageNet-100 上采用 $\lambda_{dkr} = 0.3$ ，在 Tiny ImageNet-200 和 Mini ImageNet-100 的基准测试中采用 $\lambda_{dkr} = 0.7$ 。对于 Dual-MEM-MR 方法，本章在所有基准测试中采用 $\lambda_{dkr} = 1$ 。

实验数据与测试基准 本章考虑了多种复杂程度、任务规模的测试基准，以评估基于本章的记忆构建计算机制的连续学习方法。这些测试基准是使用多个原始数据集构建的，本章将它们的详细信息在表 5-1 中进行了总结。首先，本章使用了 CIFAR-100^[272] 数据集，该数据集包含 6×10^4 张 32×32 像素的彩色图像，共有 100 个类别。每个类别包含 600 个样本，被划分为两个不相交的子集（分别用于训练和测试评估的 500 和 100 个样本）。为了构建一个平衡的数据集，本章在任务序列中为每个任务分配 5/10/20 个随机选择的类别（参见表 5-1）。这种设置使本章除能在任务序列上评估不同的连续学习方法，同时确保所有任务都是相似的。第二个数据集是 Tiny ImageNet^[324]，它包含来自 ILSVRC^[325] 的 200 类的 1×10^5 张彩色图像；每个类别有 500 个训练样本和 50 个测试样本。所有图像都被下采样到 64×64 。为了构建不同任务长度的基准测试，本章将原始数据集划分为 20/10/5 个不相交的任务，每个任务有 10/20/40 个随机选择的类别。此外，从原始的 Tiny ImageNet 数据集中抽取一个 100 类的子集，以构建一个更简单的 20 任务基准测试（记作 Tiny ImageNet-100）。第三，本章采用了 Mini ImageNet 数据集^[326]，这是一个从原始 ImageNet 中下采样的子集，总共有 100 个类别和每类 600 个图像，该集合被划分为 20 个不相交的任务。

性能评估指标 本章使用平均准确率 (Acc)、前向 (Fwt)、后向知识转移 (Bwt) 指标（下简称前、后向转移）来衡量终身学习的性能^[271]。Acc 衡量了所有任务的平均准确率，而 Bwt 量化了平均相对性能的下降 (< 0 , 即所谓的知识遗忘) 或提升 (> 0)。Bwt 的值与模型在学习当前任务后的测试集性能有关，并取决于准确率指标。前向转移则是量化了学习任务 t 对未来任务性能的影响；特别是，当模型能够利用任务结构或是跨任务的通用知识时，都可能表现为正的 Fwt 值。定义记号 $A_{T,t}$ 为在学习了 T 个任务后，任务 t 的平均准确率，那么平均准确率、后向转移和前向转移定义如下：

$$\begin{aligned} \text{Acc} &= \frac{1}{T} \sum_{t=1}^T A_{T,t}, \\ \text{Bwt} &= \frac{1}{T-1} \sum_{t=1}^{T-1} A_{T,t} - A_{t,t}, \\ \text{Fwt} &= \frac{1}{T-1} \sum_{t=2}^T A_{t-1,t} - b_t, \end{aligned} \tag{5-14}$$

其中, b_t 表示随机初始化的神经网络模型(初始状态)的测试准确率。上述这些性能指标的值越大, 方法的连续学习性能就越好。如果两种方法可以达到类似的 Acc 指标, 那么其中 Bwt 和 Fwt 较大的方法是更优的。

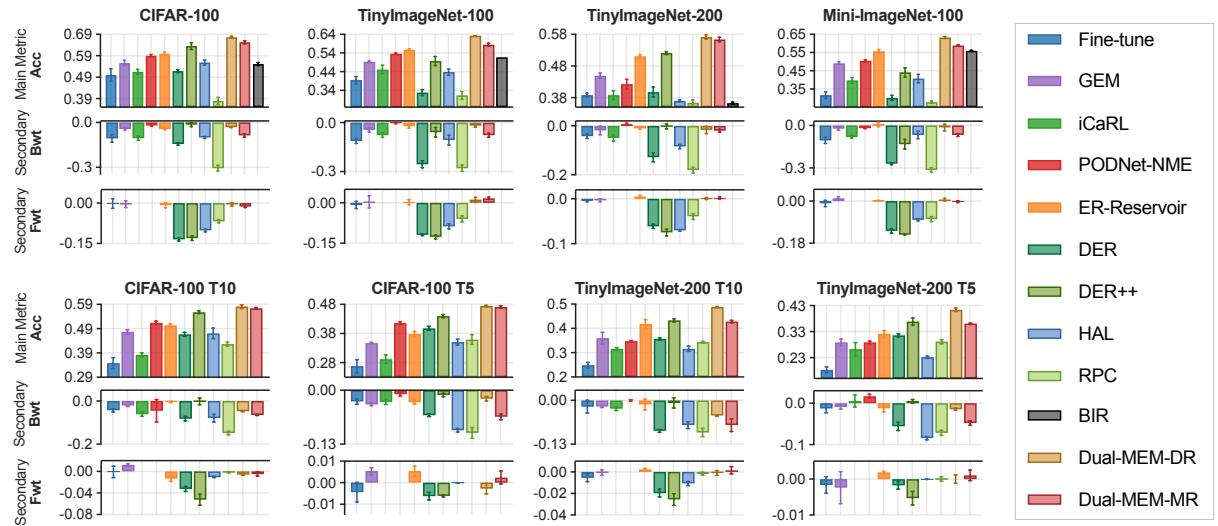


图 5-4 八种测试基准的 Acc, Bwt 以及 Fwt 评估结果。本章采用主要指标平均准确率 Acc 来衡量最终表现, 而次要指标 Bwt/Fwt 来量化学习过程中的相对知识转移。为不同任务分配独立参数组的方法在这里统一记作 0Bwt。本章采用 $|\mathcal{M}|_{\text{per cls}} = 5$ 作为所有基于记忆的方法的默认值。

用于评估的基线方法 这里将本章介绍的以记忆构建与计算为核心的连续学习方法 Dual-MEM 与以下基线方法或模型进行对比:

- 朴素微调 (Fine-tune) 方法, 即在任务序列上连续微调神经网络模型。此方法从前一个任务学习到的模型参数开始, 继续进行当前任务的优化。
- GEM^[271] 是一种使用记忆缓存的基于正则化的方法。它通过在由先前任务梯度概述的可行域上投影估计的梯度方向, 以实现对先前任务的干扰较小的模型参数更新。
- iCaRL^[272] 使用最近的样本均值 (Nearest Mean Example, NME) 策略进行分类, 并通过额外的知识蒸馏损失项在特征空间中进行正则化以避免灾难性遗忘。

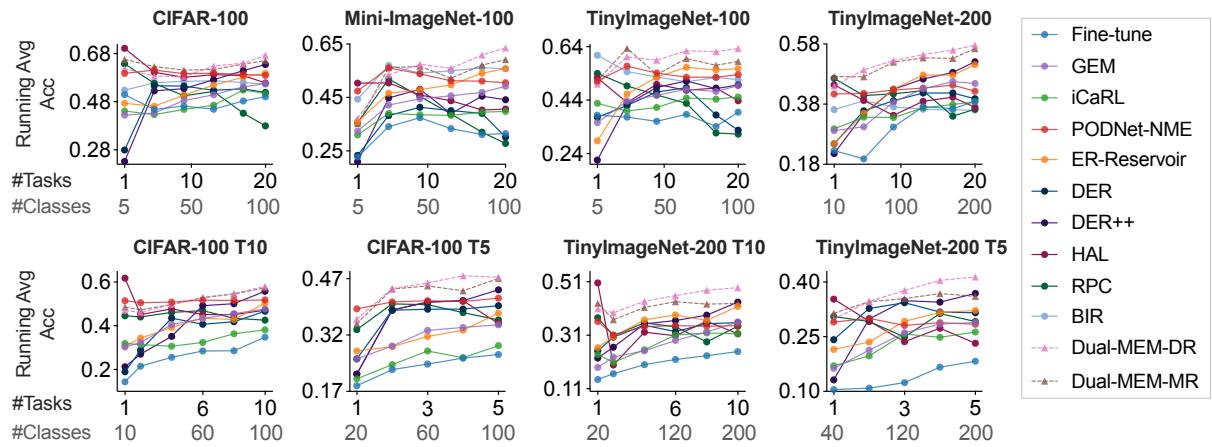


图 5-5 连续学习过程中的 Acc 指标变化。该图展示了在本章默认的单次接触任务增量设置下，12 种方法在 8 个基准测试上的移动平均 Acc 动态，也即此处的 Acc 是基于迄今为止所有已经历的任务的平均 Acc。默认 $|\mathcal{M}|_{\text{per cls}} = 5$ 。

- PODNet-NME^[327] 通过快照存储连续学习过程中先前的模型参数来进行跨时间的模型蒸馏，以减轻遗忘现象。
- ER-Reservoir^[296] 是一种具有蓄水池采样（Reservoir Sampling）记忆缓存更新的真实记忆回放方法。
- Bir^[295] (Brain-inspired Replay) 通过 VAE 生成器实现条件化的内部生成式记忆回放（伪样本回放），在学习每个任务时，激活模型中不同的神经元子集。
- DER, DER++^[328-329] 是基于暗知识记忆回放的方法，同时结合了直接的记忆回放和平衡模型激活值的蒸馏技术。
- HAL^[297] 通过新的锚点样本来补充常规的记忆回放过程。模型使用双循环的优化过程来更新任务统计信息和模型参数。
- RPC^[330] 方法构建了一个具有多个预分配的输出节点的分类器，这些节点从训练之初就受到分类损失的影响，这些节点通过 N-单纯形进行初始化计算。

此外，参与对比试验评估的本章介绍的方法为：

- Dual-MEM-DR 使用 Dual-MEM 模型架构，包括主要的神经网络模型和长短期记忆组成的双重记忆系统，Dual-MEM-DR 的模型学习策略为直接记忆提取学习。

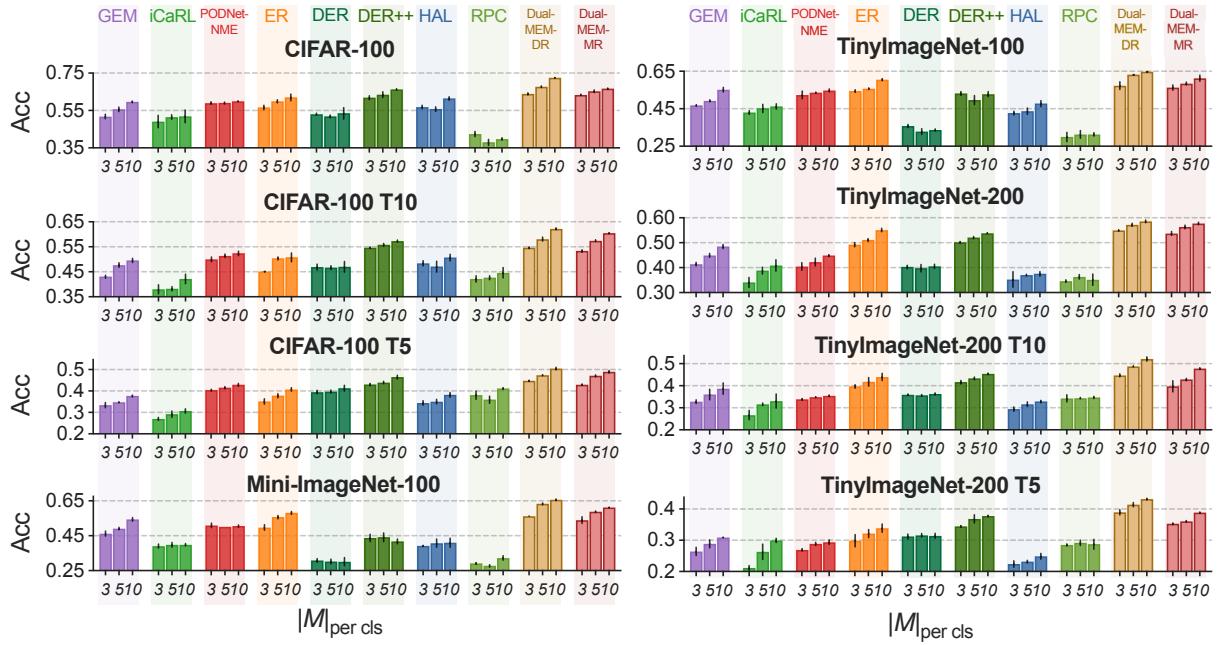


图 5-6 不同记忆容量下的性能表现。本章展示了 $|\mathcal{M}|_{\text{per cls}} \in \{3, 5, 10\}$ 容量下基于记忆的方法的 Acc 性能指标。

- Dual-MEM-MR 具有与 Dual-MEM-DR 相同的架构设置，并通过混合记忆提取学习进行优化。

首先将本章介绍的 Dual-MEM 系列方法与基线进行性能比较。为此，本章报告了在各种测试基准上获得的性能结果；所有方法都在单次接触任务增量连续学习设置下进行训练。特殊地，对于 Bir 方法，其包括一个生成器网络，需要更多的迭代更新来产生理想的模型表征，因此这里沿用了原文献中的实现^[295] 的训练超参数即训练过程。对于用到记忆缓存的方法，其缓存容量被统一为 $|\mathcal{M}|_{\text{per cls}}$ ，其定义如下 $|\mathcal{M}|_{\text{per cls}} = \frac{|\mathcal{M}|_{\text{per task}}}{N_{\text{class per task}}}$ 。除了最终状态的性能指标结果外，在图 5-5 中展示了学习过程中的移动平均 Acc，以更直观地比较不同方法在整个过程中的性能动态。在八种测试基准的实验中，大多数方法都成功减少了学习过程中的遗忘。图 5-4 全面展示了本节对比实验的主要结果。特别是，在所有测试中，Dual-MEM 方法在报告更小的负 Bwt（实现最小遗忘）的同时，实现了 Acc 的显著提升。此外，本节的实验使用了来自同一源数据不同划分（例如，CIFAR-100 和 CIFAR-100 T10/T5）的测试基准，以评估不同任务规模下的方法性能。根据图 5-4 中的结果，当单个任务的规模上升时，大多数方法的 Fwt 指标都有所提高，这表明模型在

单个任务学习过程中积累了更多的通用知识。同时，增加序列中的任务数量会加剧遗忘现象，然而，本章介绍的 Dual-MEM 系列方法仍然在如此具有挑战性的测试基准测试中取得不俗性能，展现出相比于一众基线方法的稳定优势。

尽管常规的记忆回放方法 ER 成功地缓解了连续学习过程中的遗忘现象，但其记忆构建与计算过程的实现仍是相对粗糙的，因而无法充分发挥以记忆为核心的连续学习方法的潜能。通过额外引入一个生成模型^[331]，或许能够部分地解决这个问题，因为这使得回放过程可以通过条件化变得更为精细和复杂。然而，仍值得一提的是，训练这样的生成模型本身也是一个具有挑战性的问题。特别是，在实验中作者观察到，尽管 Bir 方法经过更多迭代的训练，但仍落后于它的一些竞争者。本章的实验结果表明，Dual-MEM-DR 的性能更为稳定。相对于 CIFAR-100、Tiny ImageNet-100/200 和 Mini ImageNet-100 上的性能最佳的基线方法，Dual-MEM-DR 的 Acc 指标分别提升了 11.0%、12.8%、11.7%、8.4%。此外，相比于朴素的 Fine-tune 在 CIFAR-100、Tiny ImageNet-100/200 和 Mini ImageNet-100 上的表现，Dual-MEM-DR 将相对遗忘（由负 Bwt 表示）分别降低了 70.2%、82.9%、84.0%、89.8% 之多。然而本章也观察到，尽管在准确度指标方面表现较为抢眼，但结合 MRL 的 Dual-MEM 模型的 BWT 指标相对较高。由于 MRL 使用基于采样的线性插值来实现记忆提取过程，因此不能保证像 DRL 策略那样精确地回放先前任务的原始样本。因此，混合检索策略提高了当前任务的学习效率，但可能会叫弱地保留对先前任务的知识。作为证据，在图 5-5 中，在任务序列的前几个任务中，Dual-MEM-MR 的平均 Acc 比 Dual-MEM-DR 方法更高。总体而言，本章的实验结果表明 Dual-MEM 方法相较于其他同样以记忆回放为核心的方法具有显著优势。

对于规模相对小的测试基准（例如使用 CIFAR-100 数据构建的基准），神经网络在训练集中只完成了少数任务的学习后就可以达到较高的测试性能。另一方面，对于更复杂的测试基准，如基于 Tiny ImageNet 数据的基准，神经网络能够在较长的过程中持续积累通用知识，这使得移动平均 Acc 显示出持续上升的趋势。因此，这一连续的学习过程涉及到抵抗遗忘和收集通用信息。PODNet 和 Bir 在任务增量学习过程中表现出稳定的性能，主要归因于它们的参数分置的策略，同时也导致了图 5-4 所展示的不俗 Bwt 性能。然而，使用任务特定的参数也阻碍了任务间通用知识的积累，导致在学习若干任务后其 Acc 的提升微乎其微（准确率曲线的斜率小）。此外，本章注意到 Dual-MEM-DR/MR 在学习了少量的任务后就可以达到较高的性能，并且，随着新任务不断出现，其性能仍能

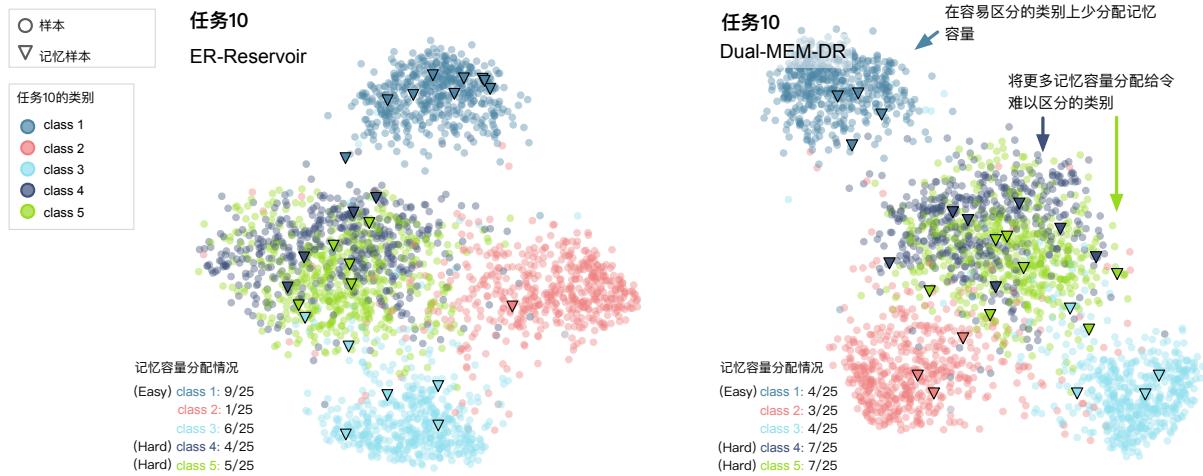


图 5-7 使用 ER-Reservoir、Dual-MEM-DR 方法，在 $|\mathcal{M}|_{\text{per cls}} = 5$ 下得到的 CIFAR-100 基准任务特征空间中记忆样本点的 t-SNE 可视化。在特征空间中，本章介绍的 ISMU 更新策略倾向于记接近决策边界（类的聚类边缘）的观察样本。相比之下，基线方法抽样记忆的样本分布是随机的。此外，ISMU 倾向于为具有挑战性的类分配更多的记忆容量，以更好地保留该任务的知识结构。

有提高，这表明 Dual-MEM 方法具有很高学习效率。

本节进一步评估了在不同内存大小（记忆容量）下，基于记忆的方法的性能变化。尽管回放记忆的数据可以缓解遗忘现象，然而其具体效果与记忆容量是密切相关的，且在实际场景中，该记忆容量不能非常大。因此，本章希望连续学习方法能够在更小的记忆容量预算下实现具有竞争力的性能。由于待评估的方法采用了不同的内存分配策略（按类存储或按任务存储），此处我们统一以每类别容量来表示记忆容量的大小，以进行公平比较。图 5-6 展示了在不同内存预算下的不同方法的 Acc 性能。本章介绍的 Dual-MEM-DR/MR 方法在所有记忆容量设定下的评估基准上，都显著提高了记忆的使用效率。此外，对于 Dual-MEM-MR 方法而言，增加记忆容量所获得的性能提升不如 Dual-MEM-DR 显著。这里推测这是由采样操作引入的额外随机性的结果，这一过程可能阻碍模型直接从更大的记忆容量中受益。在 Dual-MEM 中，我们使用了受大脑启发的修改来改进在记忆回放过程中对记忆内容的使用，这能够实现更有效的记忆信息利用来帮助学习并减少遗忘。进一步的对照实验证实了这一直觉。这里观察到，具有更小记忆容量的 Dual-MEM-DR ($|\mathcal{M}|_{\text{per cls}} = 3$) 的性能超过了许多具有更大记忆容量的竞争者 ($|\mathcal{M}|_{\text{per cls}} = 5, 10$)。具体而言，本章介绍的 ISMU 更新策略记忆的样本点可能更好地

表 5-2 本章介绍的记忆构建（更新）策略的有效性验证实验结果。

测试基准	保留 ISMU	去除 ISMU
CIFAR-100	0.638±0.006	0.599±0.008
Tiny ImageNet-100	0.584±0.007	0.558±0.004
Tiny ImageNet-200	0.516±0.006	0.511±0.006
Mini ImageNet-100	0.577±0.006	0.561±0.010
CIFAR-100 T10	0.545±0.005	0.514±0.006
CIFAR-100 T5	0.440±0.008	0.388±0.011
Tiny ImageNet-200 T10	0.427±0.003	0.418±0.019
Tiny ImageNet-200 T5	0.364±0.007	0.322±0.013

描述了任务知识结构。本章比较了使用和不使用 ISMU 更新的方法的性能表现。表 5-2 中列出的结果显示，使用 ISMU 更新策略的方法在所有评估基准上都展现出一致的优越性。此外，本章在图 5-7 中展示了特征空间中记忆样本点的 t-SNE^[332] 可视化，以直观展现记忆样本点在模型特征空间中的绝对位置和相对关系。结果表明本章介绍的记忆更新策略可以更好地保留任务知识结构，这有利于通过后续的记忆回放来缓解遗忘现象。

本章研究了不同平衡因子值的选择如何影响本章介绍的方法在 CIFAR-100 和 Tiny ImageNet-200 测试基准上的性能表现。在图 5-8 中展示的结果表明，Dual-MEM-MR 方法对 λ_{dkr} 非常鲁棒。而对于 Dual-MEM-DR 方法，其性能对于不同值的 λ_{dkr} 较为稳定。对于较为复杂的测试基准，更大的取值对性能更有益；而对于简单的测试基准，较小的取值效果更好。此外， λ_{short} （短期记忆回放的权重因子）需要维持在一个较低的取值范围内，以避免在学习新任务时过度约束模型从而影响整体性能表现。

本节还使用 CIFAR-100 T10 和 T5 测试基准对具有代表性的基于长短期双重记忆的方法（IL2M^[302]，SCoMMER^[303]）进行了对比。如本章相关工作中所描述的，本章介绍的长短期记忆构建与计算方法与上述对比方法有明显区别。与这些方法相比，本章介绍的方法更侧重于借鉴大脑记忆机制来改进传统的记忆回放方式，以实现具有较小额外计算负担的高性能连续学习。表 5-3 展示了这部分实验结果。从中可以看出，本章介绍的系列方法（Dual-MEM-DR/MR）在不同的记忆容量预算下始终表现出优于竞争者的性能。

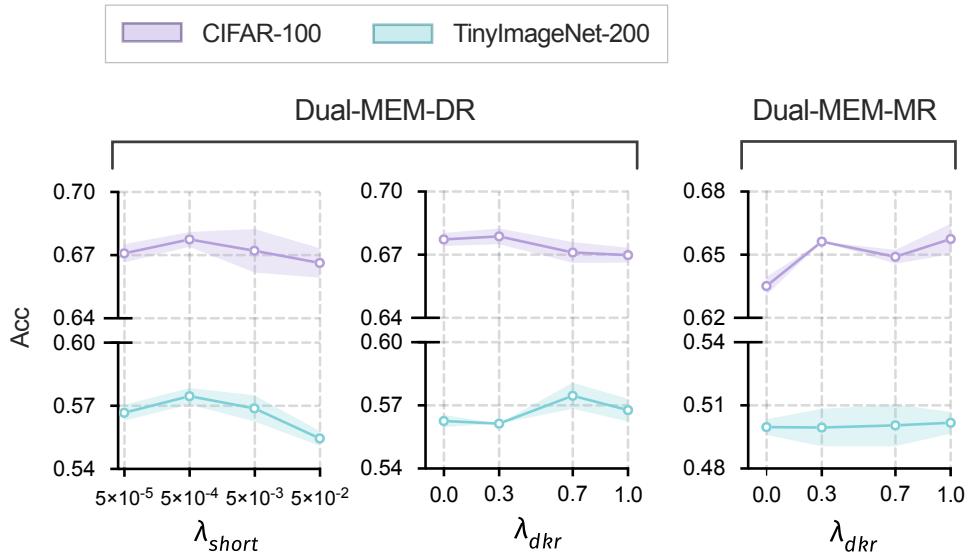


图 5-8 超参数敏感性分析实验结果。Dual-MEM 方法在 CIFAR-100 和 Tiny ImageNet-200 基准的评估中对参数 $\lambda_{short}, \lambda_{dkr}$ 的敏感度分析。

5.4 本章小结

除了利用神经科学的见解来优化记忆构建与计算机制的计算建模，进而在任务端改善以记忆为核心的连续学习，本章研究的另一个目标是探索关于大脑中连续学习过程中的记忆的计算角色的新视角和假设。关于记忆在生物体终身学习过程中扮演的角色，本章的研究考虑了一个经典的理论记忆模型，即双存储记忆模型^[57]作为基础。尽管对海马-前额叶和海马-新皮质之间的相互作用的一些早期研究提供了些许见解，也即，记忆模式的重新激活可以减轻遗忘并加强记忆，然而是否能够将这些机制移植并用于解决现实的问题上仍悬而未解。这个问题在本章中得到了部分的回答。关于记忆的功能，本章的研究强调了记忆构建策略在记忆形成过程中的关键性。具体来说，本章使用神经科学启发的修改，使用**基于新颖性（诧异度）的策略来指导记忆的构建与计算过程**，并通过实验证明这些修改可以在下游的连续学习任务上显著提高学习效率并提高整体性能。此外，本章研究表明**短期记忆-长期记忆的转化过程可以通过功能区域的转移来实现**。本章考虑的记忆巩固策略是比较基础的，然而延续该思路，可以很容易地拓展到通过不同神经网络，亦或是神经网络不同部分之间的转移来实现。最后，本章研究中仍然缺少一些重要的方面。其中之一，是没有考虑在细胞参数空间的正则化。该过程的挑战

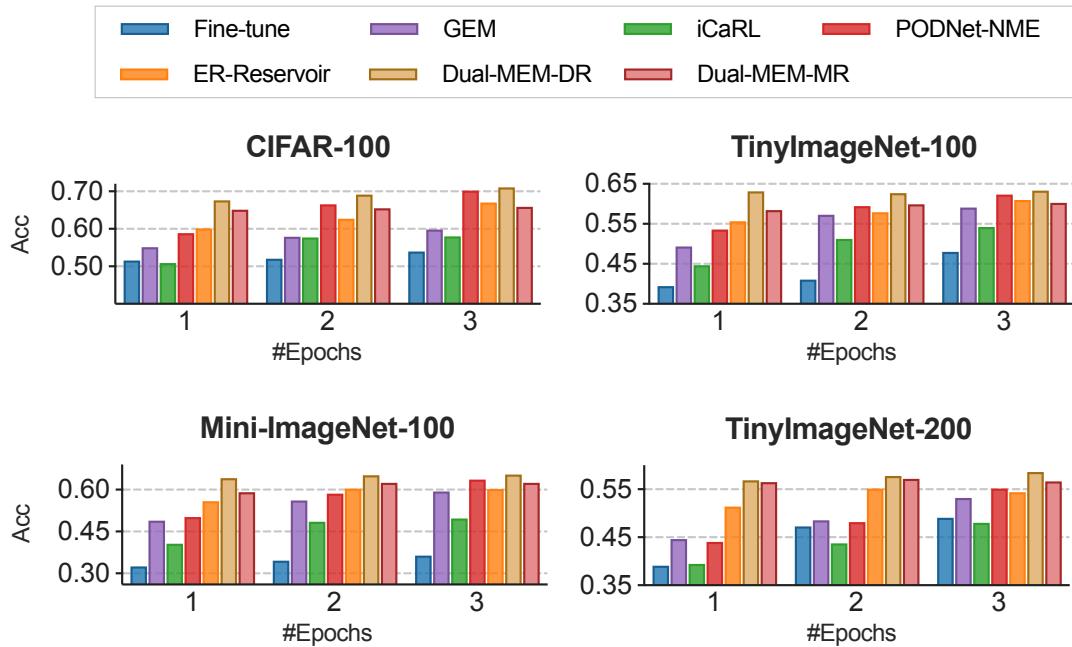


图 5-9 多次接触任务设定下的 Acc 性能表现。

是正确、有效地将信用分配给网络的突触权重。虽然既有的记忆回放机制已经约束了模型在函数级别的响应，但细胞级别的约束或许能够提供有益的补充，并进一步保护记忆。本章研究中得到的理论与模型构建经验将在后续的章节中得到应用，从而对本文的整体研究目标起到支持。

表 5-3 本章介绍方法与多种长短期双重记忆为核心的典型方法的对比试验结果，数据为 Acc AVG \pm SD。

$M_{\text{per cls}}$	CIFAR-100 T10		
	3	5	10
Dual-MEM-DR	0.547 \pm 0.004	0.581 \pm 0.008	0.622 \pm 0.003
Dual-MEM-MR	0.533 \pm 0.005	0.572 \pm 0.004	0.603 \pm 0.002
IL2M	0.419 \pm 0.004	0.423 \pm 0.006	0.440 \pm 0.012
SCoMMER	0.475 \pm 0.011	0.514 \pm 0.013	0.558 \pm 0.008
CIFAR-100 T5			
Dual-MEM-DR	0.448 \pm 0.002	0.474 \pm 0.004	0.504 \pm 0.006
Dual-MEM-MR	0.430 \pm 0.003	0.471 \pm 0.005	0.489 \pm 0.006
IL2M	0.383 \pm 0.011	0.394 \pm 0.007	0.418 \pm 0.005
SCoMMER	0.334 \pm 0.007	0.413 \pm 0.008	0.445 \pm 0.010

第6章 一种时空记忆构建与计算的脉冲生成式模型

6.1 本章引言

本章将对本文中前述的模型和算法进行归纳与整理，并在此基础上实现时空记忆构建与计算的脉冲生成式模型系统。延续了本文前述章节中的研究方法与技术路线，本文介绍的时空记忆构建与计算模型是基于隐变量模型的，亦即通过隐变量来理解生物大脑的计算过程。时空记忆构建与计算的脉冲生成式模型的隐变量模型实现大致包含两个部分：一个推理模型和一个生成模型。推理模型是一个压缩性的参数化映射，计算给定观察值（或刺激值）下的隐变量。生成模型将隐变量与记忆活动或是观察模式（神经元的活动或是外部刺激的内容）相关联。

在本文的研究范畴内，考虑此种简化的模型，或者说预先设定的模型类别是非常重要的。因为无法确切地得知记忆构建与计算过程中所有的细节参数，而只能通过有限地埋点来获取部分阶段中的神经活动情况和计算策略。此外，本文采用的方法在一些较为复杂的用例中已经能够较准确地进行隐变量的推理和后续的生成。这对于一些更加进阶的计算机制研究已然足够：通常，我们可能允许对大脑特有性质进行一些不变性处理，并通过简单的（例如，线性的或低复杂度的）映射关系将隐变量与真实的神经系统活动关联起来。

进一步地，本章考虑将时空记忆构建与计算的脉冲生成式模型包含的两部分的实现路线进一步细化，以锚定前述的探讨：一个前馈的、判别式的脉冲神经网络模型，拟合从外部输入到类别、位置、场景的抽象几何描述或者是语义描述；一个包含视觉统计信息的概率生成模型，用于捕获可能的先验概念并重构出真实的场景。这二者的组合构成时空记忆构建与计算的脉冲生成式模型系统的主要部分。值得注意的是，在这里事实上忽略了一些可能的选择或情况。例如，判别模型部分也可以是递归的，因此，原则上，研究者可以通过多种通用的函数逼近器来进行实现。在真实的情况下，研究者通常可以通过假设特定的约束和优先级来限制可能的候选模型的种类。在合理的近似处理下，我们认为这些计算实现能够一定程度上地还原出大脑中的计算过程^[333]。

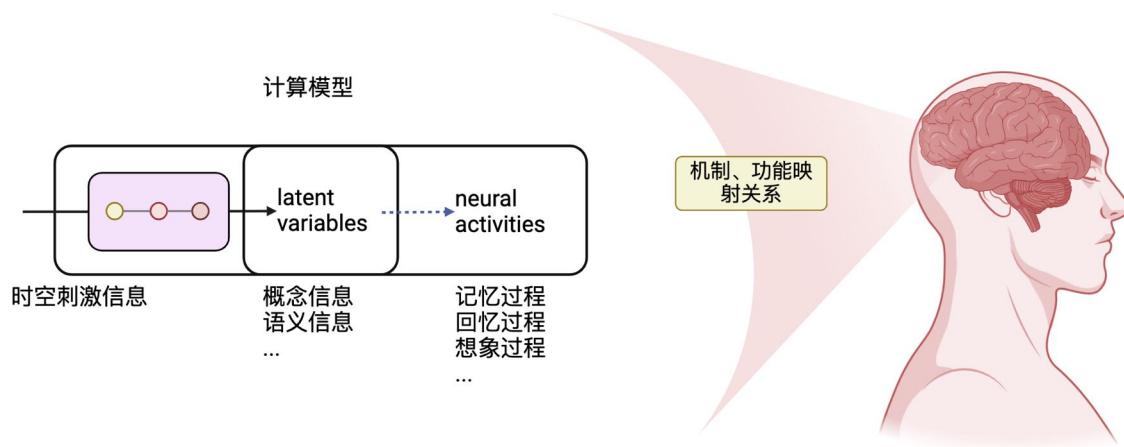


图 6-1 本章节的计算模型构建过程简图。

6.2 时空记忆构建与计算的脉冲生成式模型系统

延续前述章节的研究思路，本章仍考虑按照短期记忆、长期记忆的形式来分别对时空记忆的构建及计算过程进行模型设计。正如章 5 中提到的，直接进行原始样本存储是计算实现记忆的最为基础和简单的形式，本章将在前几章研究之基础上，将记忆存储过程通过参数化的自联想网络进行实现。这种设计能够在有限的缓存预算下更高效地提升记忆存储的容量，从而使得前文中的结论和机制能够进一步扩展到更加非标准的、更一般的泛时、空记忆构建的应用中。在本章介绍的时空记忆构建与计算的脉冲生成式模型系统中，短期记忆由自联想网络实现，其对应单次接触（章 5）下的空间记忆构建与计算过程。这种设定存在较为充分的合理性，因为短期记忆过程是较为快速的^[334]，而时间信息、时空信息需要接收一段时间的刺激序列。本章的系统中，长期记忆构建及其计算过程是通过脉冲生成式网络实现的，该部分在短期记忆的基础上，构建输入刺激序列（空间场景时序）的记忆范式，并分布式、参数化地存储在神经元突触连接权重中。

总体而言，本章介绍的时空记忆构建与计算的脉冲生成式模型系统中（图 6-1），短期记忆包含了复杂空间场景的瞬时记忆，通过单次接触学习方式编码在对应大脑海马体的自联想网络中。在时空长期记忆的构建过程中，海马体自联想网络中的短期记忆信息将通过多次接触的学习方式逐渐转移到生成式网络中，该过程基于前文章 5 研究的结论，即将记忆巩固过程建模为不同部分间的信息转移过程。在前几章研究的基础上，本章介

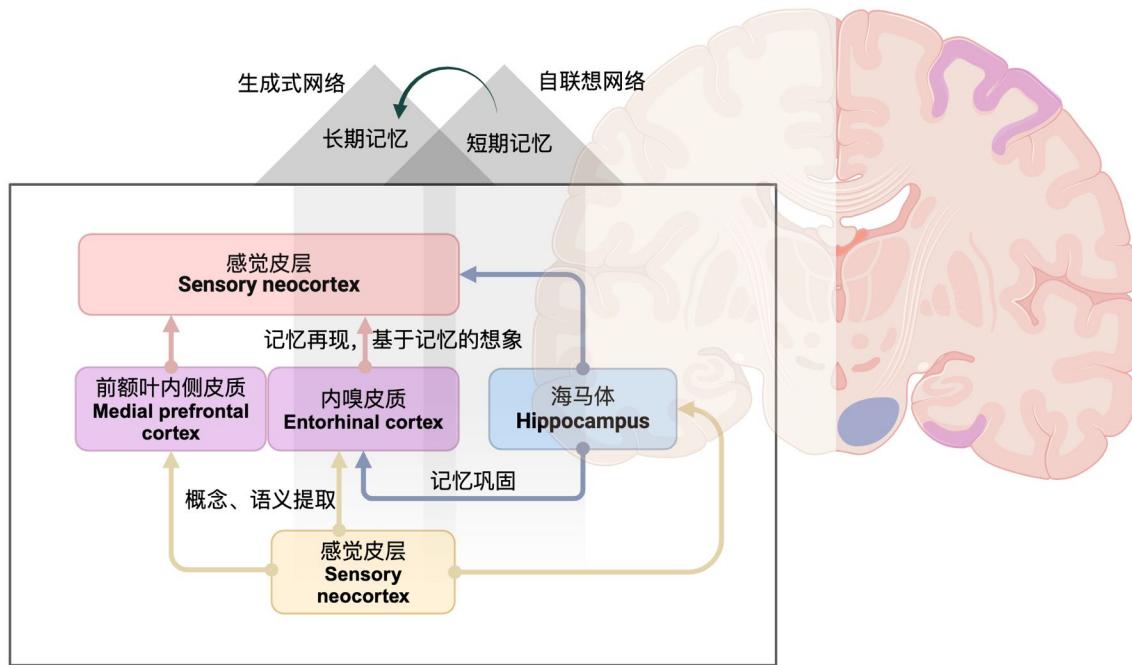


图 6-2 时空记忆构建与计算的脉冲生成式模型系统图示。

绍的系统使用了短期记忆监督长期记忆的构建过程，而非显式地直接转移记忆信息。本章介绍的系统中，时空刺激输入中的抽象信息，即概念信息与语义信息通过建模感觉皮层-内嗅皮质、内侧前额叶皮质回路的参数化编码器进行计算支持，该编码器对应生成式网络中的压缩映射部分。在这一映射过程中，时空输入信息中的细节内容和具象信息被不断剥离，从而输出紧致的概念信息隐变量表征以支持稳定的长期记忆存储需求。通过概念信息到感觉皮层的映射对应了基于记忆的场景再现（回忆）和想象过程，该过程通过一个参数化的解码器进行解码，向抽象的概念和语义增添颜色、光影等具象细节，从而还原出感觉皮层的活动。基于前述章节中的研究基础，本章介绍的系统中的生成式网络采用了基于时空特征交叉的具有统一时空维度（章 4）的编码器进行输入时空刺激的表征，并采用时间条件操作（章 3）使模型进行在自然范式的时序处理。这一由噪声脉冲神经元（章 2）实现的生成式网络通过不断减小时空记忆再现的重构误差，优化模型参数。此外，上述的短期、长期时空记忆都会产生误差，该过程对应了生物体回忆过程中可能发生的扭曲和错误。

自联想网络模型 二值的 Hopfield 网络是经典的自联想网络模型，它可以存储和检索模式的联想记忆^[335]。在 Hopfield 网络中，一个查询模式可以检索出与其最相似的模式，或者是多个相似模式的均值。最简单的联想记忆存储 N 个模式 $\{x_i\}_{i=1}^N$ 的外积之和。在经典的 Hopfield 网络中，这些模式是二值的，亦即 $x_i \in \{-1, 1\}^d$ ，其中 d 是模式的维度。相应的权重矩阵表示为 $W = \sum_{i=1}^N x_i x_i^T$ ，该权重矩阵存储了模式，这些模式可以从一个状态模式 ξ 开始进行检索。基础的 Hopfield 的同步更新规则是重复将状态模式 ξ 与权重矩阵 W 相乘，减去偏置并取符号 $\xi_{t+1} = \text{sgn}(W\xi_t - b)$ ，其中， $b \in \mathbb{R}^d$ 是一个偏置向量，可以解释为每个模式成分的阈值。而异步更新规则只对 ξ 的一个组分进行此更新，然后选继续更新下一组分。如果 $\xi_{t+1} = \xi_t$ ，或是差异小于某一预设的阈值，则认为网络收敛。

上述的更新规则的目标是最小化能量函数 E ，其定义如下

$$\begin{aligned} E &= -\frac{1}{2}\xi^T W \xi + \xi^T b \\ &= -\frac{1}{2} \sum_{i=1}^d \sum_{j=1}^d w_{ij} \xi_i \xi_j + \sum_{i=1}^d b_i \xi_i \end{aligned} \quad (6-1)$$

在一些研究中，学者们尝试通过设计新的能量函数来改进其性质，主要关注点是提升其稳定性和记忆容量。在一个 d 维空间中，标准的 Hopfield 模型可以零误差地存储 d 个不相关的模式，但是只能存储至多 $\frac{C}{2} \frac{d}{\log d}$ 个随机模式^[336-337]。若是将检索错误的容忍度稍稍放宽，则其存储容量约能达到 $0.138d$ ^[338]。与存储容量相比，Hopfield 网络的能量最小值数目（即均衡态的数目）随维度 d 指数增长^[339]。在更近一些的研究中，推广的 Hopfield 网络能够存储连续状态的模式，且保留了其存储容量随模式维度指数上升的优良性质，因而是用于实现短期记忆的理想候选。

本章中采用了密集联想记忆^[340]（Dense Associative Memories）的一般形式^[341]以实现连续值模式的短期记忆构建与计算过程。密集联想记忆引入了一个新的能量函数，取代前述标准 Hopfield 网络中使用的能量函数，以实现更高的存储容量

$$E = - \sum_{i=1}^N F(x_i^T \xi) \quad (6-2)$$

其中， F 是交互函数， N 是存储的模式的数量。一个常见的选择是采用多项式交互函数

$F(z) = z^a$, 在该情况下, 密集联想记忆的零检索误差的模式存储容量为:

$$C \approx \frac{1}{2(2a-3)!!} \frac{d^{a-1}}{\log d} \quad (6-3)$$

而容忍少量检索错误的模式存储容量为

$$C \approx \alpha_a d^{a-1} \quad (6-4)$$

其中 α_a 是一个常数, 依赖于错误概率的容忍度。在 $a = 2$ 下, 可以还原出经典的 Hopfield 模型的情况^[335]。进一步的研究通过使用指数交互函数 $F(z) = \exp(z)$ 来构造能量函数^[342], $E = -\sum_{i=1}^N \exp(x_i^T \xi)$, 其中 N 同样是存储的模式的数量。该情况下, 能量函数也可以记作 $E = -\exp(\text{lse}(1, X^T \xi))$, 其中 $X = (x_1, \dots, x_N)$ 为存储模式的矩阵。其中对数-求和-指数函数 (log-sum-exponential, lse) 定义为

$$\text{lse}(\beta, z) = \frac{1}{\beta} \log\left(\sum_{l=1}^N \exp(\beta \cdot z_l)\right) \quad (6-5)$$

使用该种能量函数下的存储容量为 $C \approx 2^{d/2}$ 。为了将上述方式扩展到连续值模式的情况下, 遵循先前的研究^[341], 使用上述能量函数的负对数, 并添加一个二次项的形式, 该二次项能够确保状态 ξ 的范数有限。则适用于连续模式的能量函数定义为

$$E = -\text{lse}(\beta, X^T \xi) + \frac{1}{2} \xi^T \xi + \frac{1}{\beta} \log N + \frac{1}{2} M^2 \quad (6-6)$$

这是由表示存储了 N 个连续值模式的矩阵 $X = (x_1, \dots, x_N)$ 构造的, 其中 M 是所有存储的模式的最大范数。在该中 Hopfield 网络中, 存储模式 X^T 可以被视为从 ξ 到隐藏单元的权重, 而 X 可以被视为从隐藏单元到 ξ 的权重。通过这种理解, 此种一般化的 Hopfield 自联想模型实际上并未存储模式, 而是单纯考虑了模型权重, 正如经典的 Hopfield 网络中一样。基于上述连续情况下的能量函数以及凹凸过程^[343] (ConCave-Convex Procedure, CCCP), 可得 ξ 的更新规则。总能量 $E(\xi)$ 被划分为凸函数项和凹函数项: $E(\xi) = E_1(\xi) + E_2(\xi)$, 其中 $E_1(\xi) = \frac{1}{2} \xi^T \xi + C$ 是凸函数 (C 是一个独立常数); 而 $E_2(\xi) = -\text{lse}(\beta, X^T \xi)$ 是凹函数 (由于其 Hessian 是负半定的^[343])。由 CCCP, 其状

态模式 ξ 的更新规则为：

$$\xi_{\text{new}} = X \text{ softmax}(\beta X^T \xi). \quad (6-7)$$

在短期记忆构建，亦即自联想网络学习完成后，运用上述规则，即可通过任意给定的查询模式 ξ 实现短期空间记忆的多种计算。

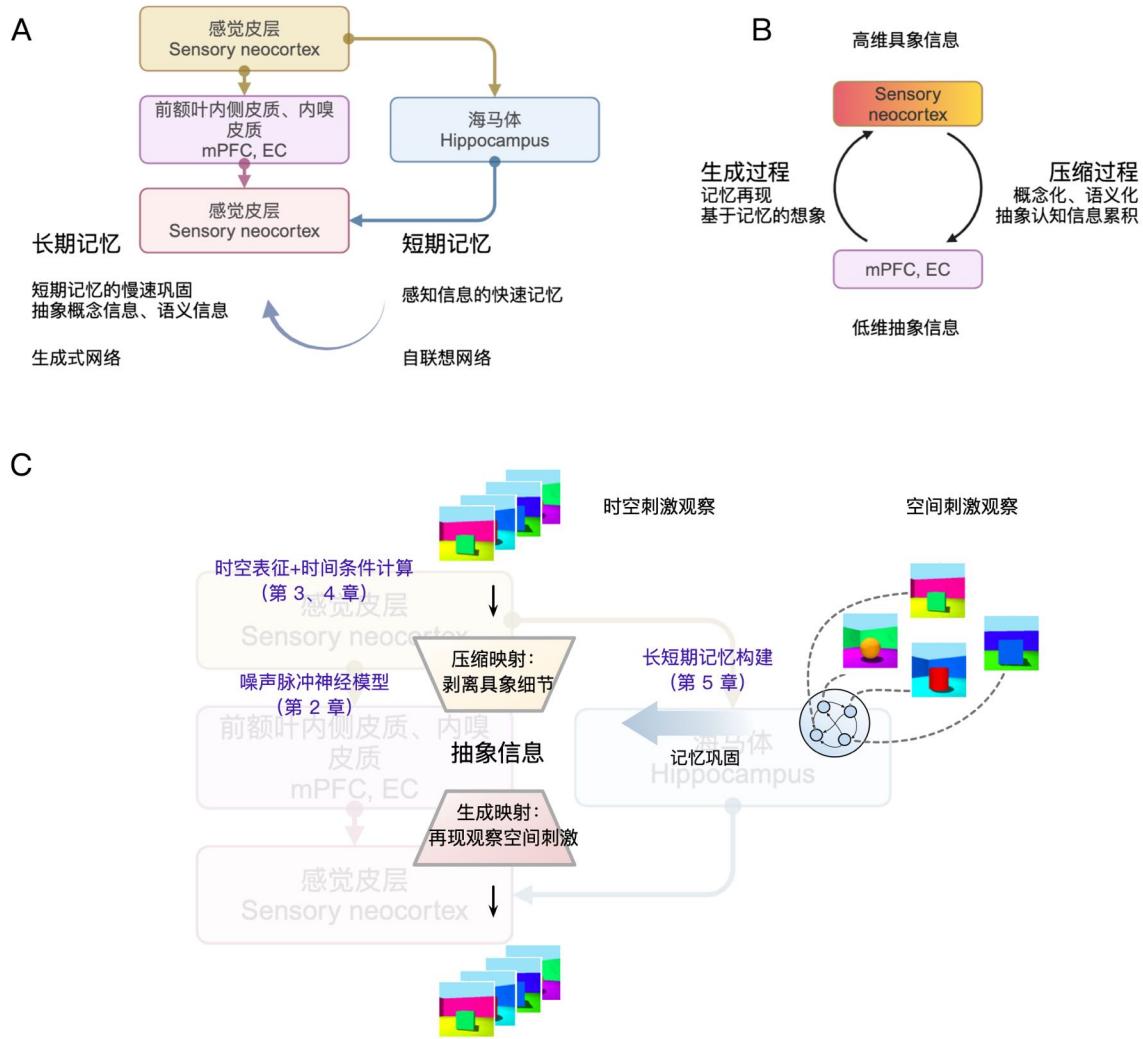


图 6-3 时空记忆构建与计算的脉冲生成式模型系统包含的神经计算过程。A. 时空记忆构建与计算的脉冲生成式模型系统的完整计算过程。B. 系统中长期时空记忆的构建与计算过程。

本章介绍的系统采用的时空表征方式延续了本文前述章节中的思路，本章系统所涉及之模型的端到端的学习过程中，负责时空表征的部分通过参数化跨连的方式强制时空维度进行交互，通过鼓励模型在更早的阶段进行时空刺激信息的信息融合来提升其表

征的效率^[252]。在本文前述章节的时空表征和时间条件计算结构基础上，本章系统中的时空记忆构建与计算的脉冲生成式模型网络结构采用 40C3-80C4-160C4-FC16 的编码器结构，将 $64 \times 64 \times 3$ 的空间场景刺激压缩到 16 维的隐变量空间中。其中 C 为卷积层，FC 为全连接层。解码器采用了与编码器网络对称的结构，向隐变量空间的抽象表征中添加具象细节信息，重构出原空间尺寸的场景刺激。编码器将时空感觉体验压缩为隐变量，再由解码器基于隐变量生成时空感觉体验。这一生成过程（图 6-3）对应了从语义层次、抽象程度更高的脑区到感觉皮层的映射过程，从而支持了完全线索、部分线索（缺损线索）下的长期记忆的回放以及基于其的想象的计算过程^[52]。

由编码-解码器组成的生成式网络模型基于表示海马体短期记忆的自联想网络的检索结果进行学习。在长期记忆构建过程中，生成式模型的重构误差量化了其回忆的诧异度（章 5），模型学习的目标为该减小长期时空刺激回忆过程中的重构误差。当通过重构获得的回忆时空刺激与真实刺激差异越小，则表明通过网络构建的长期记忆质量越高。换言之，该生成网络部分捕获了时空刺激信息背后的数据生成分布，或称为时空刺激的模式。而这种模式是准确回忆时空记忆的规则或先验，也就是其概率分布的预期。该生成式模型的隐变量表征被假定形成于内嗅皮质（Entorhinal Cortex, EC）、内侧前额叶皮质（medial Prefrontal Cortex, mPFC）中。内嗅皮质是海马体和感觉皮层间信息交互的重要通道，且已知能够表征抽象信息的网格细胞正是位于内嗅皮质^[22,229]。而内侧前额叶皮质在情景记忆处理中被认为具有对通用模式的编码、记忆整合和压缩的功能^[313,344]。

6.3 实验结果

实验数据 为了构建一个直观的时空记忆任务，本文采用了 3DShapes 空间场景数据^[345]。这是一个由 6 个独立的真实隐变量通过生成的三维空间场景数据集。这些隐变量包括了地面颜色、墙体颜色、物体颜色、场景尺度、物体形状和场景方向。所有上述的隐变量的所有可能组合都恰好只出现一次，总计生成了 480000 个空间场景。上述隐变量的取值范围如下。地面颜色有 10 个可能的取值，线性分布在 [0, 1] 之间；墙体颜色有 10 个可能的取值，线性分布在 [0, 1] 之间；物体颜色有 10 个可能的取值，线性分布在 [0, 1] 之间；场景尺度有 8 个可能的取值，线性分布在 [0, 1] 之间；物体形状有 4 个可能的取值；场景方向有 15 种取值，线性分布在 [-30, 30] 角度之间。在数据生成过程中，程序一次

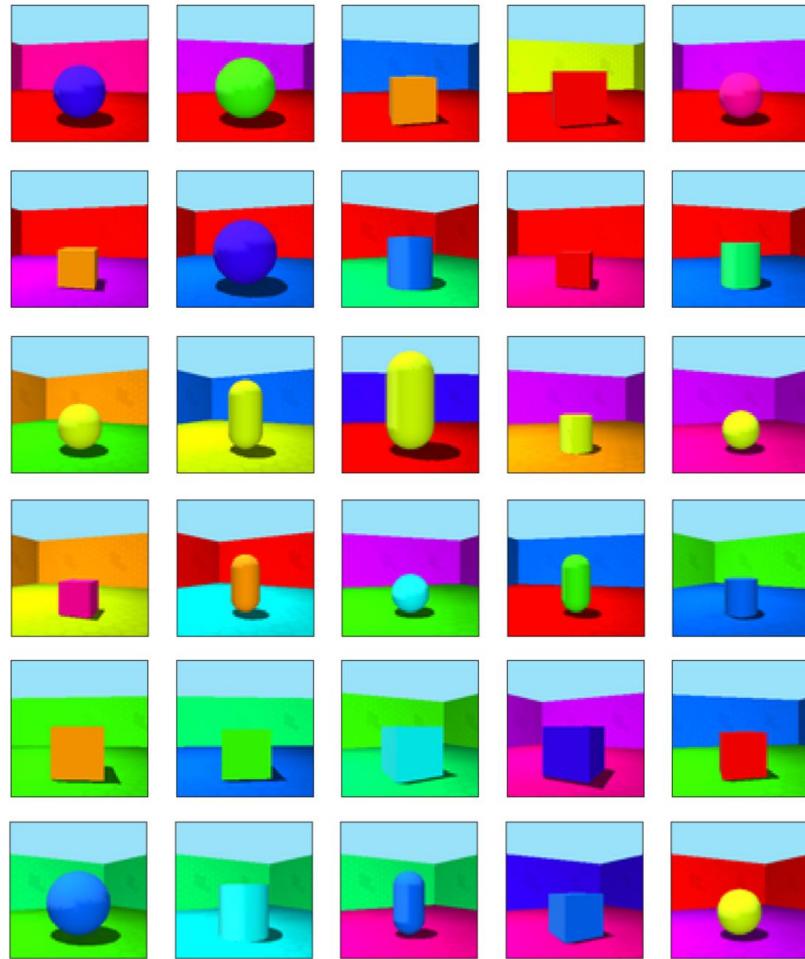


图 6-4 空间场景样本图例，图中每一行为单个变量相同取值下的一组随机提取的样本。该数据集合是一个由六个独立的隐变量生成的三维场景数据集，这些因素包括了地面颜色、墙面颜色、对象物体颜色、场景尺度、对象物体形状和场景朝向。

改变一个隐变量，并按照固定的顺序将场景图像顺序储存在图像数组中，其对应隐变量的值也以同样的顺序存储在标签数组中。本章将上述空间场景随机组成长度为 8 的空间场景序列形式，作为本章实验采用的时-空刺激数据。其中 70% 的数据作为训练集，余下部分为测试、评估使用。

本章所介绍的系统中的生成式网络模型采用前节所述的重构误差（以均方误差实现）为主目标函数在进行优化（章 3），并在不重叠的测试数据上进行了评估与可视化。在生成式网络的学习过程中，测试集合重构误差被用作权重保存的主要依据指标。本章通过贝叶斯搜索为该网络选取了较优的超参数组合。实验中的脉冲神经网络模拟时间步被设为与时空刺激长度相同。实验中将神经元膜电压的噪声的标准差（强度）设置为

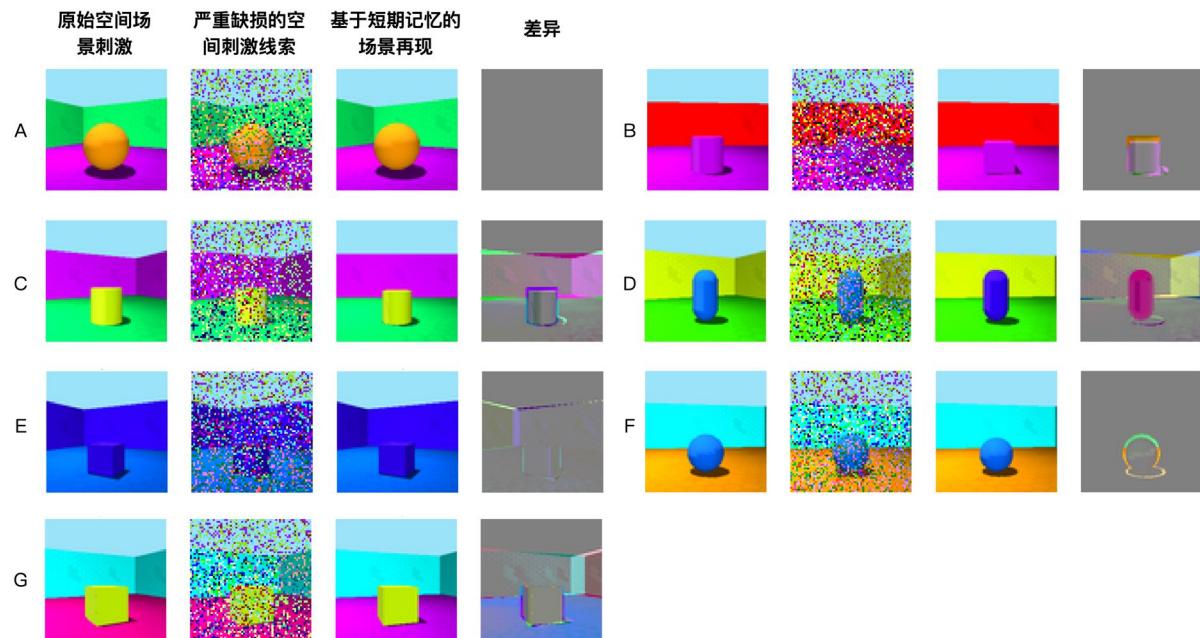


图 6-5 短期空间记忆场景再现过程中的记忆扭曲。

0.25，并采用噪声驱动学习方式进行突触权重更新（章 3），更新过程使用了 Adam 求解器^[120]与余弦退火学习率衰减策略^[121]，初始学习率为 0.004，批大小为 64。

本章中的时空记忆构建与计算脉冲生成式模型模拟了时空记忆形成过程和基于时空记忆的计算过程。记忆回放在本章的设定下对应了时空场景的再现，是最典型的基于记忆的计算过程。图 6-5 中展现了在基于海马体短期记忆的记忆再现计算过程的结果。除了模拟出基于短期记忆的准确的空间场景再现的结果外（图 6-5-A），本章介绍的系统同样再现了基于短期记忆的场景再现过程中的记忆扭曲现象^[346-347]。视记忆扭曲的程度而定，通过模型计算得到的回忆内容与真实内容会存在或多或少的差异。例如在图 6-5-B 的计算过程中，回忆的场景与真实的场景就存在着物体形状的不一致性。这种扭曲也可能导致其他方面的描述产生偏差，如角度（图 6-5-C, D, G）。而部分情况下回忆的场景与真实值仅存在细微的差别（图 6-5-E, F）。

尽管对应长期记忆的生成式网络使用场景再现的重构误差作为目标函数进行学习，然而本章观察到模型隐变量的概念可区分性（表现为用模型隐变量预测真实隐变量的预测误差）随着重构误差的下降而同步呈现下降趋势（图 6-6-C）。这表明使用本章所述的生成式模型建模的长期记忆构建过程中自然地形成了表征概念、语义的（六种真

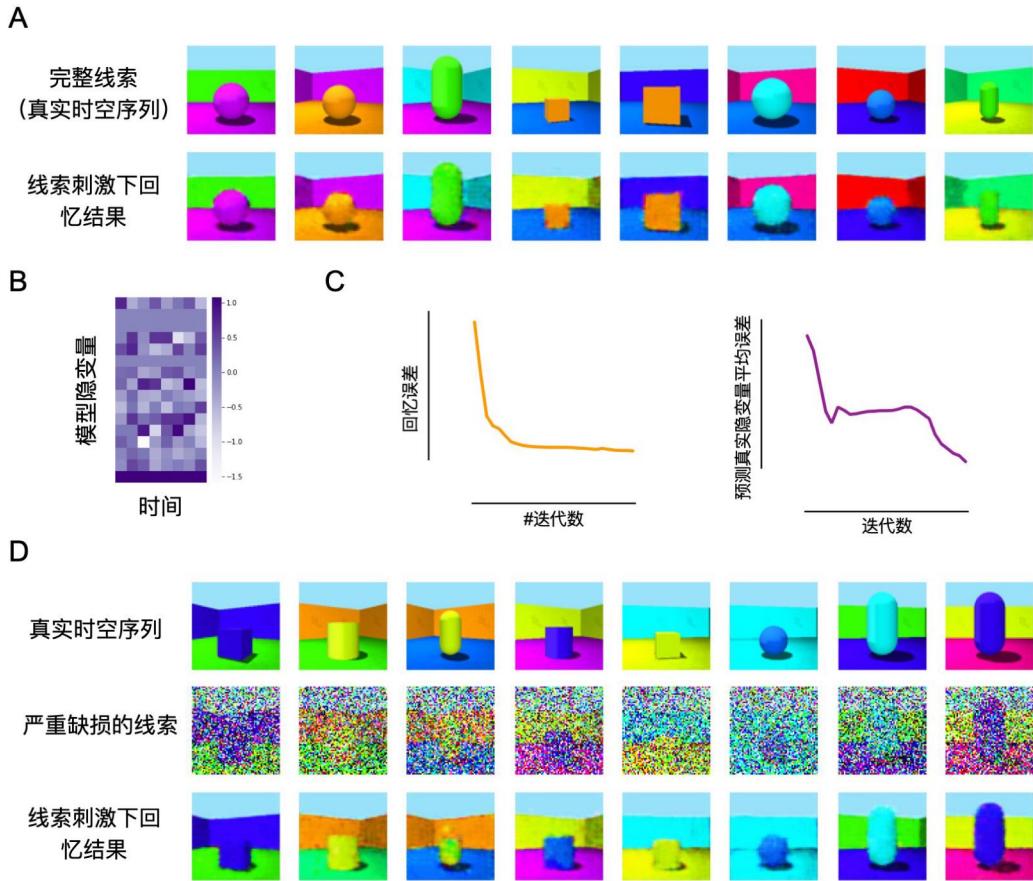


图 6-6 基于时空记忆的完全线索下的回忆计算过程。A. 基于时空记忆的完全线索下的回忆计算结果。B. 该计算过程中的模型隐变量可视化。C. 在长期记忆生成式模型学习过程中，基于模型隐变量的真实隐变量预测误差随场景再现重构误差呈现同步下降趋势。D. 基于时空记忆的严重缺损线索下的回忆计算结果。

实隐变量) 的编码过程，且能够有效地从这些紧致的抽象空间表征中还原出真实场景(图 6-6-A)，仅产生非常轻微的记忆扭曲。为了进一步评估本章的系统中生成式网络建模的长期记忆的有效性，本章使用严重缺损的线索序列(60% 的像素重置为随机值)驱动生成式网络以获取回忆。图 6-6-D 中展示了严重缺损的线索序列情况下生成式模型产生的回忆序列，回忆序列基本准确地还原出了真实的时空刺激序列的关键信息。

本章介绍的系统再现了基于时空记忆的想象计算过程。具体而言，在想象过程的计算模拟中，本章使用纯随机噪声作为回忆的线索驱动模型生成输出。由于这种状态下的输入可以被认为不包含任何有意义的时空信息，因此模型将单纯通过其在观察训练数据时空刺激的基础上习得的外部世界描述模型来还原出场景序列。图 6-7-A 中展示了

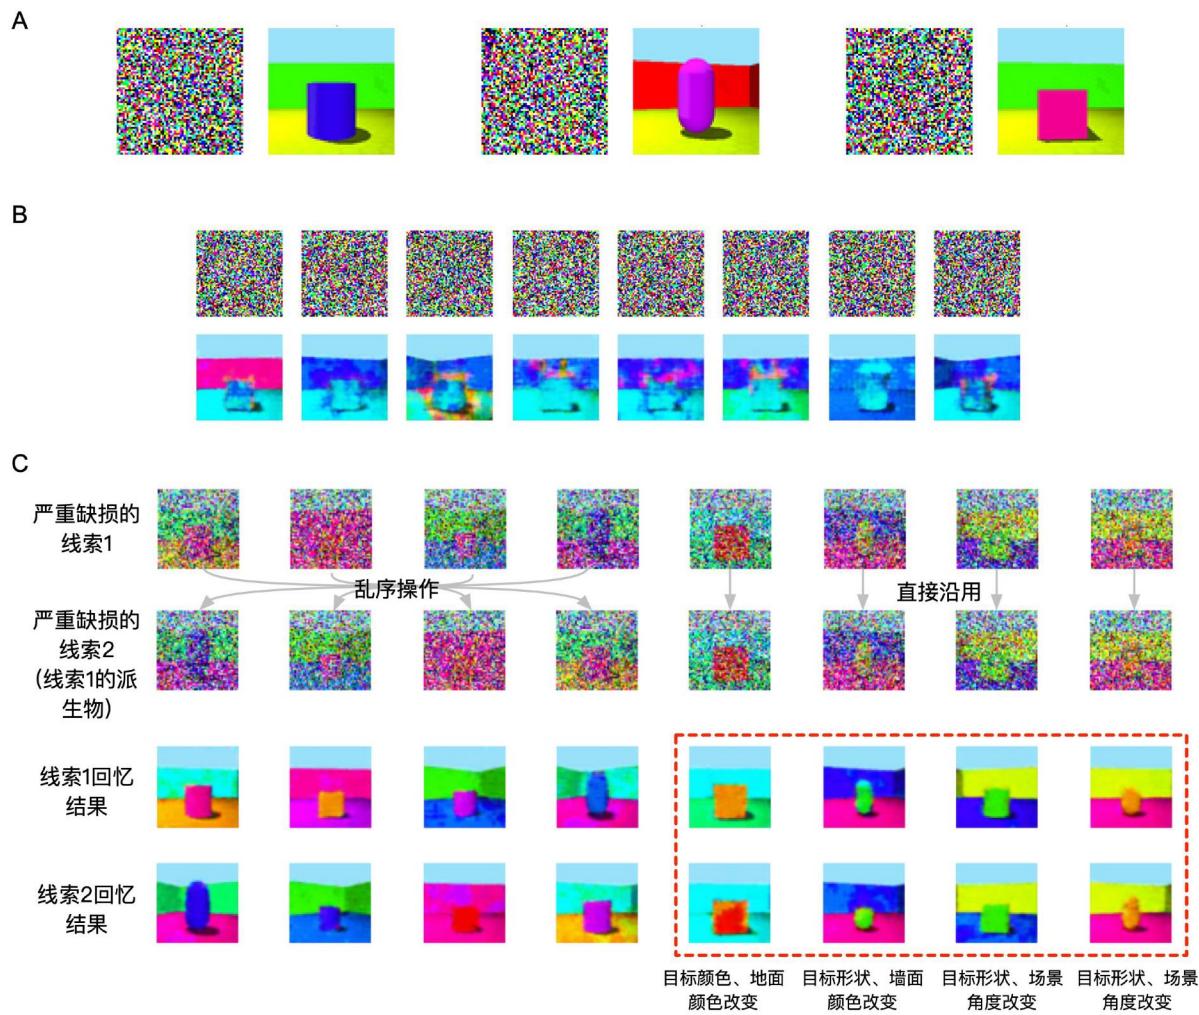


图 6-7 基于时空记忆的想象类计算过程。A. 基于短期记忆的想象。B. 基于长期记忆的想象过程。C. 基于时空记忆的计算过程时间依赖信息的重要性。线索序列 1 与其乱序（前半段）的线索序列 2 所导致的回忆内容存在明显差异。

基于海马体短期记忆的想象计算过程产生的结果。在此种计算中，建模海马体短期记忆的自联想网络模型在完全随机的线索输入下，通过检索生成了多样的想象场景。而在图 6-7-B 中，本章展示了基于长期时空记忆的想象计算过程的生成物。在该种计算中，本章使用连续的完全随机线索驱动生成式网络，生成基于时空长期记忆的想象场景序列。

为进一步探索时空记忆下的回忆计算过程中时序信息的作用，亦即时空记忆并非是空间记忆的简单组合与拼接，在图 6-7-C 中展示了基于两种线索的回忆生成结果。其中，线索序列 2 仅将线索序列 1 中的前半段打乱顺序，而两个序列在后半段的线索完全一致。

(前半段的线索是完全一致但顺序不同)。在该种实验设置下，如果本章系统中的生成式网络建模的时空记忆单纯或主要依靠空间记忆拼凑而成，则两种线索驱动下的回忆结果在后半段应该是完全一致，或至少是基本一致的。而从图 6-7-C 的结果中可见，即便两个线索序列的后半段完全相同，在不同的线索上文下的基于时空记忆的回忆结果(即使在完全相同的当前时刻线索驱动下)产生了明显的不同，具体表现为较为清晰的概念信息的改变(颜色、形状、角度等)。这表明本章系统的长期记忆很大程度上利用了时空刺激中的时序信息以形成稳定的时空长期记忆，并且有效构造出了连续的复杂时空刺激的概念表征空间，从而创造出了语义上较为清晰的“虚假记忆”内容^[348]。

6.4 本章小结

本章介绍了基于本文前述几个章节的研究基础、算法和模型开发的时空记忆构建与计算的脉冲生成式模型系统，及其在时空刺激序列记忆构建与基于记忆的计算上的应用实例。时空记忆构建与计算过程的建模对于系统神经科学、认知神经科学、计算神经科学以及人工智能方法的研究有着广泛的深远。通过对比分析计算模型模拟生成的计算结果和真实神经记录结果的区别，可以帮助构建、验证基于记忆的计算的理论与假设。此外，基于记忆的计算是近年来人工智能业界重点关注的问题之一，因而本章及本文所涉之研究问题亦具有相当的实用价值和经济价值。

第7章 总结与展望

7.1 本文工作总结

时空记忆的构建与计算构成了人类诸多高级认知行为的计算基础。尽管如此，建立一定程度上模仿神经计算机制，特别是时空记忆的内在表征和组织方式的计算模型，从而为神经形态人工智能领域提供有效的模型构建范式，仍是一个充满挑战的前沿科学问题。尽管现有的时空记忆计算模型已经在一些精心设计的模式任务上展现出一定的效果，但它们仍然存在着模型性能和生物真实性上方面的缺陷。因此，本文深入探索了如何在现有的神经科学、认知科学以及机器学习研究的基础上，构造时空记忆构建与计算的设计范式，并通过脉冲生成式模型加以实现，从而提供一套既具有广泛适用性又兼顾生物真实性的计算模型设计蓝本。这项工作亦能为神经形态人工智能系统的开发提供宝贵的理论指导，以期发展出支持灵活度更好，适应性更强的人工智能系统。

本文对时空记忆构建与计算的脉冲生成式模型及其系统开展了深入研究，主要取得创新成果如下：

- 本文的第二章系统研究了一种通过考虑噪声扰动膜电位的神经元动态的非确定性脉冲神经网络，并通过概率图模型建立了相应的一般性脉冲神经网络框架：噪声脉冲神经网络。该框架能够支持大型脉冲神经网络的概率推理过程建模，并从随机噪声的角度为其计算和学习过程提供了统一的数学形式化。在该框架下，噪声脉冲神经网络能够通过一种被称为噪声驱动学习的三因子学习规则，通过典型的梯度下降、反向传播工作流进行端到端的突触优化。本文的研究同样揭示了广为使用的脉冲神经网络一种临机技术，即替代梯度背后的生物物理学原理和随机噪声解释，从而为后者提供了开发和调制的理论依据。在包括多种静态、动态数据构成的测试基准上的评估表明，噪声脉冲神经网络框架能够导致具有竞争力的脉冲神经模型，且广泛适用于多种不同的脉冲神经网络算法和网络结构。此外，在面对极具挑战性的外部扰动（包括对抗性攻击）以及内部错误的情况下，该框架诱导的脉冲神经网络模型展现出显著增强的鲁棒性。最后，基于该框架的生物神经网络编码对应物能够很好地再现真实的神经活动变异性，从而展现出其作为计算神经科学工具的强大潜力。该部分研究也为本文的时空记忆构建与计算脉冲生

成式模型研究提供了重要的脉冲神经网络组件基础。

- 本文的第三章深入探索了自然范式下运行的时间条件计算脉冲生成式模型。构建这种计算模型是感觉神经科学、系统神经科学以及计算神经科学研究的一个基本科学问题。这些模型能够提供对神经计算环路的深入的、可观的了解，并可能解释神经处理机制或验证理论假设。然而目前的大多数相关工作主要考虑基于人工神经元建立的模型，因而不能够充分发挥脉冲表征的稀疏性优势，并且在实际处理流程中往往需要将神经活动的优化目标进行有损的统计转化。此外，现有的大部分相关技术普遍通过预设的固定尺寸的时间滤波器来进行时序信息处理。这种方式首先难以可靠地捕获并建模中长时程的时序依赖信息，再有也无法运行在与生物神经系统一致的自然处理范式下（即模型参数空间中不显式包含时间维）。上述的问题既在一定程度上限制了作为计算工具的生成式模型的性能，亦对其灵活性、生物真实性带来了不利影响。因而本文介绍了一种时间条件的脉冲生成式模型。本文所介绍的方法采用了前述的噪声脉冲神经元，以增强生成式计算工具的性能与生物可信度，并发挥脉冲表征的稀疏性优势。该方法通过一种时间条件的计算操作，将推理-生成过程显式地条件化到中长时程的时空输入序列，从而能够在自然范式下有效处理时空刺激流。本文所述方法在高效编码理论的启发下，通过变分信息瓶颈框架进行形式化并确定其优化目标。在视觉神经编码的测试基准下的评估结果表明，本文所介绍的方法在生成统计数据、原始神经响应任务上均展现出显著的性能提升。此外，本文介绍的该模型能够在短时空序列上进行训练并很好地泛化到长度更大的测试时空序列上，展现出在不同时间尺度下的泛化性能。这一模型在噪声脉冲神经网络研究的基础上，为实现本文的研究目标提供了切实的模型要件。
- 第四章针对用于时空记忆构建与计算的脉冲生成式模型系统设计的记忆构建机制进行了深入研究。该部分研究以经典的记忆再现方法为切入点，基于神经科学关于记忆机制与构建机理的研究进行了计算实现的优化探索。根据相关研究，短期记忆与长期记忆刻画不同层次的记忆形式，且有机制不同的系统对这二者进行支撑。根据系统巩固理论，记忆最初由海马体的快速学习系统进行组织、构建，再经有前额叶皮质、内嗅皮质、新皮质等组成的慢速学习系统稳定化、长期化，并抽象

出概念和语义内容。基于这种分层、分部的记忆构建范式，本文的研究介绍了一种简化的双重记忆系统记忆构建的计算实现。其主要过程包括长短期记忆的构建，并通过功能区块的转移来具象化记忆的巩固过程。此外，该工作还探索了基于诧异度^[206]的记忆构建监督方式，使得长短期记忆的构建过程得以高效计算实现。本文以连续学习任务场景为测试设定，在多种不同测试基准下的系统地评估并证明了上述研究成果的有效性。该部分的研究成果为本文的核心研究目标提供了重要的记忆构建机理计算化依据。

- 第五章研究、探索了用于时空记忆构建的时空表征方法及策略。本章中主要从获得诺贝尔奖的神经科学研究^[227]中汲取了关于时空特性刻画、时空表征方式方面的启发。其一是内嗅皮质网格细胞的多时空尺度表征特性，其二是海马体位置细胞提供多视角融合的感知信息刻画功能^[22]。上述方式将时空表征策略具象化为带有早期时空信息融合的多尺度下的信息提取过程。基于这一机制上的启示，本文的研究介绍了一种时空感知的嵌入框架，通过早期时空信息融合的统一时空维度下的图表征策略进行时空表征学习。本文介绍的时空表征框架通过多种不同的基于时空的预测任务基准进行了系统性的评估，并展现出了显著提升的时空表征效率。该部分的研究成果为本文的主要研究目标提供了重要的时空信息处理策略依据。
- 在第六章中，介绍了面向一般性时空数据流的时空记忆构建与计算的脉冲生成式模型系统。该系统能够实现长、短期记忆的相关过程和计算功能，包括基于快速、单次接触学习的短期记忆的构建、计算过程，以及慢速的长期记忆构建与计算过程。

7.2 未来展望

脑启发的神经形态人工智能系统已成为近年以及下一阶段的研究热点，时空记忆的计算模型则是其中非常关键的部分。本文开展了关于时空记忆构建与计算的脉冲生成式模型研究，在该工作的基础上，该领域在未来仍有大量的研究空间和良好的研究前景。

- 优化噪声脉冲神经网络的学习方法，通过引入其他学习信号或学习机制使得模型

对动态环境下的学习任务进行自适应调节与优化。

- 优化现有的基于时间条件计算的脉冲生成式计算工具，将其和神经形态计算平台、器件进行有机结合。在保留其生物合理性与神经形态计算平台高效性的同时，实现更多模态的神经计算环路功能建模。
- 优化现有的类脑时空表征方法和时空记忆构建机制，通过结合类脑器件、类脑芯片等神经形态人工智能载体实现在硅的记忆构建与计算高效实现。

参考文献

- [1] Yamins D L, DiCarlo J J. Using goal-driven deep learning models to understand sensory cortex[J]. *Nature Neuroscience*, 2016, 19(3): 356-365.
- [2] Newell A, Simon H A, et al. Human problem solving[M]. Prentice-hall Englewood Cliffs, NJ, 1972.
- [3] Posner M I, Petersen S E. The attention system of the human brain[J]. *Annual Review of Neuroscience*, 1990, 13(1): 25-42.
- [4] Kriegeskorte N, Douglas P K. Cognitive computational neuroscience[J]. *Nature Neuroscience*, 2018, 21(9): 1148-1160.
- [5] Cadena S A, Denfield G H, Walker E Y, et al. Deep convolutional models improve predictions of macaque V1 responses to natural images[J]. *PLoS Computational Biology*, 2019, 15(4): e1006897. DOI: <https://doi.org/10.1371/journal.pcbi.1006897>.
- [6] Zhuang C, Yan S, Nayebi A, et al. Unsupervised neural network models of the ventral visual stream[J]. *Proceedings of the National Academy of Sciences*, 2021, 118(3): e2014196118. DOI: <https://doi.org/10.1073/pnas.2014196118>.
- [7] Ratan Murty N A, Bashivan P, Abate A, et al. Computational models of category-selective brain regions enable high-throughput tests of selectivity[J]. *Nature Communications*, 2021, 12(1): 5540. DOI: <https://doi.org/10.1038/s41467-021-25409-6>.
- [8] Zador A, Escola S, Richards B, et al. Catalyzing next-generation artificial intelligence through neuroai[J]. *Nature Communications*, 2023, 14(1): 1597. DOI: <https://doi.org/10.1038/s41467-023-3718-0-x>.
- [9] Teeter C, Iyer R, Menon V, et al. Generalized leaky integrate-and-fire models classify multiple neuron types[J]. *Nature Communications*, 2018, 9(1): 709. DOI: <https://doi.org/10.1038/s41467-017-0271-7-4>.
- [10] Masland R H. Neuronal cell types[J]. *Current Biology*, 2004, 14(13): R497-R500. DOI: [10.1016/j.cub.2004.06.035](https://doi.org/10.1016/j.cub.2004.06.035).
- [11] Klindt D, Ecker A S, Euler T, et al. Neural system identification for large populations separating “what” and “where”[C]//*Advances in Neural Information Processing Systems (NeurIPS)*: vol. 30. 2017: 3509-3519. DOI: <https://dl.acm.org/doi/10.5555/3294996.3295109>.
- [12] 黄铁军, 施路平, 唐华锦, 等. 多媒体技术研究: 2015——类脑计算的研究进展与发展趋势[J]. *中国图象图形学报*, 2016, 21(11): 1411-1424.
- [13] 蒲慕明, 徐波, 谭铁牛. 脑科学与类脑研究概述[J]. *中国科学院院刊*, 2016, 31(7): 725-736.
- [14] 曾毅, 刘成林, 谭铁牛. 类脑智能研究的回顾与展望[J]. *计算机学报*, 2016, 39(1): 212-222.
- [15] Marković D, Mizrahi A, Querlioz D, et al. Physics for neuromorphic computing[J]. *Nature Reviews Physics*, 2020, 2(9): 499-510.
- [16] 张铁林, 徐波. 脉冲神经网络研究现状及展望[J]. *计算机学报*, 2020, 1: 1-21.
- [17] 李家宁, 田永鸿. 神经形态视觉传感器的研究进展及应用综述[J]. *计算机学报*, 2021, 44(6): 1258-1286.
- [18] De Ruyter van Steveninck R R, Lewen G D, Strong S P, et al. Reproducibility and variability in neural spike trains[J]. *Science*, 1997, 275(5307): 1805-1808. DOI: <https://doi.org/10.1126/science.275.5307.1805>.
- [19] Grossman S, Yeagle E M, Harel M, et al. The noisy brain: power of resting-state fluctuations predicts individual recognition performance[J]. *Cell Reports*, 2019, 29(12): 3775-3784. DOI: <https://doi.org/10.1016/j.celrep.2019.11.081>.
- [20] Starzyk J A, He H. Spatio-temporal memories for machine learning: A long-term memory organization[J]. *IEEE Transactions on Neural Networks*, 2009, 20(5): 768-780.

- [21] Hu J, Tang H, Tan K C, et al. How the brain formulates memory: A spatio-temporal model research frontier[J]. IEEE Computational Intelligence Magazine, 2016, 11(2): 56-68.
- [22] Whittington J C, Muller T H, Mark S, et al. The Tolman-Eichenbaum Machine: Unifying Space and Relational Memory through Generalization in the Hippocampal Formation[J]. Cell, 2020, 183(5): 1249-1263.e23.
- [23] Kremer S C. Spatiotemporal connectionist networks: A taxonomy and review[J]. Neural Computation, 2001, 13(2): 249-306.
- [24] Wang X J. Synaptic basis of cortical persistent activity: the importance of NMDA receptors to working memory[J]. Journal of Neuroscience, 1999, 19(21): 9587-9603.
- [25] Hazy T E, Frank M J, O'Reilly R C. Banishing the homunculus: making working memory work[J]. Neuroscience, 2006, 139(1): 105-118.
- [26] Eliasmith C. How to build a brain: A neural architecture for biological cognition[M]. OUP USA, 2013.
- [27] Graves A, Wayne G, Danihelka I. Neural turing machines[J]. ArXiv preprint arXiv:1410.5401, 2014.
- [28] Graves A, Wayne G, Reynolds M, et al. Hybrid computing using a neural network with dynamic external memory[J]. Nature, 2016, 538(7626): 471-476.
- [29] Ju H, Dranias M R, Banumurthy G, et al. Spatiotemporal memory is an intrinsic property of networks of dissociated cortical neurons[J]. Journal of Neuroscience, 2015, 35(9): 4040-4051.
- [30] Gemici M, Hung C C, Santoro A, et al. Generative temporal models with memory[J]. ArXiv preprint arXiv:1702.04649, 2017.
- [31] Roebroeck A, Formisano E, Goebel R. The identification of interacting networks in the brain using fMRI: model selection, causality and deconvolution[J]. Neuroimage, 2011, 58(2): 296-302.
- [32] Izhikevich E M. Which model to use for cortical spiking neurons?[J]. IEEE transactions on Neural Networks, 2004, 15(5): 1063-1070.
- [33] Hodgkin A L, Huxley A F. A quantitative description of membrane current and its application to conduction and excitation in nerve[J]. The Journal of Physiology, 1952, 117(4): 500.
- [34] Izhikevich E M. Dynamical systems in neuroscience[M]. MIT press, 2007.
- [35] Tal D, Schwartz E L. Computing with the leaky integrate-and-fire neuron: logarithmic computation and multiplication[J]. Neural Computation, 1997, 9(2): 305-318. DOI: <https://doi.org/10.1162/neco.1997.9.2.305>.
- [36] Brunel N, Van Rossum M C. Lapicque's 1907 paper: from frogs to integrate-and-fire[J]. Biological Cybernetics, 2007, 97(5-6): 337-339. DOI: <https://doi.org/10.1007/s00422-007-0190-0>.
- [37] Dan Y, Poo M m. Spike timing-dependent plasticity of neural circuits[J]. Neuron, 2004, 44(1): 23-30. DOI: <https://doi.org/10.1016/j.neuron.2004.09.007>.
- [38] Hebb D O. The organization of behavior: A neuropsychological theory[M]. Psychology press, 2005.
- [39] Bohte S M, Kok J N, La Poutré J A. SpikeProp: backpropagation for networks of spiking neurons.[C] //ESANN: vol. 48. 2000: 419-424.
- [40] Zenke F, Ganguli S. Superspike: Supervised learning in multilayer spiking neural networks[J]. Neural Computation, 2018, 30(6): 1514-1541. DOI: https://doi.org/10.1162/neco_a_01086.
- [41] Sporea I, Grüning A. Supervised learning in multilayer spiking neural networks[J]. Neural Computation, 2013, 25(2): 473-509.
- [42] Neftci E O, Mostafa H, Zenke F. Surrogate gradient learning in spiking neural networks: Bringing the power of gradient-based optimization to spiking neural networks[J]. IEEE Signal Processing Magazine, 2019, 36(6): 51-63. DOI: <https://doi.org/10.1109/MSP.2019.2931595>.
- [43] Cramer B, Billaudelle S, Kanya S, et al. Surrogate gradients for analog neuromorphic computing[J]. Proceedings of the National Academy of Sciences, 2022, 119(4): e2109194119. DOI: <https://doi.org/10.1073/pnas.2109194119>.

- [44] Eshraghian J K, Ward M, Neftci E, et al. Training spiking neural networks using lessons from deep learning[J]. ArXiv, 2021. DOI: <https://doi.org/10.48550/arXiv.2109.12894>.
- [45] Bellec G, Scherr F, Subramoney A, et al. A solution to the learning dilemma for recurrent networks of spiking neurons[J]. Nature Communications, 2020, 11(1): 1-15. DOI: <https://doi.org/10.1038/s41467-020-17236-y>.
- [46] Huh D, Sejnowski T. Gradient Descent for Spiking Neural Networks [Internet][J]. ArXiv preprint arXiv:1706.04698, 2017.
- [47] McDonnell M D, Ward L M. The benefits of noise in neural systems: bridging theory and experiment[J]. Nature Reviews Neuroscience, 2011, 12(7): 415-425. DOI: <https://doi.org/10.1038/nrn3061>.
- [48] Noh H, You T, Mun J, et al. Regularizing deep neural networks by noise: Its interpretation and optimization[C]//Advances in Neural Information Processing Systems (NeurIPS). 2017. DOI: <https://doi.org/10.48550/arXiv.1710.05179>.
- [49] Liu X, Xiao T, Si S, et al. How does noise help robustness? explanation and exploration under the neural sde framework[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2020: 282-290. DOI: <https://doi.org/10.1109/CVPR42600.2020.00036>.
- [50] Shin H, Lee J K, Kim J, et al. Continual learning with deep generative replay[C]//Advances in Neural Information Processing Systems (NeurIPS). 2017. eprint: 1705.08690.
- [51] Lavda F, Ramapuram J, Gregorova M, et al. Continual classification learning using generative model[C]//Advances in Neural Information Processing Systems (NeurIPS). 2018. eprint: 1810.10612.
- [52] Spens E, Burgess N. A generative model of memory construction and consolidation[J]. Nature Human Behaviour, 2024: 1-18.
- [53] Knill D C, Richards W. Perception as Bayesian inference[M]. Cambridge University Press, 1996. DOI: <https://doi.org/10.1017/CBO9780511984037>.
- [54] Itti L, Baldi P. Bayesian surprise attracts human attention[J]. Vision Research, 2009, 49(10): 1295-1306. DOI: [10.1016/j.visres.2008.09.007](https://doi.org/10.1016/j.visres.2008.09.007).
- [55] Friston K. The free-energy principle: a unified brain theory?[J]. Nature Reviews Neuroscience, 2010, 11(2): 127-138. DOI: [10.1038/nrn2787](https://doi.org/10.1038/nrn2787).
- [56] Paller K A. Memory consolidation: systems[J]. Encyclopedia of Neuroscience, 2009, 1: 741-749. DOI: [10.1016/b978-008045046-9.00770-1](https://doi.org/10.1016/b978-008045046-9.00770-1).
- [57] Atkinson R C, Shiffrin R M. Human memory: A proposed system and its control processes[M]. Elsevier, 1968. DOI: [10.1016/b978-0-12-121050-2.50006-5](https://doi.org/10.1016/b978-0-12-121050-2.50006-5).
- [58] Zilli E A, Hasselmo M E. Coupled noisy spiking neurons as velocity-controlled oscillators in a model of grid cell spatial firing[J]. Journal of Neuroscience, 2010, 30(41): 13850-13860. DOI: <https://doi.org/10.1523/JNEUROSCI.0547-10.2010>.
- [59] Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition[J]. ArXiv, 2014. DOI: <https://doi.org/10.48550/arXiv.1409.1556>.
- [60] Szegedy C, Liu W, Jia Y, et al. Going deeper with convolutions[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2015: 1-9. DOI: <https://doi.org/10.1109/CVPR.2015.7298594>.
- [61] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2016: 770-778. DOI: <https://doi.org/10.1109/CVPR.2016.90>.
- [62] Lee J H, Delbruck T, Pfeiffer M. Training deep spiking neural networks using backpropagation[J]. Frontiers in Neuroscience, 2016, 10. DOI: <https://doi.org/10.3389/fnins.2016.00508>.
- [63] Wu Y, Deng L, Li G, et al. Spatio-temporal backpropagation for training high-performance spiking neural networks[J]. Frontiers in Neuroscience, 2018, 12: 1-12. DOI: <https://doi.org/10.3389/fnins.2018.00331>.

- [64] Wu Y, Deng L, Li G, et al. Direct training for spiking neural networks: Faster, larger, better[C]// Proceedings of the AAAI conference on artificial intelligence (AAAI). 2019. DOI: <https://doi.org/10.1609/aaai.v33i01.33011311>.
- [65] Deng S, Li Y, Zhang S, et al. Temporal Efficient Training of Spiking Neural Network via Gradient Re-weighting[C]//International Conference on Learning Representations (ICLR). 2021. DOI: <https://doi.org/10.48550/arXiv.2202.11946>.
- [66] Volinski A, Zaidel Y, Shalumov A, et al. Data-driven artificial and spiking neural networks for inverse kinematics in neurorobotics[J]. Patterns, 2022, 3(1): 100391. DOI: <https://doi.org/10.1016/j.patter.2021.100391>.
- [67] Zhao F, Zeng Y, Han B, et al. Nature-inspired self-organizing collision avoidance for drone swarm based on reward-modulated spiking neural network[J]. Patterns, 2022, 3(11): 100611. DOI: <https://doi.org/10.1016/j.patter.2022.100611>.
- [68] Fang W, Yu Z, Chen Y, et al. Deep residual learning in spiking neural networks[C]//Advances in Neural Information Processing Systems (NeurIPS). 2021. DOI: <https://doi.org/10.48550/arXiv.2102.04159>.
- [69] Liu Q, Ruan H, Xing D, et al. Effective AER object classification using segmented probability-maximization learning in spiking neural networks[C]//Proceedings of the AAAI conference on artificial intelligence (AAAI). 2020. DOI: <https://doi.org/10.1609/aaai.v34i02.5486>.
- [70] Roy K, Jaiswal A, Panda P. Towards spike-based machine intelligence with neuromorphic computing[J]. Nature, 2019, 575(7784): 607-617. DOI: <https://doi.org/10.1038/s41586-019-1677-2>.
- [71] Verveen A, DeFelice L. Membrane noise[J]. Progress in Biophysics and Molecular Biology, 1974, 28: 189-265. DOI: [https://doi.org/10.1016/0079-6107\(74\)90019-4](https://doi.org/10.1016/0079-6107(74)90019-4).
- [72] Kempter R, Gerstner W, Van Hemmen J L, et al. Extracting oscillations: Neuronal coincidence detection with noisy periodic spike input[J]. Neural Computation, 1998, 10(8): 1987-2017. DOI: <https://doi.org/10.1162/089976698300016945>.
- [73] Stein R B. A theoretical analysis of neuronal variability[J]. Biophysical Journal, 1965, 5(2): 173-194. DOI: [https://doi.org/10.1016/s0006-3495\(65\)86709-1](https://doi.org/10.1016/s0006-3495(65)86709-1).
- [74] Stein R B, Gossen E R, Jones K E. Neuronal variability: noise or part of the signal?[J]. Nature Reviews Neuroscience, 2005, 6(5): 389-397. DOI: <https://doi.org/10.1038/nrn1668>.
- [75] Faisal A A, Selen L P, Wolpert D M. Noise in the nervous system[J]. Nature Reviews Neuroscience, 2008, 9(4): 292-303. DOI: <https://doi.org/10.1038/nrn2258>.
- [76] Maass W. On the computational power of noisy spiking neurons[C]//Advances in Neural Information Processing Systems (NeurIPS). 1995: 211-217. DOI: <https://dl.acm.org/doi/abs/10.5555/2998858>.
- [77] Maass W. Noisy spiking neurons with temporal coding have more computational power than sigmoidal neurons[C]//Advances in Neural Information Processing Systems (NeurIPS). 1996: 211-217. DOI: <https://dl.acm.org/doi/10.5555/2998981.2999011>.
- [78] Patel A, Kosko B. Stochastic resonance in noisy spiking retinal and sensory neuron models[J]. Neural Networks, 2005, 18(5-6): 467-478. DOI: <https://doi.org/10.1016/j.neunet.2005.06.031>.
- [79] Camuto A, Willetts M, Simsekli U, et al. Explicit regularisation in gaussian noise injections[C]// Advances in Neural Information Processing Systems (NeurIPS): vol. 33. 2020: 16603-16614. DOI: <https://dl.acm.org/doi/abs/10.5555/3495724.3497117>.
- [80] Lim S H, Erichson N B, Hodgkinson L, et al. Noisy recurrent neural networks[C]//Advances in Neural Information Processing Systems (NeurIPS). 2021. DOI: <https://doi.org/10.48550/arXiv.2102.04877>.
- [81] Hinton G E, Srivastava N, Krizhevsky A, et al. Improving neural networks by preventing co-adaptation of feature detectors[J]. ArXiv, 2012. DOI: <https://doi.org/10.48550/arXiv.1207.0580>.

- [82] Gerstein G L, Mandelbrot B. Random walk models for the spike activity of a single neuron[J]. *Biophysical Journal*, 1964, 4(1): 41-68. DOI: [https://doi.org/10.1016/s0006-3495\(64\)86768-0](https://doi.org/10.1016/s0006-3495(64)86768-0).
- [83] Tuckwell H C. Stochastic Processes in the Neurosciences[M]. SIAM, 1989. DOI: <https://doi.org/10.1137/1032064>.
- [84] Plesser H E, Gerstner W. Noise in integrate-and-fire neurons: from stochastic input to escape rates[J]. *Neural Computation*, 2000, 12(2): 367-384. DOI: <https://doi.org/10.1162/089976600300015835>.
- [85] Gerstner W, Kistler W M, Naud R, et al. Neuronal dynamics: From single neurons to networks and models of cognition[M]. Cambridge University Press, 2014. DOI: <https://doi.org/10.1017/CBO9781107447615>.
- [86] Rao R P. Bayesian computation in recurrent neural circuits[J]. *Neural Computation*, 2004, 16(1): 1-38. DOI: <https://doi.org/10.1162/08997660460733976>.
- [87] Rao R P. Hierarchical Bayesian inference in networks of spiking neurons[C]//Advances in Neural Information Processing Systems (NeurIPS): vol. 17. 2004. DOI: <https://dl.acm.org/doi/10.5555/2976040.2976180>.
- [88] Deneve S. Bayesian inference in spiking neurons[C]//Advances in Neural Information Processing Systems (NeurIPS): vol. 17. 2004. DOI: <https://dl.acm.org/doi/abs/10.5555/2976040.2976085>.
- [89] Kasabov N. To spike or not to spike: A probabilistic spiking neuron model[J]. *Neural Networks*, 2010, 23(1): 16-19. DOI: <https://doi.org/10.1016/j.neunet.2009.08.010>.
- [90] Skatchkovsky N, Jang H, Simeone O. Spiking neural networks—Part II: Detecting spatio-temporal patterns[J]. *IEEE Communications Letters*, 2021, 25(6): 1741-1745. DOI: <https://doi.org/10.1109/LCOMM.2021.3050242>.
- [91] Rumelhart D E, Hinton G E, Williams R J. Learning representations by back-propagating errors[J]. *Nature*, 1986, 323(6088): 533-536. DOI: <https://doi.org/10.1038/323533a0>.
- [92] Zenke F, Vogels T P. The remarkable robustness of surrogate gradient learning for instilling complex function in spiking neural networks[J]. *Neural Computation*, 2021, 33(4): 899-925. DOI: https://doi.org/10.1162/neco_a_01367.
- [93] Jang H, Simeone O, Gardner B, et al. An introduction to probabilistic spiking neural networks: Probabilistic models, learning rules, and applications[J]. *IEEE Signal Processing Magazine*, 2019, 36(6): 64-77. DOI: <https://doi.org/10.1109/MSP.2019.2935234>.
- [94] Froemke R C, Poo M m, Dan Y. Spike-timing-dependent synaptic plasticity depends on dendritic location[J]. *Nature*, 2005, 434(7030): 221-225. DOI: <https://doi.org/10.1038/nature03366>.
- [95] Guyonneau R, VanRullen R, Thorpe S J. Neurons tune to the earliest spikes through STDP[J]. *Neural Computation*, 2005, 17(4): 859-879. DOI: <https://doi.org/10.1162/0899766053429390>.
- [96] Maass W. Noise as a resource for computation and learning in networks of spiking neurons[J]. *Proceedings of the IEEE*, 2014, 102(5): 860-880. DOI: <https://doi.org/10.1109/JPROC.2014.2310593>.
- [97] Xiao M, Meng Q, Zhang Z, et al. Online Training Through Time for Spiking Neural Networks[C]//Advances in Neural Information Processing Systems (NeurIPS). 2022. DOI: <http://dx.doi.org/10.48550/arXiv.2210.04195>.
- [98] Burkitt A N. A review of the integrate-and-fire neuron model: I. Homogeneous synaptic input[J]. *Biological Cybernetics*, 2006, 95(1): 1-19. DOI: <https://doi.org/10.1007/s00422-006-0068-6>.
- [99] Van Kampen N G. Stochastic processes in physics and chemistry[M]. Elsevier, 1992. DOI: https://doi.org/10.1007/978-3-662-12616-5_4.
- [100] Kloeden P E, Platen E. Stochastic differential equations[M]. Springer, 1992: 103-160. DOI: https://doi.org/10.1007/978-3-662-12616-5_4.
- [101] Barndorff-Nielsen O E, Shephard N. Non-Gaussian Ornstein-Uhlenbeck-based models and some of their uses in financial economics[J]. *Journal of the Royal Statistical Society: Series B (Statistical Methodology)*, 2001, 63(2): 167-241. DOI: <https://doi.org/10.1111/1467-9868.00282>.

- [102] Patel A, Kosko B. Stochastic resonance in continuous and spiking neuron models with Levy noise[J]. *IEEE Transactions on Neural Networks*, 2008, 19(12): 1993-2008. DOI: <https://doi.org/10.1109/TNN.2008.2005610>.
- [103] Plesser H E, Gerstner W. Escape rate models for noisy integrate-and-free neurons[J]. *Neurocomputing*, 2000, 32: 219-224. DOI: [https://doi.org/10.1016/S0925-2312\(00\)00167-3](https://doi.org/10.1016/S0925-2312(00)00167-3).
- [104] Jolivet R, Rauch A, Lüscher H R, et al. Predicting spike timing of neocortical pyramidal neurons by simple threshold models[J]. *Journal of Computational Neuroscience*, 2006, 21: 35-49. DOI: <https://doi.org/10.1007/s10827-006-7074-5>.
- [105] Burt Jr J M, Garman M B. Conditional Monte Carlo: A simulation technique for stochastic network analysis[J]. *Management Science*, 1971, 18(3): 207-217. DOI: <https://doi.org/10.1287/mnsc.18.3.207>.
- [106] Titsias M K, Lázaro-Gredilla M, et al. Local expectation gradients for black box variational inference[C]//Advances in Neural Information Processing Systems (NeurIPS). 2015: 2638-2646. DOI: <https://dl.acm.org/doi/abs/10.5555/2969442.2969534>.
- [107] Tokui S, Sato I. Evaluating the variance of likelihood-ratio gradient estimators[C]//International Conference on Machine Learning (ICML). 2017: 3414-3423. DOI: <https://dl.acm.org/doi/10.5555/305890.3306034>.
- [108] Fiete I R, Seung H S. Gradient learning in spiking neural networks by dynamic perturbation of conductances[J]. *Physical Review Letters*, 2006, 97(4): 048104. DOI: <https://doi.org/10.1103/PhysRevLett.97.048104>.
- [109] Shekhovtsov A, Yanush V, Flach B. Path sample-analytic gradient estimators for stochastic binary networks[C]//Advances in Neural Information Processing Systems (NeurIPS). 2020: 12884-12894. DOI: <https://doi.org/10.48550/arXiv.2006.03143>.
- [110] Frémaux N, Gerstner W. Neuromodulated spike-timing-dependent plasticity, and theory of three-factor learning rules[J]. *Frontiers in Neural Circuits*, 2016, 9: 85. DOI: <https://doi.org/10.3389/fncir.2015.00085>.
- [111] Gerstner W, Lehmann M, Liakoni V, et al. Eligibility traces and plasticity on behavioral time scales: experimental support of neohebbian three-factor learning rules[J]. *Frontiers in Neural Circuits*, 2018, 12: 53. DOI: <https://doi.org/10.3389/fncir.2018.00053>.
- [112] Shrestha S B, Orchard G. Slayer: Spike layer error reassignment in time[C]//Advances in Neural Information Processing Systems (NeurIPS): vol. 31. 2018. DOI: <https://doi.org/10.48550/arXiv.1810.08646>.
- [113] Basalyga G, Salinas E. When response variability increases neural network robustness to synaptic noise[J]. *Neural Computation*, 2006, 18(6): 1349-1379. DOI: <https://doi.org/10.1162/neco.2006.18.6.1349>.
- [114] Mao X. Stochastic differential equations and applications[M]. Elsevier, 2007. DOI: <https://doi.org/10.1533/9780857099402.47>.
- [115] Krizhevsky A, Hinton G, et al. Learning multiple layers of features from tiny images[J]., 2009.
- [116] Li H, Liu H, Ji X, et al. Cifar10-dvs: an event-stream dataset for object classification[J]. *Frontiers in Neuroscience*, 2017, 11: 309. DOI: <https://doi.org/10.3389/fnins.2017.00309>.
- [117] Amir A, Taba B, Berg D, et al. A low power, fully event-based gesture recognition system[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2017: 7243-7252. DOI: <https://doi.org/10.1109/CVPR.2017.781>.
- [118] Cubuk E D, Zoph B, Mane D, et al. Autoaugment: Learning augmentation policies from data[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2018. DOI: <https://doi.org/10.48550/arXiv.1805.09501>.
- [119] Samadzadeh A, Far F S T, Javadi A, et al. Convolutional spiking neural networks for spatio-temporal feature extraction[J]. *ArXiv*, 2020. DOI: [10.1107/s11063-023-11247-8](https://doi.org/10.1107/s11063-023-11247-8).

- [120] Kingma D P, Ba J. Adam: A method for stochastic optimization[J]. ArXiv, 2014. DOI: <https://doi.org/10.48550/arXiv.1412.6980>.
- [121] Loshchilov I, Hutter F. SGDR: Stochastic gradient descent with warm restarts[J]. ArXiv, 2016. DOI: <https://doi.org/10.48550/arXiv.1608.03983>.
- [122] Zheng H, Wu Y, Deng L, et al. Going deeper with directly-trained larger spiking neural networks[C] //Proceedings of the AAAI conference on artificial intelligence (AAAI): vol. 35: 12. 2021: 11062-11070. DOI: <http://dx.doi.org/10.1609/aaai.v35i12.17320>.
- [123] Gu P, Xiao R, Pan G, et al. STCA: Spatio-temporal credit assignment with delayed feedback in deep spiking neural networks[C] //International Joint Conferences on Artificial Intelligence (IJCAI). 2019: 1366-1372. DOI: <https://doi.org/10.24963/ijcai.2019/189>.
- [124] Wu Z, Zhang H, Lin Y, et al. LIAF-net: Leaky integrate and analog fire network for lightweight and efficient spatiotemporal information processing[J]. IEEE Transactions on Neural Networks and Learning Systems, 2021. DOI: <https://doi.org/10.1109/TNNLS.2021.3073016>.
- [125] Gu F, Sng W, Hu X, et al. EventDrop: Data augmentation for event-based learning[J]. ArXiv, 2021. DOI: <https://doi.org/10.48550/arXiv.2106.05836>.
- [126] Lezcano-Casado M. Trivializations for gradient-based optimization on manifolds[C] //Advances in Neural Information Processing Systems (NeurIPS). 2019: 9154-9164. DOI: <https://doi.org/10.48550/arXiv.1909.09501>.
- [127] Goodfellow I J, Shlens J, Szegedy C. Explaining and harnessing adversarial examples[C] //International Conference on Learning Representations (ICLR). 2015. eprint: 1412.6572.
- [128] Liu J, Yang X, Zhu Y, et al. How Neuronal Noises Influence the Spiking Neural Networks's Cognitive Learning Process: A Preliminary Study[J]. Brain Sciences, 2021, 11(2): 153. DOI: <https://doi.org/10.3390/brainsci11020153>.
- [129] Rathi N, Srinivasan G, Panda P, et al. Enabling Deep Spiking Neural Networks with Hybrid Conversion and Spike Timing Dependent Backpropagation[C] //International Conference on Learning Representations (ICLR). 2019. DOI: <https://doi.org/10.48550/arXiv.2005.01807>.
- [130] Hu Y, Tang H, Pan G. Spiking deep residual networks[J]. IEEE Transactions on Neural Networks and Learning Systems, 2021. DOI: <https://doi.org/10.1109/TNNLS.2021.3119238>.
- [131] Zhang W, Li P. Temporal spike sequence learning via backpropagation for deep spiking neural networks[C] //Advances in Neural Information Processing Systems (NeurIPS): vol. 33. 2020: 12022-12033. DOI: <https://dl.acm.org/doi/10.5555/3495724.3496732>.
- [132] Rathi N, Roy K. DIET-SNN: A Low-Latency Spiking Neural Network With Direct Input Encoding and Leakage and Threshold Optimization[J]. IEEE Transactions on Neural Networks and Learning Systems, 2023, 34(6): 3174-3182. DOI: <https://doi.org/10.1109/TNNLS.2021.3111897>.
- [133] Sironi A, Brambilla M, Bourdis N, et al. HATS: Histograms of averaged time surfaces for robust event-based object classification[C] //Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2018: 1731-1740.
- [134] Ramesh B, Yang H, Orchard G, et al. Dart: distribution aware retinal transform for event-based cameras[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2019, 42(11): 2767-2780.
- [135] Kugele A, Pfeil T, Pfeiffer M, et al. Efficient processing of spatio-temporal data streams with spiking neural networks[J]. Frontiers in Neuroscience, 2020, 14: 439. DOI: [10.3389/fnins.2020.00439](https://doi.org/10.3389/fnins.2020.00439).
- [136] Gerstner W, Kistler W M. Spiking neuron models: Single neurons, populations, plasticity[M]. Cambridge university press, 2002. DOI: <https://doi.org/10.1017/CBO9780511815706>.
- [137] White J A, Rubinstein J T, Kay A R. Channel noise in neurons[J]. Trends in Neurosciences, 2000, 23(3): 131-137. DOI: [https://doi.org/10.1016/S0166-2236\(99\)01521-0](https://doi.org/10.1016/S0166-2236(99)01521-0).
- [138] Rolls E T, Deco G. The Noisy Brain: Stochastic Dynamics as a Principle of Brain Function[M]. Oxford University Press, 2010. DOI: [10.1093/acprof:oso/9780199587865.001.0001](https://doi.org/10.1093/acprof:oso/9780199587865.001.0001).

- [139] Gollisch T, Meister M. Eye smarter than scientists believed: neural computations in circuits of the retina[J]. *Neuron*, 2010, 65(2): 150-164.
- [140] Pillow J W, Shlens J, Paninski L, et al. Spatio-temporal correlations and visual signalling in a complete neuronal population[J]. *Nature*, 2008, 454(7207): 995-999.
- [141] Kastner D B, Baccus S A. Coordinated dynamic encoding in the retina using opposing forms of plasticity[J]. *Nature Neuroscience*, 2011, 14(10): 1317-1322.
- [142] Atick J J, Redlich A N. Towards a theory of early visual processing[J]. *Neural Computation*, 1990, 2(3): 308-320.
- [143] Ölveczky B P, Baccus S A, Meister M. Segregation of object and background motion in the retina[J]. *Nature*, 2003, 423(6938): 401-408.
- [144] Wang E Y, Fahey P G, Ponder K, et al. Towards a Foundation Model of the Mouse Visual Cortex[J]. *BioRxiv*, 2023. DOI: 10.1101/2023.03.21.533548.
- [145] Pillow J W, Paninski L, Uzzell V J, et al. Prediction and decoding of retinal ganglion cell responses with a probabilistic spiking model[J]. *Journal of Neuroscience*, 2005, 25(47): 11003-11013.
- [146] Heitman A, Brackbill N, Greschner M, et al. Testing pseudo-linear models of responses to natural scenes in primate retina[J]. *BioRxiv*, 2016.
- [147] McIntosh L, Maheswaranathan N, Nayebi A, et al. Deep Learning Models of the Retinal Response to Natural Scenes[C]//Advances in Neural Information Processing Systems (NeurIPS). 2016. DOI: <https://dl.acm.org/doi/10.5555/3157096.3157249>.
- [148] Kriegeskorte N. Deep neural networks: a new framework for modeling biological vision and brain information processing[J]. *Annual Review of Vision Science*, 2015, 1: 417-446.
- [149] Yang G R, Wang X J. Artificial neural networks for neuroscientists: a primer[J]. *Neuron*, 2020, 107(6): 1048-1070.
- [150] Batty E, Merel J, Brackbill N, et al. Multilayer Recurrent Network Models of Primate Retinal Ganglion Cell Responses[C]//International Conference on Learning Representations (ICLR). 2017.
- [151] Sinz F, Ecker A S, Fahey P, et al. Stimulus domain transfer in recurrent models for large scale cortical population prediction on video[C]//Advances in Neural Information Processing Systems (NeurIPS): vol. 31. 2018.
- [152] Molano-Mazon M, Onken A, Piasini* E, et al. Synthesizing realistic neural population activity patterns using Generative Adversarial Networks[C]//International Conference on Learning Representations (ICLR). 2018.
- [153] Zheng Y, Jia S, Yu Z, et al. Unraveling neural coding of dynamic natural visual scenes via convolutional recurrent neural networks[J]. *Patterns*, 2021, 2(10): 100350. DOI: <https://doi.org/10.1016/j.pattern.2021.100350>.
- [154] Sadtler P T, Quick K M, Golub M D, et al. Neural constraints on learning[J]. *Nature*, 2014, 512(7515): 423-426.
- [155] Elsayed G F, Cunningham J P. Structure in neural population recordings: an expected byproduct of simpler phenomena?[J]. *Nature Neuroscience*, 2017, 20(9): 1310-1318.
- [156] Macke J H, Berens P, Ecker A S, et al. Generating spike trains with specified correlation coefficients[J]. *Neural Computation*, 2009, 21(2): 397-423.
- [157] Lyamzin D R, Macke J H, Lesica N A. Modeling population spike trains with specified time-varying spike rates, trial-to-trial variability, and pairwise signal and noise correlations[J]. *Frontiers in Computational Neuroscience*, 2010, 4: 144.
- [158] Pandarinath C, O’Shea D J, Collins J, et al. Inferring single-trial neural population dynamics using sequential auto-encoders[J]. *Nature Methods*, 2018, 15(10): 805-815.
- [159] Rahmani B, Psaltis D, Moser C. Natural image synthesis for the retina with variational information bottleneck representation[C]//Advances in Neural Information Processing Systems (NeurIPS): vol. 35. 2022: 6034-6046.

- [160] Liu R, Azabou M, Dabagia M, et al. Drop, swap, and generate: A self-supervised approach for generating neural activity[C]//Advances in Neural Information Processing Systems (NeurIPS): vol. 34. 2021: 10587-10599.
- [161] Zhou D, Wei X X. Learning identifiable and interpretable latent models of high-dimensional neural activity using pi-VAE[C]//Advances in Neural Information Processing Systems (NeurIPS): vol. 33. 2020: 7234-7247.
- [162] Wang Z, Zhang Z, Lee C Y, et al. Learning to prompt for continual learning[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2022: 139-149. DOI: 10.1109/cvpr52688.2022.00024.
- [163] Park I M, Seth S, Rao M, et al. Strictly positive-definite spike train kernels for point-process divergences[J]. Neural Computation, 2012, 24(8): 2223-2250.
- [164] Park I M, Seth S, Paiva A R, et al. Kernel methods on spike train space for neuroscience: a tutorial[J]. IEEE Signal Processing Magazine, 2013, 30(4): 149-160. DOI: <https://doi.org/10.1109/MSP.2013.251072>.
- [165] Chichilnisky E. A simple white noise analysis of neuronal light responses[J]. Network: Computation in Neural Systems, 2001, 12(2): 199.
- [166] Keat J, Reinagel P, Reid R C, et al. Predicting every spike: a model for the responses of visual neurons[J]. Neuron, 2001, 30(3): 803-817.
- [167] Mahuas G, Isacchini G, Marre O, et al. A new inference approach for training shallow and deep generalized linear models of noisy interacting neurons[C]//Advances in Neural Information Processing Systems (NeurIPS): vol. 33. 2020: 5070-5080.
- [168] Bellec G, Wang S, Modirshanechi A, et al. Fitting summary statistics of neural data with a differentiable spiking network simulator[C]//Ranzato M, Beygelzimer A, Dauphin Y, et al. Advances in Neural Information Processing Systems (NeurIPS). 2021: 18552-18563.
- [169] Hurwitz C, Srivastava A, Xu K, et al. Targeted neural dynamical modeling[C]//Advances in Neural Information Processing Systems (NeurIPS): vol. 34. 2021: 29379-29392.
- [170] Nichol A Q, Dhariwal P. Improved denoising diffusion probabilistic models[C]//International Conference on Machine Learning (ICML). 2021: 8162-8171.
- [171] Ho J, Saharia C, Chan W, et al. Cascaded Diffusion Models for High Fidelity Image Generation[J]. Journal of Machine Learning Research, 2022, 23(47): 1-33.
- [172] Saharia C, Ho J, Chan W, et al. Image super-resolution via iterative refinement[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2022.
- [173] Liu Y, Zhang K, Li Y, et al. Sora: A Review on Background, Technology, Limitations, and Opportunities of Large Vision Models[J]. ArXiv, 2024.
- [174] Whittington J C, Muller T H, Mark S, et al. The Tolman-Eichenbaum machine: unifying space and relational memory through generalization in the hippocampal formation[J]. Cell, 2020, 183(5): 1249-1263.
- [175] Chen T, Zhang R, Hinton G. Analog bits: Generating discrete data using diffusion models with self-conditioning[C]//International Conference on Learning Representations (ICLR). 2023.
- [176] Pascal N, Nathan R, Yarin G, et al. Machine learning for functional protein design[J]. Nature Biotechnology, 2024, 42: 216-228.
- [177] Tishby N, Pereira F C, Bialek W. The information bottleneck method[J]. ArXiv, 1999.
- [178] Alemi A A, Fischer I, Dillon J V, et al. Deep Variational Information Bottleneck[C]//International Conference on Learning Representations (ICLR). 2017.
- [179] Chalk M, Marre O, Tkacik G. Relevant sparse codes with variational information bottleneck[C]//Advances in Neural Information Processing Systems (NeurIPS). 2016.
- [180] Kingma D P, Welling M. Auto-encoding variational bayes[C]//International Conference on Learning Representations (ICLR). 2014.

- [181] Casale F P, Dalca A, Saglietti L, et al. Gaussian process prior variational autoencoders[C]//Advances in Neural Information Processing Systems (NeurIPS): vol. 31. 2018.
- [182] Borst A, Theunissen F E. Information theory and neural coding[J]. *Nature Neuroscience*, 1999, 2(11): 947-957.
- [183] Meister M, Berry M J. The neural code of the retina[J]. *Neuron*, 1999, 22(3): 435-450.
- [184] Nieder A, Miller E K. Coding of cognitive magnitude: Compressed scaling of numerical information in the primate prefrontal cortex[J]. *Neuron*, 2003, 37(1): 149-157.
- [185] Gallego J A, Perich M G, Miller L E, et al. Neural manifolds for the control of movement[J]. *Neuron*, 2017, 94(5): 978-984.
- [186] Engel A K, König P, Kreiter A K, et al. Temporal coding in the visual cortex: new vistas on integration in the nervous system[J]. *Trends in Neurosciences*, 1992, 15(6): 218-226.
- [187] Reinagel P, Reid R C. Temporal coding of visual information in the thalamus[J]. *Journal of Neuroscience*, 2000, 20(14): 5392-5400.
- [188] Rucci M, Ahissar E, Burr D. Temporal coding of visual space[J]. *Trends in Cognitive Sciences*, 2018, 22(10): 883-895.
- [189] Boulanger-Lewandowski N, Bengio Y, Vincent P. Modeling temporal dependencies in high-dimensional sequences: application to polyphonic music generation and transcription[C]//International Conference on Machine Learning (ICML). 2012: 1881-1888.
- [190] Bayer J, Osendorfer C. Learning Stochastic Recurrent Networks[C]//Advances in Neural Information Processing Systems (NeurIPS) Workshop on Advances in Variational Inference. 2014.
- [191] Fabius O, Van Amersfoort J R. Variational recurrent auto-encoders[J]. ArXiv, 2014.
- [192] Chung J, Kastner K, Dinh L, et al. A recurrent latent variable model for sequential data[C]//Advances in Neural Information Processing Systems (NeurIPS): vol. 28. 2015.
- [193] Gregor K, Danihelka I, Graves A, et al. Draw: A recurrent neural network for image generation[C] //International Conference on Machine Learning (ICML). 2015: 1462-1471.
- [194] Zhang A, Lipton Z C, Li M, et al. Dive into deep learning[J]. ArXiv, 2021.
- [195] Sperling G. The information available in brief visual presentations.[J]. *Psychological monographs: General and applied*, 1960, 74(11): 1.
- [196] Arribas D, Zhao Y, Park I M. Rescuing neural spike train models from bad MLE[C]//Advances in Neural Information Processing Systems (NeurIPS): vol. 33. 2020: 2293-2303. DOI: <https://dl.acm.org/doi/abs/10.5555/3495724.3495917>.
- [197] Ma G, Yan R, Tang H. Exploiting Noise as a Resource for Computation and Learning in Spiking Neural Networks[J/OL]. *Patterns*, 2023. [cell.com/patterns/fulltext/S2666-3899\(23\)00200-3](http://cell.com/patterns/fulltext/S2666-3899(23)00200-3). DOI: doi.org/10.1016/j.patter.2023.100831.
- [198] Onken A, Liu J K, Karunasekara P C R, et al. Using matrix and tensor factorizations for the single-trial analysis of population spike trains[J]. *PLoS Computational Biology*, 2016, 12(11): e1005189. DOI: <https://doi.org/10.1371/journal.pcbi.1005189>.
- [199] Kamata H, Mukuta Y, Harada T. Fully spiking variational autoencoder[C]//Proceedings of the AAAI conference on artificial intelligence (AAAI): vol. 36: 6. 2022: 7059-7067.
- [200] Van Rossum, CW M. A novel spike distance[J]. *Neural Computation*, 2001, 13(4): 751-763.
- [201] Victor J D, Purpura K P. Metric-space analysis of spike trains: theory, algorithms and application[J]. *Network: Computation in Neural Systems*, 1997, 8(2): 127-164.
- [202] Kreuz T, Chicharro D, Houghton C, et al. Monitoring spike train synchrony[J]. *Journal of Neurophysiology*, 2013, 109(5): 1457-1472.
- [203] Itti L, Baldi P. Bayesian Surprise Attracts Human Attention[C]//Weiss Y, Schölkopf B, Platt J. Advances in Neural Information Processing Systems (NeurIPS): vol. 18. 2005.
- [204] Smirnakis S M, Berry M J, Warland D K, et al. Adaptation of retinal processing to image contrast and spatial scale[J]. *Nature*, 1997, 386(6620): 69-73.

- [205] Brown S P, Masland R H. Spatial scale and cellular substrate of contrast adaptation by retinal ganglion cells[J]. *Nature Neuroscience*, 2001, 4(1): 44-51.
- [206] Levi-Aharoni H, Shriki O, Tishby N. Surprise response as a probe for compressed memory states[J]. *PLoS Computational Biology*, 2020, 16(2): 1-21.
- [207] Chalk M, Marre O, Tkačík G. Toward a unified theory of efficient, predictive, and sparse coding[J]. *Proceedings of the National Academy of Sciences*, 2018, 115(1): 186-191. DOI: 10.1073/pnas.1711114115.
- [208] Mikolov T, Chen K, Corrado G, et al. Distributed Representations of Words and Phrases and their Compositionality[C]//Advances in Neural Information Processing Systems (NeurIPS). 2013.
- [209] Ye M, Yin P, Lee W c, et al. Exploiting Geographical Influence for Collaborative Point-of-Interest Recommendation[C]//Proceedings of the International ACM SIGIR Conference on Research and Development in Information Retrieval (ACM SIGIR). 2011: 325-334.
- [210] Liu X, Liu Y, Aberer K, et al. Personalized Point-of-Interest Recommendation by Mining Users ' Preference Transition[C]//Proceedings of the ACM International Conference on Information & Knowledge Management (CIKM). 2013: 733-738. DOI: 10.1145/2505515.2505639.
- [211] Zhang J d. LORE : Exploiting Sequential Influence for Location Recommendations[C]//Proceedings of the ACM SIGSPATIAL International Conference on Advances in Geographic Information Systems. 2014: 103-112. DOI: 10.1145/2666310.2666400.
- [212] Feng S, Li X, Zeng Y, et al. Personalized Ranking Metric Embedding for Next New POI Recommendation[C]//International Joint Conferences on Artificial Intelligence (IJCAI). 2015.
- [213] Yang C, Bai L, Zhang C, et al. Bridging collaborative filtering and semi-supervised learning: A neural approach for POI recommendation[C]//Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (ACM SIGKDD). 2017: 1245-1254.
- [214] Wang H, Shen H, Ouyang W, et al. Exploiting POI-specific geographical influence for point-of-interest recommendation[C]//International Joint Conferences on Artificial Intelligence (IJCAI). 2018: 3877-3883. DOI: 10.24963/ijcai.2018/539.
- [215] Liu Q, Wu S, Wang L, et al. Predicting the next location: A recurrent model with spatial and temporal contexts[C]//Proceedings of the AAAI conference on artificial intelligence (AAAI). 2016: 194-200. DOI: 10.1609/aaai.v30i1.9971.
- [216] Zhao P, Zhu H, Liu Y, et al. Where to Go Next : A Spatio-Temporal Gated Network for Next POI Recommendation[C]//Proceedings of the AAAI conference on artificial intelligence (AAAI). 2019.
- [217] Zhu Y, Li H, Liao Y, et al. What to Do Next: Modeling User Behaviors by Time-LSTM.[C]// International Joint Conferences on Artificial Intelligence (IJCAI). 2017: 3602-3608.
- [218] Lian D, Zhao C, Xie X, et al. GeoMF : Joint Geographical Modeling and Matrix Factorization for Point-of-Interest Recommendation[C]//Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (ACM SIGKDD). 2014: 831-840.
- [219] Feng S, Cong G, An B, et al. POI2Vec : Geographical Latent Representation for Predicting Future Visitors[C]//Proceedings of the AAAI conference on artificial intelligence (AAAI). 2017: 102-108.
- [220] Chang B, Kim S. Learning Graph-Based Geographical Latent Representation for Point-of-Interest Recommendation[C]//Proceedings of the ACM International Conference on Information & Knowledge Management (CIKM). 2020: 135-144.
- [221] Luo H, Zhou J, Bao Z, et al. Spatial Object Recommendation with Hints : When Spatial Granularity Matters[C]//Proceedings of the International ACM SIGIR Conference on Research and Development in Information Retrieval (ACM SIGIR). 2020: 781-790.
- [222] Zhao S, Zhao T, Yang H, et al. STELLAR : Spatial-Temporal Latent Ranking for Successive Point-of-Interest Recommendation[C]//Proceedings of the AAAI conference on artificial intelligence (AAAI). 2016: 315-321.

- [223] Zhao S, Zhao T, King I, et al. Geo-Temporal Sequential Embedding Rank for Point-of-interest Recommendation[C]//Proceedings of the International World Wide Web Conference (WWW). 2017: 153-162.
- [224] Li R, Shen Y, Zhu Y. Next Point-of-Interest Recommendation with Temporal and Multi-level Context Attention[C]//Proceedings of the IEEE International Conference on Data Mining (ICDM). 2018: 1110-1115.
- [225] Manotumruksa J, Macdonald C, Ounis I. A Contextual Attention Recurrent Architecture for Context-Aware Venue Recommendation[C]//Proceedings of the International ACM SIGIR Conference on Research and Development in Information Retrieval (ACM SIGIR). 2018: 555-564.
- [226] Zhao P, Zhu H, Liu Y, et al. Where to Go Next: A Spatio-Temporal Gated Network for Next POI Recommendation[J]. IEEE Transactions on Knowledge and Data Engineering, 2020, 43(7(c)): 1-13.
- [227] O'keefe J, Nadel L. The hippocampus as a cognitive map[M]. Oxford: Clarendon Press, 1978.
- [228] Yuan M, Tian B, Shim V A, et al. An entorhinal-hippocampal model for simultaneous cognitive map building[C]//Proceedings of the AAAI conference on artificial intelligence (AAAI): vol. 29: 1. 2015: 582-596.
- [229] Banino A, Barry C, Uria B, et al. Vector-based navigation using grid-like representations in artificial agents[J]. Nature, 2018, 557(7705): 429-433.
- [230] Mai G, Krzysztof J, Bo Y, et al. Multi-Scale Representation Learning for Spatial Feature Distributions using Grid Cells[C]//International Conference on Learning Representations (ICLR). 2020.
- [231] Whittington J C, Muller T H, Barry C, et al. Generalisation of structural knowledge in the hippocampal-entorhinal system[C]//Advances in Neural Information Processing Systems (NeurIPS). 2018.
- [232] Stachenfeld K L, Botvinick M M, Gershman S J. The hippocampus as a predictive map[J]. Nature Neuroscience, 2018, 20(11): 1643-1653.
- [233] Gustafson N J, Daw N D. Grid Cells , Place Cells , and Geodesic Generalization for Spatial Reinforcement Learning[J]. PLoS Computational Biology, 2011, 7(10): 1-14.
- [234] Eichenbaum H. On the integration of space, time, and memory[J]. Neuron, 2017, 95(5): 1007-1018.
- [235] MacDonald C J, Lepage K Q, Eden U T, et al. Hippocampal ?time cells? bridge the gap in memory for discontiguous events[J]. Neuron, 2011, 71(4): 737-749.
- [236] Sargolini F, Fyhn M, Hafting T, et al. Conjunctive representation of position, direction, and velocity in entorhinal cortex[J]. Science, 2006, 312(5774): 758-762.
- [237] Lim N, Hooi B, Wang X. STP-UDGAT : Spatial-Temporal-Preference User Dimensional Graph Attention Network for Next POI Recommendation[C]//Proceedings of the ACM International Conference on Information & Knowledge Management (CIKM). 2020: 845-854.
- [238] Hadsell R, Chopra S, LeCun Y. Dimensionality reduction by learning an invariant mapping[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR): vol. 2. 2006: 1735-1742.
- [239] Gutmann M U, Hyvärinen A. Noise-Contrastive Estimation of Unnormalized Statistical Models, with Applications to Natural Image Statistics.[J]. Journal of Machine Learning Research, 2012, 13(2).
- [240] Gao R, Xie J, Zhu S W, et al. Learning Grid Cells as Vector Representation of Self-Position Coupled with Matrix Representation of Self-Motion[C]//International Conference on Learning Representations (ICLR). 2019.
- [241] Chang B, Park Y, Park D, et al. Content-aware hierarchical point-of-interest embedding model for successive POI recommendation[C]//International Joint Conferences on Artificial Intelligence (IJCAI). 2018: 3301-3307.
- [242] Cho E, Myers S A, Leskovec J. Friendship and mobility: user movement in location-based social networks[C]//Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (ACM SIGKDD). 2011: 1082-1090.

- [243] Liu X, Liu Y, Li X. Exploring the Context of Locations for Personalized Location Recommendations[C]//International Joint Conferences on Artificial Intelligence (IJCAI). 2016: 1188-1194.
- [244] Merri B V, Fellow C S. Learning Phrase Representations using RNN Encoder – Decoder for Statistical Machine Translation[C]//Proceedings of the Conference on Empirical Methods in Natural Language Processing (EMNLP). 2014: 1724-1734.
- [245] Hochreiter S, Schmidhuber J. Long short-term memory[J]. Neural Computation, 1997, 9(8): 1735-1780.
- [246] Sun K, Qian T, Chen T, et al. Where to Go Next: Modeling Long- and Short-Term User Preferences for Point-of-Interest Recommendation[C]//Proceedings of the AAAI conference on artificial intelligence (AAAI). 2020: 214-221.
- [247] Hoang M X, Zheng Y, Singh A K. FCCF: forecasting citywide crowd flows based on big data[C]// Proceedings of the ACM SIGSPATIAL International Conference on Advances in Geographic Information Systems. 2016.
- [248] Zhang J, Zheng Y, Qi D, et al. DNN-based prediction model for spatio-temporal data[C]//Proceedings of the ACM SIGSPATIAL International Conference on Advances in Geographic Information Systems. 2016.
- [249] Zhang J, Zheng Y, Qi D. Deep spatio-temporal residual networks for citywide crowd flows prediction[C]//Proceedings of the AAAI conference on artificial intelligence (AAAI). 2017.
- [250] Tong Y, Chen Y, Zhou Z, et al. The simpler the better: a unified approach to predicting original taxi demands based on large-scale online platforms[C]//Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (ACM SIGKDD). 2017: 1653-1662.
- [251] Xingjian S, Chen Z, Wang H, et al. Convolutional LSTM network: A machine learning approach for precipitation nowcasting[C]//Advances in Neural Information Processing Systems (NeurIPS). 2015: 802-810.
- [252] Shan Y, Hoens T R, Jiao J, et al. Deep crossing: Web-scale modeling without manually crafted combinatorial features[C]//Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (ACM SIGKDD). 2016: 255-262.
- [253] McCloskey M, Cohen N J. Catastrophic interference in connectionist networks: The sequential learning problem[M]. Elsevier, 1989. DOI: 10.1016/s0079-7421(08)60536-8.
- [254] French R M. Catastrophic forgetting in connectionist networks[J]. Trends in Cognitive Sciences, 1999, 3(4): 128-135. DOI: 10.1002/0470018860.s00096.
- [255] Hassabis D, Kumaran D, Summerfield C, et al. Neuroscience-inspired artificial intelligence[J]. Neuron, 2017, 95(2): 245-258. DOI: 10.1016/j.neuron.2017.06.011.
- [256] Parisi G I, Kemker R, Part J L, et al. Continual lifelong learning with neural networks: A review[J]. Neural Networks, 2019, 113: 54-71. DOI: 10.1016/j.neunet.2019.01.012.
- [257] James W, Burkhardt F, Bowers F, et al. The principles of psychology[M]. Macmillan London, 1890.
- [258] Chen P C, Niknazar H, Alaynick W A, et al. Competitive dynamics underlie cognitive improvements during sleep[J]. Proceedings of the National Academy of Sciences, 2021, 118(51). DOI: 10.1101/2021.03.31.437952.
- [259] Gais S, Albouy G, Boly M, et al. Sleep transforms the cerebral trace of declarative memories[J]. Proceedings of the National Academy of Sciences, 2007, 104(47): 18778-18783. DOI: 10.1073/pnas.0705454104.
- [260] Rasch B, Born J. About sleep's role in memory[J]. Physiological Reviews, 2013. DOI: 10.1152/physrev.00032.2012.
- [261] Mednick S C, McDevitt E A, Walsh J K, et al. The critical role of sleep spindles in hippocampal-dependent memory: a pharmacology study[J]. Journal of Neuroscience, 2013, 33(10): 4494-4504. DOI: 10.1523/jneurosci.3127-12.2013.

- [262] Ngo H V, Fell J, Staresina B. Sleep spindles mediate hippocampal-neocortical coupling during long-duration ripples[J]. *ELife*, 2020, 9: e57011. DOI: 10.7554/elife.57011.
- [263] Funahashi S, Bruce C J, Goldman-Rakic P S. Mnemonic coding of visual space in the monkey's dorsolateral prefrontal cortex[J]. *Journal of Neurophysiology*, 1989, 61(2): 331-349. DOI: 10.1152/jn.1989.61.2.331.
- [264] Konidaris G, Barto A. Autonomous shaping: Knowledge transfer in reinforcement learning[C]// International Conference on Machine Learning (ICML). 2006: 489-496. DOI: 10.1145/1143844.1143906.
- [265] Taylor M E, Stone P. Transfer learning for reinforcement learning domains: A survey.[J]. *Journal of Machine Learning Research*, 2009, 10(7).
- [266] Thrun S. A lifelong learning perspective for mobile robot control[C]//Intelligent Robots and Systems. 1995: 201-214. DOI: 10.1016/b978-044482250-5/50015-3.
- [267] Abel D, Jinnai Y, Guo S Y, et al. Policy and value transfer in lifelong reinforcement learning[C]// International Conference on Machine Learning (ICML). 2018: 20-29.
- [268] Xu Z, Li X, Stojanovic V. Exponential stability of nonlinear state-dependent delayed impulsive systems with applications[J]. *Nonlinear Analysis: Hybrid Systems*, 2021, 42: 101088. DOI: 10.1016/j.nahs.2021.101088.
- [269] Xin X, Tu Y, Stojanovic V, et al. Online reinforcement learning multiplayer non-zero sum games of continuous-time Markov jump linear systems[J]. *Applied Mathematics and Computation*, 2022, 412: 126537. DOI: 10.1016/j.amc.2021.126537.
- [270] Song X, Sun P, Song S, et al. Event-driven NN adaptive fixed-time control for nonlinear systems with guaranteed performance[J]. *Journal of the Franklin Institute*, 2022. DOI: 10.1016/j.jfranklin.2022.04.003.
- [271] Lopez-Paz D, Ranzato M. Gradient episodic memory for continual learning[C]//Advances in Neural Information Processing Systems (NeurIPS). 2017. eprint: 1706.08840.
- [272] Rebuffi S A, Kolesnikov A, Sperl G, et al. Icarl: Incremental classifier and representation learning[C] //Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2017. DOI: 10.1109/cvpr.2017.587.
- [273] Wilson A, Fern A, Ray S, et al. Multi-task reinforcement learning: a hierarchical bayesian approach[C] //International Conference on Machine Learning (ICML). 2007: 1015-1022. DOI: 10.1145/1273496.1273624.
- [274] Jung H, Ju J, Jung M, et al. Less-forgetting learning in deep neural networks[J]. ArXiv, 2016.
- [275] Li Z, Hoiem D. Learning without forgetting[J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2017, 40(12): 2935-2947. DOI: 10.1109/tpami.2017.2773081.
- [276] Rannen A, Aljundi R, Blaschko M B, et al. Encoder based lifelong learning[C]//Proceedings of European Conference on Computer Vision (ECCV). 2017. DOI: 10.1109/iccv.2017.148.
- [277] Zenke F, Poole B, Ganguli S. Continual learning through synaptic intelligence[C]//International Conference on Machine Learning (ICML). 2017. eprint: 1703.04200.
- [278] Aljundi R, Babiloni F, Elhoseiny M, et al. Memory aware synapses: Learning what (not) to forget[C] //Proceedings of European Conference on Computer Vision (ECCV). 2018. DOI: 10.1007/978-3-030-01219-9_9.
- [279] Kirkpatrick J, Pascanu R, Rabinowitz N, et al. Overcoming catastrophic forgetting in neural networks[J]. *Proceedings of the National Academy of Sciences*, 2017, 114(13): 3521-3526. DOI: 10.1073/pnas.1611835114.
- [280] Chaudhry A, Marc'Aurelio R, Rohrbach M, et al. Efficient lifelong learning with A-GEM[C]// International Conference on Learning Representations (ICLR). 2019. eprint: 1812.00420.
- [281] Zeng G, Chen Y, Cui B, et al. Continual learning of context-dependent processing in neural networks[J]. *Nature Machine Intelligence*, 2019, 1(8): 364-372. DOI: 10.1038/s42256-019-0080-x.

- [282] Friston K. Learning and inference in the brain[J]. *Neural Networks*, 2003, 16(9): 1325-1352. DOI: 10.1016/j.neunet.2003.06.005.
- [283] Nguyen C V, Li Y, Bui T D, et al. Variational Continual Learning[C]//International Conference on Learning Representations (ICLR). 2018. eprint: 1710.10628.
- [284] Ahn H, Cha S, Lee D, et al. Uncertainty-based Continual Learning with Adaptive Regularization[C] //Advances in Neural Information Processing Systems (NeurIPS). 2019. eprint: 1905.11614.
- [285] Zhao T, Wang Z, Masoomi A, et al. Deep Bayesian Unsupervised Lifelong Learning[J]. *Neural Networks*, 2022, 149: 95-106. DOI: 10.1016/j.neunet.2022.02.001.
- [286] Aljundi R, Chakravarty P, Tuytelaars T. Expert gate: Lifelong learning with a network of experts[C] //Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2017. DOI: 10.1109/cvpr.2017.753.
- [287] Mallya A, Lazebnik S. Packnet: Adding multiple tasks to a single network by iterative pruning[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2018. DOI: 10.1109/cvpr.2018.00810.
- [288] Serra J, Suris D, Miron M, et al. Overcoming catastrophic forgetting with hard attention to the task[C] //International Conference on Machine Learning (ICML). 2018. eprint: 1801.01423.
- [289] Masse N Y, Grant G D, Freedman D J. Alleviating catastrophic forgetting using context-dependent gating and synaptic stabilization[J]. *Proceedings of the National Academy of Sciences*, 2018, 115(44): E10467-E10475. DOI: 10.1073/pnas.1803839115.
- [290] Wilson M A, McNaughton B L. Reactivation of hippocampal ensemble memories during sleep[J]. *Science*, 1994, 265(5172): 676-679. DOI: 10.1126/science.8036517.
- [291] Qin Y L, McNaughton B L, Skaggs W E, et al. Memory reprocessing in corticocortical and hippocampocortical neuronal ensembles[J]. *Philosophical Transactions of the Royal Society of London. Series B: Biological Sciences*, 1997, 352(1360): 1525-1533. DOI: 10.1098/rstb.1997.0139.
- [292] Ji D, Wilson M A. Coordinated memory replay in the visual cortex and hippocampus during sleep[J]. *Nature Neuroscience*, 2007, 10(1): 100-107.
- [293] Rasch B, Born J. Maintaining memories by reactivation[J]. *Current Opinion in Neurobiology*, 2007, 17(6): 698-703. DOI: 10.1016/j.conb.2007.11.007.
- [294] Kemker R, Kanan C. FearNet: Brain-Inspired Model for Incremental Learning[C]//International Conference on Learning Representations (ICLR). 2018.
- [295] Van de Ven G M, Siegelmann H T, Tolias A S. Brain-inspired replay for continual learning with artificial neural networks[J]. *Nature Communications*, 2020, 11(1): 1-14. DOI: 10.1038/s41467-020-17866-2.
- [296] Chaudhry A, Rohrbach M, Elhoseiny M, et al. Continual learning with tiny episodic memories[C]// International Conference on Machine Learning (ICML). 2019.
- [297] Chaudhry A, Gordo A, Dokania P, et al. Using hindsight to anchor past knowledge in continual learning[C]//Proceedings of the AAAI conference on artificial intelligence (AAAI): vol. 35: 8. 2021: 6993-7001. DOI: 10.1609/aaai.v35i8.16861.
- [298] Pham Q, Liu C, Hoi S. Dualnet: Continual learning, fast and slow[C]//Advances in Neural Information Processing Systems (NeurIPS): vol. 34. 2021: 16131-16144.
- [299] Arani E, Sarfraz F, Zonooz B. Learning Fast, Learning Slow: A general continual learning method based on complementary learning system[C]//International Conference on Learning Representations (ICLR). 2022.
- [300] Kamra N, Gupta U, Liu Y. Deep Generative Dual Memory Network for Continual Learning[J]. ArXiv, 2018.
- [301] Rostami M, Kolouri S, Pilly P K. Complementary Learning for Overcoming Catastrophic Forgetting Using Experience Replay[C]//International Joint Conferences on Artificial Intelligence (IJCAI). 2019: 3339-3345. DOI: 10.24963/ijcai.2019/463.

- [302] Belouadah E, Popescu A. IL2M: Class Incremental Learning With Dual Memory[C]//Proceedings of European Conference on Computer Vision (ECCV). 2019: 583-592. DOI: 10.1109/iccv.2019.00067.
- [303] Sarfraz F, Arani E, Zonooz B. Sparse Coding in a Dual Memory System for Lifelong Learning[C]// Proceedings of the AAAI conference on artificial intelligence (AAAI). 2023. DOI: 10.1609/aaai.v37i8.26161.
- [304] Saxena R, Shobe J L, McNaughton B L. Learning in deep neural networks and brains with similarity-weighted interleaved learning[J]. Proceedings of the National Academy of Sciences, 2022, 119(27): e2115229119. DOI: 10.1073/pnas.2115229119.
- [305] Kudithipudi D, Aguilar-Simon M, Babb J, et al. Biological underpinnings for lifelong learning machines[J]. Nature Machine Intelligence, 2022, 4(3): 196-210. DOI: 10.1038/s42256-022-00452-0.
- [306] Hayes T L, Cahill N D, Kanan C. Memory efficient experience replay for streaming learning[C]// International Conference on Robotics and Automation (ICRA). 2019: 9769-9776. DOI: 10.1109/icra.2019.8793982.
- [307] Van de Ven G M, Tolias A S. Three scenarios for continual learning[J]. ArXiv, 2019. eprint: 1904.07734.
- [308] Chen J, Cook P A, Wagner A D. Prediction strength modulates responses in human area CA1 to sequence violations[J]. Journal of Neurophysiology, 2015, 114(2): 1227-1238. DOI: 10.1152/jn.00149.2015.
- [309] Felzenszwalb P, McAllester D, Ramanan D. A discriminatively trained, multiscale, deformable part model[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2008: 1-8. DOI: 10.1109/cvpr.2008.4587597.
- [310] Shrivastava A, Gupta A, Girshick R. Training region-based object detectors with online hard example mining[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2016: 761-769. DOI: 10.1109/cvpr.2016.89.
- [311] Preston A R, Eichenbaum H. Interplay of hippocampus and prefrontal cortex in memory[J]. Current Biology, 2013, 23(17): R764-R773. DOI: 10.1016/j.cub.2013.05.041.
- [312] Van de Ven G M, Trouche S, McNamara C G, et al. Hippocampal offline reactivation consolidates recently formed cell assembly patterns during sharp wave-ripples[J]. Neuron, 2016, 92(5): 968-974. DOI: 10.1016/j.neuron.2016.10.020.
- [313] Takashima A, Petersson K M, Rutters F, et al. Declarative memory consolidation in humans: a prospective functional magnetic resonance imaging study[J]. Proceedings of the National Academy of Sciences, 2006, 103(3): 756-761.
- [314] Rosenzweig E S, Barnes C A, McNaughton B L. Making room for new memories[J]. Nature Neuroscience, 2002, 5(1): 6-8. DOI: 10.1038/nn0102-6.
- [315] Karlsson M P, Frank L M. Awake replay of remote experiences in the hippocampus[J]. Nature Neuroscience, 2009, 12(7): 913-918. DOI: 10.1038/nn.2344.
- [316] Yamamoto J, Tonegawa S. Direct medial entorhinal cortex input to hippocampal CA1 is crucial for extended quiet awake replay[J]. Neuron, 2017, 96(1): 217-227. DOI: 10.1016/j.neuron.2017.09.017.
- [317] Hinton G, Vinyals O, Dean J. Dark knowledge[J]. Presented as the keynote in BayLearn, 2014, 2(2).
- [318] Efron B, Tibshirani R J. An introduction to the bootstrap[M]. CRC press, 1994.
- [319] Zhang H, Cisse M, Dauphin Y N, et al. Mixup: Beyond Empirical Risk Minimization[C]//International Conference on Learning Representations (ICLR). 2018.
- [320] Chawla N V, Bowyer K W, Hall L O, et al. SMOTE: synthetic minority over-sampling technique[J]. Journal of Artificial Intelligence Research, 2002, 16: 321-357. DOI: 10.1613/jair.953.
- [321] DeVries T, Taylor G W. Dataset augmentation in feature space[J]. ArXiv, 2017.
- [322] Hinton G, Vinyals O, Dean J. Distilling the knowledge in a neural network[J]. ArXiv, 2015.

- [323] Zhang L, Song J, Gao A, et al. Be your own teacher: Improve the performance of convolutional neural networks via self distillation[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2019. DOI: 10.1109/iccv.2019.00381.
- [324] University S. Tiny ImageNet Challenge, CS231N Course[Z]. <https://tiny-imagenet.herokuapp.com/>. 2017.
- [325] Russakovsky O, Deng J, Su H, et al. ImageNet Large Scale Visual Recognition Challenge[J]. International Journal of Computer Vision, 2015, 115(3): 211-252. DOI: 10.1007/s11263-015-0816-y.
- [326] Vinyals O, Blundell C, Lillicrap T, et al. Matching networks for one shot learning[C]//Advances in Neural Information Processing Systems (NeurIPS): vol. 29. 2016.
- [327] Douillard A, Cord M, Ollion C, et al. Podnet: Pooled outputs distillation for small-tasks incremental learning[C]//Proceedings of European Conference on Computer Vision (ECCV). 2020. DOI: 10.1007/978-3-030-58565-5_6.
- [328] Buzzega P, Boschini M, Porrello A, et al. Dark experience for general continual learning: a strong, simple baseline[C]//Advances in Neural Information Processing Systems (NeurIPS): vol. 33. 2020: 15920-15930.
- [329] Boschini M, Bonicelli L, Buzzega P, et al. Class-Incremental Continual Learning into the eXtended DER-verse[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2022. DOI: 10.1109/tpami.2022.3206549.
- [330] Pernici F, Bruni M, Baechi C, et al. Class-incremental learning with pre-allocated fixed classifiers[C]//International Conference on Pattern Recognition (ICPR). 2021: 6259-6266. DOI: 10.1109/icpr48806.2021.9413299.
- [331] Wu C, Herranz L, Liu X, et al. Memory replay gans: Learning to generate new categories without forgetting[C]//Advances in Neural Information Processing Systems (NeurIPS): vol. 31. 2018.
- [332] Van der Maaten L, Hinton G. Visualizing data using t-SNE.[J]. Journal of Machine Learning Research, 2008, 9(11).
- [333] Van Bergen R S, Kriegeskorte N. Going in circles is the way forward: the role of recurrence in visual inference[J]. Current Opinion in Neurobiology, 2020, 65: 176-193.
- [334] Krotov D, Hopfield J J. Large Associative Memory Problem in Neurobiology and Machine Learning[C]//International Conference on Learning Representations (ICLR). 2021.
- [335] Hopfield J J. Neural networks and physical systems with emergent collective computational abilities.[J]. Proceedings of the National Academy of Sciences, 1982, 79(8): 2554-2558.
- [336] McEliece R, Posner E, Rodemich E, et al. The capacity of the Hopfield associative memory[J]. IEEE Transactions on Information Theory, 1987, 33(4): 461-482.
- [337] Mazza C. On the storage capacity of nonlinear neural networks[J]. Neural Networks, 1997, 10(4): 593-597.
- [338] Torres J J, Pantic L, Kappen H J. Storage capacity of attractor neural networks with depressing synapses[J]. Physical Review E, 2002, 66(6): 061910.
- [339] Wainrib G, Touboul J. Topological and dynamical complexity of random neural networks[J]. Physical Review Letters, 2013, 110(11): 118101.
- [340] Krotov D, Hopfield J J. Dense associative memory for pattern recognition[C]//Advances in Neural Information Processing Systems (NeurIPS): vol. 29. 2016.
- [341] Ramsauer H, Schäfl B, Lehner J, et al. Hopfield Networks is All You Need[C]//International Conference on Learning Representations (ICLR). 2021.
- [342] Demircigil M, Heusel J, Löwe M, et al. On a model of associative memory with huge storage capacity[J]. Journal of Statistical Physics, 2017, 168: 288-299.
- [343] Yuille A L, Rangarajan A. The concave-convex procedure (CCCP)[C]//Advances in Neural Information Processing Systems (NeurIPS): vol. 14. 2001.

- [344] Benchenane K, Peyrache A, Khamassi M, et al. Coherent theta oscillations and reorganization of spike timing in the hippocampal-prefrontal network upon learning[J]. *Neuron*, 2010, 66(6): 921-936.
- [345] Burgess C, Kim H. 3D Shapes Dataset[Z]. <https://github.com/deepmind/3dshapes-dataset/>. 2018.
- [346] Deese J. On the prediction of occurrence of particular verbal intrusions in immediate recall.[J]. *Journal of Experimental Psychology*, 1959, 58(1): 17.
- [347] Payne J D, Schacter D L, Propper R E, et al. The role of sleep in false memory formation[J]. *Neurobiology of learning and memory*, 2009, 92(3): 327-334.
- [348] Roediger H L, McDermott K B. Creating false memories: Remembering words not presented in lists.[J]. *Journal of experimental psychology: Learning, Memory, and Cognition*, 1995, 21(4): 803.

攻读期间的代表性科研成果

学术论文

- Ma, Gehua, Rui Yan, and Huajin Tang. “Exploiting noise as a resource for computation and learning in spiking neural networks.” Patterns 4.10 (2023). C/N/S 子刊， SCI.
- Ma, Gehua, et al. “Temporal Conditioning Spiking Latent Variable Models of the Neural Response to Natural Visual Scenes.” Advances in Neural Information Processing Systems 36 (2023). CCF A 类正式论文, 清华 TH-CPL A 类正式论文.
- Ma, Gehua, et al. “Successive POI Recommendation via Brain-Inspired Spatiotemporal Aware Representation.” Proceedings of the AAAI Conference on Artificial Intelligence. Vol. 38. No. 1. 2024. CCF A 类正式论文, 清华 TH-CPL A 类正式论文.
- Ma, Gehua, et al. “Dual memory model for experience-once task-incremental lifelong learning.” Neural Networks 166 (2023): 174-187. 中科院分区一区, CCF B 类正式论文, 清华 TH-CPL B 类正式论文.

发明专利

- 唐华锦, 马歌华, 燕锐, “一种基于类脑时空感知表征的兴趣点推荐方法及系统”, CN202110930940.0.
- Huajin Tang, Gehua Ma, and Rui Yan, “Point of interest recommendation method and system based on brain-inspired spatiotemporal perceptual representation”, WO/2023/015658.

主要项目经历

- 科技创新 2030-“新一代人工智能”重大项目：基于脉冲神经网络的感知-学习-决策神经网络模型
- 国家自然科学基金重点项目：模拟生物智能的混合架构类脑系统及应用验证